本科毕业设计答辩

東南大學

基于领域自适应的
工业过程故障诊断方法研究

面向 TEP 数据集的无监督领域自适应故障诊断

08022311　陈鲲龙

指导教师：　王永健

自动化学院

2026.6

研究问题界定：TE 过程无监督领域自适应故障诊断

聚焦 TE 过程及其数据集，将领域自适应故障诊断定义为无监督跨工况自适应问题。

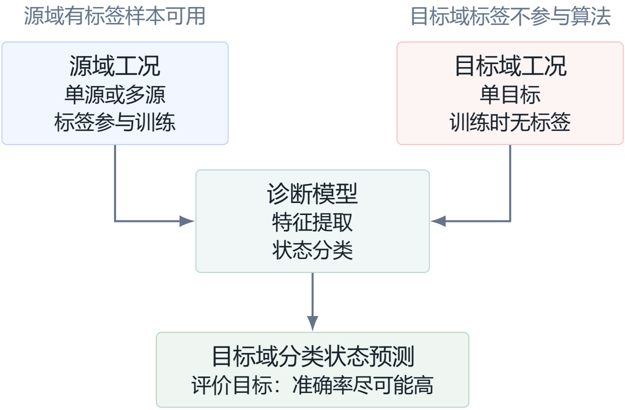

TEP 数据集

6 个工况 → 6 个领域
0 正常 ＋ 1–28 类故障 →
29 个分类状态

单源 / 多源 → 单目标

源域监督，目标域无监督训练

训练约束

目标域标签不参与算法

目标

提高目标域 29 类状态诊断准确率

核心成果：3 套创新算法

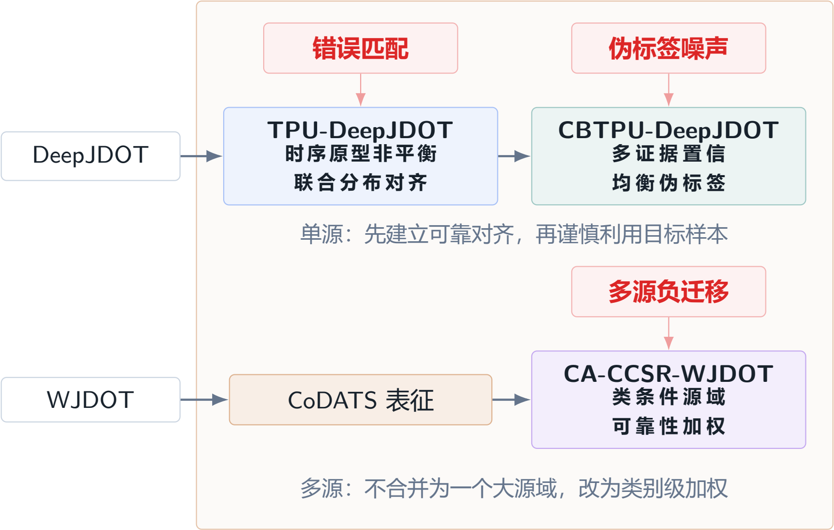
错误匹配
伪标签噪声
DeepJDOT
TPU-DeepJDOT
时序原型非平衡
联合分布对齐
CBTPU-DeepJDOT
多证据置信
均衡伪标签
单源：先建立可靠对齐，再谨慎利用目标样本
多源负迁移
WJDOT
CoDATS 表征
CA-CCSR-WJDOT
类条件源域
可靠性加权
多源：不合并为一个大源域，改为类别级加权

方法一：TPU-DeepJDOT 架构

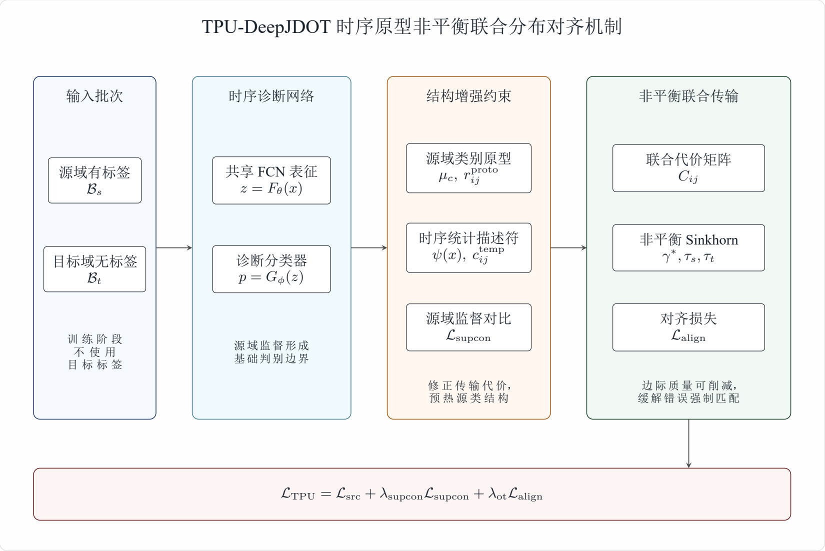

方法一：联合代价与非平衡传输

联合代价

$$C_{ij} = \lambda_f c_{ij}^f + \lambda_y c_{ij}^y + \lambda_p(\nu) r_{ij}^{\text{proto}} + \lambda_{\text{temp}}(\nu) c_{ij}^{\text{temp}} \tag{3-13}$$

原型惩罚

$$r_{ij}^{\text{proto}} = \text{clip}\left(\frac{d_{y_i^s j}^{\text{proto}} - \overline{d}_{-y_i^s, j}^{\text{proto}}}{\sigma_j^{\text{proto}} + \epsilon}, r_{\min}, r_{\max} \right) \tag{3-7}$$

时序代价

$$c_{ij}^{\text{temp}} = \frac{1}{d_\psi} \|\psi(x_i^s) - \psi(x_j^t)\|_2^2 \tag{3-11}$$

总目标

$$\mathcal{L}_{\text{TPU}} = \mathcal{L}_{\text{src}} + \lambda_{\text{supcon}}(\nu)\mathcal{L}_{\text{supcon}} + \lambda_{\text{ot}}(\nu)\mathcal{L}_{\text{align}} \tag{3-20}$$

方法一：TPU-DeepJDOT 训练流程

01 批次输入
源域标记
目标无标签

→

02 FCN 表征
特征提取
分类预测

→

03 源域结构
类别原型
SupCon

→

04 联合匹配
特征标签
原型时序

→

05 优化更新
非平衡 OT
对齐目标域

C_{ij}	γ^*	$\mathcal{L}_{\mathrm{TPU}}$
联合代价	非平衡传输计划	训练目标

方法一验证：$m_5 \to m_2$ 对齐递进

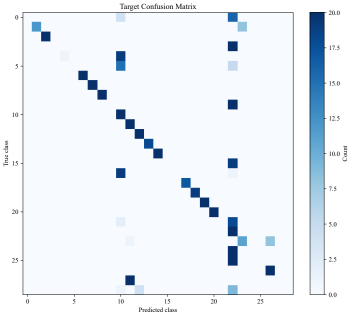

SourceOnly
56.08%

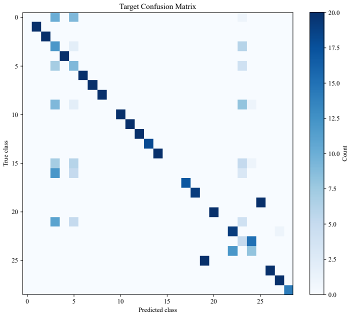

DeepJDOT
67.20%

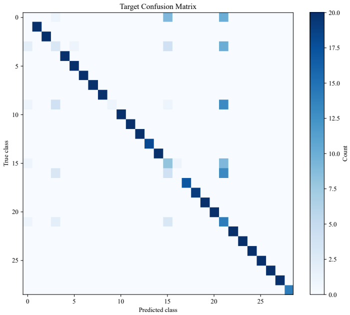

TPU-DeepJDOT
83.60%

方法一验证：域分布与类别结构

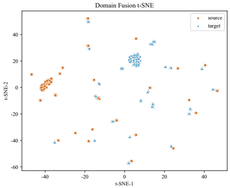

SourceOnly：域 t-SNE

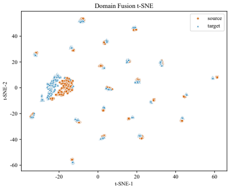

DeepJDOT：域 t-SNE

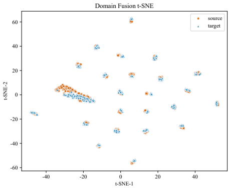

TPU-DeepJDOT：域 t-SNE

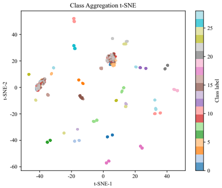

SourceOnly：类 t-SNE

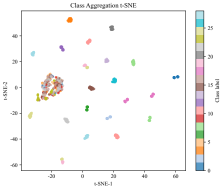

DeepJDOT：类 t-SNE

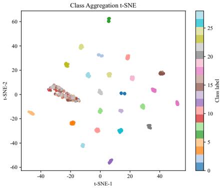

TPU-DeepJDOT：类 t-SNE

方法二：CBTPU-DeepJDOT 架构

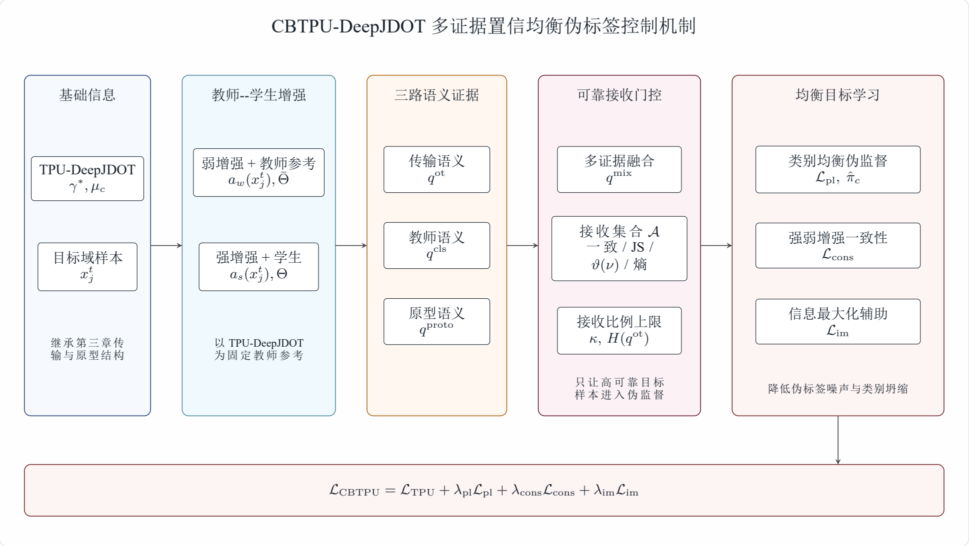

方法二：多证据伪标签筛选

证据融合

$$q_{jc}^{\text{mix}} = \frac{(q_{jc}^{\text{ot}})^{\alpha_{\text{ot}}}(q_{jc}^{\text{cls}})^{\alpha_{\text{cls}}}(q_{jc}^{\text{proto}})^{\alpha_{\text{proto}}}}{\sum_{c'=1}^{N_c}(q_{jc'}^{\text{ot}})^{\alpha_{\text{ot}}}(q_{jc'}^{\text{cls}})^{\alpha_{\text{cls}}}(q_{jc'}^{\text{proto}})^{\alpha_{\text{proto}}}} \tag{4-12}$$

接收条件

$$\mathcal{A}_j = [\hat{y}_j^{\text{ot}} = \hat{y}_j^{\text{cls}} = \hat{y}_j^{\text{proto}} \text{ or } D_{\text{JS}} \le \delta_{\text{JS}}] \wedge [\max_c q_{jc}^{\text{mix}} \ge \vartheta(\nu)] \wedge [H(q_j^{\text{ot}}) \le h_{\text{ot}}] \tag{4-15}$$

总目标

$$\mathcal{L}_{\text{CBTPU}} = \mathcal{L}_{\text{src}} + \lambda_{\text{supcon}}(\nu)\mathcal{L}_{\text{supcon}} + \lambda_{\text{ot}}(\nu)\mathcal{L}_{\text{align}} + \lambda_{\text{pl}}(\nu)\mathcal{L}_{\text{pl}} + \lambda_{\text{cons}}(\nu)\mathcal{L}_{\text{cons}} + \lambda_{\text{im}}(\nu)\mathcal{L}_{\text{im}} \tag{4-22}$$

方法二：CBTPU-DeepJDOT 训练流程

01 继承 TPU
学生初始化
教师维护

→

02 目标增强
弱视图
强视图

→

03 证据生成
传输
分类原型

→

04 融合筛选
一致性
置信低熵

→

05 自训练更新
伪标签学习
一致性约束

q_{jc}^{mix}
融合证据

$\mathcal{A}_j$
伪标签接收集合

$\mathcal{L}_{\mathrm{CBTPU}}$
训练目标

方法二验证：$m_5 \rightarrow m_1$ 伪标签细化

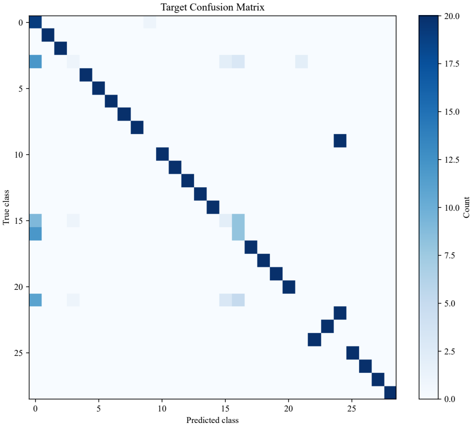

TPU-DeepJDOT
77.59%

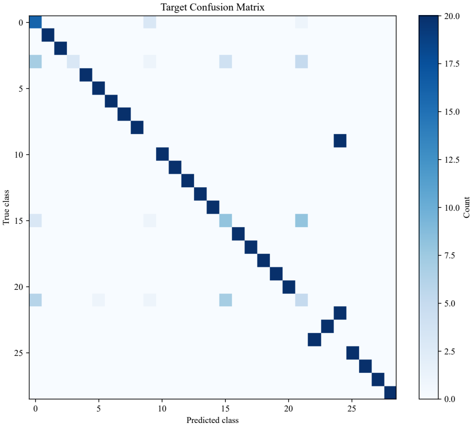

CBTPU-DeepJDOT
81.38%

方法二验证：局部边界继续收紧

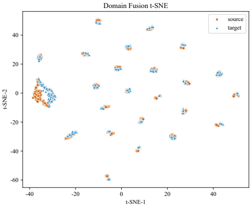

TPU-DeepJDOT：域 t-SNE

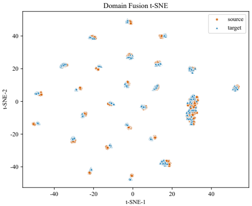

CBTPU-DeepJDOT：域 t-SNE

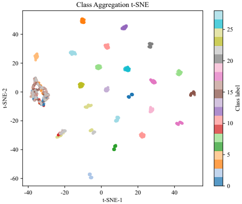

TPU-DeepJDOT：类 t-SNE

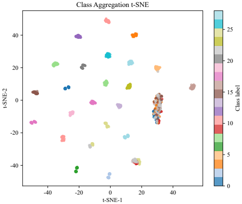

CBTPU-DeepJDOT：类 t-SNE

方法三：CA-CCSR-WJDOT 架构

CA-CCSR-WJDOT 类条件源域可靠性加权机制

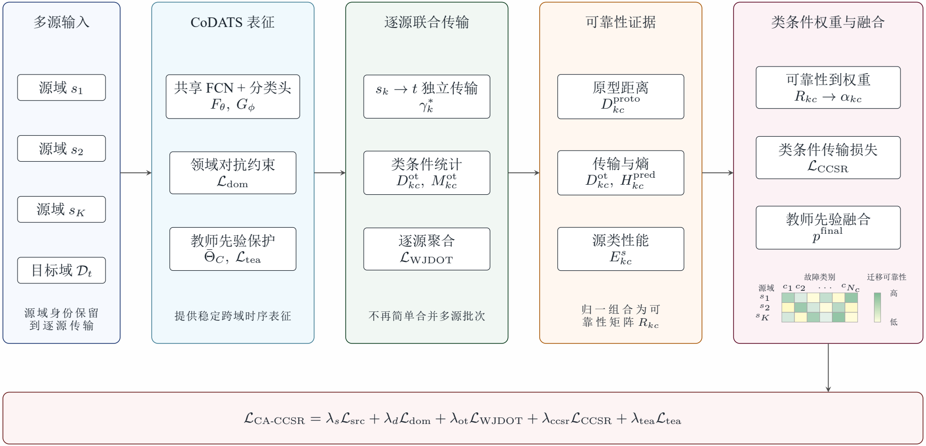

方法三：类条件源域可靠性

可靠性评分

$$R_{kc} = w_p \widetilde{D}^{\mathrm{proto}}_{kc} + w_o \widetilde{D}^{\mathrm{ot}}_{kc} + w_h \widetilde{H}^{\mathrm{pred}}_{kc} + w_e \widetilde{E}^{s}_{kc} \tag{5-14}$$

源域权重

$$\alpha_{kc} = \frac{\exp(-R_{kc}/T_{\mathrm{rel}})}{\sum_{k'=1}^{K} \exp(-R_{k'c}/T_{\mathrm{rel}})} \tag{5-15}$$

CCSR 约束

$$\mathcal{L}_{\mathrm{CCSR}} = \frac{1}{|\mathcal{C}_{\mathrm{act}}|} \sum_{c \in \mathcal{C}_{\mathrm{act}}} \sum_{k=1}^{K} \mathbb{I}_{kc} \alpha_{kc} D^{\mathrm{ot}}_{kc} \tag{5-17}$$

总目标

$$\mathcal{L}_{\mathrm{CA\text{-}CCSR}} = \lambda_s \mathcal{L}_{\mathrm{src}} + \lambda_d(\nu)\mathcal{L}_{\mathrm{dom}} + \lambda_{\mathrm{ot}} r_{\mathrm{ot}}(\nu)\mathcal{L}_{\mathrm{WJDOT}} + \lambda_{\mathrm{ccsr}} r_{\mathrm{ccsr}}(\nu)\mathcal{L}_{\mathrm{CCSR}} + \lambda_{\mathrm{tea}}(\nu)\mathcal{L}_{\mathrm{tea}} \tag{5-22}$$

方法三：CA-CCSR-WJDOT 训练流程

01 多源输入
多个源域
目标无标签

→

02 CoDATS 表征
特征建模
域判别教师

→

03 逐源 WJDOT
源域单独
目标对齐

→

04 可靠性估计
原型传输
熵召回

→

05 类别级迁移
源域贡献
按类分配

R_{kc}
类条件可靠性

α_{kc}
源域类别权重

$\mathcal{L}_{\text{CA-CCSR}}$
训练目标

方法三验证：五源代表任务减少误判

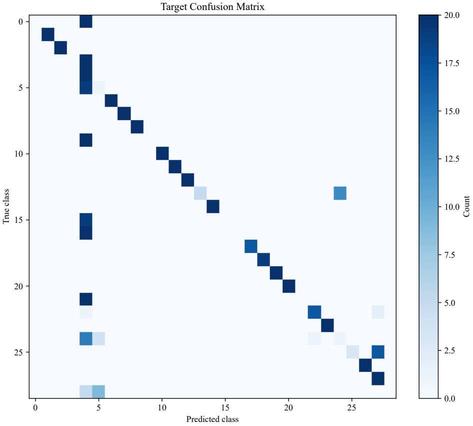

SourceOnly
64.02%

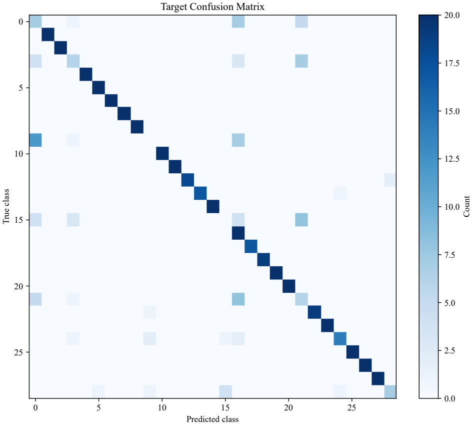

CA-CCSR-WJDOT
82.89%

方法三验证：域间融合与类别聚集

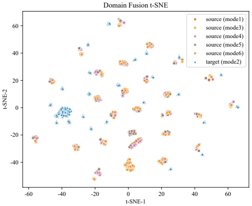

SourceOnly：域 t-SNE

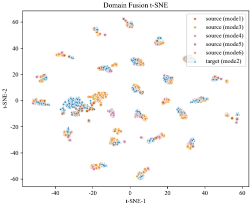

CA-CCSR-WJDOT：域 t-SNE

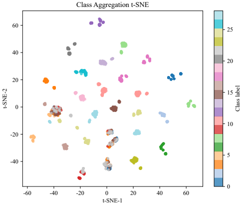

SourceOnly：类 t-SNE

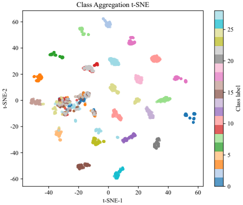

CA-CCSR-WJDOT：类 t-SNE

方法三解释：源域–类别权重矩阵

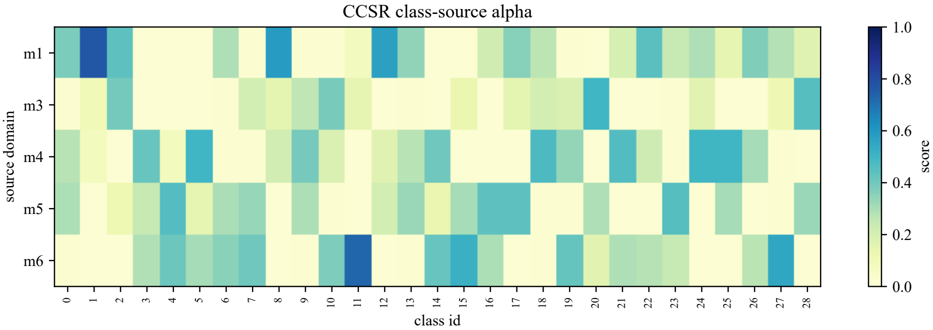

五源任务 $\{m_1, m_3, m_4, m_5, m_6\} \rightarrow m_2$

实验协议：场景 × 方法汇总对比

源域数	目标域数	场景构造	汇总规模
1	1	m_1, m_2, m_5 全量握手原则	6 单到单场景 × 8 方法
2	1	m_1, m_2, m_5 全量握手原则	3 两源一目标场景 × 5 方法
5	1	6 个工况轮流作为目标	6 五源一目标场景 × 5 方法

m_1, m_2, m_5 **全量握手原则**

三个代表工况两两作为源域与目标域；
形成 6 个有向单到单场景；
两源实验对应 3 个留一目标场景。

ACC
整体诊断准确率
主汇总指标

Macro-F1
类别等权 F1
关注少数类

混淆矩阵
类别误判结构
逐任务展示

t-SNE
结构证据
看域与类

单源结果：主提升来自对齐，细化来自伪标签

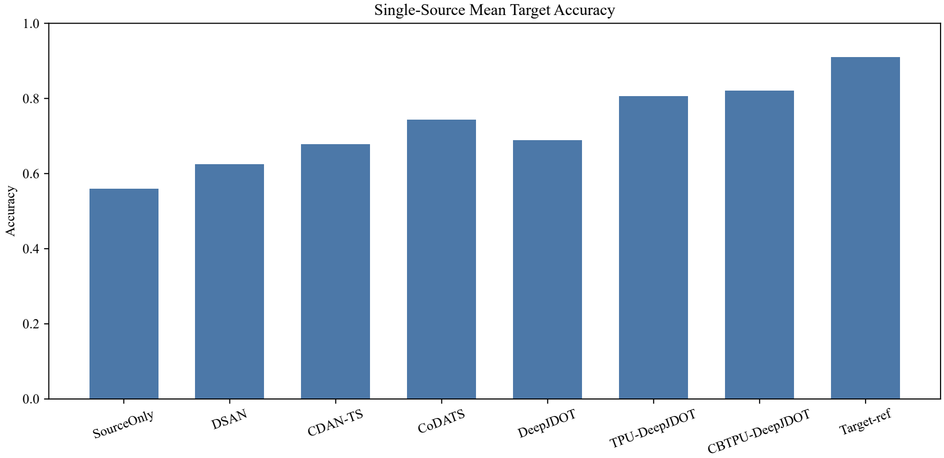

多源结果：类别级可靠性压住负迁移

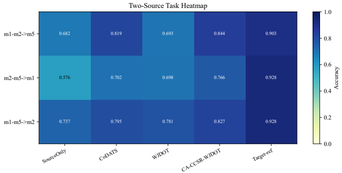

两源任务准确率热力图

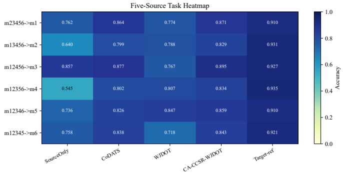

五源任务准确率热力图

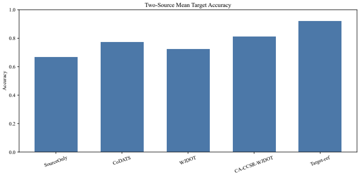

两源 CA-CCSR-WJDOT
81.21%

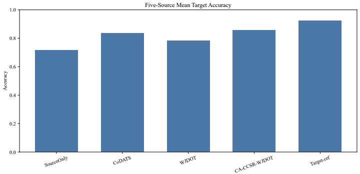

五源 CA-CCSR-WJDOT
85.50%

结论：基线对比实验结果

+11.66%	+1.48%	+7.69%
TPU-DeepJDOT ↑> DeepJDOT	CBTPU-DeepJDOT ↑> TPU	CA-CCSR-WJDOT ↑> WJDOT
$p = 0.015625$	$p = 0.015625$	$p = 0.001953$

单源场景中，TPU-DeepJDOT 与 CBTPU-DeepJDOT 相对基线依次提升，体现了对齐约束与伪标签细化的递进作用。

多源场景中，CA-CCSR-WJDOT 相对 WJDOT 基线胜出，说明类别级源域可靠性能够缓解负迁移。

整体上，三套方法在对应实验场景中均取得有效提升，完成了跨生产模式故障诊断课题任务。

谢谢