

基于领域自适应的工业过程故障诊断方法研究

答辩演讲稿

08022311 陈鲲龙

2026 年 6 月

中文口播稿，预计用时约 7 分钟。

建议节奏：问题界定约 1 分钟，三套方法约 4 分钟，实验与结论约 2 分钟。

演讲稿正文

封面页 各位老师好，我是自动化学院 08022311 陈鲲龙，我的毕业设计题目是《基于领域自适应的工业过程故障诊断方法研究》，指导教师是王永健老师。我的汇报围绕田纳西伊斯曼过程，也就是 TEP 数据集展开，核心问题是：当生产模式变化之后，目标工况没有故障标签，诊断模型怎样从源工况迁移到目标工况。

研究问题界定 首先说明任务设定。TEP 数据集包含 6 个生产模式，我把每一个生产模式看作一个领域；每个领域中包含正常状态和 1 到 28 类故障，一共 29 个分类状态。在训练时，源域样本有标签，目标域样本只提供无标签数据，目标域标签只在最后评价准确率时使用。因此，这个问题不是普通的监督分类，而是无监督跨工况领域自适应故障诊断。它的难点主要有三点：生产模式改变会带来边缘分布偏移；同一故障在不同工况下的响应形态会发生变形；同时，目标域故障标签在训练阶段不可见。

核心成果 围绕这三个困难，我完成了三套方法。第一套是 TPU-DeepJDOT，重点解决单源场景下源目标样本如何可靠对齐的问题；第二套是 CBTPU-DeepJDOT，在对齐基础上进一步筛选目标域伪标签；第三套是 CA-CCSR-WJDOT，面向多源场景，解决不同源域、不同故障类别贡献不一致导致的负迁移问题。整体逻辑可以概括为：先把样本匹配做稳，再谨慎使用目标样本，最后在多源任务中按类别分配源域贡献。

方法一：TPU-DeepJDOT 第一部分是 TPU-DeepJDOT。它以 DeepJDOT 为基础。DeepJDOT 的优点是把特征距离和标签预测误差放在联合空间中，用最优传输建立源域样本和目标域样本之间的软匹配关系。但在小批量训练中，普通平衡传输要求每个批次的边际质量严格匹配。如果源域批次和目标域批次的类别组成不一致，就可能为了满足边际约束而保留低质量匹配。

针对这个问题，我引入了非平衡最优传输，让传输计划可以适度放松边际约束，从而减少明显不合适的强制匹配。与此同时，联合代价不只包含特征项和标签项，还加入了源域类别原型惩罚和原始时间窗口统计代价。原型项用于保留类别中心结构，时序项用于补充故障动态响应信息，源域监督对比学习则进一步提高源域特征的类别可分性。训练流程上，

模型先输入源域有标签样本和目标域无标签样本，经过 FCN 提取时间序列表征，再构造联合代价矩阵，求解非平衡传输计划，最后把源域监督损失、对比损失和对齐损失联合优化。

方法一验证 从代表任务 $m_5 \rightarrow m_2$ 可以看到，SourceOnly 的目标域准确率为 56.08%，DeepJDOT 提升到 67.20%，而 TPU-DeepJDOT 达到 83.60%。这说明非平衡传输、类别原型和时序代价确实改善了对齐质量。t-SNE 可视化也进一步说明，方法一不仅让源域和目标域分布更接近，同时让类别结构更加清晰。

方法二：CBTPU-DeepJDOT 第二部分是 CBTPU-DeepJDOT。方法一完成的是“怎么对齐”，但目标域无标签样本能不能进入监督训练，还需要进一步判断。如果只根据分类器最大概率选伪标签，早期错误很容易被后续训练放大。因此我设计了多证据置信均衡伪标签机制。

具体来说，每个目标样本的伪标签不只来自分类器预测，而是同时参考三类证据：第一是最优传输计划给出的传输语义，第二是固定教师模型的预测语义，第三是源域原型距离给出的原型语义。三类证据通过幂加权几何平均进行融合。只有当三类证据基本一致，或者分布差异足够小，同时融合置信度达到动态阈值、传输语义熵足够低时，目标样本才会被接收为伪标签。除此之外，我还加入类别均衡和强弱增强一致性约束，用来控制伪标签偏置。

方法二验证 在代表任务 $m_5 \rightarrow m_1$ 上，TPU-DeepJDOT 的准确率为 77.59%，加入伪标签细化后的 CBTPU-DeepJDOT 提升到 81.38%。从局部 t-SNE 结果看，CBTPU-DeepJDOT 对目标域边界有进一步收紧作用。也就是说，伪标签阶段的提升幅度不像方法一那么大，但它在可靠对齐基础上继续修正了目标域决策边界。

方法三：CA-CCSR-WJDOT 第三部分转向多源任务。多源迁移的直觉是源域越多，可用信息越多；但在跨生产模式故障诊断中，这个直觉不一定成立。因为某个源域可能整体接近目标域，却只对部分类别可靠；也可能整体距离较远，但在某些故障上非常有参考价值。因此，如果只给每个源域一个整体权重，就难以刻画这种类别级差异。

CA-CCSR-WJDOT 的核心是构建源域-故障类别可靠性矩阵。对于第 k 个源域和第 c 个故障类别，我从四类信息估计可靠性：源域原型与目标原型距离、类条件传输代价、目标预测熵，以及源域类别性能。可靠性分数越低，说明该源域对该类别越值得迁移；随后通过 softmax 得到类别级源域权重 α_{kc} 。训练时，模型结合 CoDATs 风格的时间序列表征和领域对抗约束，保留 WJDOT 的逐源联合传输，同时加入 CCSR 类条件可靠性约束和教师先验约束。这样，多源信息不是简单合并，而是按故障类别重新分配。

方法三验证 在五源到 m_2 的代表任务中，直接合并源域的 SourceOnly 准确率为 64.02%，CA-CCSR-WJDOT 达到 82.89%。对应的 t-SNE 结果显示，目标域类别聚集更明显，误判结构减少。源域-类别权重矩阵也能解释这一点：不同故障类别并不依赖同一个源域，而是有的类别更依赖 m_1 ，有的更依赖 m_4 或 m_6 ，也有部分类别由多个源域共同提供信息。

实验协议 实验部分我设置了三类场景：单源到单目标任务一共 6 个，两源到单目标任务 3 个，五源到单目标任务 6 个。评价指标包括整体准确率、宏平均 F1、平衡准确率、混淆矩阵和 t-SNE 可视化。所有无监督领域自适应方法都遵守同一约束：目标域标签不参与训练、早停、模型选择或参数确定，只在最终评价时使用。

汇总结果 从单源汇总结果看，DeepJDOT 的平均准确率为 68.88%，TPU-DeepJDOT 达到 80.54%，相对 DeepJDOT 提升 11.66 个百分点；CBTPU-DeepJDOT 进一步达到 82.02%，并在 6 个单源迁移方向上都取得无监督方法第一。这说明单源性能的主提升来自更可靠的

联合分布对齐，伪标签阶段则提供了稳定的边界细化。

从多源结果看，CA-CCSR-WJDOT 在 3 个两源任务上的平均准确率为 81.21%，在 6 个五源任务上达到 85.50%，并且两源和五源任务中都取得了无监督方法第一。相对 WJDOT，CA-CCSR-WJDOT 在多源任务上的平均准确率提升为 7.69 个百分点。配对显著性检验也表明，三组相邻方法的提升在对应迁移场景中均为正向，且 Wilcoxon p 值小于 0.05。

结论页 最后总结一下。本文围绕 TEP 跨生产模式故障诊断，形成了三条递进的方法链。TPU-DeepJDOT 解决源目标样本匹配质量问题；CBTPU-DeepJDOT 解决目标样本伪标签可靠性问题；CA-CCSR-WJDOT 解决多源场景下源域类别贡献分配问题。实验结果说明，跨工况故障诊断不能只追求整体分布对齐，而需要同时处理样本匹配、目标样本筛选和源域-类别贡献分配。以上就是我的汇报，请各位老师批评指正。