

基于领域自适应的工业过程故障诊断方法研究

答辩演讲稿

08022311 陈鲲龙

2026 年 6 月

封面页

老师们好，我是 08022311 陈鲲龙。我在王永健老师的指导下完成了课题：《基于领域自适应的工业过程故障诊断方法研究》。

问题边界收敛页

对于此课题，可能比较抽象、比较大，所以我们先快速收敛到一个具体问题：严格的无监督跨工况自适应问题。实际上，我所把握的题眼是“工业过程”，所以选择了田纳西伊斯曼过程，即 TE 过程，这是这个方向很经典、很权威的数据集。

“域”在这里具体指第 40 页的 6 个不同工况。不同工况的数据特征互不相同，也就是不同的域。而“故障诊断”则退化为一个正常状态加 28 种故障、一共 29 类的分类问题。我们要解决的问题就是：用源工况训练好的模型，为什么在目标域上表现不好，以及目标域无标签时怎么适应。

核心论文结构架构页

第 7 页呈现了全文的框架。本课题的核心成果是 3 套创新算法，分别对应三、四、五章。我们从联合分布最优传输系列方法出发，针对工业过程数据集的特点做了一些改良。这三章方法之间也有递进关联，我用了高度统一的结构范式进行撰写，也按这个范式进行今天的介绍。

方法一：TPU-DeepJDOT 架构

首先算法一，新增前缀 TPU: temporal、prototypical、unbalanced，对应时序、原型、非平衡。也就是说，方法一是在 DeepJDOT 的特征-标签联合传输基础上，额外加入时序信息、源域类别原型，以及非平衡传输机制。

方法一：公式页

我们都是 JDOT 家族的方法，所以最核心的就是 C_{ij} ，也就是联合传输代价。第 19 页式 3-13 前两项是最基础的：第 9 页式 2-8 里的特征代价和标签代价。第三项是相对原型代价，对应式 3-7，即目标样本相对于源域样本类别中心的距离代价。最后一项是时序信息，对应式 3-8 到 3-11，引入原始序列和一阶差分的均值、标准差，一共 4 个统计量，针对连续时

间信号捕捉更多时序信息。它们会体现在损失函数最后一项 $\mathcal{L}_{\text{align}}$ 中。

非平衡指的是根据 C_{ij} 求解最优传输计划 γ 时，对第 16 页式 3-3 中凸优化求解的边际约束进行 KL 散度放宽。中间的 SupCon 损失是标准的监督对比学习，主要用于增强源域的聚类能力；这里更准确地说，监督对比损失本身在第 20 页式 3-19，总目标在第 20 页式 3-20。

方法一：TPU-DeepJDOT 训练流程

我们采用 FCN 全卷积网络，模型框架统一。输入源域样本带标签，以及目标域无标签样本；所有创新方法主要改变总损失函数，并通过反向传播训练。最后输出的就是第 15 页式 3-1 中特征提取器 F 的参数 θ 和分类器 G 的参数 ϕ 。

方法一实验验证：混淆矩阵

我们通过混淆矩阵可以直观感受到新方法相对于基底方法 DeepJDOT, 以及空白对照 SourceOnly 的显著提升。越集中于对角线, 代表故障诊断效果越好。在代表任务 $m_5 \rightarrow m_2$ 上, SourceOnly 为 56.08%, DeepJDOT 为 67.20%, TPU-DeepJDOT 达到 83.60%。

方法一实验验证：t-SNE

接下来域和类的 t-SNE 图，分别体现出域的融合以及类别的清晰隔离。也就是说，方法一不是简单把源域和目标域混在一起，而是在保持类别结构的情况下改善跨域对齐。

方法二：CBTPU-DeepJDOT 架构

第三章已经通过传输利用了目标域无标签数据，但还没有把目标样本作为明确的监督信号使用。所以第四章 CBTPU 在此基础上又叠加一个 confidence-balanced，将可信的伪标签当成真值标签参与训练。

方法二：多证据伪标签筛选

核心新增损失项是第 26 页式 4-17 的 pseudo label 伪标签损失，以及第 27 页式 4-18 的 consistency 一致性约束。第 25 页式 4-12 对传输、教师、原型 3 个语义进行幂加权几何平均，完成融合。语义本质上就是通过 softmax 等算式把输出转换为概率，进而参与计算。

对于伪标签置信度判断，第 25 页式 4-15 首先要求 3 个语义的最大概率类别一致，或者 JS 差异小于阈值；其次融合语义的概率要足够大，简单说就是“3 个 0.1 没用，3 个 0.9 才信任”；并且传输语义归一化熵要足够小，意味着较少的源域类别向它传输，语义比较纯净。最后 consistency 项以上一章 TPU 的结果为纲，尽量利用置信度没那么高、但仍然比较稳定的目标样本。

方法二：CBTPU-DeepJDOT 训练流程

CBTPU 的流程相当于承接在 TPU 之后，多了伪标签的生成和利用，整体框架不变。也就是用 TPU 作为教师参考，再结合传输语义、教师语义和原型语义筛选目标样本，最后把通过筛选的伪标签和一致性约束加入训练。

方法二验证

类似的，在 $m_5 \rightarrow m_1$ 上，TPU-DeepJDOT 为 77.59%，CBTPU-DeepJDOT 提升到 81.38%。可以看到混淆矩阵第一列，原本被误判为正常的故障明显减少。

方法二实验验证：t-SNE

域明显进一步融合，聚类依旧保持边界清晰。我的理解是，第四章不是推翻第三章，而是在 TPU 已经可靠对齐的基础上，继续细化目标域决策边界。

方法三：CA-CCSR-WJDOT 架构

和前两者不同，这个方法针对的是有多个源域的情况。CA 表示 CoDATS 增强，CCSR 表示类条件源域可靠性，WJDOT 是多源加权联合分布最优传输。核心新增的损失项是 $\mathcal{L}_{CCSR}$ 。

方法三：类条件源域可靠性

其实反而呢，这个方法的创新点是最简单、最符合直觉的。如图所示，以 5 源 1 目标场景为例，一般 WJDOT 是对源域进行加权，也就是 5 个权重。而我进一步细化了权重计算，使得每个源中的每一个类别也都有权重，直接扩大到 $5 \times 29 = 145$ 个权重，充分捕捉所有源域中的有效信息，而不是选择某一个源域主导，退化为单源域。

方法三：公式页

第 33 页这里一共设计了 4 个指标用于计算权重。第一是源目标原型距离，看源域某一类和目标域估计出的同类中心近不近；第二是类条件传输代价，看这一类跨域匹配难不难；第三是目标预测熵，看预测稳不稳定；第四是源域类别召回误差，看源域自己这一类学得好不好。它们组合成 R_{kc} ， R_{kc} 越小越可靠，再对 $-R_{kc}$ 做 softmax 得到 α_{kc} 。

方法三：CA-CCSR-WJDOT 训练流程

此方法就是在原有框架上多了权重计算这个核心步骤。此外，这里也有教师监督机制。和第四章 CBTPU 用 TPU 作为教师不同，这里使用 CoDATS 的结果作为教师监督；宗旨不变，都是选择保守、稳定、置信高的方法结果来限制新加入机制，防止其发散跑偏。

方法三验证

在五源到 m_2 的代表任务中，SourceOnly 是 64.02%，CA-CCSR-WJDOT 达到 82.89%。可以明显看到混淆矩阵向对角线上收敛。

方法三实验结果：t-SNE

t-SNE 中也能看到多源融合，同时保持聚类效果。源域-类别权重热力图说明，不同故障类别并不依赖同一个源域，而是由不同源域或多个源域共同提供信息。

实验协议

后续大的基线对比实验比较简单。实验设置分三类：6 个单源任务、3 个两源任务、6 个五源任务。评价指标包括准确率、宏平均 F1、平衡准确率、混淆矩阵和 t-SNE。除 Target-ref

外，所有无监督方法都遵守同一约束：目标域标签只在最终评价时使用，不参与训练和模型选择。

单源汇总结果

单源汇总结果中，DeepJDOT 平均准确率为 68.88%，TPU-DeepJDOT 达到 80.54%，相对提升 11.66 个百分点；CBTPU-DeepJDOT 进一步达到 82.02%，并在 6 个单源迁移方向上都取得无监督方法第一。

多源汇总结果

多源结果中，CA-CCSR-WJDOT 在 3 个两源任务上的平均准确率为 81.21%，在 6 个五源任务上达到 85.50%，并且两源和五源任务中都取得无监督第一。相对 WJDOT，多源任务平均提升 7.69 个百分点。配对显著性检验也表明，三组相邻方法的提升均为正向，且 Wilcoxon p 值小于 0.05。

结论页

最后总结一下。本文围绕 TEP 跨生产模式故障诊断，形成了三条递进的方法链。TPU-DeepJDOT 解决源目标样本匹配质量问题；CBTPU-DeepJDOT 解决目标样本伪标签可靠性问题；CA-CCSR-WJDOT 解决多源场景下源域-类别贡献分配问题。以上就是我的汇报，请各位老师批评指正。

谢谢页

谢谢各位老师。