本科毕业设计（论文）报告

题 目：基于领域自适应的工业过程故障诊断方法研究

学　　号：08022311

姓　　名：陈鲲龙

学　　院：自动化

专　　业：自动化

指导教师：王永健、童国道

起止日期：2026 年 3 月 ~2026 年 6 月

东南大学毕业（设计）论文独创性声明

本人声明所呈交的毕业（设计）论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签名：_____　　日期：__2026__年__6__月_____日

东南大学毕业（设计）论文使用授权声明

东南大学有权保留本人所送交毕业（设计）论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括刊登）论文的全部或部分内容。论文的公布（包括刊登）授权东南大学教务处办理。

论文作者签名：_____　　导师签名：_____

日期：__2026__年__6__月_____日　　日期：__2026__年__6__月_____日

摘　　要

工业过程故障诊断对于保障生产安全、降低非计划停机损失和提升过程运行可靠性具有重要意义。然而，在真实流程工业现场中，不同操作模式、负载水平和控制阶段往往对应不同的数据分布，使得基于单源、多源及更一般跨域设置训练得到的诊断模型均难以直接迁移到新工况。面向这一问题，本文以 Tennessee Eastman Process Domain Adaptation 数据集为对象，研究跨工况无监督领域自适应故障诊断，并围绕统一实验基准构建、典型方法比较和改进方法设计展开系统研究。

本文首先构建了面向 TEP 跨工况迁移诊断的统一实验流程，统一了数据组织方式、预处理策略、共享骨干网络、模型选择规则和结果管理方式，在一致协议下比较了多种代表性领域自适应方法。围绕基线比较部分，本文已经预留了用于分析显式领域对齐效果、类别混叠以及伪标签噪声问题的结果结构，待最终实验结果回填后即可形成完整论证。

在此基础上，本文提出可靠性门控的类条件时序自适应方法 RCTA。该方法以强基线对齐分支为基础，引入 EMA 教师网络、弱强双视图时序增强、多因素可靠性门控、双原型记忆以及一致性约束，以实现更稳定的目标域伪监督利用和更清晰的类条件结构建模。当前版本已完成实验结果章节的结构化占位整理，待最终实验数据与图件回填后再形成完整的定量比较与定性分析。

总体而言，本文形成了从统一实验基准构建到改进方法验证的完整研究链路，可为流程工业无监督领域自适应故障诊断研究提供可复现的比较基础和有效的方法参考。

关键词：故障诊断，领域自适应，TEP，无监督领域自适应

ABSTRACT

Industrial fault diagnosis is important for production safety, reducing unplanned downtime, and ensuring reliable process operation. In real industrial processes, however, data collected under different operating modes, load levels, and control stages often follow different distributions. Consequently, diagnostic models trained in single-source, multi-source, and more general cross-domain settings often generalize poorly to new operating conditions. To address this problem, this thesis investigates unsupervised domain adaptation for cross-mode fault diagnosis on the Tennessee Eastman Process Domain Adaptation dataset, focusing on unified benchmark construction, baseline comparison, and method improvement.

This work first establishes a unified and reproducible experimental pipeline for cross-mode transfer fault diagnosis on TEP. The pipeline standardizes data organization, preprocessing, shared backbone design, model selection, and result management, enabling fair comparisons among representative domain adaptation methods under a consistent protocol. Baseline experiments show that explicit domain alignment can substantially improve cross-mode diagnostic performance, but global alignment alone is still insufficient to robustly handle class confusion, noisy pseudo labels, and scenario sensitivity in multi-class industrial time-series tasks.

On this basis, the thesis proposes a Reliability-Gated Class-Conditional Temporal Adaptation method, denoted as RCTA. Built on a strong alignment baseline, the method integrates an EMA teacher, weak and strong temporal augmentations, multi-factor reliability gating, dual prototype memories, and consistency regularization to achieve more stable target-domain pseudo supervision and clearer class-conditional structure. In the current draft, the result chapters have been converted into structured placeholders, so that the final quantitative and qualitative findings can be filled in after the experimental artifacts are finalized.

Overall, this thesis develops a coherent research line from unified benchmark construction to improved method validation, providing both a reproducible comparison basis and an effective methodological reference for unsupervised domain adaptation in industrial process fault diagnosis.

KEY WORDS: Fault Diagnosis, Domain Adaptation, TEP, Unsupervised Domain Adaptation

目　　录

摘　　要 I
ABSTRACT II
目　　录 III
第一章　绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 2
1.3 研究内容与技术路线 3
1.4 研究问题、核心挑战与创新点 4
1.5 论文结构安排 5
第二章　跨工况迁移诊断的基准脉络 6
2.1 任务定义与符号说明 6
2.2 域定义与统一输入表示 6
2.3 共享骨干网络 7
2.4 基础训练目标 7
2.5 典型基线方法 8
2.5.1 Source Only 8
2.5.2 分布对齐方法 8
2.5.3 对抗式方法 8
2.5.4 最优传输方法 9
2.6 评价指标与模型选择 9
2.7 本章小结 9
第三章　教师–学生时序一致性自适应 10
3.1 模块定位 10
3.2 RCTA 总体框架 10
3.3 EMA 教师网络 11
3.4 弱强双视图时序增强 11
3.5 一致性损失 12

3.6 本章小结 12
第四章 可靠性门控的伪标签学习 13
4.1 模块定位 13
4.2 多因素可靠性评分 13
4.3 按类门控策略 14
4.4 可靠性加权伪标签损失 14
4.5 与后续原型模块的衔接 14
4.6 本章小结 15
第五章 双原型记忆的类条件结构约束 16
5.1 模块定位 16
5.2 源域原型记忆 16
5.3 目标域原型记忆 16
5.4 参考原型构造 17
5.5 原型吸引损失 17
5.6 原型分离损失 17
5.7 递进验证中的作用 18
5.8 本章小结 18
第六章 课程化优化与完整训练流程 19
6.1 模块定位 19
6.2 课程化损失调度 19
6.3 完整目标函数 19
6.4 训练流程表 20
6.5 递进验证中的作用 20
6.6 本章小结 21
第七章 实验设计与递进验证 22
7.1 实验章节定位 22
7.2 数据集与域划分 22
7.2.1 TEP 领域自适应数据集 22
7.2.2 迁移任务构造 23

7.3 输入预处理与实验协议 23
7.3.1 时序样本表示 23
7.3.2 归一化与数据划分 23
7.3.3 训练与结果产物 24
7.4 基线方法总体结果 24
7.5 创新点递进验证 24
7.5.1 验证顺序设计 24
7.5.2 A：教师–学生时序一致性验证 25
7.5.3 A+B：加入可靠性门控后的验证 25
7.5.4 A+B+C：加入双原型记忆后的验证 25
7.5.5 A+B+C+D：完整 RCTA 验证 25
7.6 定性分析图件 26
7.7 本章小结 26
第八章 总结与展望 28
8.1 全文工作总结 28
8.2 主要结论 28
8.3 不足与未来展望 28
8.4 本章小结 29
参考文献 30
附录 A 实验补充材料 32
A.1 附录说明 32
A.2 基线方法关键超参数 32
A.3 RCTA aggressive 配置摘要 32
A.4 四个关键单源场景的完整结果 33
A.5 补充说明 33
致 谢 34

第一章 绪论

1.1 研究背景与意义

流程工业广泛存在于化工、能源、冶金、制药、环保和材料制造等关键行业，其生产过程通常具有连续运行、物料与能量强耦合、动态特性显著、控制回路复杂以及安全风险高等特点。一旦关键设备或工艺环节发生异常，不仅会导致产品质量波动、能耗上升和非计划停机，还可能进一步诱发连锁故障甚至安全事故。因此，如何及时、准确地发现并识别工业过程中的故障，一直是过程监测、运行优化和安全保障中的重要研究问题[1]。

随着分布式控制系统、工业互联网和边缘采集装置的普及，工业现场能够持续积累大规模、多变量、高频率的过程数据。与传统依赖专家经验、机理模型或阈值规则的方法相比，数据驱动故障诊断方法能够在较弱先验条件下从历史运行数据中自动提取判别特征，因此已经成为工业过程监测的重要技术路线之一。尤其是在深度学习方法进入故障诊断领域之后，卷积神经网络、循环神经网络以及各类时序表征模型进一步提升了模型对复杂动态模式的建模能力。

然而，工业故障诊断中的一个核心困难在于训练分布与部署分布往往并不一致。设备老化、原料性质变化、环境扰动、控制参数重整定、负载切换以及生产阶段变更等因素，都会造成不同时间段、不同工况乃至不同装置上的过程数据分布发生偏移。设训练阶段的数据分布为 $P_s(x,y)$，部署阶段的数据分布为 $P_t(x,y)$，在很多真实场景下有

$$P_s(x,y) \neq P_t(x,y). \tag{1.1}$$

当模型仅利用源域标注数据训练时，即使其在源域上取得较高准确率，也可能在目标域上出现显著性能下降。这一问题在流程工业中尤为突出，因为目标工况下的故障样本往往稀缺、代价高昂且带有较强风险属性，重新采集并人工标注大量目标域故障数据通常并不可行[2]。

领域自适应作为迁移学习的重要分支，正是为缓解上述分布偏移问题而提出。其核心思想是在源域有标签、目标域少标签甚至无标签的条件下，通过特征对齐、对抗学习、类别约束或最优传输等方式提升模型在目标域上的泛化能力。对于流程工业而言，如果能够在不依赖目标域大量标注样本的条件下稳定提升跨工况故障识别性能，将对提升模型的工程可用性、降低部署成本和缩短模型迁移周期具有实际意义。

Tennessee Eastman Process（TEP）是过程系统工程领域广泛使用的经典工业过程仿真

平台，由 Downs 和 Vogel 提出[3]。围绕 TEP 构造的领域自适应数据集将不同运行模式组织为不同领域，使得“跨工况故障诊断”能够被清晰表述为无监督领域自适应任务。该数据集既保留了工业多变量时序数据的动态特征，又提供了较规范的任务边界，因此非常适合用于构建统一实验基准、比较典型方法并验证新方法的有效性。

1.2 国内外研究现状

工业过程故障诊断研究。早期工业过程故障诊断较多依赖过程机理模型、专家知识和人工规则，典型思路包括残差生成、观测器、故障树分析、专家规则库以及软测量模型等。这类方法在对象机理明确、可建模性较强且工况变化范围有限的场景下具有较好的解释性，但对于大型流程工业系统而言，完整建立高精度机理模型并不容易；设备磨损、原料波动和工况切换也会不断改变系统实际行为，使纯机理模型难以长期保持稳定。

随着工业信息化水平提高，基于历史运行数据进行状态监测与故障识别逐渐成为主流思路[1]。主成分分析、偏最小二乘、动态 PCA、动态 PLS 等统计过程监测方法长期是流程工业故障检测中的重要工具；支持向量机、近邻分类器、决策树和集成学习等浅层机器学习方法也被广泛用于故障分类任务。近年来，深度学习方法通过多层非线性变换自动学习故障相关表征，卷积神经网络能够从多变量时序片段中学习局部动态模式，循环神经网络和时序注意力模型则擅长建模长时依赖关系。不过，当工况切换导致训练集与测试集分布不一致时，仅依赖源域监督训练的深度模型仍会暴露出跨域泛化不足的问题。

迁移学习与领域自适应研究。迁移学习旨在利用已有任务或已有域中的知识，提升目标任务或目标域上的学习效果。Pan 和 Yang 将迁移学习系统地定义为在源域和目标域分布或任务不同的情况下，通过知识迁移改善目标任务学习性能的过程[2]。当源域与目标域任务相同，但数据分布不同，即

$$\mathcal{Y}_s = \mathcal{Y}_t, \qquad P_s(x) \neq P_t(x), \tag{1.2}$$

就得到领域自适应问题。按照目标域是否具有标签，领域自适应可分为监督式、半监督式和无监督式等多种设置，本文重点关注目标域无标签的无监督领域自适应。

现有无监督领域自适应方法大体可以分为分布对齐、对抗式对齐、最优传输以及伪标签/类条件结构学习等方向。CORAL 通过对齐协方差矩阵减小二阶统计差异[4]，DAN 使用最大均值差异在核空间中逼近边缘分布对齐[5]；DANN 通过域判别器和梯度反转层学习域不变特征[6]，CDAN 进一步利用分类预测结果进行条件化对齐[7]；DeepJDOT 则从最优传

输角度联合建模特征距离与类别预测代价[8]。这些方法为跨工况诊断提供了重要基础，但多数方法仍更偏向整体域差异的削弱，对多类别工业时序数据中的类条件结构、伪标签噪声和训练稳定性考虑仍不充分。

TEP 跨工况迁移诊断研究。 Tennessee Eastman Process 由于过程结构完整、变量丰富、耦合复杂且具有较强代表性，长期被用于过程监测、故障检测和故障诊断算法评估[3]。面向领域自适应任务构造的 TEP 扩展数据集将不同操作模式组织为不同领域，同一故障类别在不同工况下具有共享语义，但又呈现出不同的统计分布，从而能够自然构造跨工况无监督领域自适应诊断任务。

已有研究普遍表明，统一任务定义、数据划分、归一化方式、骨干网络结构和模型选择策略，对于公平比较不同领域自适应方法至关重要。同时，TEP 多工况迁移诊断也为观察类别混叠、分析对齐机制和提出改进方法提供了清晰场景。基于上述研究现状，本文把工作重点放在“统一实验基准构建”和“面向多类别工业时序任务的可靠类条件自适应方法”两条主线上。

1.3 研究内容与技术路线

围绕跨工况无监督领域自适应故障诊断问题，本文的研究内容主要包括以下四个方面。

1. 面向 TEP 多工况迁移诊断任务，建立统一的数据读取、预处理、训练、评估与结果汇总流程，在统一协议下组织单源到单目标领域自适应实验；
2. 在共享 FCN 骨干网络和一致训练设定下，系统比较 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 六种典型方法在关键单源场景上的表现，分析不同对齐机制的收益与局限；
3. 针对基线实验揭示出的类别混叠、伪标签噪声和训练阶段不稳定问题，提出可靠性门控的类条件时序自适应方法 RCTA，并将其关键环节拆分为教师–学生时序一致性、可靠性门控伪标签、双原型记忆和课程化优化四个创新章节；
4. 在实验章节中按照创新点顺序开展递进式验证，依次比较基础模型、加入时序一致性、继续加入可靠性门控、继续加入双原型记忆以及完整 RCTA 的表现，以验证各创新环节的有效性。

本文的技术路线可以概括为以下步骤：首先，结合 TEP 领域自适应数据集明确域定

义、输入表示、训练协议和评价指标；其次，在统一骨干网络与统一模型选择规则下复现典型领域自适应基线方法；再次，根据基线结果定位全局对齐不足、伪标签噪声和类别结构利用不足等关键痛点；最后，围绕这些痛点设计 RCTA 的多个创新环节，并通过逐步叠加的实验验证其贡献。

1.4 研究问题、核心挑战与创新点

基于前述国内外研究现状，本文关注的核心问题是：在目标域缺少故障标签的条件下，如何利用源域标注样本与目标域无标注样本，训练一个能够跨工况迁移的故障诊断模型。围绕这一问题，本文将研究场景限定为单源到单目标的无监督领域自适应诊断任务。源域与目标域分别对应不同的 TEP 操作模式，模型输入为多变量过程时序片段，输出为对应的正常/故障类别预测。

为了使创新点与问题痛点形成一一对应，本文将核心挑战与后文展开的创新章节组织如下。

1. **挑战一：跨工况全局分布偏移显著，但单纯对齐不足以稳定利用目标域时序样本。**不同运行模式下的负载水平、控制策略和动态响应均可能不同，目标域样本虽然可见但无标签，模型难以直接获得目标域监督。针对这一痛点，第三章提出教师–学生时序一致性自适应，在强基线对齐分支之上引入 EMA 教师网络和弱强双视图增强，使目标域样本能够以更平滑的方式进入训练闭环。
2. **挑战二：目标域伪标签容易受噪声和类别不均衡影响。**在 29 类故障诊断任务中，若直接使用高置信伪标签，容易放大早期错误并让少数头部类别占据伪监督预算。针对这一痛点，第四章提出可靠性门控的伪标签学习，从教师置信度、逆熵、增强一致性和原型相似度等维度综合评估样本可靠性，并采用按类门控控制伪标签采纳。
3. **挑战三：全局域对齐容易带来类别混叠，难以保证跨域同类样本聚合、异类样本分离。**流程工业故障类别多且类间响应差异复杂，简单缩小整体域差异可能引发负迁移。针对这一痛点，第五章提出双原型记忆的类条件结构约束，分别维护源域和目标域原型，并通过原型吸引与分离损失显式塑造类别几何结构。
4. **挑战四：多个辅助目标的作用时机不同，若同时强行注入可能破坏训练稳定性。**伪标签、一致性和原型约束均依赖模型阶段性质量，过早或过强施加都会干扰基础分类边界。针对这一痛点，第六章提出课程化优化与完整训练流程，通过分阶段权重

调度和算法流程表组织 RCTA 的完整训练过程，使各模块按“先对齐、再伪监督、后结构化”的顺序发挥作用。

由此，本文的主要创新点可概括为：构建可复现的 TEP 跨工况单源无监督领域自适应实验基准；提出面向目标域时序样本的教师–学生一致性机制；提出多因素可靠性门控与按类伪标签采纳策略；提出双原型记忆驱动的类条件结构约束；并通过递进式叠加实验验证各环节的实际贡献。

1.5 论文结构安排

全文共分为八章，各章内容安排如下。

第一章为绪论，介绍研究背景、国内外研究现状、研究内容、核心挑战以及本文创新点。第二章为跨工况迁移诊断的基准脉络，说明任务定义、统一协议、共享骨干网络和典型基线方法。第三章为教师–学生时序一致性自适应，阐述 RCTA 的总体框架以及 EMA 教师和弱强双视图一致性机制。第四章为可靠性门控的伪标签学习，说明多因素可靠性评分、按类门控和伪标签损失设计。第五章为双原型记忆的类条件结构约束，介绍源域/目标域原型记忆以及原型吸引与分离机制。第六章为课程化优化与完整训练流程，给出损失调度、训练流程和 Algorithm 形式的算法表。第七章为实验设计与递进验证，介绍数据集与实验设置，并按照创新点顺序开展 A、A+B、A+B+C、A+B+C+D 的逐步验证。第八章为总结与展望，对全文工作进行归纳，并讨论进一步扩展方向。

第二章 跨工况迁移诊断的基准脉络

2.1 任务定义与符号说明

本文研究的任务为单源域到单目标域的无监督领域自适应故障诊断。设源域训练样本为

$$\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}, \tag{2.1}$$

其中 x_i^s 为源域样本，$y_i^s \in \mathcal{Y}$ 为故障类别标签；目标域训练样本为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}, \tag{2.2}$$

其中目标域标签在训练阶段不可用。本文的目标是在利用源域有标签样本和目标域无标签样本的条件下，学习一个分类模型

$$f(x) = h(\phi(x)), \tag{2.3}$$

使其在目标域测试集上的风险尽可能小，其中 $\phi(\cdot)$ 表示特征提取器，$h(\cdot)$ 表示分类头。

若将目标域真实风险记为

$$R_t(f) = \mathbb{E}_{(x,y)\sim P_t(x,y)}[\ell(f(x), y)], \tag{2.4}$$

则无监督领域自适应的困难在于训练阶段无法直接最小化 $R_t(f)$。因此，实际训练通常采用

$$\mathcal{L} = \mathcal{L}_{cls}^s + \lambda \mathcal{L}_{adapt} + \mathcal{L}_{aux} \tag{2.5}$$

的形式，其中 $\mathcal{L}_{cls}^s$ 为源域监督分类损失，$\mathcal{L}_{adapt}$ 为领域对齐损失，$\mathcal{L}_{aux}$ 为伪标签、一致性、原型或其他辅助约束项。

2.2 域定义与统一输入表示

在本文实验设定中，不同 TEP 操作模式被视为不同领域，即

$$\mathcal{M} = \{\text{mode1}, \text{mode2}, \ldots, \text{mode6}\}. \tag{2.6}$$

源域与目标域共享相同的标签空间，

$$\mathcal{Y} = \{0, 1, \ldots, 28\}, \tag{2.7}$$

但样本分布并不一致。输入样本采用多变量过程时序片段表示，按照 channels-first 方式组织为 (N, C, T) 形状，其中 $C = 34$ 表示过程变量通道数，$T = 600$ 表示时间窗口长度，模

型输出为 29 类工况与故障类别的预测结果。

数据集的详细构成、域规模、迁移方向和实验划分放在第七章统一说明。本章只保留后续方法推导所需的共同符号与协议，使后文各创新章节能够围绕同一任务边界展开。

2.3 共享骨干网络

本文所有方法共享同一套一维全卷积网络（FCN）骨干，以降低骨干结构差异对实验结论的干扰。编码器由三层一维卷积构成，其计算过程可写为

$$z^{(1)} = \mathrm{ReLU}(\mathrm{IN}(\mathrm{Conv1D}_{9,128}(x))), \tag{2.8}$$

$$z^{(2)} = \mathrm{ReLU}(\mathrm{IN}(\mathrm{Conv1D}_{5,256}(z^{(1)}))), \tag{2.9}$$

$$z^{(3)} = \mathrm{ReLU}(\mathrm{IN}(\mathrm{Conv1D}_{3,128}(z^{(2)}))), \tag{2.10}$$

其中卷积核长度依次为 9、5 和 3，输出通道数依次为 128、256 和 128，$\mathrm{IN}(\cdot)$ 表示实例归一化。随后对时间维执行全局平均池化得到紧凑特征向量：

$$f = \frac{1}{T'} \sum_{t=1}^{T'} z_{:,t}^{(3)} \in \mathbb{R}^{128}. \tag{2.11}$$

分类头采用一层隐藏维度为 128 的全连接网络：

$$p(x) = \mathrm{softmax}(W_2\, \mathrm{ReLU}(W_1 f + b_1) + b_2). \tag{2.12}$$

该结构既保留了时序卷积对局部动态模式的提取能力，又避免了过于复杂的骨干网络给横向比较带来额外变量。

2.4 基础训练目标

源域监督分类损失统一采用交叉熵形式：

$$\mathcal{L}_{cls}^{s} = -\frac{1}{n_s} \sum_{i=1}^{n_s} \sum_{k=1}^{K} \mathbf{1}[y_i^s = k] \log p_k(x_i^s), \tag{2.13}$$

其中 $K = 29$，$p_k(x)$ 为模型对第 k 类的预测概率。不同领域自适应方法在此基础上分别引入协方差对齐、MMD 对齐、域对抗损失、条件对抗损失或最优传输损失；本文提出的 RCTA 则进一步加入可靠伪标签、原型记忆和一致性约束。

在训练脚手架层面，本文统一采用 Adam 优化器，基础学习率设为 10^{-4}，权重衰减设为 0。六种基线方法的训练轮数设为 70，批大小设为 32；RCTA 为了容纳更长的伪标签与原型课程调度，将训练轮数扩展为 96。对于 CDAN 与 RCTA 等更敏感的方法，额外采用最大范数为 5.0 的梯度裁剪，以减小训练过程中的数值波动对收敛稳定性的影响。

2.5 典型基线方法

本节保留六种典型基线方法的骨架说明，具体结果统一放在第七章实验章节中呈现。

2.5.1 Source Only

Source Only 仅依赖源域监督分类损失训练模型，不显式处理源域与目标域之间的分布偏移，其优化目标可写为

$$\mathcal{L}_{SO} = \mathcal{L}_{cls}^{s}. \tag{2.14}$$

该方法可视为所有领域自适应方法的基础对照组。若某一领域自适应方法在目标域上不能显著优于 Source Only，则说明其对齐策略尚未真正缓解跨工况迁移带来的分布差异问题。

2.5.2 分布对齐方法

CORAL 通过约束源域与目标域特征协方差矩阵的一致性来减小二阶统计差异[4]。设源域与目标域特征分别为 $F_s \in \mathbb{R}^{n_s \times d}$ 和 $F_t \in \mathbb{R}^{n_t \times d}$，对应协方差矩阵为 C_s, C_t，则 CORAL 损失为

$$\mathcal{L}_{coral} = \frac{\|C_s - C_t\|_F^2}{4d^2}. \tag{2.15}$$

DAN 使用多核最大均值差异约束源域与目标域特征分布，在核空间中实现边缘分布对齐[5]。给定核函数族 $\{k_u\}_{u=1}^{U}$，其损失可表示为

$$\mathcal{L}_{mmd} = \left\| \frac{1}{n_s} \sum_{i=1}^{n_s} \varphi(f_i^s) - \frac{1}{n_t} \sum_{j=1}^{n_t} \varphi(f_j^t) \right\|_{\mathcal{H}}^2. \tag{2.16}$$

这两类方法结构直接、训练相对稳定，因此适合作为基础分布对齐参照。

2.5.3 对抗式方法

DANN 在共享特征提取网络之后加入域判别器，并利用梯度反转层实现特征表示与域分类之间的对抗学习，从而逼近域不变特征[6]。设域标签 $d = 1$ 表示源域，$d = 0$ 表示目标域，域判别器为 $D(\cdot)$，则对抗损失可写为

$$\mathcal{L}_{adv} = -\frac{1}{n_s} \sum_{i=1}^{n_s} \log D(f_i^s) - \frac{1}{n_t} \sum_{j=1}^{n_t} \log(1 - D(f_j^t)). \tag{2.17}$$

CDAN 在 DANN 基础上进一步将类别预测结果纳入条件化对齐过程，使域判别器感知类别结构信息[7]。若记分类器输出概率为 $p(x)$，则 CDAN 对特征与类别预测进行联合映射：

$$g(x) = f(x) \otimes p(x), \tag{2.18}$$

其中 $\otimes$ 表示多线性组合。对抗式方法通常具有较强的适应能力，但训练稳定性和超参数敏

感性也更值得关注。

2.5.4 最优传输方法

DeepJDOT 通过联合建模特征空间距离与类别预测差异，构建源域和目标域样本之间的运输代价，在深度特征学习过程中同时优化分类与跨域匹配[8]。设 γ 为源域与目标域样本间的运输矩阵，则其代价函数可写为

$$\mathcal{L}_{OT} = \min_{\gamma \in \Pi(a,b)} \sum_{i,j} \gamma_{ij} \left(\alpha \| f_i^s - f_j^t \|_2^2 + \beta \ell(y_i^s, p_j^t) \right). \tag{2.19}$$

该方法能够提供样本级跨域关系约束，但也更容易受到批大小、代价尺度和计算开销的影响。

2.6 评价指标与模型选择

本文重点比较各方法的目标域诊断性能。评价指标主要包括目标域准确率、平衡准确率、混淆矩阵，以及反映域对齐程度和类别聚合情况的特征可视化结果。目标域准确率定义为

$$\mathrm{Acc}_t = \frac{1}{N_t^{eval}} \sum_{i=1}^{N_t^{eval}} \mathbf{1}[\hat{y}_i = y_i], \tag{2.20}$$

平衡准确率定义为

$$\mathrm{BA}_t = \frac{1}{K} \sum_{k=1}^{K} \frac{\mathrm{TP}_k}{\mathrm{TP}_k + \mathrm{FN}_k}, \tag{2.21}$$

其中 TP_k 和 FN_k 分别表示第 k 类的真正例和假负例数量。与普通准确率相比，平衡准确率能够更稳定地反映多类别任务下不同类别的平均识别水平。

考虑到无监督领域自适应缺少统一公认的目标域有标签验证标准，本文采用基于源域评估性能与目标域无标签代理信息的混合模型选择策略。对多数方法，默认采用

$$S_{\mathrm{hyb}} = w_s \cdot \mathrm{Acc}_s^{eval} - w_h \cdot \bar{H}_t, \tag{2.22}$$

其中 Acc_s^{eval} 为源域评估准确率，$\bar{H}_t$ 为目标域训练集上归一化预测熵的均值。该指标兼顾源域判别能力与目标域预测结构化程度，用于选择更稳健的 checkpoint。

2.7 本章小结

本章不再以单纯“相关基础”方式组织内容，而是围绕后续方法和实验所需的共同前提，说明了跨工况迁移诊断的任务定义、输入表示、共享骨干网络、基础训练目标、典型基线方法和评价指标。原数据集细节和基线实验结果被内化到第七章实验设计与递进验证中，避免形成单独的大章节割裂。

第三章 教师–学生时序一致性自适应

3.1 模块定位

第二章中的基准方法主要解决源域与目标域之间的整体分布差异，但目标域样本在训练阶段没有标签，模型无法直接获得目标域分类监督。若只依赖全局域对齐，目标域特征虽然可能靠近源域特征，却不一定形成稳定的类别边界。为此，RCTA 的第一个创新环节是在强基线对齐分支之上，引入教师–学生协同和弱强双视图时序一致性，使目标域样本能够以更稳健的方式参与训练。

本章对应第一章提出的挑战一：跨工况全局分布偏移显著，但单纯对齐不足以稳定利用目标域时序样本。其目标不是单独替代域对齐，而是在保留基础对齐能力的同时，为后续可靠性门控和原型约束提供更平滑的目标域预测来源。

3.2 RCTA 总体框架

设学生网络由编码器 $\phi(\cdot)$ 与分类器 $h(\cdot)$ 构成，教师网络由参数的指数滑动平均版本 $\phi_{\text{tea}}(\cdot)$ 和 $h_{\text{tea}}(\cdot)$ 构成。对于一个源域小批量

$$\mathcal{B}_s = \{(x_i^s, y_i^s)\}_{i=1}^{m_s} \tag{3.1}$$

和一个目标域小批量

$$\mathcal{B}_t = \{x_j^t\}_{j=1}^{m_t}, \tag{3.2}$$

RCTA 的一次训练迭代由以下环节组成：

1. 源域样本经学生网络前向传播，计算监督分类损失与基础域对齐损失；
2. 目标域样本构造弱增强与强增强双视图，教师网络在弱增强视图上生成软伪标签，学生网络在强增强视图上接受一致性约束；
3. 利用教师置信度、逆熵、强增强一致性与原型相似度构造可靠性分数，并按类别分别筛选高可靠目标样本；
4. 基于源域与目标域双原型记忆，对源域样本和高可靠目标样本施加原型吸引与原型分离约束；
5. 通过课程化权重调度联合优化各项损失，并以 EMA 方式更新教师网络参数。

本文最终采用 DANN 作为 RCTA 的基础对齐分支。一方面，DANN 的对抗对齐机制能够为源域和目标域建立较强的共享表示底座；另一方面，它的结构相对清晰，便于在其

上叠加目标域伪监督和类条件约束。RCTA 的总损失可先写为

$$\mathcal{L}_{\text{RCTA}} = \mathcal{L}_{cls}^{s} + \lambda_{align}\mathcal{L}_{align} + \lambda_{mcc}\mathcal{L}_{mcc} + \lambda_{pl}(t)\mathcal{L}_{pl} + \lambda_{proto}(t)\mathcal{L}_{proto} + \lambda_{cons}(t)\mathcal{L}_{cons}, \quad (3.3)$$

其中 $\mathcal{L}_{align}$ 为 DANN 对抗对齐损失，$\mathcal{L}_{mcc}$ 为最小类混淆正则[9]，$\mathcal{L}_{pl}$、$\mathcal{L}_{proto}$ 和 $\mathcal{L}_{cons}$ 分别对应后续章节展开的伪标签、原型和一致性目标。

3.3 EMA 教师网络

为减轻目标域伪标签的瞬时波动，RCTA 不直接使用学生网络当前时刻的预测作为监督，而是引入教师网络生成更平滑的目标域概率分布[10]。教师参数通过学生参数的指数滑动平均更新：

$$\theta_{\text{tea}} \leftarrow \mu\theta_{\text{tea}} + (1-\mu)\theta_{\text{stu}}, \quad (3.4)$$

其中 μ 为 EMA 衰减系数，本文采用的 aggressive 配置中取 $\mu = 0.99$。EMA 的作用可以理解为在参数空间做低通滤波，使教师输出对单步梯度扰动不那么敏感，因此更适合作为目标域伪标签来源。

对目标域样本 x_j^t，教师网络给出的软标签分布为

$$p_j^{tea} = \text{softmax}\left(\frac{h_{\text{tea}}(\phi_{\text{tea}}(\tilde{x}_{j,w}^t))}{T_{tea}}\right), \quad (3.5)$$

其中 T_{tea} 为教师温度参数，$\tilde{x}_{j,w}^t$ 为弱增强视图。相应的伪标签定义为

$$\hat{y}_j^t = \arg\max p_j^{tea}. \quad (3.6)$$

本文在 aggressive 配置中采用 $T_{tea} = 1.1$，既保留类别判别性，又避免温度过低造成的过度自信。

3.4 弱强双视图时序增强

RCTA 在目标域上采用保守的弱增强与相对困难的强增强[11]。设随机增强算子分别为 $\mathcal{A}_w$ 与 $\mathcal{A}_s$，则有

$$\tilde{x}_{j,w}^t = \mathcal{A}_w(x_j^t), \qquad \tilde{x}_{j,s}^t = \mathcal{A}_s(x_j^t). \quad (3.7)$$

其中弱增强主要包含轻微抖动与缩放，强增强进一步加入时间屏蔽和通道 dropout。这样的设计遵循“教师看清晰视图、学生学困难视图”的思路：教师在信息保留更多的弱增强视图上产生更稳定的软标签，学生则在受扰动更强的视图上学习鲁棒表示。

对于流程工业时序数据，增强策略需要保持过程变量的语义一致性，不能破坏故障类

型本身。因而本文采用的增强均控制在局部扰动范围内：抖动用于模拟传感噪声，缩放用于模拟量纲与负载轻微变化，时间屏蔽用于提升局部缺失鲁棒性，通道 dropout 用于缓解模型过度依赖少数变量的问题。后续实验章节会把该环节作为递进验证中的 A 模块。

3.5 一致性损失

对目标域样本，学生网络在强增强视图上的输出记为 p_j^{stu}。一致性损失采用教师分布与学生分布之间的 KL 散度：

$$\mathcal{L}_{cons} = \frac{1}{m_t} \sum_{j=1}^{m_t} w_j^{cons} \, D_{KL}\big(p_j^{tea} \,\|\, p_j^{stu}\big) \,, \tag{3.8}$$

其中 w_j^{cons} 为由可靠性得分导出的样本权重。当前实现中，一致性项主要对通过门控的样本施加显式约束，并对可靠性权重做幂次放大，从而把更多梯度预算分配给更可信的目标样本。

从整体结构上看，本章引入的教师–学生时序一致性解决的是“目标域样本如何进入训练”的问题；下一章进一步解决“哪些目标域样本值得相信”的问题。二者共同构成 RCTA 目标域伪监督机制的前后两层。

3.6 本章小结

本章将原 RCTA 框架中的教师网络与时序一致性环节拆分为独立章节，说明了其在全文创新链条中的位置。该环节以 DANN 对齐分支为基础，通过 EMA 教师网络和弱强双视图增强，为目标域样本提供更平滑、更鲁棒的伪监督入口，为后续可靠性门控和双原型约束奠定基础。

第四章 可靠性门控的伪标签学习

4.1 模块定位

第三章解决了目标域样本如何通过教师–学生一致性进入训练的问题，但目标域伪标签本身仍可能存在噪声。对于 29 类流程工业故障诊断任务，简单采用最大概率作为伪标签采纳依据，容易把高置信错误样本引入训练，并进一步造成错误监督的累积。与此同时，不同故障类别在目标域上的预测置信度并不均衡，若采用全局阈值，伪标签预算可能被少数容易类别占据。

本章对应第一章提出的挑战二：目标域伪标签容易受噪声和类别不均衡影响。为此，RCTA 在教师–学生一致性的基础上进一步引入多因素可靠性评分和按类门控策略，使目标域伪监督从“可见样本全部使用”转变为“可信样本逐步采纳”。

4.2 多因素可靠性评分

目标域伪标签是否可用，不能只由单一最大概率决定。为此，RCTA 对每个目标样本构造四个互补的可靠性分量：

$$q_j = \max p_j^{tea}, \tag{4.1}$$

$$e_j = 1 - \frac{-\sum_{k=1}^{K} p_{jk}^{tea} \log p_{jk}^{tea}}{\log K}, \tag{4.2}$$

$$u_j = p_{j,\hat{y}_j^t}^{stu}, \tag{4.3}$$

$$s_j = \frac{1 + \cos(f_j^{tea}, c_{\hat{y}_j^t}^{ref})}{2}. \tag{4.4}$$

其中 q_j 表示教师置信度，e_j 表示逆归一化熵，u_j 表示学生在强增强视图上对伪标签类别的响应强度，s_j 表示教师特征与参考原型之间的相似度。于是综合可靠性得分定义为

$$r_j = \omega_1 q_j + \omega_2 e_j + \omega_3 u_j + \omega_4 s_j, \qquad \sum_{m=1}^{4} \omega_m = 1. \tag{4.5}$$

在 aggressive 配置中，四个分量的原始权重依次设置为 1.6、0.9、1.2 和 1.4，并在实现中归一化后参与加权。

这样的设计具有明显的互补性。仅依赖最大概率，容易把“高置信但错误”的样本误认为可靠；仅依赖熵，难以区分边界附近的犹豫样本与真正混乱的样本；仅依赖增强一致性，可能忽略类别结构位置；仅依赖原型相似度，又可能在原型尚未稳定时引入偏差。将四种信息联合起来，能够在“预测置信、分布尖锐度、增强一致性、结构匹配”四个维度

上同时评估伪标签质量。

4.3 按类门控策略

在获得可靠性得分之后，RCTA 并不让所有目标域样本都参与伪标签监督，而是引入分数下界和按类接受比例两个门控量。分数下界定义为

$$\tau(t) = \tau_{start} + (\tau_{end} - \tau_{start}) \cdot \min\left(\frac{t}{T_\tau}, 1\right), \tag{4.6}$$

按类接受比例定义为

$$\rho(t) = \rho_{start} + (\rho_{end} - \rho_{start}) \cdot \min\left(\frac{t}{T_\rho}, 1\right). \tag{4.7}$$

本文的 aggressive 配置中，$\tau(t)$ 从 0.24 线性增加到 0.58，$\rho(t)$ 从 0.30 线性增加到 0.92。这样做的目的在于：训练早期只保留少量高置信、高一致性的目标样本，避免噪声伪监督过早主导训练；训练后期再逐步扩大采纳范围，使更多目标域样本参与类条件适应。

与简单的全局阈值不同，RCTA 采用按预测类别分别筛选的策略。对每个预测类别 k，先保留满足 $r_j \geq \tau(t)$ 的样本，再在该类别内部选取得分前 $\lceil \rho(t) \cdot n_k \rceil$ 个样本进入门控集合 Ω_t。这种按类门控机制能够缓解类别不均衡带来的“头部类别占满伪标签预算”问题，更适合 29 类流程工业诊断任务。

4.4 可靠性加权伪标签损失

对于通过门控的目标样本，伪标签损失采用带可靠性加权的交叉熵[12]：

$$\mathcal{L}_{pl} = \frac{1}{|\Omega_t|} \sum_{j \in \Omega_t} \tilde{r}_j \, \ell_{ce}\big(h(\phi(\tilde{x}^t_{j,s})), \hat{y}^t_j\big), \tag{4.8}$$

其中 $\tilde{r}_j$ 为经幂次变换后的可靠性权重，本文采用的幂指数为 1.6。这样一来，不同目标样本虽然都被接纳进入训练，但高可靠样本将对梯度更新产生更大的影响。

从递进验证角度看，本章模块将在第七章中作为 B 模块叠加到第三章的 A 模块之上。对应实验形式为 A 与 A+B 的比较：若 A+B 在多个迁移方向上优于 A，则说明可靠性门控能够有效过滤噪声伪标签并提升目标域监督质量。

4.5 与后续原型模块的衔接

可靠性评分中的原型相似度 s_j 需要参考原型 $c^{ref}_{\hat{y}^t_j}$。在训练早期，参考原型主要由源域类别中心提供；随着门控目标样本逐步被采纳，第五章的目标域原型记忆将开始更新，并反过来提升可靠性评分中的结构判别能力。因而，可靠性门控与双原型记忆不是孤立模块，

而是相互反馈的两个环节：门控决定哪些目标样本能够更新目标域原型，原型又帮助判断后续目标样本是否可信。

4.6 本章小结

本章将原 RCTA 框架中的可靠性门控伪标签学习拆分为独立章节，围绕多因素可靠性评分、按类门控策略和可靠性加权伪标签损失进行了说明。该环节直接回应目标域伪标签噪声与类别不均衡问题，并为第五章的双原型记忆提供高质量目标域样本来源。

第五章 双原型记忆的类条件结构约束

5.1 模块定位

全局域对齐能够缩小源域与目标域的整体差异，但并不能保证跨域同类样本彼此靠近，也不能保证不同故障类别之间保持足够间隔。在 TEP 这类 29 类工业时序诊断任务中，若只强调域间混合，模型可能把不同类别的样本压缩到相近区域，从而产生类别混叠甚至负迁移。为此，RCTA 在可靠性门控伪标签的基础上进一步引入双原型记忆，用显式类别中心约束目标域结构。

本章对应第一章提出的挑战三：全局域对齐容易带来类别混叠，难以保证跨域同类样本聚合、异类样本分离。第三章和第四章分别解决“目标域样本如何进入训练”和“哪些目标域样本可信”，本章则进一步解决“可信目标域样本应被组织到怎样的类别结构中”。

5.2 源域原型记忆

为了显式建模类别结构，RCTA 首先为源域维护原型记忆库[13]。设学生网络在源域样本上的特征表示为

$$f_i^s = \phi(x_i^s). \tag{5.1}$$

对第 k 类样本，源域小批量原型定义为

$$\tilde{c}_k^s = \frac{1}{|\mathcal{B}_s^k|} \sum_{i:y_i^s=k} f_i^s, \tag{5.2}$$

并在实现中做单位化处理。跨批次的源域原型记忆采用动量更新：

$$c_k^s \leftarrow \mathrm{Norm}(\beta c_k^s + (1-\beta)\tilde{c}_k^s), \tag{5.3}$$

其中 β 为原型动量系数，本文取 0.9。源域原型的优势在于标签可靠，能够为各故障类别提供稳定锚点；其不足在于只反映源域类别中心，无法完全覆盖目标域工况下的类别形态。

5.3 目标域原型记忆

为弥补源域原型对目标域结构的表达不足，RCTA 同时维护目标域原型记忆。目标域原型只由通过第四章门控集合 Ω_t 的样本更新，避免大量低可靠伪标签污染类别中心。对第 k 类门控目标样本，其小批量目标原型可写为

$$\tilde{c}_k^t = \frac{1}{|\Omega_t^k|} \sum_{j\in\Omega_t^k} f_j^t, \tag{5.4}$$

其中 $\Omega_t^k = \{j \in \Omega_t | \hat{y}_j^t = k\}$。目标域原型同样采用动量更新：

$$c_k^t \leftarrow \mathrm{Norm}\big(\beta c_k^t + (1-\beta)\tilde{c}_k^t\big)\,. \tag{5.5}$$

这样，目标域原型会随着训练推进逐渐吸收可信目标样本的信息，使类别中心从纯源域锚点过渡为跨域共享锚点。

5.4 参考原型构造

在实际训练中，参考原型并非简单等于源域原型，而是综合当前源域小批量原型、源域记忆原型和目标域记忆原型构成：

$$c_k^{ref} = \mathrm{Norm}\big(\alpha_1 \tilde{c}_k^s + \alpha_2 c_k^s + \alpha_3 c_k^t\big)\,, \tag{5.6}$$

其中权重由各类原型是否可用决定。若某一类别在当前批次中没有可靠目标样本，则参考原型主要由源域信息提供；若目标域原型已经稳定，则参考原型将同时吸收目标域类别结构。

这种设计避免了两个极端：只使用源域原型会忽略目标域工况差异，只使用目标域伪标签原型又容易在训练早期受到噪声影响。双原型记忆通过源域稳定性和目标域适应性的组合，为后续类条件约束提供更平衡的几何中心。

5.5 原型吸引损失

在获得参考原型后，RCTA 同时对源域样本和高可靠目标样本施加原型吸引约束：

$$\mathcal{L}_{att} = \frac{1}{N}\sum_i \big(1 - \cos(f_i, c_{y_i}^{ref})\big)\,. \tag{5.7}$$

对于源域样本，标签 y_i 为真实标签；对于目标域样本，标签由门控后保留的伪标签给出。该损失的几何意义是，在归一化特征空间中把同类样本朝各自类别中心拉近。

源域吸引项能够继续稳定已知类别边界，目标域吸引项则把可信目标样本纳入类别结构。二者共同作用，使模型不再只追求“域不可分”，而是进一步追求“跨域同类可聚合”。

5.6 原型分离损失

仅有类内吸引还不够，为避免原型之间过度接近，进一步定义原型分离损失：

$$\mathcal{L}_{sep} = \frac{1}{|\mathcal{P}|}\sum_{(k,l)\in\mathcal{P}} \max\Big(0, \cos(c_k^{ref}, c_l^{ref}) - m\Big)\,, \tag{5.8}$$

其中 $\mathcal{P}$ 表示所有有效类别原型对的集合，m 为分离边界。最终的原型约束写为

$$\mathcal{L}_{proto} = \mathcal{L}_{att}^{s} + \mathcal{L}_{att}^{t} + \lambda_{sep}\mathcal{L}_{sep}. \tag{5.9}$$

这样一来，特征空间不仅被要求“源域与目标域更接近”，还被要求“跨域同类更紧、异类更开”，这正是类条件结构学习相对于纯全局对齐的关键补充。

5.7 递进验证中的作用

在第七章的递进实验中，本章模块作为 C 模块叠加到 A+B 之上。对应比较形式为 A+B 与 A+B+C：若 A+B+C 能在目标域准确率、平衡准确率、混淆矩阵主对角线连续性和 t-SNE 类簇分离度等方面取得更好表现，则说明双原型记忆确实缓解了类别混叠问题。该验证顺序与第一章的挑战–创新点对应关系保持一致。

5.8 本章小结

本章将原 RCTA 框架中的双原型记忆与类条件约束拆分为独立章节，分别说明了源域原型、目标域原型、参考原型、原型吸引和原型分离损失的设计。该环节直接回应多类别工业时序迁移中的类别混叠问题，并为完整 RCTA 提供显式类别结构支撑。

第六章 课程化优化与完整训练流程

6.1 模块定位

第三章、第四章和第五章分别给出了 RCTA 的时序一致性、可靠性门控和双原型结构约束。它们解决的问题不同，所依赖的训练阶段也不同：基础对齐和源域分类可以从训练开始即发挥作用；伪标签和一致性约束需要模型具备初步判别能力；原型约束则更依赖稳定的类别结构。如果多个辅助目标在训练初期同时以较大权重注入，可能会破坏尚未形成的分类边界。

本章对应第一章提出的挑战四：多个辅助目标的作用时机不同，若同时强行注入可能破坏训练稳定性。为此，RCTA 采用课程化优化策略，并给出完整算法流程，使各创新环节按照“先搭底座、再引入目标域监督、最后强化类条件结构”的顺序逐步发挥作用。

6.2 课程化损失调度

RCTA 的三项目标域辅助损失并不是同时、同权重地注入训练，而是按照训练步数逐步激活。若记任一辅助项的基础权重为 λ，开始步数为 t_0，预热长度为 Δt，则其课程化权重可统一写为

$$\lambda(t) = \begin{cases} 0, & t < t_0, \\ \lambda \cdot \min\left(\frac{t-t_0}{\Delta t}, 1\right), & t \geq t_0. \end{cases} \tag{6.1}$$

其中伪标签损失较早进入训练，一致性损失与其近似同步，原型损失则略晚启动，以避免在特征空间尚未稳定时过早冻结类别结构。

这一调度策略与第四章的门控机制相互配合。训练早期主要由源域监督损失和基础对齐分支主导；中期随着可靠伪标签数量增加，目标域伪监督开始发挥作用；后期则通过原型约束进一步稳定类别边界。对于多类别流程工业时序任务而言，这种渐进式策略比一开始就施加强目标域约束更稳定。

6.3 完整目标函数

结合前述各章，RCTA 的完整优化目标为

$$\mathcal{L}_{\text{RCTA}} = \mathcal{L}_{cls}^{s} + \lambda_{align}\mathcal{L}_{align} + \lambda_{mcc}\mathcal{L}_{mcc} + \lambda_{pl}(t)\mathcal{L}_{pl} + \lambda_{proto}(t)\mathcal{L}_{proto} + \lambda_{cons}(t)\mathcal{L}_{cons}. \tag{6.2}$$

其中，$\mathcal{L}_{cls}^{s}$ 负责源域有标签监督，$\mathcal{L}_{align}$ 负责基础域对齐，$\mathcal{L}_{mcc}$ 用于抑制目标域类别混淆，$\mathcal{L}_{cons}$ 由第三章给出，$\mathcal{L}_{pl}$ 由第四章给出，$\mathcal{L}_{proto}$ 由第五章给出。

从章节逻辑上看，第三章提供目标域预测的平滑来源，第四章筛选可信目标样本，第五章塑造类条件结构，本章则决定这些目标以怎样的节奏进入优化过程。四个环节共同构成完整 RCTA。

6.4 训练流程表

算法 1 给出了 RCTA 的训练流程。该流程表可在后续精修时进一步替换为更完整的流程图，但当前骨架已经明确展示了各创新环节之间的先后关系和信息流向。

算法 1: RCTA 训练流程

Input: 源域批量 $\mathcal{B}_s$，目标域批量 $\mathcal{B}_t$，学生网络参数 θ_{stu}，教师网络参数 θ_{tea}，原型记忆 C_s, C_t

Output: 更新后的学生网络、教师网络和双原型记忆

```
初始化学生网络、教师网络和源/目标域原型记忆;
for 训练步 t = 1, 2, ..., T do
    从源域和目标域采样 B_s, B_t;
    计算源域分类损失 L_cls^s 和基础对齐损失 L_align;
    对目标域样本构造弱增强 x̃_w^t 与强增强 x̃_s^t;
    教师网络在弱增强视图上生成 p^tea 和伪标签 ŷ^t;
    学生网络在强增强视图上生成 p^stu，计算一致性信息;
    根据置信度、逆熵、增强一致性和原型相似度计算可靠性得分 r;
    按类别执行门控，得到高可靠目标集合 Ω_t;
    使用 Ω_t 计算伪标签损失 L_pl，并更新目标域原型候选;
    基于源域真实标签和目标域门控伪标签更新 C_s, C_t;
    计算原型吸引与分离损失 L_proto;
    根据课程函数得到 λ_pl(t)、λ_cons(t)、λ_proto(t);
    汇总 L_RCTA 并更新学生网络参数 θ_stu;
    通过 EMA 更新教师网络参数 θ_tea ← μθ_tea + (1 − μ)θ_stu;
end
```

6.5 递进验证中的作用

在第七章的实验设计中，本章模块作为 D 模块与前三个创新环节共同组成完整 RCTA。递进验证顺序为 A、A+B、A+B+C 和 A+B+C+D，其中：

1. A 表示第三章的教师–学生时序一致性；
2. B 表示第四章的可靠性门控伪标签学习；
3. C 表示第五章的双原型记忆类条件约束；
4. D 表示本章的课程化优化与完整训练流程。

这样的实验组织方式能够避免只给出“完整方法优于基线”的笼统结论，而是逐步说明每个创新点在解决相应痛点时是否带来可观察收益。

6.6 本章小结

本章将 RCTA 的训练节奏和完整算法流程单独成章，说明了课程化损失调度、完整目标函数和 Algorithm 流程表。至此，RCTA 的四个创新环节已经按章节展开；下一章将作为倒数第二章，围绕数据集、实验设置和递进验证结果进行统一组织。

第七章 实验设计与递进验证

7.1 实验章节定位

本章作为全文倒数第二章，统一承接前文的基准构建、方法设计和递进验证任务。与原先将“实验设定”和“基线结果”拆成独立大章的写法不同，本章把数据集介绍、统一实验协议、基线对比和 RCTA 创新点验证放在同一实验章节中，形成从任务背景到模块有效性验证的完整闭环。

本章的实验组织遵循第一章提出的挑战–创新点对应关系：先给出统一数据集与评价协议，再呈现基线方法结果，最后按照第三章至第六章的创新顺序进行逐步叠加验证。若将第三章、第四章、第五章和第六章分别记为 A、B、C、D，则实验验证顺序为 A、A+B、A+B+C、A+B+C+D。

7.2 数据集与域划分

7.2.1 TEP 领域自适应数据集

本文采用 Tennessee Eastman Process Domain Adaptation 数据集开展实验。该数据集面向跨工况迁移诊断任务构造，将 6 个操作模式视为 6 个不同领域，标签空间为 29 类，即正常工况和 28 类故障。与普通单域分类任务相比，该数据集更适合用于分析工业过程在工况切换条件下产生的分布偏移问题。

根据 manifest 文件，6 个域的样本规模与默认 Fold 1 划分情况如表 7.1 所示。可以看到，各域样本总量均接近 2900，默认采用 5 折中的 Fold 1 作为评估集时，训练样本量约为 2300，测试样本量约为 570。这样的规模既能够支撑本文的系统化单源比较，也保留了工业时序诊断任务的复杂性。

表 7.1 TEP 领域自适应数据集的域规模与默认 Fold 1 划分

域	样本总数	训练样本数	评估样本数	单样本形状	类别数
mode1	2900	2320	580	600×34	29
mode2	2845	2278	567	600×34	29
mode3	2899	2320	579	600×34	29
mode4	2865	2294	571	600×34	29
mode5	2883	2307	576	600×34	29
mode6	2897	2318	579	600×34	29

7.2.2 迁移任务构造

本文将不同运行模式之间的迁移任务表示为单源域到单目标域的无监督领域自适应场景。训练阶段仅使用源域标签和目标域无标签样本，测试阶段使用目标域标签进行性能评估。正文聚焦以下四个关键单源场景：

$$\text{mode2} \to \text{mode5}, \quad \text{mode3} \to \text{mode6}, \quad \text{mode5} \to \text{mode2}, \quad \text{mode6} \to \text{mode3}. \tag{7.1}$$

这四个场景覆盖了互逆迁移方向，既包含分布偏移显著的困难方向，也包含 Source Only 已具有一定可迁移性、但仍有改进空间的相对容易方向，因此能够较完整地反映方法在不同迁移难度下的表现。

7.3 输入预处理与实验协议

7.3.1 时序样本表示

数据集中的每个样本均表示为固定长度的多变量时间窗口，可形式化写为

$$x \in \mathbb{R}^{T \times C}, \tag{7.2}$$

其中 $T = 600$，$C = 34$。在进入神经网络前，数据被转置为 channels-first 形式：

$$x' = \text{Transpose}(x) \in \mathbb{R}^{C \times T}. \tag{7.3}$$

这种表示方式既保留了过程变量间的相关性，也保留了短时动态变化信息，适合由一维卷积网络沿时间维提取局部模式。所有方法均在相同输入形式下进行比较，以避免由于样本组织方式差异而引入额外干扰。

7.3.2 归一化与数据划分

为保证不同方法之间具有可比性，本文采用固定折划分区分训练样本与评估样本，并在域内执行标准化处理，以减小量纲差异对模型训练的影响。对任意一个域内通道 c，首先计算该域全体样本在该通道上的均值与标准差：

$$\mu_c = \frac{1}{NT} \sum_{n=1}^{N} \sum_{t=1}^{T} x_{n,t,c}, \qquad \sigma_c = \sqrt{\frac{1}{NT} \sum_{n=1}^{N} \sum_{t=1}^{T} (x_{n,t,c} - \mu_c)^2}, \tag{7.4}$$

随后执行标准化：

$$\tilde{x}_{n,t,c} = \frac{x_{n,t,c} - \mu_c}{\sigma_c + \varepsilon}. \tag{7.5}$$

当前采用的策略是 `normalization_scope=domain`，即对每个域分别基于该域全量样本统计量进行标准化，然后再按照 Fold 1 划分训练集与评估集。这一做法能够减小不同域

量纲差异对特征学习的干扰，使比较尽量聚焦于领域自适应机制本身。

7.3.3 训练与结果产物

各方法采用一致的数据划分、共享骨干网络和统一的数据输入格式，并在相同任务设定下进行比较。训练阶段统一遵循“源域有标签、目标域无标签”的无监督领域自适应协议；评估阶段同时记录源域表现和目标域表现，以便分析模型是否存在“源域拟合较强但目标域迁移有限”的现象。

为了保证结果核对、图表生成和论文撰写过程中的一致性，训练脚手架对每次运行均保存统一结构的产物，包括 checkpoint、结果表、运行评审摘要、混淆矩阵图、t-SNE 可视化图以及分析用中间特征。实验结果统一以 `result.json` 和 `review.json` 形式保存，便于批量汇总和交叉校验。

7.4 基线方法总体结果

表 7.2 预留了 6 种基线方法在四个关键单源场景上的目标域结果位置。考虑到当前版本需要先完成论文骨架调整，本表中的具体数值统一保留为占位实现，待最终实验结果整理完成后再统一回填。

表 7.2 四个关键单源场景上的基线结果（占位）

方法	mode2→mode5	mode3→mode6	mode5→mode2	mode6→mode3	平均准确率	平均平衡准确率
Source Only	待补充	待补充	待补充	待补充	待补充	待补充
CORAL	待补充	待补充	待补充	待补充	待补充	待补充
DAN	待补充	待补充	待补充	待补充	待补充	待补充
DANN	待补充	待补充	待补充	待补充	待补充	待补充
CDAN	待补充	待补充	待补充	待补充	待补充	待补充
DeepJDOT	待补充	待补充	待补充	待补充	待补充	待补充

在最终版本中，本节将基于该表比较不同基线方法在四个迁移方向上的整体表现，并从平均准确率、平均平衡准确率以及跨场景稳定性三个角度展开分析。基线结果还将为后续 RCTA 递进验证提供参照，尤其用于观察完整方法相对于 Source Only 和最强基线的收益。

7.5 创新点递进验证

7.5.1 验证顺序设计

为了体现创新点针对性解决现存痛点，本章不只比较完整 RCTA 与基线方法，而是按照章节顺序进行模块递进验证。四个模块定义如下：

1. A：第三章的教师–学生时序一致性自适应；

2. B：第四章的可靠性门控伪标签学习；
3. C：第五章的双原型记忆类条件约束；
4. D：第六章的课程化优化与完整训练流程。

对应的实验组合为 A、A+B、A+B+C、A+B+C+D。这样的验证方式能够观察每个创新环节加入后是否带来目标域性能、类别平衡性和训练稳定性的提升。

7.5.2 A：教师–学生时序一致性验证

表 7.3 预留 A 模块的验证结果位置。该实验以强基线对齐分支为底座，加入 EMA 教师和弱强双视图一致性，用于判断目标域时序一致性是否能够改善跨工况迁移表现。

表 7.3 A 模块：教师–学生时序一致性验证（占位）

模型	mode2→mode5	mode3→mode6	mode5→mode2	mode6→mode3
强基线	待补充	待补充	待补充	待补充
A	待补充	待补充	待补充	待补充

7.5.3 A+B：加入可靠性门控后的验证

表 7.4 预留 A+B 组合的验证结果位置。该实验在 A 的基础上加入多因素可靠性评分和按类门控，用于判断伪标签噪声控制是否进一步提升目标域监督质量。

表 7.4 A+B 模块：加入可靠性门控后的递进验证（占位）

模型	mode2→mode5	mode3→mode6	mode5→mode2	mode6→mode3
A	待补充	待补充	待补充	待补充
A+B	待补充	待补充	待补充	待补充

7.5.4 A+B+C：加入双原型记忆后的验证

表 7.5 预留 A+B+C 组合的验证结果位置。该实验在可靠伪标签基础上加入源域/目标域双原型记忆和类条件结构约束，用于判断类别混叠是否得到缓解。

表 7.5 A+B+C 模块：加入双原型记忆后的递进验证（占位）

模型	mode2→mode5	mode3→mode6	mode5→mode2	mode6→mode3
A+B	待补充	待补充	待补充	待补充
A+B+C	待补充	待补充	待补充	待补充

7.5.5 A+B+C+D：完整 RCTA 验证

表 7.6 预留完整 RCTA 与 Source Only 以及逐场景最强基线的对比结果位置。完整 RCTA 对应 A+B+C+D，即前三个创新模块加上课程化优化与完整训练流程。

表 7.6 完整 RCTA 与 Source Only 及逐场景最强基线的比较（占位）

场景	Source Only	最强基线	A+B+C	完整 RCTA	相对最强基线增益
mode2→mode5	待补充	待补充	待补充	待补充	待补充
mode3→mode6	待补充	待补充	待补充	待补充	待补充
mode5→mode2	待补充	待补充	待补充	待补充	待补充
mode6→mode3	待补充	待补充	待补充	待补充	待补充

7.6 定性分析图件

为了进一步说明各创新模块的作用机制，本节预留代表性单源场景的定性分析位置。后续将在最终结果回填后，结合具体表现选择代表性迁移方向，并补充相应的混淆矩阵与特征可视化图件。图件建议优先导出为矢量格式，推荐使用 PDF；若需要兼顾兼容性，也可采用 SVG。相较于 PNG 等位图格式，矢量图在论文排版中更便于无损缩放，且通常能够更好控制文件体积。

(a) Source Only 或最强基线　　(b) 完整 RCTA

图 7-1 代表性场景下基线方法与完整 RCTA 的混淆矩阵对比（占位）

图中纵坐标建议采用简写形式以提升可读性，例如将 `mode1_to_mode4` 统一记为 `m1_m4`，`mode2_to_mode5` 记为 `m2_m5`，`mode3_to_mode6` 记为 `m3_m6`，`mode5_to_mode2` 记为 `m5_m2`，`mode6_to_mode3` 记为 `m6_m3`。这样既能保持标签简洁，也更适合在有限空间内展示热力图、t-SNE 图或迁移对比图。

待图件回填后，本节将重点观察误分类是否集中于少数类别、主对角线连续性是否增强、源域与目标域样本是否更好重叠，以及类别簇结构是否保持清晰。上述定性分析将与 A、A+B、A+B+C、A+B+C+D 的定量结果相互印证。

7.7 本章小结

本章将数据集介绍、统一实验协议、基线对比和 RCTA 递进验证统一组织为倒数第二章。实验骨架按照 A、A+B、A+B+C、A+B+C+D 的顺序展开，能够逐一验证第三章至第

实验结果占位图

基线方法 t-SNE 图待补充

(a) Source Only 或最强基线

实验结果占位图

完整 RCTA t-SNE 图待补充

(b) 完整 RCTA

图 7-2 代表性场景下基线方法与完整 RCTA 的域分布 t-SNE 对比（占位）

六章创新环节的有效性，并为最终结果回填预留了表格、混淆矩阵和 t-SNE 图件位置。

第八章 总结与展望

8.1 全文工作总结

本文围绕流程工业场景下的领域自适应故障诊断问题，面向 Tennessee Eastman Process Domain Adaptation 数据集，完成了从研究现状梳理、统一实验基准构建、典型基线比较到 RCTA 方法拆解设计与递进验证规划的一系列工作。全文首先在绪论中梳理国内外研究现状，并将研究挑战与后续创新章节建立对应关系；随后说明跨工况迁移诊断的统一任务边界、共享骨干网络、基础训练目标和典型领域自适应基线；在此基础上，将 RCTA 拆分为教师–学生时序一致性、可靠性门控伪标签、双原型记忆类条件约束和课程化优化四个创新环节；最后在实验章节中按照 A、A+B、A+B+C、A+B+C+D 的顺序组织递进验证框架。

相较于原有章节组织，当前骨架将文献综述前移至绪论，将原问题定义、数据集、实验设定和基线结果内化到基准章节与实验章节中，并把 RCTA 的关键模块拆分为独立章节。这样的结构更有利于体现“现有痛点–方法创新–实验验证”之间的对应关系。

8.2 主要结论

在当前骨架版本中，本文可确认的阶段性结论主要包括以下四点。

1. TEP 多工况故障诊断可以被清晰表述为单源到单目标的无监督领域自适应问题，并能够在统一数据划分、统一骨干网络和统一模型选择准则下开展可复现比较。
2. 典型领域自适应基线方法能够为 RCTA 的设计提供参照，其中全局分布对齐、对抗式对齐和最优传输方法各有优势，但在多类别工业时序任务中仍需要进一步处理目标域伪标签噪声和类别结构混叠问题。
3. RCTA 的四个创新环节分别回应四类痛点：教师–学生时序一致性用于稳定目标域预测来源，可靠性门控用于筛选可信伪标签，双原型记忆用于显式塑造类条件结构，课程化优化用于控制各辅助目标的进入时机。
4. 倒数第二章已经按照创新点顺序预留了递进实验框架，后续可直接回填 A、A+B、A+B+C、A+B+C+D 的定量结果、混淆矩阵和 t-SNE 可视化，从而形成完整的验证闭环。

8.3 不足与未来展望

尽管本文已经在单源到单目标跨工况诊断场景上形成了较完整的研究链路，但仍存在若干值得进一步完善之处。

1. 当前正文聚焦四个关键单源场景，尚未对更大范围的迁移对进行系统统计，因此对于不同工况组合下方法收益边界的认识仍可继续拓展。
2. RCTA 的完整验证结论仍待最终结果回填，后续需要进一步补充严格的模块消融、参数敏感性分析和统计显著性检验，以明确各模块的独立贡献与相互作用。
3. 当前分析主要集中在离线无监督领域自适应设置，对更复杂迁移场景、在线适应、持续诊断以及工程部署约束等问题尚未展开深入研究。

围绕上述不足，后续工作可以从以下几个方向继续推进：其一，扩展到更多迁移方向和更复杂场景，系统考察 RCTA 在更广泛工业诊断任务中的稳定性；其二，围绕可靠性门控、双原型记忆、一致性正则和课程化调度开展严格消融实验，进一步厘清方法机制；其三，引入更丰富的可解释性分析，如类别级误差分解、原型演化轨迹和伪标签质量统计，以增强方法分析深度；其四，探索与工业先验知识、在线更新机制和轻量化部署约束结合的混合方法，为后续工程应用奠定基础。

8.4 本章小结

总体来看，本文已经围绕 TEP 跨工况故障诊断任务形成了一条更清晰的论文主线：绪论中交代研究现状与挑战，基准章节统一实验前提，方法章节按创新点逐一展开，实验章节按同一顺序递进验证，最后总结全文并展望后续工作。当前版本重点完成骨架调整，后续可在既有结构中继续补入最终实验结果与精修分析。

参考文献

[1] QIN S J. Survey on data-driven industrial process monitoring and diagnosis[J/OL]. Annual Reviews in Control, 2012, 36(2): 220-234. DOI: 10.1016/j.arcontrol.2012.09.004.

[2] PAN S J, YANG Q. A survey on transfer learning[J/OL]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359. DOI: 10.1109/TKDE.2009.191.

[3] DOWNS J J, VOGEL E F. A plant-wide industrial process control problem[J/OL]. Computers & Chemical Engineering, 1993, 17(3): 245-255. DOI: 10.1016/0098-1354(93)80018-I.

[4] SUN B, SAENKO K. Deep CORAL: Correlation alignment for deep domain adaptation[C/OL]//Lecture Notes in Computer Science: volume 9915 Computer Vision – ECCV 2016 Workshops. Cham: Springer International Publishing, 2016: 443-450. DOI: 10.1007/978-3-319-49409-8_35.

[5] LONG M, CAO Y, WANG J, et al. Learning transferable features with deep adaptation networks[C/OL]// Proceedings of Machine Learning Research: volume 37 Proceedings of the 32nd International Conference on Machine Learning. Lille, France: PMLR, 2015: 97-105. https://proceedings.mlr.press/v37/long15.html.

[6] GANIN Y, USTINOVA E, AJAKAN H, et al. Domain-adversarial training of neural networks[J/OL]. Journal of Machine Learning Research, 2016, 17(59): 1-35. https://jmlr.org/papers/v17/15-239.html.

[7] LONG M, CAO Z, WANG J, et al. Conditional adversarial domain adaptation[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 31. Curran Associates, Inc., 2018: 1647-1657. https://proceedings.neurips.cc/paper/2018/hash/ab88b15733f543179858600245108dd8-Abstract.html.

[8] DAMODARAN B B, KELLENBERGER B, FLAMARY R, et al. DeepJDOT: Deep joint distribution optimal transport for unsupervised domain adaptation[C/OL]//Lecture Notes in Computer Science: volume 11208 Computer Vision – ECCV 2018. Cham: Springer International Publishing, 2018: 467-483. https://openaccess.thecvf.com/content_ECCV_2018/html/Bharath_Bhushan_Damodaran_DeepJDOT_Deep_Joint_ECCV_2018_paper.html. DOI: 10.1007/978-3-030-01225-0_28.

[9] JIN Y, WANG X, LONG M, et al. Minimum class confusion for versatile domain adaptation[C/OL]// Lecture Notes in Computer Science: volume 12366 Computer Vision – ECCV 2020. Cham: Springer International Publishing, 2020: 464-480. DOI: 10.1007/978-3-030-58589-1_28.

[10] TARVAINEN A, VALPOLA H. Mean teachers are better role models: Weight-averaged consistency tar-

gets improve semi-supervised deep learning results[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 30. Curran Associates, Inc., 2017: 1195-1204. https://proceedings.neurips.cc/paper/2017/hash/68053af2923e00204c3ca7c6a3150cf7-Abstract.html.

[11] XIE Q, DAI Z, HOVY E, et al. Unsupervised data augmentation for consistency training[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 33. Curran Associates, Inc., 2020: 6256-6268. https://proceedings.neurips.cc/paper_files/paper/2020/file/44feb0096faa8326192570788b38c1d1-Paper.pdf.

[12] LEE D H. Pseudo-Label: The simple and efficient semi-supervised learning method for deep neural networks[C/OL]//ICML 2013 Workshop: Challenges in Representation Learning (WREPL). Atlanta, Georgia, USA, 2013. https://storage.googleapis.com/kaggle-forum-message-attachments/8924/pseudo_label_final.pdf.

[13] TANWISUTH K, FAN X, ZHENG H, et al. A prototype-oriented framework for unsupervised domain adaptation[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 34. Curran Associates, Inc., 2021: 17194-17208. https://proceedings.neurips.cc/paper/2021/hash/8edd72158ccd2a879f79cb2538568fdc-Abstract.html.

附录 A 实验补充材料

A.1 附录说明

本附录给出正文之外的补充材料，包括关键超参数表、RCTA aggressive 配置摘要以及四个关键单源场景的完整结果占位表。所有内容均服务于本文正文聚焦的单源到单目标跨工况诊断任务。

A.2 基线方法关键超参数

表 1.1 给出了本文 6 种基线方法在 aggressive 配置下采用的关键超参数。这些配置由 `configs/method/*.yaml` 与实验覆盖项共同确定。

表 1.1 基线方法关键超参数

方法	epochs	batch size	学习率	关键对齐参数
Source Only	70	32	1×10^{-4}	无显式对齐项
CORAL	70	32	1×10^{-4}	$\lambda_{coral} = 0.5$，warm-start
DAN	70	32	1×10^{-4}	$\lambda_{mmd} = 0.05$，5 组高斯核尺度
DANN	70	32	1×10^{-4}	$\lambda_{adv} = 0.5$，GRL warm-start，判别器 256×2
CDAN	70	32	1×10^{-4}	$\lambda_{cadv} = 0.2$，randomized dim=256，熵保护选择指标
DeepJDOT	70	32	1×10^{-4}	$\lambda_{ot} = 1.0$，$\alpha = 0.1$，$\beta = 1.0$

A.3 RCTA aggressive 配置摘要

表 1.2 汇总了本文单源四场景中采用的 RCTA aggressive 配置。该配置以 DANN 为基础对齐分支，同时融合 MCC 正则、可靠性门控、双原型记忆与一致性学习。

表 1.2 RCTA aggressive 配置摘要

模块	配置
训练轮数	96
基础对齐分支	DANN
MCC 正则	$\lambda_{mcc} = 0.1$，temperature=2.0
教师网络	EMA decay=0.99，teacher temperature=1.1
可靠性权重	cal_conf=1.6，inv_entropy=0.9，consistency=1.2，proto_sim=1.4
分数下界课程	0.24 → 0.58，持续 2400 steps
按类接受比例课程	0.30 → 0.92，持续 2400 steps
伪标签损失	最大权重 0.42，warmup 500 steps，可靠性加权，power=1.6
原型损失	最大权重 0.08，start step=700，warmup 1000 steps
一致性损失	最大权重 0.12，start step=500，warmup 1000 steps
一致性门控	仅对 gate 内样本启用，reliability power=1.8
数据增强	弱增强：轻微抖动/缩放；强增强：抖动、缩放、时间屏蔽、通道 dropout

A.4 四个关键单源场景的完整结果

表 1.3 预留了本文四个关键单源场景的完整结果位置，包括源域训练准确率、源域评估准确率、目标域准确率、目标域平衡准确率和最终选择 epoch。当前版本已将其中的具体数值替换为占位实现，待最终实验结果确认后再统一补入。

表 1.3 四个关键单源场景的完整结果（占位）

方法	场景	源域训练准确率	源域评估准确率	目标域准确率	目标域平衡准确率	选择 epoch
完整实验结果数据占位，待最终版本补充。						

A.5 补充说明

正文中的汇总图与代表性定性图当前均已改为占位实现。待最终实验结果确认后，可在本附录与正文既有结构中同步补入完整结果表、代表性场景图件及其说明文字。

致　　谢

值此本科毕业论文完成之际，谨向在大学期间关心、指导和帮助过我的老师、学长、同学及家人致以诚挚的感谢。

首先，衷心感谢指导教师王永健教授，在毕业设计选题、研究思路梳理、实验推进和论文撰写过程中给予了我耐心细致的指导与帮助，使我得以顺利完成本论文的研究工作；同时，在个人发展与后续规划等方面给予我的支持与鼓励，也使我深受感激；严谨认真的治学态度和认真负责的工作作风，使我受益匪浅。

其次，感谢蒋徐颢、蔡闻骁、邹滨阳等学长和同学榜样在学习与成长过程中给予我的帮助与示范。他们在专业学习、科研视野和个人规划方面的经验分享，对我产生了积极而深远的影响。

感谢严震霆、周志铭、曲振宁等同学和朋友在本科阶段给予我的陪伴、支持与鼓励。在课题讨论、日常学习和生活交流中，他们给予了我许多真诚的帮助，使我能够更加从容地面对学习和毕业设计过程中的困难与挑战。

最后，衷心感谢我的父母和家人。感谢他们一直以来给予我的理解、包容和支持，使我能够安心完成本科阶段的学习任务与毕业论文工作。