本科毕业设计（论文）报告

题 目：基于领域自适应的工业过程故障诊断方法研究

学　　号：08022311

姓　　名：陈鲲龙

学　　院：自动化

专　　业：自动化

指导教师：王永健、童国道

起止日期：2026 年 3 月 ~2026 年 6 月

东南大学毕业（设计）论文独创性声明

本人声明所呈交的毕业（设计）论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签名：_____　　日期：__2026__年__6__月_____日

东南大学毕业（设计）论文使用授权声明

东南大学有权保留本人所送交毕业（设计）论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括刊登）论文的全部或部分内容。论文的公布（包括刊登）授权东南大学教务处办理。

论文作者签名：_____　　导师签名：_____

日期：__2026__年__6__月_____日　　日期：__2026__年__6__月_____日

摘　　要

工业过程故障诊断对于保障生产安全、降低非计划停机损失和提升过程运行可靠性具有重要意义。随着流程工业工况日益复杂，基于数据驱动的故障诊断方法得到了广泛应用。然而，在不同操作条件、不同负载水平或不同时间阶段下采集到的过程数据往往存在明显的分布偏移，导致仅依赖源域标注数据训练得到的模型在目标域上的诊断性能显著下降。围绕这一问题，本文以 Tennessee Eastman Process Domain Adaptation 数据集为研究对象，面向单源到单目标的无监督领域自适应故障诊断场景，构建了一个面向 benchmark 复现与方法比较的实验工作流。

本文结合当前项目实现，完成了数据勘察、基准元数据构建、训练评估、结果汇总与图表导出等基础模块，并在统一的一维卷积特征提取骨干网络下实现了 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 等代表性方法。针对流程工业时序信号的特点，本文对域内标准化、固定折划分、目标域无标签训练、目标域测试评估等关键环节进行了统一约定，同时设计了准确率、平衡准确率、混淆矩阵与特征可视化等评价方式，以支持后续对不同领域自适应方法迁移效果的系统分析。

当前阶段的工作重点在于完成论文整体结构搭建与实验基线实现，为后续开展多场景对比实验、误差分析与方法改进奠定基础。本文的研究有助于形成一个较为规范、可复现、便于扩展的流程工业领域自适应故障诊断实验框架。

关键词：流程工业故障诊断，领域自适应，迁移学习，Tennessee Eastman Process，基准复现

ABSTRACT

Industrial fault diagnosis is essential for production safety, reduction of unplanned downtime, and reliable process operation. With increasingly complex operating conditions in process industries, data-driven diagnosis methods have become widely adopted. However, process data collected under different operating modes, load levels, or time periods usually exhibit evident distribution shifts, which makes a model trained only with labeled source-domain data generalize poorly to a target domain. To address this issue, this thesis focuses on the Tennessee Eastman Process Domain Adaptation dataset and builds a benchmark-oriented workflow for single-source to single-target unsupervised domain adaptation in industrial fault diagnosis.

Based on the current project implementation, the thesis organizes the full pipeline including data inspection, benchmark metadata construction, model training, evaluation, result aggregation, and figure export. Under a unified one-dimensional convolutional backbone, several representative methods have been implemented for comparison, including Source Only, CORAL, DAN, DANN, CDAN, and DeepJDOT. To make later experiments comparable and reproducible, this work defines a consistent protocol covering domain-wise normalization, fixed fold splitting, unlabeled target-domain adaptation, and target-domain evaluation. It also prepares multiple analysis views such as accuracy, balanced accuracy, confusion matrices, and feature visualization.

At the current stage, the main focus is to establish a complete thesis structure and a reproducible experimental baseline, which will support subsequent multi-scenario comparisons, error analysis, and further method improvement. The study aims to provide a practical and extensible experimental foundation for domain adaptation based fault diagnosis in process industries.

KEY WORDS: Industrial Fault Diagnosis, Domain Adaptation, Transfer Learning, Tennessee Eastman Process, Benchmark Reproduction

目　　录

摘　　要 I
ABSTRACT II
目　　录 III
第一章　绪论 1
1.1 研究背景与意义 1
1.2 研究问题与目标 1
1.3 本文主要工作 2
1.4 论文结构安排 2
第二章　相关工作 3
2.1 工业过程故障诊断研究现状 3
2.2 迁移学习与领域自适应方法 3
2.3 田纳西伊士曼过程基准与启示 4
2.4 本章小结 5
第三章　任务定义与方法设计 6
3.1 任务定义与符号说明 6
3.2 基准实验流程设计 6
3.3 骨干网络与 Source Only 基线 6
3.4 分布对齐类方法 7
3.5 对抗式领域自适应方法 7
3.6 基于最优传输的方法 7
3.7 本章小结 7
第四章　实验设计与结果分析 9
4.1 实验环境与数据准备 9
4.2 评价指标与对比方案 9
4.3 实验结果与分析 9
4.4 本章小结 10
第五章　总结与展望 11

5.1 全文工作总结 11
5.2 不足与未来展望 11
参考文献 12
附录 A 实验配置与补充材料 13
A.1 附录说明 13
A.2 后续可补充内容 13
致 谢 14

第一章 绪论

1.1 研究背景与意义

流程工业广泛存在于化工、能源、冶金、制药等关键行业，其生产过程通常具有连续运行、耦合强、非线性明显和安全要求高等特点。一旦关键设备或工艺环节发生异常，不仅会造成产品质量下降，还可能引发连锁波动甚至安全事故。因此，如何及时、准确地发现并识别工业过程中的故障，一直是过程监测与控制领域的重要研究方向。随着传感器和控制系统的普及，工业现场可以持续采集大量过程变量，这为基于数据驱动的故障诊断方法提供了良好的应用基础[1]。

传统的数据驱动故障诊断方法通常默认训练数据与测试数据满足相同分布，但这一假设在真实工业场景中往往难以成立。设备老化、原料波动、控制策略变化以及操作负载切换等因素，都会导致不同时间或不同工况下采集到的数据分布发生偏移。当模型仅利用某一工况下的标注数据进行训练时，其在新工况或新域上的诊断性能往往显著下降。对于流程工业而言，重新采集并标注大量目标域故障样本通常成本高昂，甚至在某些工况下几乎不可行。因此，研究能够利用源域知识提升目标域诊断性能的迁移学习与领域自适应方法，具有明确的工程价值和现实意义[2]。

Tennessee Eastman Process（TEP）是过程系统工程领域广泛采用的工业过程仿真基准，由 Downs 和 Vogel 提出[3]。围绕该过程构造的领域自适应数据集能够较好地模拟不同操作模式下的分布差异，为验证故障诊断模型的跨域泛化能力提供了统一平台。基于 TEP 数据集构建规范的 benchmark，系统比较不同领域自适应方法在流程工业故障诊断中的适用性，不仅有助于梳理现有方法的优缺点，也能为后续方法改进和工程部署提供实验基础。

1.2 研究问题与目标

本文关注的核心问题是：在目标域缺少故障标签的条件下，如何利用源域标注样本和目标域无标注样本，构建能够适应工况变化的故障诊断模型。围绕这一问题，本文将研究场景限定为单源域到单目标域的无监督领域自适应诊断任务。源域与目标域分别对应不同的 TEP 操作模式，模型输入为多变量过程时序片段，输出为对应的故障类别预测。

为使研究工作聚焦且可复现，本文设置了以下几个具体目标。首先，基于当前工作区中的数据处理与训练脚本，构建一套清晰、统一的 benchmark 复现实验流程，使数据读取、归一化、折划分、训练、评估和可视化等环节具有稳定接口。其次，在统一骨干网络与尽量

一致的训练协议下，实现并比较多种代表性领域自适应方法，包括分布对齐类、对抗式方法和最优传输类方法，从而为后续分析不同方法在流程工业场景中的行为差异提供基础。最后，通过准确率、平衡准确率、混淆矩阵和特征可视化等多维指标，对模型的源域拟合能力、目标域迁移能力和类别混淆现象进行系统分析。

从论文写作角度看，本文并不急于在现阶段给出最终实验结论，而是先完成研究问题定义、技术路线梳理和实验框架搭建。这样既有利于后续逐步填充实验结果，也能保证正文结构与当前代码实现保持一致，减少后期反复调整目录与章节内容的工作量。

1.3 本文主要工作

结合当前已完成的项目实现，本文的主要工作可以概括为以下几个方面。

其一，围绕 TEP 领域自适应数据集完成了数据勘察与 benchmark 基础设施搭建。本文对原始数据文件结构、标签分布、折划分方式和归一化流程进行了整理，并形成了面向后续实验调用的数据接口与配置文件。

其二，构建了统一的故障诊断模型比较框架。本文采用一维全卷积网络作为共享特征提取骨干，在相同输入形态和分类头结构下，复现了 Source Only、CORAL、DAN、DANN、CDAN 和 DeepJDOT 等典型方法，便于后续在统一条件下进行横向比较。

其三，完善了训练评估与结果分析流程。当前工作流支持基于配置文件执行训练任务、保存结果摘要、生成评审信息，并导出柱状图、热力图、混淆矩阵和 t-SNE 可视化图，为论文中实验结果展示和分析提供了直接支撑。

1.4 论文结构安排

全文共分为五章，各章内容安排如下。

第一章为绪论，主要介绍研究背景、问题来源、研究目标以及本文完成的主要工作。第二章为相关工作，围绕工业过程故障诊断、迁移学习与领域自适应方法以及 TEP 基准展开综述。第三章介绍本文的任务定义、数据与模型设定，并对所实现的各类领域自适应方法进行说明。第四章给出实验设计方案，包括数据准备、对比方法、评价指标、结果展示与分析思路。第五章对全文工作进行总结，并对后续可进一步深入的研究方向进行展望。

第二章 相关工作

2.1 工业过程故障诊断研究现状

工业过程故障诊断研究经历了从机理模型方法到数据驱动方法不断发展的过程。早期方法较多依赖精确的过程机理建模、专家经验或人工设计特征，这类方法在机理明确、工况单一的场景下具有较好的可解释性，但面对大型复杂工业过程时，往往存在建模困难、推广性有限和维护成本较高等问题。随着工业信息化水平提高，基于历史运行数据进行状态监测与故障识别逐渐成为主流思路[1]。

数据驱动方法通常通过统计建模、机器学习或深度学习技术，从大量过程变量中自动提取与故障相关的表征。典型方法包括主成分分析、偏最小二乘、支持向量机以及近年来广泛应用的卷积神经网络和循环神经网络等。相比传统方法，深度模型能够直接从原始或弱处理后的多变量时序信号中学习高层特征，在复杂模式识别任务中展现出更强的拟合能力。然而，深度模型往往需要较多标注数据，并且对训练集与测试集分布一致性的依赖更强。当工况发生变化时，模型容易出现性能衰减，这使得跨域泛化成为工业故障诊断研究中的关键问题。

对于流程工业场景，仅依赖单一工况下采集到的故障样本训练模型，难以覆盖真实生产中可能出现的工况变化。与通用视觉任务不同，工业过程数据具有时序性、强相关性和工况依赖性，诊断模型不仅需要识别类别间差异，还要对不同域之间的统计偏移保持鲁棒。因此，将迁移学习与领域自适应思想引入工业过程故障诊断，已经成为近年来值得关注的发展方向。

2.2 迁移学习与领域自适应方法

迁移学习旨在利用已有任务或已有域中的知识，提升目标任务或目标域上的学习效果。Pan 和 Yang 将迁移学习系统地定义为在源域和目标域分布或任务不同的情况下，通过知识迁移改善目标任务学习性能的过程[2]。其中，领域自适应是迁移学习的重要分支，主要研究源域和目标域任务相同但数据分布不同的情形。按照目标域是否具有标签，领域自适应可分为监督式、半监督式和无监督式等多种设置，本文重点关注目标域无标签的无监督领域自适应。

现有无监督领域自适应方法大体可以分为三类。第一类是分布对齐方法，其核心思想是在保持源域分类能力的同时，缩小源域与目标域特征分布之间的差异。例如，CORAL

通过对齐特征协方差矩阵减小二阶统计量差异[4]；DAN 则利用多核最大均值差异在再生核希尔伯特空间中约束源域与目标域特征分布接近[5]。这类方法结构相对清晰，训练较为稳定，适合作为流程工业场景中的基础对比方案。

第二类是对抗式领域自适应方法。DANN 在特征提取网络后引入域判别器，并利用梯度反转层实现特征学习与域判别之间的对抗博弈，从而促使提取到的特征具有域不变性[6]。CDAN 在此基础上进一步利用分类预测结果对特征进行条件化，使域判别过程能够感知类别结构信息，从而缓解简单对抗对齐可能造成的类别混叠问题[7]。对抗式方法通常具有较强的表示学习能力，但训练稳定性和超参数敏感性也更值得关注。

第三类是基于最优传输的领域自适应方法。相关方法通过构造源域和目标域样本之间的运输代价，直接在概率分布层面寻找匹配关系。DeepJDOT 将特征空间距离与类别预测差异结合起来，在深度特征学习过程中联合优化跨域样本匹配与分类目标[8]。这类方法能够在全局层面描述跨域样本关系，但通常对批大小、代价构造和计算效率较为敏感。

总体来看，不同领域自适应方法在假设前提、优化目标与训练稳定性方面各有特点。将这些方法置于统一的流程工业故障诊断 benchmark 中进行比较，有助于观察它们在工业时序数据上的适用范围与局限性。

2.3 田纳西伊士曼过程基准与启示

Tennessee Eastman Process 是经典的化工过程仿真平台，包含多个相互耦合的单元操作和控制回路，能够模拟多种正常工况与故障情形[3]。由于该过程结构较为完整、变量丰富且具有较强代表性，TEP 长期被用于过程监测、故障检测和故障诊断算法的评估。与一般静态分类数据集相比，TEP 数据具有明显的动态特性和工业背景，更能体现方法在复杂过程系统中的实际适应能力。

在本文对应的数据集设置中，不同操作模式可被视为不同领域，同一故障类别在不同模式下的统计分布存在偏移，这为构造领域自适应诊断任务提供了天然条件。结合当前工作区中的数据接口和实验配置，本文主要关注单源域到单目标域的迁移情形，并以固定折划分、统一归一化方式和共享骨干网络实现跨方法对比。这样的设计有助于减少与任务无关的干扰因素，把分析重点放在不同适配机制本身。

从研究启示上看，TEP 基准不仅能够帮助验证模型在跨工况诊断中的迁移能力，还能为实验流程规范化提供参考。特别是在本科毕业论文写作阶段，先搭建稳定的 benchmark

框架，再逐步补充实验结果和方法分析，是一种更可控也更高效的推进方式。

2.4 本章小结

本章从工业过程故障诊断、迁移学习与领域自适应方法以及 TEP 基准三个方面梳理了与本文课题密切相关的研究背景。可以看到，工业过程中的域偏移问题使得传统仅依赖同分布假设的诊断模型面临明显挑战，而分布对齐、对抗学习和最优传输等方法为跨域故障诊断提供了可行思路。基于此，下一章将结合当前项目实现，对本文采用的任务定义、模型结构与具体方法进行说明。

第三章 任务定义与方法设计

3.1 任务定义与符号说明

本文研究的任务为单源域到单目标域的无监督领域自适应故障诊断。设源域为 $\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$，其中 x_i^s 表示源域样本，y_i^s 表示其故障类别标签；目标域为 $\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}$，目标域训练阶段不使用标签。本文的目标是在利用源域有标签样本和目标域无标签样本的条件下，训练一个能够在目标域测试集上保持较好诊断性能的分类模型。

结合当前代码实现，输入样本采用多变量过程时序片段表示，按照 channels-first 的方式组织为 (N, C, T) 形状，其中 $C = 34$ 表示过程变量通道数，T 表示时间长度，输出为 29 类故障类别的分类结果。源域与目标域分别对应不同操作模式下采集的数据，本文通过统一配置文件指定源域、目标域、折划分和归一化策略，从而保证不同实验设置之间具有一致的数据处理方式。

3.2 基准实验流程设计

为了支持后续多方法的统一比较，本文先构建了面向 benchmark 的实验流程。整体流程包括原始数据勘察、元数据构建、训练集与测试集划分、归一化处理、模型训练、结果汇总以及图表导出等模块。当前工作区中已实现相应脚本和配置接口，能够根据实验配置自动完成场景组织与结果保存。

在数据处理阶段，本文采用固定折划分来区分训练样本与评估样本，并在域内执行标准化处理，以减小量纲差异对模型训练的影响。在实验管理阶段，各方法共用统一的运行目录结构与 JSON 结果摘要，便于后续对目标域准确率、源域训练表现以及可视化结果进行集中整理。这种先规范流程、再开展方法比较的思路，有助于提升实验复现性和论文写作效率。

3.3 骨干网络与 Source Only 基线

本文采用一维全卷积网络作为共享特征提取骨干。该网络由多层一维卷积、归一化、ReLU 激活和 Dropout 组成，能够从多变量时序信号中提取紧凑的全局特征表示。卷积特征经过时间维平均池化后，送入包含全连接层的分类头得到最终故障类别预测。相比更复杂的时序建模结构，该骨干网络实现简单、训练稳定，适合作为 benchmark 的统一基础。

Source Only 方法作为最基本的对照组，仅使用源域有标签数据进行监督训练，不对源域与目标域之间的分布差异作额外处理。该方法能够反映模型在跨域适配缺失时的基础性

能，也是衡量其他领域自适应方法是否带来有效迁移收益的重要参照。

3.4 分布对齐类方法

为减小源域与目标域特征分布之间的差异，本文首先实现了 CORAL 和 DAN 两类代表性分布对齐方法。CORAL 通过约束源域与目标域特征协方差矩阵的一致性，使网络在保留源域分类判别信息的同时，尽可能学习对域偏移不敏感的表示。DAN 则基于多核最大均值差异度量源域与目标域在特征空间中的分布距离，并将其作为附加损失加入训练目标。

这类方法的共同特点是结构相对直接，训练过程中不引入额外的对抗优化回路，因此在工程实现上较为稳定。对于流程工业故障诊断任务而言，分布对齐类方法可以作为观察跨域迁移收益的第一类重要比较对象。

3.5 对抗式领域自适应方法

在对抗式方法部分，本文实现了 DANN 与 CDAN。DANN 在特征提取网络之后引入域判别器，并借助梯度反转层，使特征提取器在训练过程中学习到既有利于源域分类、又难以被域判别器区分的特征表示，从而提升跨域泛化能力。CDAN 在此基础上进一步引入类别预测信息，对特征与预测结果进行条件化组合，以增强域对齐过程对类别结构的感知能力。

对抗式方法通常能够学习更强的域不变特征，但训练中也更容易受到学习率、对抗损失权重和判别器容量等因素影响。将其与分布对齐方法放在统一框架下比较，有助于观察其在工业时序信号场景中的稳定性与适配效果。

3.6 基于最优传输的方法

除上述两类方法外，本文还实现了 DeepJDOT 作为最优传输思路的代表。该方法在训练过程中综合考虑源域与目标域样本在特征空间中的距离以及类别预测层面的匹配关系，通过联合分布对齐促进目标域特征表示学习。与仅关注边缘分布的对齐方法相比，DeepJDOT 更强调样本级关系建模，能够从另一个角度刻画跨域迁移过程。

3.7 本章小结

本章结合当前项目实现，对本文研究任务、输入输出形式、benchmark 流程以及所采用的几类领域自适应方法进行了说明。整体上，本文以统一骨干网络和统一训练协议为前

提，围绕 Source Only、分布对齐、对抗学习和最优传输三类思路组织方法比较。下一章将在此基础上进一步给出实验设置、评价指标与结果分析框架。

第四章 实验设计与结果分析

4.1 实验环境与数据准备

本文实验基于 Tennessee Eastman Process Domain Adaptation 数据集开展。原始数据文件以不同操作模式组织，并通过统一的数据接口加载为源域与目标域样本。按照当前配置，实验默认采用固定折划分区分训练集与评估集，并在域内进行标准化处理。为保证不同方法之间的可比性，本文在实验中统一输入通道组织方式、批量组织形式以及目标域无标签训练约束。

从工程实现上看，当前工作区已经提供了从原始数据勘察、benchmark 元数据构建到训练启动的完整脚本。训练实验默认使用配置文件管理设备、随机种子、运行目录和保存策略，便于在后续论文写作过程中追踪不同实验场景的来源与结果。后续正式成稿时，可在本节补充具体的软件版本、硬件平台和最终采用的训练超参数表。

4.2 评价指标与对比方案

本文主要从分类性能和迁移效果两个角度评价模型。分类性能方面，可采用源域训练准确率、源域测试准确率和目标域测试准确率衡量模型的拟合能力、泛化能力及跨域表现；为降低类别不平衡对整体判断的干扰，还可进一步统计目标域平衡准确率。除数值指标外，本文还将结合目标域混淆矩阵分析模型在不同故障类别上的混淆模式，并利用 t-SNE 可视化观察源域与目标域特征在嵌入空间中的聚合与分离情况。

在对比方案方面，本文以 Source Only 作为无适配基线，并在相同骨干网络上比较 CORAL、DAN、DANN、CDAN 和 DeepJDOT 等方法。后续若实验时间允许，还可在统一流程下扩展更多方法或开展参数敏感性分析。当前阶段的重点是先确保主要对比方法都能在统一协议下运行并生成可分析结果。

4.3 实验结果与分析

结合当前工作区中的自动化脚本，后续实验可从单一场景验证逐步扩展到多场景小规模批量比较。例如，可先以某一组源域到目标域的迁移任务进行 smoke test，确认训练与评估链路运行正常，再逐步扩展到多组模式迁移场景，观察不同方法在不同域偏移条件下的表现差异。

正式撰写本节时，可按照“主结果表格、横向比较、可视化分析、误差讨论”的顺序展开。首先给出目标域准确率和相对 Source Only 的提升情况，分析不同方法在各场景中

的整体表现；随后结合混淆矩阵讨论主要错误类别及其可能原因；最后结合域融合和类别聚合的 t-SNE 图，分析特征对齐程度与诊断性能之间的关系。若某些方法出现源域性能较高但目标域迁移较弱的现象，还可进一步讨论其潜在原因，例如过拟合、对齐不足或过度对齐等问题。

4.4 本章小结

本章给出了本文实验部分的组织方式，包括数据准备、训练环境、评价指标、对比方案以及结果分析思路。由于当前阶段仍以实验框架搭建和论文结构完善为主，本章先对后续实验写作所需的信息结构进行了预设。待各组实验结果补充完成后，可在此基础上直接填入表格、图像和定量分析内容。

第五章 总结与展望

5.1 全文工作总结

本文围绕流程工业场景下的领域自适应故障诊断问题，面向 Tennessee Eastman Process Domain Adaptation 数据集，初步完成了论文结构搭建、任务定义梳理与 benchmark 实验框架实现。通过统一数据接口、训练协议和结果分析流程，本文为后续比较不同领域自适应方法在跨工况故障诊断中的表现提供了基础支撑。

在方法层面，本文基于统一的一维卷积骨干网络，实现了 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 等多种代表性方法，并围绕数据准备、模型训练、结果汇总和图表导出形成了较完整的实验工作流。当前阶段的主要成果在于完成了研究工作的整体组织，使论文写作、代码实现与后续实验分析能够围绕同一套结构持续推进。

5.2 不足与未来展望

当前工作仍存在若干不足。首先，论文中的大规模对比实验和定量结果分析尚需进一步补充，尤其需要在更多迁移场景下系统比较不同方法的稳定性与收益。其次，现阶段的研究重点仍以 benchmark 复现为主，对流程工业数据中时序依赖、类别不平衡和复杂工况变化的针对性建模还不够深入。最后，当前框架主要面向单源域到单目标域设置，尚未扩展到多源迁移、少样本目标域适配或更贴近工程部署的在线诊断情形。

后续研究可以从以下几个方向继续展开。其一，补充多场景实验结果，形成更完整的横向比较和误差分析。其二，在现有基线基础上探索更适合工业时序数据的结构设计与损失约束，例如结合时序上下文建模、类别级对齐或不确定性估计。其三，进一步完善实验平台的可扩展性，把多源域设置、消融实验和自动化报告能力纳入同一工作流。通过这些工作，可使本文从“完成 benchmark 搭建与方法复现”逐步推进到“形成具有针对性的流程工业领域自适应诊断研究结果”。

参考文献

[1] QIN S J. Survey on data-driven industrial process monitoring and diagnosis[J]. Annual Reviews in Control, 2012, 36(2): 220-234.

[2] PAN S J, YANG Q. A survey on transfer learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2009, 22(10): 1345-1359.

[3] DOWNS J J, VOGEL E F. A plant-wide industrial process control problem[J]. Computers & Chemical Engineering, 1993, 17(3): 245-255.

[4] SUN B, SAENKO K. Deep CORAL: Correlation alignment for deep domain adaptation[C]//Computer Vision – ECCV 2016 Workshops. 2016: 443-450.

[5] LONG M, CAO Y, WANG J, et al. Learning transferable features with deep adaptation networks[C]// Proceedings of the 32nd International Conference on Machine Learning. 2015: 97-105.

[6] GANIN Y, USTINOVA E, AJAKAN H, et al. Domain-adversarial training of neural networks[J]. Journal of Machine Learning Research, 2016, 17(59): 1-35.

[7] LONG M, CAO Z, WANG J, et al. Conditional adversarial domain adaptation[C]//Advances in Neural Information Processing Systems: volume 31. 2018.

[8] DAMODARAN B B, KELLENBERGER B, FLAMARY R, et al. Deepjdot: Deep joint distribution optimal transport for unsupervised domain adaptation[C]//Proceedings of the European Conference on Computer Vision. 2018: 447-463.

附录 A 实验配置与补充材料

A.1 附录说明

本附录用于放置不便完全写入正文、但对复现实验和理解实现细节仍有参考价值的补充材料，例如训练配置文件摘要、更多实验表格、运行目录结构说明、结果文件字段说明以及关键脚本入口说明等。

A.2 后续可补充内容

正式成稿时，可在本附录中补充以下内容：各方法关键超参数表、典型实验命令、结果 JSON 字段解释、图表导出脚本说明，以及正文未展开的补充可视化结果。若附录内容较多，也可继续扩展为多个附录文件。

致　　谢

此处为致谢占位内容。正式成稿时可用于感谢指导教师、课题组成员、提供帮助的同学与家人等。