本科毕业设计（论文）报告

题 目：基于领域自适应的工业过程故障诊断方法研究

学　　号：08022311

姓　　名：陈鲲龙

学　　院：自动化

专　　业：自动化

指导教师：王永健、童国道

起止日期：2026 年 3 月 ~2026 年 6 月

东南大学毕业（设计）论文独创性声明

本人声明所呈交的毕业（设计）论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签名：_____　　日期：__2026__年__6__月_____日

东南大学毕业（设计）论文使用授权声明

东南大学有权保留本人所送交毕业（设计）论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括刊登）论文的全部或部分内容。论文的公布（包括刊登）授权东南大学教务处办理。

论文作者签名：_____　　导师签名：_____

日期：__2026__年__6__月_____日　　日期：__2026__年__6__月_____日

摘　　要

工业过程故障诊断对于保障生产安全、降低非计划停机损失和提升过程运行可靠性具有重要意义。然而，在真实流程工业现场中，不同操作模式、负载水平和控制阶段往往对应不同的数据分布，使得基于单源、多源及更一般跨域设置训练得到的诊断模型均难以直接迁移到新工况。面向这一问题，本文以 Tennessee Eastman Process Domain Adaptation 数据集为对象，研究跨工况无监督领域自适应故障诊断，并围绕统一实验基准构建、典型方法比较和改进方法设计展开系统研究。

本文首先构建了面向 TEP 跨工况迁移诊断的统一实验流程，统一了数据组织方式、预处理策略、共享骨干网络、模型选择规则和结果管理方式，在一致协议下比较了多种代表性领域自适应方法。基线实验表明，显式领域对齐能够有效改善跨工况诊断性能，但仅依赖全局对齐仍难以稳定处理多类别时序任务中的类别混叠、伪标签噪声和场景敏感性问题。

在此基础上，本文提出可靠性门控的类条件时序自适应方法 RCTA。该方法以强基线对齐分支为基础，引入 EMA 教师网络、弱强双视图时序增强、多因素可靠性门控、双原型记忆以及一致性约束，以实现更稳定的目标域伪监督利用和更清晰的类条件结构建模。实验结果表明，所提方法在本文重点考察的关键单源跨工况场景上优于对比基线，能够在保持源域判别能力的同时进一步提升目标域迁移性能。

总体而言，本文形成了从统一实验基准构建到改进方法验证的完整研究链路，可为流程工业无监督领域自适应故障诊断研究提供可复现的比较基础和有效的方法参考。

关键词：故障诊断，领域自适应，TEP，无监督领域自适应

ABSTRACT

Industrial fault diagnosis is important for production safety, reducing unplanned downtime, and ensuring reliable process operation. In real industrial processes, however, data collected under different operating modes, load levels, and control stages often follow different distributions. Consequently, diagnostic models trained in single-source, multi-source, and more general cross-domain settings often generalize poorly to new operating conditions. To address this problem, this thesis investigates unsupervised domain adaptation for cross-mode fault diagnosis on the Tennessee Eastman Process Domain Adaptation dataset, focusing on unified benchmark construction, baseline comparison, and method improvement.

This work first establishes a unified and reproducible experimental pipeline for cross-mode transfer fault diagnosis on TEP. The pipeline standardizes data organization, preprocessing, shared backbone design, model selection, and result management, enabling fair comparisons among representative domain adaptation methods under a consistent protocol. Baseline experiments show that explicit domain alignment can substantially improve cross-mode diagnostic performance, but global alignment alone is still insufficient to robustly handle class confusion, noisy pseudo labels, and scenario sensitivity in multi-class industrial time-series tasks.

On this basis, the thesis proposes a Reliability-Gated Class-Conditional Temporal Adaptation method, denoted as RCTA. Built on a strong alignment baseline, the method integrates an EMA teacher, weak and strong temporal augmentations, multi-factor reliability gating, dual prototype memories, and consistency regularization to achieve more stable target-domain pseudo supervision and clearer class-conditional structure. Experimental results show that the proposed method outperforms the compared baselines in the key single-source cross-mode scenarios emphasized in this study, while preserving source-domain discriminability.

Overall, this thesis develops a coherent research line from unified benchmark construction to improved method validation, providing both a reproducible comparison basis and an effective methodological reference for unsupervised domain adaptation in industrial process fault diagnosis.

KEY WORDS: Fault Diagnosis, Domain Adaptation, TEP, Unsupervised Domain Adaptation

目　　录

摘　　要 I
ABSTRACT II
目　　录 III
第一章　绪论 1
1.1 研究背景与意义 1
1.2 研究问题与核心挑战 2
1.2.1 跨工况分布偏移显著 2
1.2.2 目标域无标签，监督信号间接 2
1.2.3 工业时序数据类别结构复杂 2
1.2.4 实验比较需要统一且可复现 3
1.3 研究内容与技术路线 3
1.3.1 研究内容 3
1.3.2 技术路线 3
1.4 本文的主要工作与创新点 3
1.5 论文结构安排 4
第二章　相关基础与文献综述 5
2.1 流程工业故障诊断方法概述 5
2.1.1 基于机理模型的方法 5
2.1.2 基于机器学习的方法 5
2.1.3 基于深度学习的方法 5
2.2 领域自适应理论基础 6
2.2.1 迁移学习与领域自适应定义 6
2.2.2 单源无监督领域自适应设定 6
2.2.3 全局对齐与类条件对齐 7
2.3 TEP 数据集与跨工况迁移诊断研究 7
2.3.1 TEP 过程与故障诊断任务 7
2.3.2 TEP 领域自适应数据集简介 8

2.3.3 多工况分布偏移与迁移诊断研究评述 8
2.4 本工作与现有研究的关系 8
2.5 本章小结 8
第三章 问题定义、数据集与实验设定 10
3.1 任务定义与符号说明 10
3.1.1 问题描述 10
3.1.2 域定义与符号约定 10
3.1.3 优化目标 11
3.2 数据集与域划分 11
3.2.1 TEP 领域自适应数据集 11
3.2.2 迁移任务构造 12
3.3 输入表示与预处理策略 12
3.3.1 时序样本表示 12
3.3.2 归一化与数据划分 12
3.4 共享骨干网络与训练脚手架 13
3.4.1 一维全卷积骨干网络 13
3.4.2 统一优化设置 13
3.5 统一实验设定 13
3.5.1 训练与评估协议 13
3.6 评价指标与模型选择 14
3.7 实验产物与复现性说明 15
3.8 本章小结 15
第四章 基线方法与实验结果分析 16
4.1 基线方法说明 16
4.1.1 Source Only 16
4.1.2 分布对齐方法 16
4.1.3 对抗式方法 17
4.1.4 最优传输方法 17
4.2 实验范围与比较协议 18

4.3 实验结果与现象分析 18
4.3.1 四个关键单源场景上的总体结果 18
4.3.2 分场景结果分析 18
4.3.3 主要现象归纳 19
4.4 对改进方法设计的启示 20
4.5 本章小结 20
第五章 可靠性门控的类条件时序自适应方法 21
5.1 方法设计动机 21
5.2 方法总体框架 21
5.2.1 整体组成 21
5.2.2 总体优化目标 22
5.3 教师网络与时序一致性学习 22
5.3.1 EMA 教师网络 22
5.3.2 弱强双视图时序增强 23
5.3.3 一致性损失 23
5.4 可靠性门控的伪标签学习 24
5.4.1 多因素可靠性评分 24
5.4.2 按类门控与课程调度 24
5.4.3 可靠性加权伪标签损失 25
5.5 双原型记忆与类条件约束 25
5.5.1 源域与目标域原型记忆 25
5.5.2 原型吸引与原型分离 26
5.6 课程化优化策略 26
5.7 四个关键单源场景上的实验验证 27
5.7.1 定量结果：四个场景均取得最优结果 27
5.7.2 定性结果：代表性场景分析 28
5.7.3 RCTA 架构创新的作用分析 29
5.8 本章小结 29
第六章 总结与展望 30

6.1 全文工作总结 30
6.2 主要结论 30
6.3 不足与未来展望 30
6.4 本章小结 31
参考文献 32
附录 A 实验补充材料 34
A.1 附录说明 34
A.2 基线方法关键超参数 34
A.3 RCTA aggressive 配置摘要 34
A.4 四个关键单源场景的完整结果 35
A.5 补充说明 35
致 谢 36

第一章 绪论

1.1 研究背景与意义

流程工业广泛存在于化工、能源、冶金、制药、环保和材料制造等关键行业，其生产过程通常具有连续运行、物料与能量强耦合、动态特性显著、控制回路复杂以及安全风险高等特点。一旦关键设备或工艺环节发生异常，不仅会导致产品质量波动、能耗上升和非计划停机，还可能进一步诱发连锁故障甚至安全事故。因此，如何及时、准确地发现并识别工业过程中的故障，一直是过程监测、运行优化和安全保障中的重要研究问题[1]。

随着分布式控制系统、工业互联网和边缘采集装置的普及，工业现场能够持续积累大规模、多变量、高频率的过程数据。与传统依赖专家经验、机理模型或阈值规则的方法相比，数据驱动故障诊断方法能够在较弱先验条件下从历史运行数据中自动提取判别特征，因此已经成为工业过程监测的重要技术路线之一[1]。尤其是在深度学习方法进入故障诊断领域之后，卷积神经网络、循环神经网络以及各类时序表征模型进一步提升了模型对复杂动态模式的建模能力。

然而，工业故障诊断中的一个核心困难在于训练分布与部署分布往往并不一致。设备老化、原料性质变化、环境扰动、控制参数重整定、负载切换以及生产阶段变更等因素，都会造成不同时间段、不同工况乃至不同装置上的过程数据分布发生偏移。设训练阶段的数据分布为 $P_s(x,y)$，部署阶段的数据分布为 $P_t(x,y)$，在很多真实场景下有

$$P_s(x,y) \neq P_t(x,y). \tag{1.1}$$

当模型仅利用源域标注数据训练时，即使其在源域上取得较高准确率，也可能在目标域上出现显著性能下降。这一问题在流程工业中尤为突出，因为目标工况下的故障样本往往稀缺、代价高昂且带有较强风险属性，重新采集并人工标注大量目标域故障数据通常并不可行[2]。

领域自适应作为迁移学习的重要分支，正是为缓解上述分布偏移问题而提出。其核心思想是在源域有标签、目标域少标签甚至无标签的条件下，通过特征对齐、对抗学习、类别约束或最优传输等方式提升模型在目标域上的泛化能力。对于流程工业而言，如果能够在不依赖目标域大量标注样本的条件下稳定提升跨工况故障识别性能，将对提升模型的工程可用性、降低部署成本和缩短模型迁移周期具有实际意义。

Tennessee Eastman Process（TEP）是过程系统工程领域广泛使用的经典工业过程仿真

平台，由 Downs 和 Vogel 提出[3]。围绕 TEP 构造的领域自适应数据集将不同运行模式组织为不同领域，使得“跨工况故障诊断”能够被清晰表述为无监督领域自适应任务。该数据集既保留了工业多变量时序数据的动态特征，又提供了较规范的任务边界，因此非常适合用于构建统一实验基准、比较典型方法并验证新方法的有效性。

1.2 研究问题与核心挑战

本文关注的核心问题是：在目标域缺少故障标签的条件下，如何利用源域标注样本与目标域无标注样本，训练一个能够跨工况迁移的故障诊断模型。围绕这一问题，本文将研究场景限定为单源到单目标的无监督领域自适应诊断任务。源域与目标域分别对应不同的 TEP 操作模式，模型输入为多变量过程时序片段，输出为对应的正常/故障类别预测。

与一般图像分类或标准迁移学习问题相比，本文任务至少面临以下几个方面的挑战。

1.2.1 跨工况分布偏移显著

不同运行模式下的负载水平、控制策略和动态响应均可能不同，因此同一故障类别在不同模式下表现出的时序轨迹并不完全一致。也就是说，目标域不仅存在边缘分布变化，

$$P_s(x) \neq P_t(x), \tag{1.2}$$

还可能伴随条件分布差异，

$$P_s(y|x) \neq P_t(y|x). \tag{1.3}$$

这使得简单依赖源域监督训练的分类器难以保证跨域泛化效果。

1.2.2 目标域无标签，监督信号间接

在无监督领域自适应设定中，训练阶段只能使用源域标签，目标域样本虽然可见，但其标签不可用。因此训练过程无法直接最小化目标域分类误差，只能依赖无标签代理指标、伪标签、域对齐或结构约束来间接逼近目标风险。如何在不过度引入噪声监督的前提下充分利用目标域样本，是方法设计的关键。

1.2.3 工业时序数据类别结构复杂

TEP 领域自适应数据集包含 29 个类别，既包括正常工况也包括多种故障类型。与若干低类别数迁移任务相比，29 类流程工业时序数据在跨域条件下更容易出现类别混叠和决策边界不稳定的问题。仅依赖全局域对齐，可能会把跨域异类样本压缩到相近区域，反而带来负迁移。

1.2.4 实验比较需要统一且可复现

领域自适应方法往往对骨干网络、数据预处理、选择指标和超参数高度敏感。如果没有统一的实验协议，不同方法之间的差异很容易被数据划分和训练细节掩盖。因此，在进行方法比较之前，必须先建立统一的数据组织方式、训练脚手架和结果管理流程。

1.3 研究内容与技术路线

1.3.1 研究内容

围绕上述问题，本文的工作主要包括以下三个方面。

1. 面向 TEP 多工况迁移诊断任务，建立统一的数据读取、预处理、训练、评估与结果汇总流程，在统一协议下组织单源到单目标领域自适应实验；
2. 在共享 FCN 骨干网络和一致训练设定下，系统比较 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 六种典型方法在四个关键单源场景上的表现，分析不同对齐机制的收益与局限；
3. 针对基线实验揭示出的类别混叠、伪标签噪声和场景敏感性问题，提出可靠性门控的类条件时序自适应方法 RCTA，并围绕其结构设计与实验结果开展论证。

1.3.2 技术路线

本文的技术路线可以概括为以下四步。

1. 首先，对 TEP 领域自适应数据集进行任务化建模，明确域定义、样本组织、归一化方式、输入表示和统一评价指标；
2. 其次，以一维全卷积网络作为共享时序特征提取骨干，在一致实验协议下复现多种典型领域自适应基线方法；
3. 再次，基于基线结果总结流程工业跨工况迁移中的主要矛盾，并据此提出 RCTA 的教师–学生协同、可靠性门控、双原型记忆与课程调度机制；
4. 最后，围绕四个关键单源场景，对基线方法与 RCTA 进行定量与定性分析，形成从实验基准构建到方法改进的完整研究链路。

1.4 本文的主要工作与创新点

本文的主要工作与创新点可概括为以下四点。

1. 构建了面向 TEP 跨工况诊断的统一单源无监督领域自适应实验框架。该框架统一了数据组织方式、输入表示、归一化策略、骨干网络、模型选择规则与结构化结果产

物，为后续公平比较奠定了基础。

2. 在统一协议下完成了六种代表性基线方法的系统比较，并围绕四个关键单源场景给出了可复核的结果表、热力图和定性分析，明确揭示了全局对齐有效但不充分、迁移方向难度不对称以及负迁移可能出现等现象。
3. 提出了可靠性门控的类条件时序自适应方法 RCTA。该方法以强基线对齐分支为底座，引入 EMA 教师网络、弱强双视图时序增强、多因素可靠性评分、按类门控伪标签采纳、双原型记忆与课程化损失调度，以更稳定地利用目标域无标签样本。
4. 在四个关键单源场景上，RCTA 均取得最优目标域准确率。实验结果表明，RCTA 的平均目标域准确率达到 0.8590，相比 Source Only 平均提升 0.1884，相比逐场景最强基线平均进一步提升 0.0186，验证了所提方法的有效性。

1.5 论文结构安排

全文共分为六章，各章内容安排如下。

第一章为绪论，介绍研究背景、任务挑战、研究内容以及本文的技术路线。第二章为相关基础与文献综述，梳理流程工业故障诊断、领域自适应方法以及 TEP 跨工况迁移诊断的研究脉络。第三章为问题定义、数据集与实验设定，系统说明任务形式、数据组织、输入表示、统一骨干网络与模型选择策略。第四章为基线方法与实验结果分析，重点比较六种典型方法在四个关键单源场景上的表现，并总结主要实验现象。第五章为可靠性门控的类条件时序自适应方法设计与实验验证，重点阐述 RCTA 的架构创新、优化目标以及定量定性结果。第六章为总结与展望，对全文工作进行归纳，并讨论进一步向更复杂迁移场景与工程应用扩展的方向。

第二章 相关基础与文献综述

2.1 流程工业故障诊断方法概述

2.1.1 基于机理模型的方法

早期工业过程故障诊断较多依赖过程机理模型、专家知识和人工规则。典型思路包括基于守恒关系的残差生成、基于观测器的状态估计、故障树分析、专家规则库以及各种软测量模型。这类方法在对象机理明确、可建模性较强且工况变化范围有限的场景下具有较好的可解释性，能够直接将故障定位到设备、单元或控制回路层面。

不过，对于大型流程工业系统而言，机理模型方法也面临明显局限。一方面，实际工业过程往往具有强非线性、强耦合和多时间尺度特征，完整建立高精度机理模型并不容易；另一方面，设备磨损、原料波动和工况切换会不断改变系统实际行为，使纯机理模型难以长期保持高精度。因此，仅依赖机理模型或人工经验难以充分满足复杂工业现场对高鲁棒性故障诊断的需求。

2.1.2 基于机器学习的方法

随着工业信息化水平提高，基于历史运行数据进行状态监测与故障识别逐渐成为主流思路[1]。这一类方法通常通过特征提取、统计建模和分类学习，从大量过程变量中挖掘与故障相关的判别信息。主成分分析、偏最小二乘、动态 PCA、动态 PLS 等统计过程监测方法长期是流程工业故障检测中的重要工具；与此同时，支持向量机、近邻分类器、决策树和集成学习等浅层机器学习方法也被广泛用于故障分类任务。

与纯机理模型方法相比，这类方法对先验知识依赖较弱，在中小规模样本条件下通常具有较好的训练效率和一定的可解释性。不过，传统机器学习方法仍然高度依赖人工特征设计或较强的统计假设，对于复杂非线性过程和跨工况分布变化的适应能力有限。当源域与目标域之间存在明显分布偏移时，仅在固定特征空间内训练浅层判别器，往往难以保持稳定的目标域性能。

2.1.3 基于深度学习的方法

深度学习方法通过多层非线性变换自动学习故障相关表征，近年来已被广泛用于流程工业的状态识别、故障检测与诊断。卷积神经网络能够从多变量时序片段中学习局部动态模式，循环神经网络和时序注意力模型则擅长建模长时依赖关系。相较于手工构造统计特征，深度模型通常能够直接从原始或弱处理后的信号中提取更具判别性的高层特征。

然而，深度模型对样本规模和训练分布的一致性具有更强依赖。当训练集与测试集分布一致时，深度模型的优势更容易发挥；而当工况切换导致分布偏移时，深度模型也可能比浅层模型更明显地暴露出跨域泛化不足的问题。因此，将深度表示学习与领域自适应机制结合，是工业故障诊断研究中的自然发展方向。

对于流程工业场景，仅依赖单一工况下采集到的故障样本训练模型，难以覆盖真实生产中可能出现的工况变化。与通用视觉任务不同，工业过程数据具有时序性、强相关性和工况依赖性，诊断模型不仅需要识别类别间差异，还要对不同域之间的统计偏移保持鲁棒。因此，将迁移学习与领域自适应思想引入工业过程故障诊断，已经成为近年来值得关注的发展方向。

2.2 领域自适应理论基础

2.2.1 迁移学习与领域自适应定义

迁移学习旨在利用已有任务或已有域中的知识，提升目标任务或目标域上的学习效果。Pan 和 Yang 将迁移学习系统地定义为在源域和目标域分布或任务不同的情况下，通过知识迁移改善目标任务学习性能的过程[2]。当源域与目标域任务相同，但数据分布不同，即

$$\mathcal{Y}_s = \mathcal{Y}_t, \qquad P_s(x) \neq P_t(x), \tag{2.1}$$

就得到领域自适应问题。按照目标域是否具有标签，领域自适应可分为监督式、半监督式和无监督式等多种设置，本文重点关注目标域无标签的无监督领域自适应。

2.2.2 单源无监督领域自适应设定

本文采用的任务设定属于单源域到单目标域的无监督领域自适应。设源域样本集为

$$\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}, \tag{2.2}$$

目标域训练集为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}, \tag{2.3}$$

其中目标域训练阶段不使用标签。源域和目标域共享同一标签空间，但其样本分布不同。对于 TEP 多工况场景而言，不同运行模式可以自然对应不同领域，因此单源无监督领域自适应能够较好地刻画跨工况迁移诊断问题。

2.2.3 全局对齐与类条件对齐

现有无监督领域自适应方法大体可以分为三类。第一类是分布对齐方法，其核心思想是在保持源域分类能力的同时，缩小源域与目标域特征分布之间的差异。例如，CORAL 通过对齐协方差矩阵减小二阶统计差异[4]，DAN 则使用最大均值差异在核空间中逼近边缘分布对齐[5]。这类方法结构相对清晰，训练稳定性较好，因此常被作为流程工业场景中的基础对比方案。

第二类是对抗式领域自适应方法。DANN 在特征提取网络后引入域判别器，并利用梯度反转层实现特征学习与域判别之间的对抗博弈，从而促使提取到的特征具有域不变性[6]。CDAN 在此基础上进一步利用分类预测结果对特征进行条件化，使域判别过程能够感知类别结构信息，从而缓解单纯全局对抗对齐造成的类别混叠问题[7]。对抗式方法通常具有较强的适应能力和较高的性能上限，但训练稳定性和超参数敏感性也更值得关注。

第三类是基于最优传输的领域自适应方法。相关方法通过构造源域与目标域样本之间的运输代价，在分布层面直接寻找匹配关系。DeepJDOT 将特征空间距离与类别预测代价联合起来，在深度特征学习过程中同时优化分类目标与跨域样本匹配[8]。这类方法能够在全局层面显式建模跨域样本关系，但通常对批大小、代价尺度和计算效率较为敏感。

从方法机制上看，上述方法大多仍属于“全局边缘分布对齐”思路，即优先减少整体域差异；而对于多类别故障诊断任务，仅仅缩小全局域差异并不能保证跨域同类样本靠近、异类样本远离，这也使类条件对齐、伪标签学习、原型约束和一致性正则逐渐成为后续方法演化的重要方向。本文提出的 RCTA 也正是在这一脉络下展开设计。

2.3 TEP 数据集与跨工况迁移诊断研究

2.3.1 TEP 过程与故障诊断任务

Tennessee Eastman Process 是经典的化工过程仿真平台，包含多个相互耦合的单元操作和控制回路，能够模拟正常工况与多种故障情形[3]。由于过程结构较为完整、变量丰富、耦合复杂且具有较强代表性，TEP 长期被用于过程监测、故障检测和故障诊断算法的评估。与一般静态分类数据集相比，TEP 数据具有明显的动态特性和工业背景，更能体现方法在复杂过程系统中的实际适应能力。

2.3.2 TEP 领域自适应数据集简介

本文使用的并非普通的 TEP 单域分类数据，而是面向领域自适应任务构造的 TEP 扩展数据集。该数据集把不同操作模式组织为不同领域，其中 6 个运行模式可视为 6 个领域，标签空间为 29 类，即正常工况和 28 类故障。每个样本为长度为 600 的多变量时间窗口，包含 34 个过程变量通道；每个域同时提供样本标签和 5 折索引信息。这样的设置使得同一故障类别在不同工况下具有共享语义，但又呈现出明显不同的统计分布，从而能够自然构造跨工况的无监督领域自适应诊断任务。

2.3.3 多工况分布偏移与迁移诊断研究评述

在 TEP 多工况场景中，不同模式之间的负载水平、控制策略和过程动态存在差异，同一故障在不同模式下往往表现出不同的时序响应特征。这种跨工况分布偏移使得仅依赖单一工况训练的模型难以直接迁移到新工况，也使 TEP 成为研究工业过程迁移诊断的重要数据基础。已有研究普遍表明，统一任务定义、数据划分、归一化方式与骨干网络结构，对于公平比较不同领域自适应方法至关重要；同时，多工况迁移诊断也为观察类别混叠、分析对齐机理和提出改进方法提供了清晰背景。

2.4 本工作与现有研究的关系

综合上述文献，可以看到当前研究仍存在三个值得继续推进的方向。其一，流程工业领域自适应研究虽然逐渐增多，但不同工作在数据使用方式和实验协议上的差异较大，导致结果横向比较存在困难。其二，传统全局域对齐方法在工业多类别时序任务上虽有效，但对类别结构的利用通常不够充分。其三，类条件对齐和伪标签方法虽然具有潜力，但在噪声控制与训练稳定性方面仍需要更谨慎的设计。

本文的工作正是围绕上述三个方向展开：先建立统一实验基准，再在统一协议下比较典型方法，最后基于结果提出并实现 RCTA。与已有工作相比，本文更强调“可复现的统一实验脚手架”与“针对流程工业多类别时序任务的可靠性门控类条件迁移机制”这两条主线。

2.5 本章小结

本章从工业过程故障诊断、迁移学习与领域自适应方法以及 TEP 数据集与跨工况迁移诊断研究三个方面梳理了与本文课题密切相关的研究背景。可以看到，工业过程中的域偏移问题使得传统仅依赖同分布假设的诊断模型面临明显挑战，而分布对齐、对抗学习、

最优传输以及类条件迁移等方法为跨域故障诊断提供了可行思路。基于此，下一章将对本文采用的任务定义、数据组织方式和统一实验设定进行系统说明。

第三章 问题定义、数据集与实验设定

3.1 任务定义与符号说明

3.1.1 问题描述

本文研究的任务为单源域到单目标域的无监督领域自适应故障诊断。设源域训练样本为

$$\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}, \tag{3.1}$$

其中 x_i^s 为源域样本，$y_i^s \in \mathcal{Y}$ 为故障类别标签；目标域训练样本为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}, \tag{3.2}$$

其中目标域标签在训练阶段不可用。本文的目标是在利用源域有标签样本和目标域无标签样本的条件下，学习一个分类模型

$$f(x) = h(\phi(x)), \tag{3.3}$$

使其在目标域测试集上的风险尽可能小，其中 $\phi(\cdot)$ 表示特征提取器，$h(\cdot)$ 表示分类头。

若将目标域真实风险记为

$$R_t(f) = \mathbb{E}_{(x,y)\sim P_t(x,y)}[\ell(f(x), y)], \tag{3.4}$$

则无监督领域自适应的困难在于训练阶段无法直接最小化 $R_t(f)$。因此，实际训练通常采用

$$\mathcal{L} = \mathcal{L}_{cls}^s + \lambda \mathcal{L}_{adapt} + \mathcal{L}_{aux} \tag{3.5}$$

的形式，其中 $\mathcal{L}_{cls}^s$ 为源域监督分类损失，$\mathcal{L}_{adapt}$ 为领域对齐损失，$\mathcal{L}_{aux}$ 为伪标签、一致性、原型或其他辅助约束项。

3.1.2 域定义与符号约定

在本文实验设定中，不同 TEP 操作模式被视为不同领域，即

$$\mathcal{M} = \{\text{mode1}, \text{mode2}, \ldots, \text{mode6}\}. \tag{3.6}$$

源域与目标域共享相同的标签空间，

$$\mathcal{Y} = \{0, 1, \ldots, 28\}, \tag{3.7}$$

但样本分布并不一致。输入样本采用多变量过程时序片段表示，按照 channels-first 方式组织为 (N, C, T) 形状，其中 $C = 34$ 表示过程变量通道数，$T = 600$ 表示时间窗口长度，模

型输出为 29 类工况与故障类别的预测结果。

3.1.3 优化目标

从模型结构上看，本文采用编码器 ϕ 从输入时序样本中提取特征表示，再由分类器 h 输出故障类别预测，即

$$\hat{y} = \arg\max h(\phi(x)). \tag{3.8}$$

源域监督分类损失统一采用交叉熵形式：

$$\mathcal{L}_{cls}^{s} = -\frac{1}{n_s}\sum_{i=1}^{n_s}\sum_{k=1}^{K}\mathbf{1}[y_i^s = k]\log p_k(x_i^s), \tag{3.9}$$

其中 $K = 29$，$p_k(x)$ 为模型对第 k 类的预测概率。不同领域自适应方法在此基础上分别引入协方差对齐、MMD 对齐、域对抗损失、条件对抗损失或最优传输损失；本文提出的 RCTA 则进一步加入可靠伪标签、原型记忆和一致性约束。

3.2 数据集与域划分

3.2.1 TEP 领域自适应数据集

本文采用 Tennessee Eastman Process Domain Adaptation 数据集开展实验。该数据集面向跨工况迁移诊断任务构造，将 6 个操作模式视为 6 个不同领域，标签空间为 29 类，即正常工况和 28 类故障。与普通单域分类任务相比，该数据集更适合用于分析工业过程在工况切换条件下产生的分布偏移问题。

根据 manifest 文件，6 个域的样本规模与默认 Fold 1 划分情况如表 3.1 所示。可以看到，各域样本总量均接近 2900，默认采用 5 折中的 Fold 1 作为评估集时，训练样本量约为 2300，测试样本量约为 570。这样的规模既能够支撑本文的系统化单源比较，也保留了工业时序诊断任务的复杂性。

表 3.1 TEP 领域自适应数据集的域规模与默认 Fold 1 划分

域	样本总数	训练样本数	评估样本数	单样本形状	类别数
mode1	2900	2320	580	600×34	29
mode2	2845	2278	567	600×34	29
mode3	2899	2320	579	600×34	29
mode4	2865	2294	571	600×34	29
mode5	2883	2307	576	600×34	29
mode6	2897	2318	579	600×34	29

3.2.2 迁移任务构造

本文将不同运行模式之间的迁移任务表示为单源域到单目标域的无监督领域自适应场景。训练阶段仅使用源域标签和目标域无标签样本，测试阶段使用目标域标签进行性能评估。正文聚焦以下四个关键单源场景：

$$\text{mode2} \to \text{mode5}, \quad \text{mode3} \to \text{mode6}, \quad \text{mode5} \to \text{mode2}, \quad \text{mode6} \to \text{mode3}. \tag{3.10}$$

这四个场景覆盖了互逆迁移方向，既包含分布偏移显著的困难方向，也包含 Source Only 已具有一定可迁移性、但仍有改进空间的相对容易方向，因此能够较完整地反映方法在不同迁移难度下的表现。

3.3 输入表示与预处理策略

3.3.1 时序样本表示

数据集中的每个样本均表示为固定长度的多变量时间窗口，可形式化写为

$$x \in \mathbb{R}^{T \times C}, \tag{3.11}$$

其中 $T = 600$，$C = 34$。在进入神经网络前，数据被转置为 channels-first 形式：

$$x' = \text{Transpose}(x) \in \mathbb{R}^{C \times T}. \tag{3.12}$$

这种表示方式既保留了过程变量间的相关性，也保留了短时动态变化信息，适合由一维卷积网络沿时间维提取局部模式。所有方法均在相同输入形式下进行比较，以避免由于样本组织方式差异而引入额外干扰。

3.3.2 归一化与数据划分

为保证不同方法之间具有可比性，本文采用固定折划分区分训练样本与评估样本，并在域内执行标准化处理，以减小量纲差异对模型训练的影响。对任意一个域内通道 c，首先计算该域全体样本在该通道上的均值与标准差：

$$\mu_c = \frac{1}{NT} \sum_{n=1}^{N} \sum_{t=1}^{T} x_{n,t,c}, \qquad \sigma_c = \sqrt{\frac{1}{NT} \sum_{n=1}^{N} \sum_{t=1}^{T} (x_{n,t,c} - \mu_c)^2}, \tag{3.13}$$

随后执行标准化：

$$\tilde{x}_{n,t,c} = \frac{x_{n,t,c} - \mu_c}{\sigma_c + \varepsilon}. \tag{3.14}$$

当前采用的策略是 `normalization_scope=domain`，即对每个域分别基于该域全量样本统计量进行标准化，然后再按照 Fold 1 划分训练集与评估集。这一做法能够减小不同域

量纲差异对特征学习的干扰，使比较尽量聚焦于领域自适应机制本身。

3.4 共享骨干网络与训练脚手架

3.4.1 一维全卷积骨干网络

本文所有方法共享同一套一维全卷积网络（FCN）骨干，以降低骨干结构差异对实验结论的干扰。编码器由三层一维卷积构成，其计算过程可写为

$$z^{(1)} = \mathrm{ReLU}(\mathrm{IN}(\mathrm{Conv1D}_{9,128}(x'))), \tag{3.15}$$

$$z^{(2)} = \mathrm{ReLU}(\mathrm{IN}(\mathrm{Conv1D}_{5,256}(z^{(1)}))), \tag{3.16}$$

$$z^{(3)} = \mathrm{ReLU}(\mathrm{IN}(\mathrm{Conv1D}_{3,128}(z^{(2)}))), \tag{3.17}$$

其中卷积核长度依次为 9、5 和 3，输出通道数依次为 128、256 和 128，IN$(\cdot)$ 表示实例归一化。随后对时间维执行全局平均池化得到紧凑特征向量：

$$f = \frac{1}{T'} \sum_{t=1}^{T'} z_{:,t}^{(3)} \in \mathbb{R}^{128}. \tag{3.18}$$

分类头采用一层隐藏维度为 128 的全连接网络：

$$p(x) = \mathrm{softmax}(W_2\, \mathrm{ReLU}(W_1 f + b_1) + b_2). \tag{3.19}$$

该结构既保留了时序卷积对局部动态模式的提取能力，又避免了过于复杂的骨干网络给横向比较带来额外变量。

3.4.2 统一优化设置

在训练脚手架层面，本文统一采用 Adam 优化器，基础学习率设为 10^{-4}，权重衰减设为 0。六种基线方法的训练轮数设为 70，批大小设为 32；RCTA 为了容纳更长的伪标签与原型课程调度，将训练轮数扩展为 96。对于 CDAN 与 RCTA 等更敏感的方法，额外采用最大范数为 5.0 的梯度裁剪，以减小训练过程中的数值波动对收敛稳定性的影响。

3.5 统一实验设定

3.5.1 训练与评估协议

各方法采用一致的数据划分、共享骨干网络和统一的数据输入格式，并在相同任务设定下进行比较。训练阶段统一遵循“源域有标签、目标域无标签”的无监督领域自适应协议；评估阶段同时记录源域表现和目标域表现，以便分析模型是否存在“源域拟合较强但目标域迁移有限”的现象。

训练过程中，以源域训练集和目标域训练集进行参数更新；在每个 epoch 结束时，分别计算源域训练准确率、源域评估准确率、目标域测试准确率以及目标域训练集上的无标签代理指标。虽然目标域测试准确率在真实部署中不可见，但在离线研究阶段保留该指标有助于分析不同模型选择策略与最终性能之间的关系。

3.6 评价指标与模型选择

本文重点比较各方法的目标域诊断性能。评价指标主要包括目标域准确率、平衡准确率、混淆矩阵，以及反映域对齐程度和类别聚合情况的特征可视化结果。目标域准确率定义为

$$\mathrm{Acc}_t = \frac{1}{N_t^{eval}} \sum_{i=1}^{N_t^{eval}} \mathbf{1}[\hat{y}_i = y_i], \tag{3.20}$$

平衡准确率定义为

$$\mathrm{BA}_t = \frac{1}{K} \sum_{k=1}^{K} \frac{\mathrm{TP}_k}{\mathrm{TP}_k + \mathrm{FN}_k}, \tag{3.21}$$

其中 TP_k 和 FN_k 分别表示第 k 类的真正例和假负例数量。与普通准确率相比，平衡准确率能够更稳定地反映多类别任务下不同类别的平均识别水平。

考虑到无监督领域自适应缺少统一公认的目标域有标签验证标准，本文采用基于源域评估性能与目标域无标签代理信息的混合模型选择策略。对多数方法，默认采用

$$S_{\mathrm{hyb}} = w_s \cdot \mathrm{Acc}_s^{eval} - w_h \cdot \bar{H}_t, \tag{3.22}$$

其中 Acc_s^{eval} 为源域评估准确率，$\bar{H}_t$ 为目标域训练集上归一化预测熵的均值，

$$\bar{H}_t = \frac{1}{N_t} \sum_{j=1}^{N_t} \frac{-\sum_{k=1}^{K} p_{jk} \log p_{jk}}{\log K}. \tag{3.23}$$

在当前实现中，默认权重设为 $w_s = 0.7$、$w_h = 0.3$。该指标兼顾源域判别能力与目标域预测结构化程度，用于选择更稳健的 checkpoint。

对于 CDAN，由于条件对抗对齐在某些阶段可能出现“目标域置信度过早升高而域对齐尚未充分”的情况，额外采用熵保护型域间隙指标：

$$S_{\mathrm{cdan}} = \mathrm{Acc}_s^{eval} - \max(0, H_0 - \bar{H}_t) \cdot |A_d - 0.5|, \tag{3.24}$$

其中 H_0 为经验熵阈值，A_d 为域判别器准确率。该指标用于避免选择那些目标域过于自信但域混淆仍不充分的 checkpoint。

早停策略与模型选择策略保持一致。当前默认设置为：最少训练 20 个 epoch 后启动早

停，耐心轮数为 10，最小改进阈值为 0.002；而 RCTA 会根据课程式训练过程适度放宽耐心轮数，以保证后期辅助项有足够的发挥空间。

3.7 实验产物与复现性说明

为了保证结果核对、图表生成和论文撰写过程中的一致性，训练脚手架对每次运行均保存统一结构的产物，包括 checkpoint、结果表、运行评审摘要、混淆矩阵图、t-SNE 可视化图以及分析用中间特征。实验结果统一以 `result.json` 和 `review.json` 形式保存，便于批量汇总和交叉校验。通过这一设计，论文中的关键表格与图件能够直接追溯到实验工件，从而降低手工整理过程中的错误风险。

3.8 本章小结

本章围绕任务定义、数据集构成、输入表示、预处理方式、共享骨干网络、模型选择准则和统一实验协议，对后续实验的共同前提进行了说明。基于这些设定，下一章将对六种基线方法及其在四个关键单源场景上的结果展开分析。

第四章 基线方法与实验结果分析

4.1 基线方法说明

本章围绕六种基线方法展开比较，包括 Source Only、CORAL、DAN、DANN、CDAN 和 DeepJDOT。所有方法共享第三章介绍的 FCN 骨干网络，因此方法差异主要体现在损失函数与对齐机制上。

4.1.1 Source Only

Source Only 仅依赖源域监督分类损失训练模型，不显式处理源域与目标域之间的分布偏移，其优化目标可写为

$$\mathcal{L}_{SO} = \mathcal{L}_{cls}^{s}. \tag{4.1}$$

该方法可视为所有领域自适应方法的基础对照组。若某一领域自适应方法在目标域上不能显著优于 Source Only，则说明其对齐策略尚未真正缓解跨工况迁移带来的分布差异问题。

4.1.2 分布对齐方法

CORAL 通过约束源域与目标域特征协方差矩阵的一致性来减小二阶统计差异[4]。设源域与目标域特征分别为 $F_s \in \mathbb{R}^{n_s \times d}$ 和 $F_t \in \mathbb{R}^{n_t \times d}$，对应均值向量与协方差矩阵为 μ_s, μ_t, C_s, C_t，则 CORAL 损失为

$$\mathcal{L}_{coral} = \frac{\|C_s - C_t\|_F^2}{4d^2} + \|\mu_s - \mu_t\|_2^2. \tag{4.2}$$

总损失写为

$$\mathcal{L}_{CORAL} = \mathcal{L}_{cls}^{s} + \lambda_{coral}\mathcal{L}_{coral}. \tag{4.3}$$

DAN 使用多核最大均值差异（MK-MMD）约束源域与目标域特征分布，在核空间中实现更细致的边缘分布对齐[5]。给定核函数族 $\{k_u\}_{u=1}^{U}$，其损失可表示为

$$\mathcal{L}_{mmd} = \left\| \frac{1}{n_s}\sum_{i=1}^{n_s}\varphi(f_i^s) - \frac{1}{n_t}\sum_{j=1}^{n_t}\varphi(f_j^t) \right\|_{\mathcal{H}}^2, \tag{4.4}$$

实际实现中采用多个高斯核的加权和，于是总损失为

$$\mathcal{L}_{DAN} = \mathcal{L}_{cls}^{s} + \lambda_{mmd}\mathcal{L}_{mmd}. \tag{4.5}$$

这两类方法的共同特点是训练目标较为直接，通常能在不引入额外判别器的情况下稳定收敛，因此适合作为基础分布对齐参照。

4.1.3 对抗式方法

DANN 在共享特征提取网络之后加入域判别器，并利用梯度反转层实现特征表示与域分类之间的对抗学习，从而逼近域不变特征[6]。设域标签 $d=1$ 表示源域，$d=0$ 表示目标域，域判别器为 $D(\cdot)$，则对抗损失可写为

$$\mathcal{L}_{adv} = -\frac{1}{n_s}\sum_{i=1}^{n_s}\log D(f_i^s) - \frac{1}{n_t}\sum_{j=1}^{n_t}\log(1-D(f_j^t)). \tag{4.6}$$

在梯度反转层作用下，特征提取器朝着“混淆域判别器”的方向更新，因此总损失为

$$\mathcal{L}_{DANN} = \mathcal{L}_{cls}^s + \lambda_{adv}\mathcal{L}_{adv}. \tag{4.7}$$

CDAN 在 DANN 基础上进一步将类别预测结果纳入条件化对齐过程，使域判别器感知类别结构信息[7]。若记分类器输出概率为 $p(x)$，则 CDAN 对特征与类别预测进行联合映射：

$$g(x) = f(x) \otimes p(x), \tag{4.8}$$

其中 $\otimes$ 表示多线性组合。域判别器不再直接作用于 $f(x)$，而是作用于 $g(x)$。当前实现中还支持随机映射版本与熵加权机制，并可附加最小类混淆损失（MCC）：

$$\mathcal{L}_{CDAN} = \mathcal{L}_{cls}^s + \lambda_{cadv}\mathcal{L}_{cadv} + \lambda_{mcc}\mathcal{L}_{mcc}. \tag{4.9}$$

这两类方法分别代表了全局对抗对齐和条件对抗对齐两种典型思路。

4.1.4 最优传输方法

DeepJDOT 通过联合建模特征空间距离与类别预测差异，构建源域和目标域样本之间的运输代价，在深度特征学习过程中同时优化分类与跨域匹配[8]。设 γ 为源域与目标域样本间的运输矩阵，则其代价函数可写为

$$\mathcal{L}_{OT} = \min_{\gamma\in\Pi(a,b)}\sum_{i,j}\gamma_{ij}\left(\alpha\|f_i^s - f_j^t\|_2^2 + \beta\ell(y_i^s, p_j^t)\right), \tag{4.10}$$

其中 $\Pi(a,b)$ 表示满足边缘约束的运输计划集合，α 和 β 分别控制特征距离代价与分类代价的权重。于是总损失写为

$$\mathcal{L}_{DeepJDOT} = \mathcal{L}_{cls}^s + \lambda_{ot}\mathcal{L}_{OT}. \tag{4.11}$$

该方法能够提供样本级跨域关系约束，但也更容易受到批大小、代价尺度和计算开销的影响。

4.2 实验范围与比较协议

本章聚焦四个关键单源场景。具体而言，本文比较

$$\text{mode2} \to \text{mode5}, \quad \text{mode3} \to \text{mode6}, \quad \text{mode5} \to \text{mode2}, \quad \text{mode6} \to \text{mode3}$$

四个迁移方向上的结果。所有结果均来自第三章给出的统一实验协议，即共享 FCN 骨干、批大小 32、学习率 10^{-4}、固定 Fold 1 划分以及一致的模型选择规则。除方法本身的对齐机制外，其余训练流程尽量保持一致，以便将性能差异尽量归因于适应机制本身。

在超参数层面，DAN 的 MK-MMD 权重为 0.05，DANN 的对抗权重为 0.5，CDAN 的条件对抗权重为 0.2，DeepJDOT 的 OT 权重为 1.0。该设置与论文附录中的配置表保持一致。

4.3 实验结果与现象分析

4.3.1 四个关键单源场景上的总体结果

表 4.1 给出了 6 种基线方法在四个关键单源场景上的目标域结果。可以看到，所有领域自适应方法的平均目标域准确率均高于 Source Only，说明跨工况分布偏移确实需要通过显式对齐机制加以处理。就平均值而言，DANN 在基线方法中表现最好，平均目标域准确率达到 0.8329；DAN 紧随其后，达到 0.8118；CORAL、CDAN 和 DeepJDOT 也均优于 Source Only，但提升幅度和稳定性存在差异。

表 4.1 四个关键单源场景上的基线结果

方法	mode2→mode5	mode3→mode6	mode5→mode2	mode6→mode3	平均准确率	平均平衡准确率
Source Only	0.6094	0.7064	0.5203	0.8463	0.6706	0.6710
CORAL	0.6875	0.7962	0.6808	0.8359	0.7501	0.7515
DAN	0.8177	0.8187	0.8131	0.7979	0.8118	0.8103
DANN	0.8299	0.8566	0.7831	0.8618	0.8329	0.8317
CDAN	0.8177	0.8204	0.7478	0.7547	0.7852	0.7840
DeepJDOT	0.7135	0.7168	0.7072	0.7478	0.7213	0.7225

若以 Source Only 为参照，DANN 的平均增益达到 0.1623，DAN 的平均增益达到 0.1413，均明显高于 CORAL 和 DeepJDOT。进一步结合平均平衡准确率可以看到，DANN 与 DAN 不仅提升了整体准确率，也在类别层面带来了更均衡的收益。这说明在 TEP 多类别时序场景中，合适的全局分布对齐机制能够显著改善跨工况迁移表现。

4.3.2 分场景结果分析

从分场景角度看，不同迁移方向之间存在明显差异，这一点对后续方法设计具有直接启示。

1. mode2→mode5 场景 该场景中 Source Only 的目标域准确率仅为 0.6094，说明 mode2 与 mode5 之间存在较明显的分布偏移。DAN、DANN 和 CDAN 均将目标域准确率提升到 0.81 以上，其中 DANN 达到 0.8299，为基线最佳结果。这表明在该场景中，全局对抗对齐和核分布对齐都能够有效缓解跨域偏移。

2. mode3→mode6 场景 Source Only 已达到 0.7064，但 DANN 仍可进一步提升至 0.8566，提升幅度为 0.1503；DAN 和 CDAN 也均超过 0.818。该结果说明 mode3 与 mode6 虽然具有一定天然可迁移性，但通过显式对齐仍能获得显著收益。

3. mode5→mode2 场景 这是四个关键场景中最困难的方向之一，Source Only 仅为 0.5203。DAN 将目标域准确率提升到 0.8131，是本场景中最强基线；DANN 和 CDAN 分别达到 0.7831 和 0.7478。该现象说明同一对运行模式在互逆方向上的迁移难度并不对称，最优方法也可能发生变化。

4. mode6→mode3 场景 该场景中 Source Only 已经达到 0.8463，意味着 mode6 与 mode3 之间的天然差距相对较小。此时如果对齐策略过强，反而可能破坏已存在的有效判别结构。CORAL、DAN、CDAN 和 DeepJDOT 在该场景上均未优于 Source Only，仅 DANN 略微提升至 0.8618。这说明“域对齐越强越好”并不成立，对齐压力的控制同样重要。

4.3.3 主要现象归纳

结合表 4.1 和上述分场景分析，可以总结出以下三点。

1. **跨工况分布偏移是目标域性能下降的直接原因。** Source Only 在源域上通常能够获得较高准确率，但在目标域上的性能下降十分明显，尤其是在 mode5→mode2 这一困难方向上表现突出。
2. **全局对齐有效，但仍然存在边界。** DAN 和 DANN 表明，只要能够有效缩小源域与目标域整体分布差异，目标域性能就能获得显著提升；然而在 mode6→mode3 这类本身较易迁移的场景中，过强对齐仍可能带来负迁移。
3. **类别结构利用仍不充分。** CDAN 在理论上引入了条件信息，但在当前场景中的平均表现未能持续超越 DANN 与 DAN，这表明仅把类别预测接入域判别器仍不足以稳定解决多类别时序任务中的伪标签噪声与类混叠问题。

4.4 对改进方法设计的启示

基线结果表明，后续方法设计不能只回答“是否对齐”，还需要回答“如何在对齐的同时维持类别结构，并避免目标域噪声监督失控”。具体而言，至少需要满足以下三个要求：

1. 保留当前已经验证有效的强基线对齐能力，避免完全脱离已有经验重新设计；
2. 引入更直接的类条件结构约束，使跨域同类样本更容易聚合、异类样本更容易分离；
3. 对目标域伪标签进行可靠性控制，使无标签监督在训练早期不过度扰动分类边界，在训练后期又能逐步发挥作用。

第五章提出的 RCTA 正是围绕这三点展开：以强基线对齐分支为底座，通过教师–学生时序一致性、可靠性门控和双原型记忆，把全局域对齐与类条件结构学习结合起来。

4.5 本章小结

本章在统一 FCN 骨干网络和统一实验协议下，对 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 等基线方法进行了比较。结果表明，领域自适应方法整体上显著优于 Source Only，其中 DANN 的平均目标域表现最强，DAN 则展现出较好的跨场景稳定性。与此同时，基线实验也揭示出场景难度不对称、全局对齐不足以及类条件结构利用不稳定等问题，这为下一章提出 RCTA 提供了明确的问题背景。

第五章 可靠性门控的类条件时序自适应方法

5.1 方法设计动机

第四章的基线实验表明，现有领域自适应方法已经能够显著改善目标域性能，但仍存在三个关键缺口。第一，DANN 和 DAN 说明全局域对齐在 TEP 跨工况任务中确实有效，但这种“先缩小整体分布差异”的思路并不能显式保证跨域同类样本聚合、异类样本分离。第二，CDAN 虽然尝试引入条件信息，却仍然受到目标域伪标签噪声和训练不稳定性的影响，说明类别结构不能只通过域判别器间接建模。第三，在 mode6→mode3 这类 Source Only 已较强的场景中，若对齐压力控制不当，仍可能出现负迁移。

因此，改进方法需要同时回答三个问题：其一，如何保留强基线已经验证有效的全局对齐能力；其二，如何把类别结构显式注入目标域适应过程；其三，如何在目标域无标签条件下控制伪监督噪声的传播。围绕这三个问题，本文提出可靠性门控的类条件时序自适应方法（Reliability-Gated Class-Conditional Temporal Adaptation, RCTA）。

RCTA 的核心思想是：以强基线对齐分支为底座，通过教师–学生协同获得更平滑的目标域预测，再利用多因素可靠性评分和按类门控策略筛选可用伪标签，最后结合双原型记忆和类条件约束，把“域间靠拢”与“类内聚合、类间分离”两个目标统一到同一个训练闭环中。与只做全局对齐的方法相比，RCTA 更强调目标域无标签样本的选择质量；与直接使用伪标签的方法相比，RCTA 更强调利用原型结构和课程调度控制噪声累积。

5.2 方法总体框架

5.2.1 整体组成

设学生网络由编码器 $\phi(\cdot)$ 与分类器 $h(\cdot)$ 构成，教师网络由参数的指数滑动平均版本 $\phi_{\text{tea}}(\cdot)$ 和 $h_{\text{tea}}(\cdot)$ 构成。对于一个源域小批量

$$\mathcal{B}_s = \{(x_i^s, y_i^s)\}_{i=1}^{m_s} \tag{5.1}$$

和一个目标域小批量

$$\mathcal{B}_t = \{x_j^t\}_{j=1}^{m_t}, \tag{5.2}$$

RCTA 的一次训练迭代包含以下五个环节：

1. 源域样本经学生网络前向传播，计算监督分类损失与基础域对齐损失；
2. 目标域样本构造弱增强与强增强双视图，教师网络在弱增强视图上生成软伪标签，学

生网络在强增强视图上接受一致性约束；

3. 利用教师置信度、逆熵、强增强一致性与原型相似度构造可靠性分数，并按类别分别筛选高可靠目标样本；
4. 基于源域与目标域双原型记忆，对源域样本和高可靠目标样本施加原型吸引与原型分离约束；
5. 通过课程化权重调度联合优化各项损失，并以 EMA 方式更新教师网络参数。

5.2.2 总体优化目标

本文最终采用 DANN 作为 RCTA 的基础对齐分支。一方面，第四章已经表明 DANN 是平均表现最强的基线方法；另一方面，DANN 在 mode6→mode3 这类相对容易的场景中仍能保持正收益，更适合作为后续类条件增强的稳定底座。在此基础上，RCTA 的总损失写为

$$\mathcal{L}_{\text{RCTA}} = \mathcal{L}_{cls}^{s} + \lambda_{align}\mathcal{L}_{align} + \lambda_{mcc}\mathcal{L}_{mcc} + \lambda_{pl}(t)\mathcal{L}_{pl} + \lambda_{proto}(t)\mathcal{L}_{proto} + \lambda_{cons}(t)\mathcal{L}_{cons}, \quad (5.3)$$

其中 $\mathcal{L}_{cls}^{s}$ 为源域监督分类损失，$\mathcal{L}_{align}$ 为 DANN 对抗对齐损失，$\mathcal{L}_{mcc}$ 为最小类混淆正则[9]，$\mathcal{L}_{pl}$ 为目标域伪标签损失，$\mathcal{L}_{proto}$ 为原型约束，$\mathcal{L}_{cons}$ 为教师–学生一致性损失，$\lambda_{pl}(t)$、$\lambda_{proto}(t)$ 和 $\lambda_{cons}(t)$ 则通过训练步数 t 进行课程化调度。

其中，基础对齐项具体写为

$$\mathcal{L}_{align} = -\frac{1}{m_s}\sum_{i=1}^{m_s}\log D(f_i^s) - \frac{1}{m_t}\sum_{j=1}^{m_t}\log(1 - D(f_j^t)), \quad (5.4)$$

即由域判别器 $D(\cdot)$ 和梯度反转层共同构成的 DANN 对抗损失。与此同时，$\mathcal{L}_{mcc}$ 通过惩罚目标域预测矩阵中的类混淆项，进一步抑制高熵且边界不清晰的目标域输出，为后续伪标签学习提供更干净的预测分布。

这一目标函数的设计思路是清晰分工的：$\mathcal{L}_{align}$ 负责缩小源域与目标域整体分布差异，$\mathcal{L}_{pl}$ 和 $\mathcal{L}_{cons}$ 负责把目标域样本逐步引入训练闭环，$\mathcal{L}_{proto}$ 则显式塑造类条件几何结构。这样一来，模型不再只依赖单一的全局对齐信号，而是在多个层面协同约束特征空间。

5.3 教师网络与时序一致性学习

5.3.1 EMA 教师网络

为减轻目标域伪标签的瞬时波动，RCTA 不直接使用学生网络当前时刻的预测作为监督，而是引入教师网络生成更平滑的目标域概率分布[10]。教师参数通过学生参数的指数滑

动平均更新：

$$\theta_{\text{tea}} \leftarrow \mu\theta_{\text{tea}} + (1-\mu)\theta_{\text{stu}}, \tag{5.5}$$

其中 μ 为 EMA 衰减系数，本文采用的 aggressive 配置中取 $\mu = 0.99$。EMA 的作用可以理解为在参数空间做低通滤波，使教师输出对单步梯度扰动不那么敏感，因此更适合作为目标域伪标签来源。

对目标域样本 x_j^t，教师网络给出的软标签分布为

$$p_j^{tea} = \text{softmax}\left(\frac{h_{\text{tea}}(\phi_{\text{tea}}(\tilde{x}_{j,w}^t))}{T_{tea}}\right), \tag{5.6}$$

其中 T_{tea} 为教师温度参数，$\tilde{x}_{j,w}^t$ 为弱增强视图。相应的伪标签定义为

$$\hat{y}_j^t = \arg\max p_j^{tea}. \tag{5.7}$$

本文在 aggressive 配置中采用 $T_{tea} = 1.1$，既保留类别判别性，又避免温度过低造成的过度自信。

5.3.2 弱强双视图时序增强

RCTA 在目标域上采用保守的弱增强与相对困难的强增强[11]。设随机增强算子分别为 $\mathcal{A}_w$ 与 $\mathcal{A}_s$，则有

$$\tilde{x}_{j,w}^t = \mathcal{A}_w(x_j^t), \qquad \tilde{x}_{j,s}^t = \mathcal{A}_s(x_j^t). \tag{5.8}$$

其中弱增强主要包含轻微抖动与缩放，强增强进一步加入时间屏蔽和通道 dropout。这样的设计遵循“教师看清晰视图、学生学困难视图”的思路：教师在信息保留更多的弱增强视图上产生更稳定的软标签，学生则在受扰动更强的视图上学习鲁棒表示。

5.3.3 一致性损失

对目标域样本，学生网络在强增强视图上的输出记为 p_j^{stu}。一致性损失采用教师分布与学生分布之间的 KL 散度：

$$\mathcal{L}_{cons} = \frac{1}{m_t}\sum_{j=1}^{m_t} w_j^{cons}\, D_{KL}\big(p_j^{tea} \,\|\, p_j^{stu}\big), \tag{5.9}$$

其中 w_j^{cons} 为由可靠性得分导出的样本权重。当前实现中，一致性项仅对通过门控的样本施加显式约束，并对可靠性权重做幂次放大，从而把更多梯度预算分配给更可信的目标样本。

5.4 可靠性门控的伪标签学习

5.4.1 多因素可靠性评分

目标域伪标签是否可用，不能只由单一最大概率决定。为此，RCTA 对每个目标样本构造四个互补的可靠性分量：

$$q_j = \max p_j^{tea}, \tag{5.10}$$

$$e_j = 1 - \frac{-\sum_{k=1}^{K} p_{jk}^{tea} \log p_{jk}^{tea}}{\log K}, \tag{5.11}$$

$$u_j = p_{j,\hat{y}_j^t}^{stu}, \tag{5.12}$$

$$s_j = \frac{1 + \cos(f_j^{tea}, c_{\hat{y}_j^t}^{ref})}{2}, \tag{5.13}$$

其中 q_j 表示教师置信度，e_j 表示逆归一化熵，u_j 表示学生在强增强视图上对伪标签类别的响应强度，s_j 表示教师特征与参考原型之间的相似度。于是综合可靠性得分定义为

$$r_j = \omega_1 q_j + \omega_2 e_j + \omega_3 u_j + \omega_4 s_j, \qquad \sum_{m=1}^{4} \omega_m = 1. \tag{5.14}$$

在 aggressive 配置中，四个分量的原始权重依次设置为 1.6、0.9、1.2 和 1.4，并在实现中归一化后参与加权。

这样的设计具有明显的互补性。仅依赖最大概率，容易把“高置信但错误”的样本误认为可靠；仅依赖熵，难以区分边界附近的犹豫样本与真正混乱的样本；仅依赖原型相似度，又可能在原型尚未稳定时引入偏差。将四种信息联合起来，能够在“预测置信、分布尖锐度、增强一致性、结构匹配”四个维度上同时评估伪标签质量。

5.4.2 按类门控与课程调度

在获得可靠性得分之后，RCTA 并不让所有目标域样本都参与伪标签监督，而是引入分数下界和按类接受比例两个课程量。分数下界定义为

$$\tau(t) = \tau_{start} + (\tau_{end} - \tau_{start}) \cdot \min\left(\frac{t}{T_\tau}, 1\right), \tag{5.15}$$

按类接受比例定义为

$$\rho(t) = \rho_{start} + (\rho_{end} - \rho_{start}) \cdot \min\left(\frac{t}{T_\rho}, 1\right). \tag{5.16}$$

本文的 aggressive 配置中，$\tau(t)$ 从 0.24 线性增加到 0.58，$\rho(t)$ 从 0.30 线性增加到 0.92。这样做的目的在于：训练早期只保留少量高置信、高一致性的目标样本，避免噪声伪监督过早主导训练；训练后期再逐步扩大采纳范围，使更多目标域样本参与类条件适应。

与简单的全局阈值不同，RCTA 采用按预测类别分别筛选的策略。对每个预测类别 k，先保留满足 $r_j \geq \tau(t)$ 的样本，再在该类别内部选取得分前 $\lceil \rho(t) \cdot n_k \rceil$ 个样本进入门控集合 Ω_t。这种按类门控机制能够缓解类别不均衡带来的“头部类别占满伪标签预算”问题，更适合 29 类流程工业诊断任务。

5.4.3 可靠性加权伪标签损失

对于通过门控的目标样本，伪标签损失采用带可靠性加权的交叉熵[12]：

$$\mathcal{L}_{pl} = \frac{1}{|\Omega_t|} \sum_{j \in \Omega_t} \tilde{r}_j \, \ell_{ce}\big(h(\phi(\tilde{x}^t_{j,s})), \hat{y}^t_j\big) \,, \tag{5.17}$$

其中 $\tilde{r}_j$ 为经幂次变换后的可靠性权重，本文采用的幂指数为 1.6。这样一来，不同目标样本虽然都被接纳进入训练，但高可靠样本将对梯度更新产生更大的影响。

5.5 双原型记忆与类条件约束

5.5.1 源域与目标域原型记忆

为了显式建模类别结构，RCTA 为源域和目标域分别维护原型记忆库[13]。设学生网络在源域样本上的特征表示为

$$f^s_i = \phi(x^s_i). \tag{5.18}$$

对第 k 类样本，源域小批量原型定义为

$$\tilde{c}^s_k = \frac{1}{|\mathcal{B}^k_s|} \sum_{i: y^s_i = k} f^s_i, \tag{5.19}$$

并在实现中做单位化处理。跨批次的源域原型记忆采用动量更新：

$$c^s_k \leftarrow \mathrm{Norm}(\beta c^s_k + (1-\beta)\tilde{c}^s_k) \,, \tag{5.20}$$

其中 β 为原型动量系数，本文取 0.9。对于通过门控的目标域样本，也采用同样方式维护目标域原型 c^t_k。

在实际训练中，参考原型并非简单等于源域原型，而是综合当前源域小批量原型、源域记忆原型和目标域记忆原型构成，即

$$c^{ref}_k = \mathrm{Norm}\big(\alpha_1 \tilde{c}^s_k + \alpha_2 c^s_k + \alpha_3 c^t_k\big) \,, \tag{5.21}$$

其中权重由各类原型是否可用决定。这样做的好处是：源域原型提供稳定的类别锚点，目标域原型则逐步把目标域类结构纳入参考中心。

5.5.2 原型吸引与原型分离

在获得参考原型后，RCTA 同时对源域样本和高可靠目标样本施加原型吸引约束：

$$\mathcal{L}_{att} = \frac{1}{N}\sum_{i}\left(1-\cos(f_i, c_{y_i}^{ref})\right). \tag{5.22}$$

对于源域样本，标签 y_i 为真实标签；对于目标域样本，标签由门控后保留的伪标签给出。该损失的几何意义非常直观，即在归一化特征空间中把同类样本朝各自类别中心拉近。

仅有类内吸引还不够，为避免原型之间过度接近，进一步定义原型分离损失：

$$\mathcal{L}_{sep} = \frac{1}{|\mathcal{P}|}\sum_{(k,l)\in\mathcal{P}}\max\left(0, \cos(c_k^{ref}, c_l^{ref}) - m\right), \tag{5.23}$$

其中 $\mathcal{P}$ 表示所有有效类别原型对的集合，m 为分离边界。最终的原型约束写为

$$\mathcal{L}_{proto} = \mathcal{L}_{att}^{s} + \mathcal{L}_{att}^{t} + \lambda_{sep}\mathcal{L}_{sep}. \tag{5.24}$$

这样一来，特征空间不仅被要求“源域与目标域更接近”，还被要求“跨域同类更紧、异类更开”，这正是类条件结构学习相对于纯全局对齐的关键补充。

5.6 课程化优化策略

RCTA 的三项目标域辅助损失并不是同时、同权重地注入训练，而是按照训练步数逐步激活。若记任一辅助项的基础权重为 λ，开始步数为 t_0，预热长度为 Δt，则其课程化权重可统一写为

$$\lambda(t) = \begin{cases} 0, & t < t_0, \\ \lambda \cdot \min\left(\frac{t-t_0}{\Delta t}, 1\right), & t \geq t_0. \end{cases} \tag{5.25}$$

其中伪标签损失较早进入训练，一致性损失与其近似同步，原型损失则略晚启动，以避免在特征空间尚未稳定时过早冻结类别结构。

这一调度策略与前述门控机制相互配合，形成了一个“先搭底座、再引入目标域监督、最后强化类条件结构”的渐进式优化过程。训练早期主要由源域监督损失和基础对齐分支主导；中期随着可靠伪标签数量增加，目标域伪监督开始发挥作用；后期则通过原型约束进一步稳定类别边界。对于多类别流程工业时序任务而言，这种渐进式策略比一开始就施加强目标域约束更稳定。

5.7 四个关键单源场景上的实验验证

5.7.1 定量结果：四个场景均取得最优结果

表 5.1 给出了 RCTA 与 Source Only 以及逐场景最强基线的对比结果。可以看到，RCTA 在四个关键单源场景上均取得最高目标域准确率。若对四个场景求平均，RCTA 的平均目标域准确率达到 0.8590；逐场景最强基线的平均准确率为 0.8403；DANN 作为平均表现最强的单一基线方法，其平均准确率为 0.8329。由此可见，RCTA 相比 Source Only 平均提升 0.1884，相比逐场景最强基线平均进一步提升 0.0186，相比 DANN 平均提升 0.0261。

表 5.1 RCTA 与 Source Only 及逐场景最强基线的比较

场景	Source Only	最强基线	RCTA	相对 Source Only 增益	相对最强基线增益
mode2→mode5	0.6094	0.8299 (DANN)	0.8542	+0.2448	+0.0243
mode3→mode6	0.7064	0.8566 (DANN)	0.8756	+0.1693	+0.0190
mode5→mode2	0.5203	0.8131 (DAN)	0.8183	+0.2981	+0.0053
mode6→mode3	0.8463	0.8618 (DANN)	0.8877	+0.0415	+0.0259

从不同场景的收益结构可以进一步看出 RCTA 的特点。对于 mode5→mode2 这类困难方向，RCTA 在最强基线之上仍有 0.0053 的额外提升，相对 Source Only 的绝对收益更是达到 0.2981，说明可靠性门控与类条件结构对困难迁移方向尤为重要。对于 mode6→mode3 这类 Source Only 已较强的方向，RCTA 仍能在不过度破坏原有判别边界的前提下，相对 DANN 再提升 0.0259，说明该方法并不是通过加大对齐压力“硬推”目标域性能，而是在结构层面做出了更细致的修正。

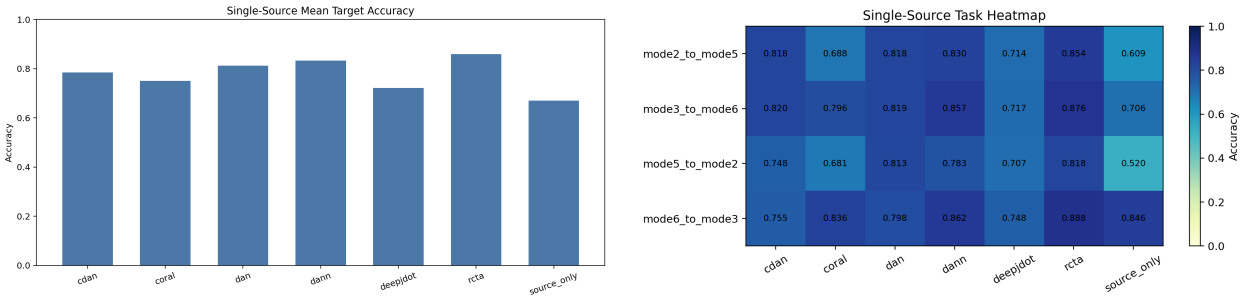

(a) 四个关键单源场景上的方法平均目标域准确率　　(b) 各方法在四个关键场景上的目标域准确率热力图

图 5-1 四个关键单源场景上的整体对比结果

图 5-1 进一步从整体视角展示了不同方法的性能格局。图 5-1(a) 表明，RCTA 在平均目标域准确率上位居第一；图 5-1(b) 则显示 RCTA 在四个关键场景上均位于最优位置，没有通过牺牲某一场景来换取整体平均值。这一点对于工业诊断任务尤为重要，因为实际部署更关心方法能否在不同迁移方向上保持稳定收益，而非只在少数场景上取得高峰值。

5.7.2 定性结果：代表性场景分析

为了进一步说明 RCTA 的作用机制，本文选取 mode2→mode5 这一具有代表性的单源场景进行定性分析。该场景中 Source Only 的目标域准确率仅为 0.6094，而 RCTA 达到 0.8542，具有较为明显的改进幅度，适合观察特征结构和误分类模式的变化。

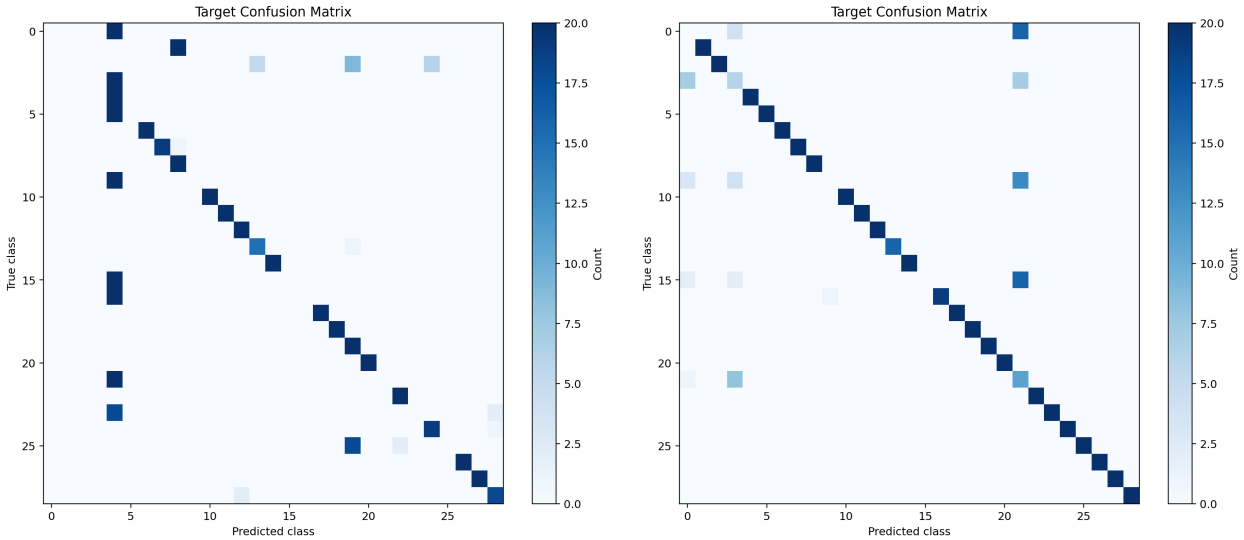

(a) Source Only　　(b) RCTA

图 5-2 mode2→mode5 场景下 Source Only 与 RCTA 的混淆矩阵对比

从图 5-2 可以看到，Source Only 的混淆矩阵中存在较多偏离主对角线的误判块，说明在跨域条件下多个类别的判别边界出现明显混叠；而 RCTA 的主对角线更加连续、非对角区域的误判分布明显收缩，说明可靠性门控和原型约束确实有助于增强目标域类别可分性。

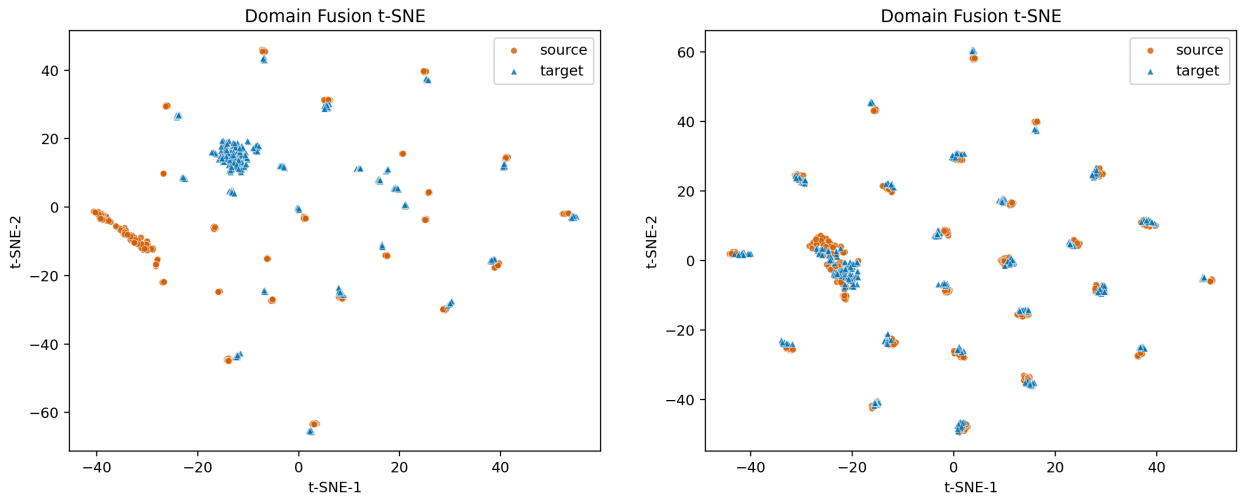

(a) Source Only　　(b) RCTA

图 5-3 mode2→mode5 场景下 Source Only 与 RCTA 的域分布 t-SNE 对比

图 5-3 展示了同一场景下的域分布 t-SNE。相比 Source Only，RCTA 学到的特征空间中，源域与目标域样本在若干主簇上混合得更加充分，但又没有出现整体塌缩成单一团块的现象。这说明 RCTA 并不是简单地把两个域强行压在一起，而是在保持类间结构的同时改善跨域重叠关系。这一现象与前文的设计目标相吻合：基础对齐分支负责减小整体域差异，可靠性门控与原型约束则负责维持类条件结构。

5.7.3 RCTA 架构创新的作用分析

结合方法设计与实验结果，RCTA 的主要优势可以概括为以下三点。

1. **在强基线之上做结构增强。**RCTA 并没有舍弃 DANN 已经证明有效的全局对齐能力，而是在其基础上加入类条件结构建模，因此能够兼顾整体域适应与类别几何约束。
2. **把目标域监督建立在可靠样本之上。**EMA 教师、弱强双视图和按类门控共同控制了伪标签质量，使目标域样本的引入更加循序渐进，降低了错误伪标签在训练早期放大传播的风险。
3. **把类条件信息从“隐式利用”变为“显式建模”。**双原型记忆、原型吸引与原型分离使模型在特征空间中显式维护类别中心和类别边界，从而弥补纯全局对齐难以稳定处理多类别流程工业时序任务的不足。

此外，RCTA 在四个关键场景上的平均源域评估准确率达到 0.9001，平均目标域平衡准确率达到 0.8594，说明其目标域收益并非通过牺牲源域判别能力换取，而是在保持源域保真度的同时提升了目标域可迁移性。这进一步说明，所提方法学到的是更具跨域共享性的判别表示，而不是单纯依赖目标域偏移某一侧的偶然收益。

5.8 本章小结

本章提出了可靠性门控的类条件时序自适应方法 RCTA，并围绕其设计动机、总体框架、教师–学生协同、可靠性门控、双原型记忆以及课程化优化策略进行了系统阐述。实验结果表明，RCTA 在四个关键单源场景上均取得最优结果，平均目标域准确率达到 0.8590；代表性场景的混淆矩阵和 t-SNE 可视化进一步说明，该方法能够在改善域间重叠的同时保持更清晰的类别结构。由此可见，围绕可靠性门控和类条件原型展开的架构创新，对于流程工业跨工况无监督领域自适应故障诊断是有效的。

第六章 总结与展望

6.1 全文工作总结

本文围绕流程工业场景下的领域自适应故障诊断问题，面向 Tennessee Eastman Process Domain Adaptation 数据集，完成了从任务建模、统一实验框架构建、典型基线比较到改进方法设计与验证的一系列工作。全文首先对跨工况故障诊断问题进行了任务化表述，明确了单源到单目标无监督领域自适应的研究边界；随后构建了 manifest 驱动的数据组织方式、统一的 FCN 骨干网络、统一的优化配置和结构化结果产物；在此基础上，对 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 等典型方法开展了系统比较；最后提出并实现了可靠性门控的类条件时序自适应方法 RCTA，并在四个关键单源场景上取得了优于基线的方法性能。

6.2 主要结论

本文的主要结论可概括为以下四点。

1. TEP 多工况故障诊断可以被清晰表述为单源到单目标的无监督领域自适应问题，并能够在统一数据划分、统一骨干网络和统一模型选择准则下开展可复现比较。
2. 在四个关键单源场景上，领域自适应方法整体显著优于 Source Only，说明跨工况分布偏移确实需要显式对齐机制加以缓解。其中，DANN 的平均目标域准确率最高，达到 0.8329；DAN 的平均表现为 0.8118，并展现出较好的跨场景稳定性。
3. 基线结果表明，单纯依赖全局域对齐并不能彻底解决多类别流程工业时序任务中的类别混叠与场景敏感问题。特别是在 Source Only 已较强的场景中，若对齐压力控制不当，仍可能发生负迁移。
4. 本文提出的 RCTA 方法能够在保留强基线对齐能力的基础上，进一步利用 EMA 教师、可靠性门控伪标签、双原型记忆和一致性约束提升跨域同类聚合能力。实验结果显示，RCTA 在四个关键单源场景上均取得最优结果，平均目标域准确率达到 0.8590，相比 Source Only 平均提升 0.1884，相比逐场景最强基线平均再提升 0.0186。

6.3 不足与未来展望

尽管本文已经在单源到单目标跨工况诊断场景上形成了较完整的研究链路，但仍存在若干值得进一步完善之处。

1. 本文正文聚焦四个关键单源场景，尚未对更大范围的迁移对进行系统统计，因此对

于不同工况组合下方法收益边界的认识仍可继续拓展。

2. RCTA 的有效性已经得到整体结果支持，但严格意义上的模块消融、参数敏感性分析和统计显著性检验仍需补充，以进一步明确各个模块的独立贡献与相互作用。
3. 当前分析主要集中在离线无监督领域自适应设置，对更复杂迁移场景、在线适应、持续诊断以及工程部署约束等问题尚未展开深入研究。

围绕上述不足，后续工作可以从以下几个方向继续推进：其一，扩展到更多迁移方向和更复杂场景，系统考察 RCTA 在更广泛工业诊断任务中的稳定性；其二，围绕可靠性门控、双原型记忆、一致性正则和基础对齐分支开展严格消融实验，进一步厘清方法机制；其三，引入更丰富的可解释性分析，如类别级误差分解、原型演化轨迹和伪标签质量统计，以增强方法分析深度；其四，探索与工业先验知识、在线更新机制和轻量化部署约束结合的混合方法，为后续工程应用奠定基础。

6.4 本章小结

总体来看，本文已经围绕 TEP 跨工况故障诊断任务形成了一条较完整且逻辑清晰的研究路线：先建立统一比较框架，再通过基线实验定位问题，最后提出并验证 RCTA 这一改进方法。现有结果表明，围绕可靠性门控和类条件结构展开的方法设计，能够有效提升流程工业无监督领域自适应故障诊断的目标域性能，并为后续向更复杂工业场景扩展提供了扎实基础。

参考文献

[1] QIN S J. Survey on data-driven industrial process monitoring and diagnosis[J/OL]. Annual Reviews in Control, 2012, 36(2): 220-234. DOI: 10.1016/j.arcontrol.2012.09.004.

[2] PAN S J, YANG Q. A survey on transfer learning[J/OL]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359. DOI: 10.1109/TKDE.2009.191.

[3] DOWNS J J, VOGEL E F. A plant-wide industrial process control problem[J/OL]. Computers & Chemical Engineering, 1993, 17(3): 245-255. DOI: 10.1016/0098-1354(93)80018-I.

[4] SUN B, SAENKO K. Deep CORAL: Correlation alignment for deep domain adaptation[C/OL]//Lecture Notes in Computer Science: volume 9915 Computer Vision – ECCV 2016 Workshops. Cham: Springer International Publishing, 2016: 443-450. DOI: 10.1007/978-3-319-49409-8_35.

[5] LONG M, CAO Y, WANG J, et al. Learning transferable features with deep adaptation networks[C/OL]// Proceedings of Machine Learning Research: volume 37 Proceedings of the 32nd International Conference on Machine Learning. Lille, France: PMLR, 2015: 97-105. https://proceedings.mlr.press/v37/long15.html.

[6] GANIN Y, USTINOVA E, AJAKAN H, et al. Domain-adversarial training of neural networks[J/OL]. Journal of Machine Learning Research, 2016, 17(59): 1-35. https://jmlr.org/papers/v17/15-239.html.

[7] LONG M, CAO Z, WANG J, et al. Conditional adversarial domain adaptation[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 31. Curran Associates, Inc., 2018: 1647-1657. https://proceedings.neurips.cc/paper/2018/hash/ab88b15733f543179858600245108dd8-Abstract.html.

[8] DAMODARAN B B, KELLENBERGER B, FLAMARY R, et al. DeepJDOT: Deep joint distribution optimal transport for unsupervised domain adaptation[C/OL]//Lecture Notes in Computer Science: volume 11208 Computer Vision – ECCV 2018. Cham: Springer International Publishing, 2018: 467-483. https://openaccess.thecvf.com/content_ECCV_2018/html/Bharath_Bhushan_Damodaran_DeepJDOT_Deep_Joint_ECCV_2018_paper.html. DOI: 10.1007/978-3-030-01225-0_28.

[9] JIN Y, WANG X, LONG M, et al. Minimum class confusion for versatile domain adaptation[C/OL]// Lecture Notes in Computer Science: volume 12366 Computer Vision – ECCV 2020. Cham: Springer International Publishing, 2020: 464-480. DOI: 10.1007/978-3-030-58589-1_28.

[10] TARVAINEN A, VALPOLA H. Mean teachers are better role models: Weight-averaged consistency tar-

gets improve semi-supervised deep learning results[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 30. Curran Associates, Inc., 2017: 1195-1204. https://proceedings.neurips.cc/paper/2017/hash/68053af2923e00204c3ca7c6a3150cf7-Abstract.html.

[11] XIE Q, DAI Z, HOVY E, et al. Unsupervised data augmentation for consistency training[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 33. Curran Associates, Inc., 2020: 6256-6268. https://proceedings.neurips.cc/paper_files/paper/2020/file/44feb0096faa8326192570788b38c1d1-Paper.pdf.

[12] LEE D H. Pseudo-Label: The simple and efficient semi-supervised learning method for deep neural networks[C/OL]//ICML 2013 Workshop: Challenges in Representation Learning (WREPL). Atlanta, Georgia, USA, 2013. https://storage.googleapis.com/kaggle-forum-message-attachments/8924/pseudo_label_final.pdf.

[13] TANWISUTH K, FAN X, ZHENG H, et al. A prototype-oriented framework for unsupervised domain adaptation[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 34. Curran Associates, Inc., 2021: 17194-17208. https://proceedings.neurips.cc/paper/2021/hash/8edd72158ccd2a879f79cb2538568fdc-Abstract.html.

附录 A 实验补充材料

A.1 附录说明

本附录给出正文之外的补充材料，包括关键超参数表、RCTA aggressive 配置摘要以及四个关键单源场景的完整结果。所有内容均服务于本文正文聚焦的单源到单目标跨工况诊断任务。

A.2 基线方法关键超参数

表 1.1 给出了本文 6 种基线方法在 aggressive 配置下采用的关键超参数。这些配置由 `configs/method/*.yaml` 与实验覆盖项共同确定。

表 1.1 基线方法关键超参数

方法	epochs	batch size	学习率	关键对齐参数
Source Only	70	32	1×10^{-4}	无显式对齐项
CORAL	70	32	1×10^{-4}	$\lambda_{coral} = 0.5$，warm-start
DAN	70	32	1×10^{-4}	$\lambda_{mmd} = 0.05$，5 组高斯核尺度
DANN	70	32	1×10^{-4}	$\lambda_{adv} = 0.5$，GRL warm-start，判别器 256×2
CDAN	70	32	1×10^{-4}	$\lambda_{cadv} = 0.2$，randomized dim=256，熵保护选择指标
DeepJDOT	70	32	1×10^{-4}	$\lambda_{ot} = 1.0$，$\alpha = 0.1$，$\beta = 1.0$

A.3 RCTA aggressive 配置摘要

表 1.2 汇总了本文单源四场景中采用的 RCTA aggressive 配置。该配置以 DANN 为基础对齐分支，同时融合 MCC 正则、可靠性门控、双原型记忆与一致性学习。

表 1.2 RCTA aggressive 配置摘要

模块	配置
训练轮数	96
基础对齐分支	DANN
MCC 正则	$\lambda_{mcc} = 0.1$，temperature=2.0
教师网络	EMA decay=0.99，teacher temperature=1.1
可靠性权重	cal_conf=1.6，inv_entropy=0.9，consistency=1.2，proto_sim=1.4
分数下界课程	0.24 → 0.58，持续 2400 steps
按类接受比例课程	0.30 → 0.92，持续 2400 steps
伪标签损失	最大权重 0.42，warmup 500 steps，可靠性加权，power=1.6
原型损失	最大权重 0.08，start step=700，warmup 1000 steps
一致性损失	最大权重 0.12，start step=500，warmup 1000 steps
一致性门控	仅对 gate 内样本启用，reliability power=1.8
数据增强	弱增强：轻微抖动/缩放；强增强：抖动、缩放、时间屏蔽、通道 dropout

A.4 四个关键单源场景的完整结果

表 1.3 给出了本文四个关键单源场景的完整结果，包括源域训练准确率、源域评估准确率、目标域准确率、目标域平衡准确率和最终选择 epoch。该表可作为正文统计结果的完整支撑材料。

表 1.3 四个关键单源场景的完整结果

方法	场景	源域训练准确率	源域评估准确率	目标域准确率	目标域平衡准确率	选择 epoch
Source Only	mode2→mode5	0.8845	0.8889	0.6094	0.6116	70
CORAL	mode2→mode5	0.8661	0.8571	0.6875	0.6871	69
DAN	mode2→mode5	0.8494	0.8536	0.8177	0.8190	68
DANN	mode2→mode5	0.8525	0.8519	0.8299	0.8310	69
CDAN	mode2→mode5	0.8661	0.8713	0.8177	0.8190	70
DeepJDOT	mode2→mode5	0.7853	0.7813	0.7135	0.7155	65
RCTA	mode2→mode5	0.8990	0.9048	0.8542	0.8552	94
Source Only	mode3→mode6	0.8759	0.8774	0.7064	0.7069	68
CORAL	mode3→mode6	0.8849	0.8774	0.7962	0.7966	65
DAN	mode3→mode6	0.8853	0.8843	0.8187	0.8190	59
DANN	mode3→mode6	0.8772	0.8705	0.8566	0.8569	69
CDAN	mode3→mode6	0.8681	0.8756	0.8204	0.8207	62
DeepJDOT	mode3→mode6	0.8203	0.8117	0.7168	0.7172	70
RCTA	mode3→mode6	0.9060	0.9102	0.8756	0.8759	96
Source Only	mode5→mode2	0.8691	0.8767	0.5203	0.5190	69
CORAL	mode5→mode2	0.8427	0.8403	0.6808	0.6862	66
DAN	mode5→mode2	0.8704	0.8663	0.8131	0.8052	67
DANN	mode5→mode2	0.8435	0.8472	0.7831	0.7766	66
CDAN	mode5→mode2	0.8721	0.8750	0.7478	0.7414	68
DeepJDOT	mode5→mode2	0.7811	0.7812	0.7072	0.7091	70
RCTA	mode5→mode2	0.9142	0.8872	0.8183	0.8184	96
Source Only	mode6→mode3	0.8654	0.8687	0.8463	0.8465	69
CORAL	mode6→mode3	0.8624	0.8618	0.8359	0.8362	68
DAN	mode6→mode3	0.8382	0.8342	0.7979	0.7983	70
DANN	mode6→mode3	0.8619	0.8618	0.8618	0.8621	70
CDAN	mode6→mode3	0.7934	0.7927	0.7547	0.7550	36
DeepJDOT	mode6→mode3	0.7994	0.7720	0.7478	0.7481	70
RCTA	mode6→mode3	0.9025	0.8981	0.8877	0.8879	95

A.5 补充说明

正文中的汇总图由四个关键单源场景的比较结果自动生成，代表性定性图则选取自 mode2→mode5 场景。之所以选择该场景，一方面是因为其相对 Source Only 的改进幅度较大，另一方面也因为该场景中 Source Only 与 RCTA 的结构差异更容易从混淆矩阵和 t-SNE 图中观察到。

致　　谢

值此本科毕业论文完成之际，谨向在大学期间关心、指导和帮助过我的老师、学长、同学及家人致以诚挚的感谢。

首先，衷心感谢指导教师王永健教授，在毕业设计选题、研究思路梳理、实验推进和论文撰写过程中给予了我耐心细致的指导与帮助，使我得以顺利完成本论文的研究工作；同时，在个人发展与后续规划等方面给予我的支持与鼓励，也使我深受感激；严谨认真的治学态度和认真负责的工作作风，使我受益匪浅。

其次，感谢蒋徐颢、蔡闻骁、邹滨阳等学长和同学榜样在学习与成长过程中给予我的帮助与示范。他们在专业学习、科研视野和个人规划方面的经验分享，对我产生了积极而深远的影响。

感谢严震霆、周志铭、曲振宁等同学和朋友在本科阶段给予我的陪伴、支持与鼓励。在课题讨论、日常学习和生活交流中，他们给予了我许多真诚的帮助，使我能够更加从容地面对学习和毕业设计过程中的困难与挑战。

最后，衷心感谢我的父母和家人。感谢他们一直以来给予我的理解、包容和支持，使我能够安心完成本科阶段的学习任务与毕业论文工作。