本科毕业设计（论文）报告

题 目：基于领域自适应的工业过程故障诊断方法研究

学　　号：08022311

姓　　名：陈鲲龙

学　　院：自动化

专　　业：自动化

指导教师：王永健、童国道

起止日期：2026 年 3 月 ~2026 年 6 月

东南大学毕业（设计）论文独创性声明

本人声明所呈交的毕业（设计）论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签名：_____　　日期：__2026__年__6__月_____日

东南大学毕业（设计）论文使用授权声明

东南大学有权保留本人所送交毕业（设计）论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括刊登）论文的全部或部分内容。论文的公布（包括刊登）授权东南大学教务处办理。

论文作者签名：_____　　导师签名：_____

日期：__2026__年__6__月_____日　　日期：__2026__年__6__月_____日

摘　　要

工业过程故障诊断对于保障生产安全、降低非计划停机损失和提升过程运行可靠性具有重要意义。然而，流程工业在不同操作条件、负载水平和运行阶段下常伴随明显的分布偏移，使得仅利用源域标注数据训练得到的模型在目标域上的诊断性能显著下降。围绕这一问题，本文以 Tennessee Eastman Process Domain Adaptation 数据集为研究对象，研究单源到单目标的无监督领域自适应故障诊断，并在统一实验设定下比较不同领域自适应方法。

本文在统一的一维卷积骨干网络下，对 Source Only、CORAL、DAN、DANN、CDAN 和 DeepJDOT 等代表性方法进行了系统比较。针对流程工业多变量时序信号的特点，本文统一了域划分方式、样本表示、归一化策略、训练协议、模型选择准则和评价指标，并采用准确率、平衡准确率、混淆矩阵与特征可视化等方式开展分析。六组代表性单源场景及部分多源场景结果表明，相较于 Source Only，分布对齐和对抗式方法在目标域上普遍能够取得明显提升，其中 DAN 与 DANN 的平均表现较优，但不同场景间仍存在稳定性差异和类别混叠现象。

在基线分析基础上，本文进一步提出一种可靠性门控的类条件时序自适应思路，通过结合教师网络伪标签、可靠性筛选、类别原型约束与一致性正则，增强跨域同类聚合能力并抑制噪声伪标签带来的负迁移影响。尽管全量场景统计和改进方法实验结果仍有待补充，本文已经完成了论文整体结构、实验基线与改进方法设计，并形成了较为清晰的流程工业领域自适应故障诊断研究主线。

关键词：故障诊断，领域自适应，TEP，无监督领域自适应

ABSTRACT

Industrial fault diagnosis is important for production safety, reduction of unplanned downtime, and reliable process operation. However, process data collected under different operating modes, load levels, or time periods usually exhibit evident distribution shifts, so a model trained only with labeled source-domain data often generalizes poorly to a target domain. To address this issue, this thesis studies single-source to single-target unsupervised domain adaptation for fault diagnosis on the Tennessee Eastman Process Domain Adaptation dataset and compares representative adaptation methods under a unified experimental protocol.

Under a unified one-dimensional convolutional backbone, six representative methods are compared: Source Only, CORAL, DAN, DANN, CDAN, and DeepJDOT. To make the comparison consistent and reproducible, this work uses a common setting for domain partition, input representation, normalization, training protocol, model selection, and evaluation, together with accuracy, balanced accuracy, confusion matrices, and feature visualization.

Results on six representative single-source scenarios together with part of the multi-source settings show that, compared with the Source Only baseline, distribution-alignment and adversarial methods generally improve target-domain accuracy, while DAN and DANN achieve stronger average performance among the completed scenes. The experiments also reveal remaining issues such as scenario sensitivity, class confusion, and unstable conditional alignment.

Based on these observations, the thesis further develops a reliability-gated class-conditional temporal adaptation strategy. It combines teacher-generated pseudo labels, reliability screening, prototype-based constraints, and consistency regularization to improve cross-domain intra-class compactness while reducing the effect of noisy target supervision. Although full-scenario statistics and final validation still need to be added, the current draft already establishes a clear comparative baseline and a concrete method-design direction.

KEY WORDS: Fault Diagnosis, Domain Adaptation, TEP, Unsupervised Domain Adaptation

目　　录

摘　　要 I
ABSTRACT II
目　　录 III
第一章　绪论 1
1.1 研究背景与意义 1
1.2 研究问题与研究目标 1
1.3 研究内容与技术路线 2
1.3.1 研究内容 2
1.3.2 技术路线 2
1.4 论文结构安排 2
第二章　相关基础与文献综述 4
2.1 流程工业故障诊断方法概述 4
2.1.1 基于机理模型的方法 4
2.1.2 基于机器学习的方法 4
2.1.3 基于深度学习的方法 4
2.2 领域自适应理论基础 5
2.2.1 迁移学习与领域自适应定义 5
2.2.2 单源无监督领域自适应设定 5
2.2.3 全局对齐与类条件对齐 5
2.3 TEP 数据集与跨工况迁移诊断研究 6
2.3.1 TEP 过程与故障诊断任务 6
2.3.2 TEP 领域自适应数据集简介 6
2.3.3 多工况分布偏移与迁移诊断研究评述 6
2.4 本章小结 7
第三章　问题定义、数据集与实验设定 8
3.1 任务定义与符号说明 8
3.1.1 问题描述 8

3.1.2 域定义与符号约定 8
3.1.3 优化目标 8
3.2 数据集与域划分 8
3.2.1 TEP 领域自适应数据集 8
3.2.2 迁移任务构造 8
3.3 输入表示与预处理策略 9
3.3.1 时序样本表示 9
3.3.2 归一化与数据划分 9
3.4 统一实验设定 9
3.4.1 共享骨干网络与对比方法 9
3.4.2 训练与评估协议 9
3.5 评价指标与模型选择 9
3.6 本章小结 10
第四章 基线方法与实验结果分析 11
4.1 实验设置 11
4.2 共享骨干网络与 Source Only 基线 11
4.3 对比方法 11
4.3.1 分布对齐方法 11
4.3.2 对抗式方法 12
4.3.3 最优传输方法 12
4.4 实验结果与现象分析 12
4.4.1 代表性单源场景的总体结果 12
4.4.2 分场景结果分析 13
4.5 讨论与方法启示 13
4.5.1 当前结果揭示的主要问题 13
4.5.2 对第五章方法设计的启示 13
4.6 本章小结 14
第五章 可靠性门控的类条件时序自适应方法设计 15
5.1 方法设计动机 15

5.2 方法总体框架 15
5.3 类别原型建模 16
5.4 目标域可靠伪标签筛选 16
5.5 类条件对齐与一致性约束 17
5.5.1 原型吸引损失 17
5.5.2 原型分离约束 17
5.5.3 一致性监督项 17
5.6 整体优化目标与训练策略 17
5.7 实验验证方案 18
5.7.1 与基线方法的总体比较 18
5.7.2 消融实验设计 18
5.7.3 重点分析指标 18
5.8 本章小结 19
第六章 总结与展望 20
6.1 全文工作总结 20
6.2 主要结论 20
6.3 不足与未来展望 20
参考文献 21
附录 A 实验补充材料 22
A.1 附录说明 22
A.2 可补充材料安排 22
致 谢 23

第一章 绪论

1.1 研究背景与意义

流程工业广泛存在于化工、能源、冶金、制药等关键行业，其生产过程通常具有连续运行、耦合强、非线性明显和安全要求高等特点。一旦关键设备或工艺环节发生异常，不仅会造成产品质量下降，还可能引发连锁波动甚至安全事故。因此，如何及时、准确地发现并识别工业过程中的故障，一直是过程监测与控制领域的重要研究方向。随着传感器和控制系统的普及，工业现场可以持续采集大量过程变量，这为基于数据驱动的故障诊断方法提供了良好的应用基础[1]。

传统的数据驱动故障诊断方法通常默认训练数据与测试数据满足相同分布，但这一假设在真实工业场景中往往难以成立。设备老化、原料波动、控制策略变化以及操作负载切换等因素，都会导致不同时间或不同工况下采集到的数据分布发生偏移。当模型仅利用某一工况下的标注数据进行训练时，其在新工况或新域上的诊断性能往往显著下降。对于流程工业而言，重新采集并标注大量目标域故障样本通常成本高昂，甚至在某些工况下几乎不可行。因此，研究能够利用源域知识提升目标域诊断性能的迁移学习与领域自适应方法，具有明确的工程价值和现实意义[2]。

Tennessee Eastman Process（TEP）是过程系统工程领域广泛采用的工业过程仿真基准，由 Downs 和 Vogel 提出[3]。围绕该过程构造的领域自适应数据集能够较好地模拟不同操作模式下的分布差异，为验证故障诊断模型的跨域泛化能力提供了统一平台。基于 TEP 数据集构建规范的实验比较体系，系统比较不同领域自适应方法在流程工业故障诊断中的适用性，不仅有助于梳理现有方法的优缺点，也能为后续方法改进和工程部署提供实验基础。

1.2 研究问题与研究目标

本文关注的核心问题是：在目标域缺少故障标签的条件下，如何利用源域标注样本和目标域无标注样本，构建能够适应工况变化的故障诊断模型。围绕这一问题，本文将研究场景限定为单源域到单目标域的无监督领域自适应诊断任务。源域与目标域分别对应不同的 TEP 操作模式，模型输入为多变量过程时序片段，输出为对应的故障类别预测。

为使研究工作聚焦且可复现，本文设置了以下几个具体目标。首先，围绕 TEP 领域自适应数据集建立统一的实验设定，明确数据表示、域划分、归一化方式、训练协议和评价准则，为不同方法的公平比较提供基础。其次，在共享骨干网络和一致实验条件下，比较

多种代表性领域自适应方法，包括分布对齐类、对抗式方法和最优传输类方法，从而分析它们在流程工业场景中的适用性与差异。最后，通过准确率、平衡准确率、混淆矩阵和特征可视化等多维指标，对模型的源域判别能力、目标域迁移能力和类别混淆现象进行系统分析。

考虑到迁移场景数量较多，本文在统一实验协议的前提下，优先完成基线方法比较与代表性场景分析，并在此基础上凝练改进方法设计。这样的组织方式既便于从已有实验结果中提炼问题，也便于后续继续补充更完整的结果统计和误差分析。

1.3 研究内容与技术路线

1.3.1 研究内容

本文的研究内容主要包括两个方面。其一，围绕 TEP 多工况单源到单目标无监督领域自适应任务，建立统一的数据集使用方式和实验比较框架，并在相同骨干网络下比较 Source Only、CORAL、DAN、DANN、CDAN 和 DeepJDOT 等典型方法。其二，在基线结果分析基础上，围绕类条件对齐、类别原型、可靠伪标签和一致性约束等机制设计具有针对性的改进方法，并给出相应的验证思路。

1.3.2 技术路线

本文的总体技术路线可以概括为：首先，明确 TEP 多工况迁移诊断的任务定义、数据集构成和统一实验设定；其次，以一维全卷积网络作为统一时序特征提取骨干，完成各类典型领域自适应基线的比较；再次，结合实验结果中暴露出的类别混淆、跨域同类未充分对齐等问题，设计可靠性门控的类条件时序自适应策略；最后，通过总体指标、分场景结果、消融实验和可视化分析，系统评估改进方法在目标域上的诊断性能与稳定性。

1.4 论文结构安排

全文共分为六章，各章内容安排如下。

第一章为绪论，主要介绍研究背景、研究问题、研究目标以及本文的技术路线。第二章为相关基础与文献综述，围绕流程工业故障诊断方法、领域自适应理论以及 TEP 数据集与跨工况迁移诊断研究展开梳理。第三章为问题定义、数据集与实验设定，介绍本文的任务形式、数据使用方式、预处理策略和统一实验协议。第四章为基线方法与实验结果分析，重点比较 FCN 骨干网络下各类典型领域自适应方法的表现，并据此归纳主要问题。第五章为可靠性门控的类条件时序自适应方法设计，用于给出本文改进方法的总体框架、损失

设计与验证方案。第六章为总结与展望，对全文工作进行归纳，并讨论后续可继续深入的研究方向。

第二章 相关基础与文献综述

2.1 流程工业故障诊断方法概述

2.1.1 基于机理模型的方法

早期工业过程故障诊断较多依赖过程机理模型、专家知识和人工规则。这类方法在对象机理清晰、工况变化范围有限的场景下具有较好的可解释性，但对于大型耦合流程、复杂控制回路和频繁变化的工业现场而言，往往面临建模困难、维护成本高和泛化能力有限等问题。

2.1.2 基于机器学习的方法

随着工业信息化水平提高，基于历史运行数据进行状态监测与故障识别逐渐成为主流思路[1]。这一类方法通常通过特征提取、统计建模和分类学习，从大量过程变量中挖掘与故障相关的判别信息。主成分分析、偏最小二乘及其动态扩展形式长期是流程工业监测中的重要工具，支持向量机、近邻分类器、决策树等浅层学习方法也被广泛用于故障识别任务。与纯机理模型方法相比，这类方法对先验知识依赖较弱，在中小规模样本条件下往往具有较好的训练效率和一定的可解释性。

不过，传统机器学习方法通常依赖人工特征或统计假设，对复杂非线性过程和跨工况分布变化的适应能力仍然有限。当源域与目标域之间存在明显分布偏移时，仅依赖固定特征空间中的浅层判别器往往难以保持稳定性能，这也推动了更强表示学习模型和迁移方法的发展。

2.1.3 基于深度学习的方法

数据驱动方法通常通过统计建模、机器学习或深度学习技术，从大量过程变量中自动提取与故障相关的表征。典型方法包括主成分分析、偏最小二乘、支持向量机以及近年来广泛应用的卷积神经网络和循环神经网络等。相比传统方法，深度模型能够直接从原始或弱处理后的多变量时序信号中学习高层特征，在复杂模式识别任务中展现出更强的拟合能力。然而，深度模型往往需要较多标注数据，并且对训练集与测试集分布一致性的依赖更强。当工况发生变化时，模型容易出现性能衰减，这使得跨域泛化成为工业故障诊断研究中的关键问题。

对于流程工业场景，仅依赖单一工况下采集到的故障样本训练模型，难以覆盖真实生产中可能出现的工况变化。与通用视觉任务不同，工业过程数据具有时序性、强相关性和

工况依赖性，诊断模型不仅需要识别类别间差异，还要对不同域之间的统计偏移保持鲁棒。因此，将迁移学习与领域自适应思想引入工业过程故障诊断，已经成为近年来值得关注的发展方向。

2.2 领域自适应理论基础

2.2.1 迁移学习与领域自适应定义

迁移学习旨在利用已有任务或已有域中的知识，提升目标任务或目标域上的学习效果。Pan 和 Yang 将迁移学习系统地定义为在源域和目标域分布或任务不同的情况下，通过知识迁移改善目标任务学习性能的过程[2]。其中，领域自适应是迁移学习的重要分支，主要研究源域和目标域任务相同但数据分布不同的情形。按照目标域是否具有标签，领域自适应可分为监督式、半监督式和无监督式等多种设置，本文重点关注目标域无标签的无监督领域自适应。

2.2.2 单源无监督领域自适应设定

本文采用的任务设定属于单源域到单目标域的无监督领域自适应。源域具有类别标签，目标域在训练阶段不使用标签，二者共享相同的故障类别集合，但数据分布并不一致。对于 TEP 多工况场景而言，不同 mode 可以自然视作不同 domain，因此该设定能够较好贴合跨工况迁移诊断问题。

2.2.3 全局对齐与类条件对齐

现有无监督领域自适应方法大体可以分为三类。第一类是分布对齐方法，其核心思想是在保持源域分类能力的同时，缩小源域与目标域特征分布之间的差异。例如，CORAL 通过对齐特征协方差矩阵减小二阶统计量差异[4]；DAN 则利用多核最大均值差异在再生核希尔伯特空间中约束源域与目标域特征分布接近[5]。这类方法结构相对清晰，训练较为稳定，适合作为流程工业场景中的基础对比方案。

第二类是对抗式领域自适应方法。DANN 在特征提取网络后引入域判别器，并利用梯度反转层实现特征学习与域判别之间的对抗博弈，从而促使提取到的特征具有域不变性[6]。CDAN 在此基础上进一步利用分类预测结果对特征进行条件化，使域判别过程能够感知类别结构信息，从而缓解简单对抗对齐可能造成的类别混叠问题[7]。对抗式方法通常具有较强的表示学习能力，但训练稳定性和超参数敏感性也更值得关注。

第三类是基于最优传输的领域自适应方法。相关方法通过构造源域和目标域样本之间

的运输代价，直接在概率分布层面寻找匹配关系。DeepJDOT 将特征空间距离与类别预测差异结合起来，在深度特征学习过程中联合优化跨域样本匹配与分类目标[8]。这类方法能够在全局层面描述跨域样本关系，但通常对批大小、代价构造和计算效率较为敏感。

总体来看，不同领域自适应方法在假设前提、优化目标与训练稳定性方面各有特点。将这些方法置于统一的流程工业故障诊断实验设定中进行比较，有助于观察它们在工业时序数据上的适用范围与局限性。

2.3 TEP 数据集与跨工况迁移诊断研究

2.3.1 TEP 过程与故障诊断任务

Tennessee Eastman Process 是经典的化工过程仿真平台，包含多个相互耦合的单元操作和控制回路，能够模拟多种正常工况与故障情形[3]。由于该过程结构较为完整、变量丰富且具有较强代表性，TEP 长期被用于过程监测、故障检测和故障诊断算法的评估。与一般静态分类数据集相比，TEP 数据具有明显的动态特性和工业背景，更能体现方法在复杂过程系统中的实际适应能力。

2.3.2 TEP 领域自适应数据集简介

本文使用的并非普通的 TEP 单域分类数据，而是面向领域自适应任务构造的 TEP 扩展数据集。该数据集把不同操作模式组织为不同领域，其中 6 个 mode 可视为 6 个 domain，标签空间为 29 类，即正常工况和 28 类故障。这样的设置使得同一故障类别在不同工况下具有共享语义，但又呈现出明显不同的统计分布，从而能够自然构造跨工况的无监督领域自适应诊断任务。

2.3.3 多工况分布偏移与迁移诊断研究评述

在 TEP 多工况场景中，不同模式之间的负载水平、控制策略和过程动态存在差异，同一故障在不同模式下往往表现出不同的时序响应特征。这种跨工况分布偏移使得仅依赖单一工况训练的模型难以直接迁移到新工况，也使 TEP 成为研究工业过程迁移诊断的重要数据基础。从已有研究可以看出，统一任务定义、数据划分、预处理方式与骨干网络结构，对于公平比较不同领域自适应方法至关重要；同时，多工况迁移诊断研究也为观察类别混淆、分析对齐机理和提出改进方法提供了清晰的实验背景。

2.4 本章小结

本章从工业过程故障诊断、迁移学习与领域自适应方法以及 TEP 数据集与跨工况迁移诊断研究三个方面梳理了与本文课题密切相关的研究背景。可以看到，工业过程中的域偏移问题使得传统仅依赖同分布假设的诊断模型面临明显挑战，而分布对齐、对抗学习和最优传输等方法为跨域故障诊断提供了可行思路。基于此，下一章将对本文采用的任务定义、数据集使用方式和统一实验设定进行说明。

第三章 问题定义、数据集与实验设定

3.1 任务定义与符号说明

3.1.1 问题描述

本文研究的任务为单源域到单目标域的无监督领域自适应故障诊断。设源域为 $\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$，其中 x_i^s 表示源域样本，y_i^s 表示其故障类别标签；目标域为 $\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}$，目标域训练阶段不使用标签。本文的目标是在利用源域有标签样本和目标域无标签样本的条件下，训练一个能够在目标域测试集上保持较好诊断性能的分类模型。

3.1.2 域定义与符号约定

在本文的实验设定中，不同 TEP 操作模式被视为不同 domain。源域与目标域共享相同的标签空间，但其样本分布并不一致。输入样本采用多变量过程时序片段表示，按照 channels-first 的方式组织为 (N, C, T) 形状，其中 $C = 34$ 表示过程变量通道数，T 表示时间窗口长度，模型输出为 29 类工况与故障类别的预测结果。

3.1.3 优化目标

从模型结构上看，本文采用编码器 ϕ 从输入时序样本中提取特征表示，再由分类器 h 输出故障类别预测，即 $\hat{y} = h(\phi(x))$。训练目标包括源域监督分类损失，以及根据不同领域自适应方法引入的分布对齐损失、对抗损失或最优传输损失。对于改进方法，还将进一步引入可靠伪标签约束、类别原型约束和一致性正则项。

3.2 数据集与域划分

3.2.1 TEP 领域自适应数据集

本文采用 Tennessee Eastman Process Domain Adaptation 数据集开展实验。该数据集面向跨工况迁移诊断任务构造，将 6 个操作模式视为 6 个不同领域，标签空间为 29 类，即正常工况和 28 类故障。与普通单域分类任务相比，这一数据集更适合用于分析工业过程在工况切换条件下产生的分布偏移问题。

3.2.2 迁移任务构造

本文将不同 mode 之间的迁移任务表示为单源域到单目标域的无监督领域自适应场景。训练阶段仅使用源域标签和目标域无标签样本，测试阶段使用目标域标签进行性能评估。为兼顾代表性与可操作性，正文重点展示若干典型单源场景的比较结果，并将部分多源场景作为补充讨论对象。

3.3 输入表示与预处理策略

3.3.1 时序样本表示

数据集中的每个样本均表示为固定长度的多变量时间窗口，可形式化写为 $x \in \mathbb{R}^{C \times T}$。这种表示方式既保留了过程变量之间的相关性，也保留了短时动态变化信息，适合由一维卷积网络进行特征提取。所有方法均在相同的输入形式下进行比较，以避免由于样本组织方式不同而引入额外干扰。

3.3.2 归一化与数据划分

为保证不同方法之间具有可比性，本文采用固定折划分区分训练样本与评估样本，并在域内执行标准化处理，以减小量纲差异对模型训练的影响。目标域标签只在最终测试阶段用于统计结果，不参与训练过程。通过统一的数据划分和预处理策略，可以把比较重点集中在不同领域自适应机制本身。

3.4 统一实验设定

3.4.1 共享骨干网络与对比方法

本文采用一维全卷积网络作为统一时序特征提取骨干，并在此基础上比较 Source Only、CORAL、DAN、DANN、CDAN 和 DeepJDOT 等代表性方法。共享骨干网络能够减少特征提取结构差异对实验结论的干扰，使比较更聚焦于各类适配策略本身。

3.4.2 训练与评估协议

各方法采用一致的数据划分、训练轮数和优化预算，并在相同任务设定下进行比较。训练阶段统一遵循“源域有标签、目标域无标签”的无监督领域自适应协议；评估阶段同时记录源域表现和目标域表现，以便分析模型是否存在源域拟合较强但目标域迁移有限的现象。

3.5 评价指标与模型选择

本文重点比较各方法的目标域诊断性能。评价指标主要包括目标域准确率、平衡准确率、混淆矩阵，以及反映域对齐程度和类别聚合情况的特征可视化结果。考虑到无监督领域自适应缺少统一的目标域有标签验证标准，本文结合源域评估表现与目标域无标签预测稳定性进行模型选择，以兼顾训练可操作性与结果一致性。

3.6 本章小结

本章围绕任务定义、数据集构成、输入表示、预处理方式和统一实验协议，对本文后续实验的共同前提进行了说明。基于这些设定，下一章将对对比方法及其实验结果展开分析。

第四章 基线方法与实验结果分析

4.1 实验设置

本章基于第三章给出的统一实验设定，对典型领域自适应方法进行比较，明确不同方法在 TEP 多工况迁移场景中的表现差异，并为后续方法改进提供依据。当前实验统计将全量比较组织为 ‘12‘ 个设置与 ‘6‘ 种方法的组合，即共 ‘72‘ 次运行。其中，‘12‘ 个设置由 ‘6‘ 组代表性单源到单目标场景与 ‘6‘ 组五源到单目标场景组成。正文先选取六组代表性单源场景进行集中展示，并结合已完成的部分多源场景做补充讨论。六组代表性单源场景分别为：mode1→mode4、mode4→mode1、mode2→mode5、mode5→mode2、mode3→mode6 和 mode6→mode3。

在实验协议上，各方法均采用相同的一维 FCN 特征提取网络和相同的数据划分方式。目标域训练阶段不使用真实标签，仅在测试阶段统计目标域准确率与平衡准确率。考虑到无监督领域自适应并不存在统一公认的模型选择标准，本文采用源域评估准确率与目标域无标签预测熵融合的代理指标进行早停与模型选择，同时记录源域训练准确率和源域评估准确率，用于分析方法是否存在“源域性能下降但目标域收益有限”的对齐失衡现象。

4.2 共享骨干网络与 Source Only 基线

本文采用一维全卷积网络作为统一特征提取骨干。该网络由三层一维卷积、归一化和非线性映射构成，并通过时间维平均池化得到紧凑特征表示。相比直接引入复杂时序结构，FCN 具有结构清晰、训练稳定和便于跨方法公平比较等优点，因此被用作本研究的统一主干网络。

Source Only 方法仅依赖源域监督分类损失进行训练，不显式处理源域与目标域之间的分布偏移，因此可视为所有领域自适应方法的基础对照组。若某一领域自适应方法在目标域上不能显著优于 Source Only，则说明其对齐策略尚未真正缓解跨工况迁移带来的分布差异问题。

4.3 对比方法

4.3.1 分布对齐方法

CORAL 通过约束源域与目标域特征协方差矩阵的一致性来减小二阶统计差异[4]；DAN 则使用多核最大均值差异来约束特征分布，在核空间中实现更细致的边缘分布对齐[5]。这两类方法的共同特点是训练目标较为直接，通常能在不引入额外判别器的情况下

稳定收敛，因此适合作为本文中的基础分布对齐参照。

4.3.2 对抗式方法

DANN 在共享特征提取网络之后加入域判别器，并利用梯度反转层实现特征表示与域分类之间的对抗学习，从而逼近域不变特征[6]。CDAN 则进一步将类别预测结果纳入条件化对齐过程，使对抗过程能够感知类别结构信息，以缓解简单全局对齐造成的类别混叠问题[7]。这两类方法分别代表了全局对抗对齐和条件对抗对齐两种典型思路。

4.3.3 最优传输方法

DeepJDOT 通过联合建模特征空间距离与类别预测差异，构建源域和目标域样本之间的运输代价，在深度特征学习过程中同时优化分类与跨域匹配[8]。该方法能够提供样本级的跨域关系约束，但也更容易受到批大小、代价尺度和训练稳定性的影响。

4.4 实验结果与现象分析

4.4.1 代表性单源场景的总体结果

在当前已完成的六组代表性单源场景上，表 4.1 给出了各方法的平均目标域准确率，以及相对于 Source Only 的平均提升。可以看到，所有领域自适应方法在平均意义上均优于 Source Only，其中 DAN 与 DANN 的平均表现最为突出。

表 4.1 六组代表性单源场景上的平均目标域准确率

方法	平均目标域准确率	相对 Source Only 平均提升
Source Only	0.5510	0.0000
CORAL	0.6956	0.1446
DAN	0.7688	0.2177
DANN	0.7533	0.2023
CDAN	0.6824	0.1314
DeepJDOT	0.6196	0.0685

进一步比较每个具体场景中的相对变化可以发现，CORAL、DAN、DANN 和 DeepJDOT 在已完成的六组代表性单源场景中均优于 Source Only，说明引入域对齐机制对于 TEP 跨工况故障诊断是必要且有效的。CDAN 在四组场景中优于 Source Only，但在 `mode4→mode1` 和 `mode6→mode3` 两组场景中的优势并不稳定，表明条件对齐策略在当前设定下仍对场景分布和训练配置较为敏感。

4.4.2 分场景结果分析

从已完成场景的最好结果来看，DAN 与 DANN 在若干代表性迁移方向上表现相对更强。例如，从 mode3 迁移到 mode6、从 mode2 迁移到 mode5，以及从 mode5 迁移到 mode2 这三组场景的目标域准确率均已达到约 0.80 以上；在较难的 mode1 迁移到 mode4 场景中，CDAN 的目标域准确率达到了 0.8126，显著高于 Source Only 的 0.3608，体现出条件化对齐在复杂类别结构迁移中仍具有潜力。另一方面，DeepJDOT 的平均收益相对有限，说明最优传输类方法在当前时序故障诊断任务上还需要进一步优化代价构造与训练稳定性。

已完成的多源到单目标场景结果也反映出一个重要现象：当源域信息更加充分时，Source Only 本身已经能够达到较高的目标域准确率。以目标域 `mode1` 的五源迁移场景为例，Source Only 已达到 0.7586，而 CORAL 进一步提升到了 0.8241。这说明多源信息融合本身是一个值得继续深入的方向，但同时也提示单纯依靠更多源域数据并不能完全替代更细粒度的类条件对齐机制。

4.5 讨论与方法启示

4.5.1 当前结果揭示的主要问题

结合已完成实验结果，可以总结出当前实验暴露出的三个主要问题。第一，Source Only 在源域上通常能够获得较高准确率，但在目标域上的性能明显下降，说明跨工况分布偏移对故障诊断模型的影响依然显著。第二，分布对齐方法虽能整体提升目标域性能，但不同方法在不同场景上的稳定性存在明显差异。例如 CDAN 在部分场景中表现突出，但并非在所有场景中都优于 DAN 或 DANN。第三，部分方法在目标域上取得收益的同时，会出现源域分类能力下降或训练过程更敏感的情况，这说明“全局域对齐”与“类别判别能力”之间仍存在权衡。

4.5.2 对第五章方法设计的启示

上述现象表明，当前问题的关键并不只是“是否进行对齐”，而是“如何在保持类别判别能力的前提下进行更稳定的对齐”。现有全局边缘分布对齐方法能够减小整体域差异，但无法显式保证跨域同类样本靠近、异类样本保持分离；而条件对齐方法虽然引入了类别信息，却仍容易受到伪标签噪声和训练不稳定性的影响。因此，改进方法需要同时兼顾以下三点：其一，保留当前实验中已经验证有效的全局域对齐机制；其二，引入更直接的类别结构约束以减少跨域类别混叠；其三，通过置信度筛选和渐进式权重调度控制目标域伪

标签噪声对训练的负面影响。

4.6 本章小结

本章在统一 FCN 骨干网络和统一实验协议下，对 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 等基线方法进行了比较。已完成的六组代表性单源场景结果表明，领域自适应方法整体上显著优于 Source Only，其中 DAN 与 DANN 的平均目标域表现较强，而 CDAN 在个别困难场景中展现出更高上限但稳定性仍需提升。基于这些结果，本文把创新重点进一步收敛到“如何利用可靠目标监督和类别结构信息提升跨域同类聚合能力”这一问题上，下一章将据此给出具体的方法设计。

第五章 可靠性门控的类条件时序自适应方法设计

5.1 方法设计动机

第四章的实验结果表明，现有领域自适应基线虽然已经能够在目标域上取得明显收益，但仍存在三个尚未解决的问题。首先，单纯的全局分布对齐难以显式保证跨域同类样本聚合、异类样本分离，因此当不同故障类别在目标域中边界接近时，模型仍可能出现较严重的类别混叠。其次，条件对齐方法虽然能够利用类别预测信息，但目标域伪标签本身存在噪声，若直接以其驱动对齐，容易把错误类别关系进一步强化。最后，从当前结果看，不同方法在场景之间的波动仍然较大，这意味着改进方法除了追求更高上限，还需要兼顾训练稳定性和目标域监督的可靠性。

基于上述问题，本文提出一种可靠性门控的类条件时序自适应方法（Reliability-Gated Class-Conditional Temporal Adaptation, RCTA）。该方法的核心思想是：利用教师网络生成更平滑的目标域预测，以多因素可靠性评分筛选可用伪标签，并结合类别原型约束与一致性正则，把全局域对齐和类条件迁移有机结合起来，从而提高跨工况故障诊断中的稳定迁移能力。

5.2 方法总体框架

本文提出的改进方法记为 RCTA。整体框架仍由特征提取器、分类器和域对齐模块三部分组成，其中 FCN 作为共享时序特征提取骨干，以保持与第四章基线比较的一致性。与现有基线相比，RCTA 的主要新增内容包括以下四项：

1. 教师网络伪标签估计：利用指数滑动平均教师网络生成更稳定的目标域预测；
2. 可靠性门控机制：综合置信度、熵、一致性和原型相似度筛选可信目标样本；
3. 类别原型建模：维护源域与目标域的类别原型，为类条件迁移提供参照；
4. 类条件与一致性约束：同时强化原型吸引、类别分离和时序一致性。

在训练过程中，RCTA 保留现有全局域对齐损失作为基础约束，例如 CDAN 的条件对抗损失或 DANN 的域对抗损失；与此同时，通过可靠目标监督、双域原型和一致性正则进一步增强跨域同类聚合，从而缓解“全局对齐有效但类别边界不清晰”的问题。

5.3 类别原型建模

设特征提取器为 $\phi(\cdot)$，分类器为 $h(\cdot)$。对于一个源域小批量 $\mathcal{B}_s = \{(x_i^s, y_i^s)\}_{i=1}^{m_s}$，记其特征表示为

$$f_i^s = \phi(x_i^s). \tag{5.1}$$

对于第 k 类故障，本文以该类别样本在特征空间中的均值作为小批量原型：

$$\tilde{c}_k = \frac{1}{|\mathcal{B}_s^k|} \sum_{i:y_i^s=k} f_i^s, \tag{5.2}$$

其中 $\mathcal{B}_s^k$ 表示当前批中属于第 k 类的样本集合。为了减小单个小批量波动对类别中心的影响，本文采用指数滑动平均方式更新全局原型：

$$c_k \leftarrow \mu c_k + (1-\mu)\tilde{c}_k, \tag{5.3}$$

其中 $\mu \in [0,1)$ 为动量系数。这样得到的源域类别原型一方面能够反映各故障类别的稳定中心，另一方面又能随训练过程逐步更新，作为目标域特征对齐的参照。

5.4 目标域可靠伪标签筛选

对于目标域小批量 $\mathcal{B}_t = \{x_j^t\}_{j=1}^{m_t}$，记其预测概率为

$$p_j^{t,\text{tea}} = \text{softmax}\left(\frac{h_{\text{tea}}(\phi_{\text{tea}}(x_j^t))}{T_{\text{tea}}}\right), \tag{5.4}$$

伪标签定义为最大概率对应的类别：

$$\hat{y}_j^t = \arg\max p_j^{t,\text{tea}}. \tag{5.5}$$

同时记预测置信度为

$$q_j^t = \max p_j^{t,\text{tea}}. \tag{5.6}$$

为了降低错误伪标签带来的负迁移风险，本文不直接让所有目标域样本参与类条件训练，而是为每个样本构造综合可靠性评分。除最大预测概率外，还考虑预测熵、学生网络与教师网络之间的一致性，以及目标样本与参考原型之间的相似度。记综合可靠性分数为

$$r_j^t = \alpha_1 q_j^t + \alpha_2(1-e_j^t) + \alpha_3 u_j^t + \alpha_4 s_j^t, \tag{5.7}$$

其中 e_j^t 表示归一化预测熵，u_j^t 表示学生网络对伪标签的响应强度，s_j^t 表示样本特征与对应类别参考原型之间的相似度，$\alpha_1, \alpha_2, \alpha_3, \alpha_4$ 为非负权重且满足和为 1。进一步通过阈值 τ

选出高可靠目标子集

$$\Omega_t = \{j \mid r_j^t > \tau\}. \tag{5.8}$$

随着训练进行，阈值和对应损失权重采用渐进式策略，使模型先依赖源域监督和全局对齐获得相对稳定的表示，再逐步利用高可靠目标样本开展更细粒度的类条件迁移。

5.5 类条件对齐与一致性约束

5.5.1 原型吸引损失

对于被选中的高置信目标域样本，本文希望其特征尽量接近对应类别的源域原型，因此定义原型一致性损失为

$$\mathcal{L}_{proto} = \frac{1}{|\Omega_t|} \sum_{j \in \Omega_t} \left\| \phi(x_j^t) - c_{\hat{y}_j^t} \right\|_2^2. \tag{5.9}$$

该项约束的作用是直接缩小目标域特征与源域同类中心的距离，从而增强跨域同类样本的聚合性。

5.5.2 原型分离约束

除增强同类样本聚合外，本文还希望不同类别的参考原型保持足够分离。记参考原型集合为 $\{c_k\}_{k=1}^K$，则原型分离损失定义为

$$\mathcal{L}_{sep} = \frac{1}{K(K-1)} \sum_{k \neq l} \max\left(0, \cos(c_k, c_l) - m\right), \tag{5.10}$$

其中 m 为原型间余弦相似度的分离边界。该项约束能够抑制不同类别中心在特征空间中过度靠近，从而减少类间混叠。

5.5.3 一致性监督项

在高可靠目标样本基础上，本文进一步约束学生网络预测与教师网络预测保持一致。设学生网络预测概率为 $p_j^{t,\text{stu}}$，则一致性损失可写为

$$\mathcal{L}_{cons} = \frac{1}{|\Omega_t|} \sum_{j \in \Omega_t} \mathrm{KL}\big(p_j^{t,\text{tea}} \,\|\, p_j^{t,\text{stu}}\big). \tag{5.11}$$

该项的作用是进一步稳定目标域判别边界，并利用教师网络提供的平滑监督减轻伪标签噪声对训练的扰动。

5.6 整体优化目标与训练策略

在保留现有全局域对齐损失 $\mathcal{L}_{global}$ 的基础上，RCTA 的总损失函数可写为

$$\mathcal{L} = \mathcal{L}_{cls}^s + \lambda_g \mathcal{L}_{global} + \lambda_p \mathcal{L}_{proto} + \lambda_s \mathcal{L}_{sep} + \lambda_c \mathcal{L}_{cons}, \tag{5.12}$$

其中 $\mathcal{L}_{cls}^{s}$ 表示源域监督分类损失，λ_g、λ_p、λ_s 和 λ_c 分别为各损失项的权重。训练策略上，本文按照以下方式组织优化：

1. 训练初期主要依赖源域分类损失和全局域对齐损失，先获得较稳定的跨域共享表示；
2. 随着训练推进，利用教师网络输出和可靠性门控机制筛选可信目标样本；
3. 在每轮迭代中更新类别原型，并通过原型吸引、原型分离和一致性监督共同约束目标域表示；
4. 最终在统一实验场景中评估该方法相对基线的目标域性能收益与稳定性变化。

该设计与现有基线方法共享统一骨干网络和基本训练框架，便于在相同实验条件下分析新增机制的有效性。

5.7 实验验证方案

5.7.1 与基线方法的总体比较

实验验证首先在第四章已经完成的六组代表性单源场景上考察 RCTA 相对于 Source Only、DAN、DANN 和 CDAN 的增益情况；在此基础上，再扩展到全量场景的系统比较中进行补充说明。

5.7.2 消融实验设计

为了明确各模块贡献，本文设计以下消融版本：

1. 仅保留全局域对齐损失的基线版本；
2. 全局域对齐 + 原型吸引损失；
3. 全局域对齐 + 原型吸引 + 原型分离约束；
4. 全局域对齐 + 原型吸引 + 一致性监督；
5. 完整版本，即同时加入可靠性门控、原型约束和一致性正则。

通过上述逐步叠加方式，可以分析每个模块对目标域性能、训练稳定性和类别区分能力的具体影响。

5.7.3 重点分析指标

在验证过程中，除了目标域准确率和平衡准确率外，还将重点关注以下现象：其一，源域准确率是否因为额外对齐约束而出现明显下降；其二，混淆矩阵中易混类别是否得到改善；其三，t-SNE 可视化中跨域同类样本是否比现有基线更加聚合；其四，所提方法在不同迁移方向上的收益是否更加稳定。

5.8 本章小结

本章在第四章实验结果分析的基础上，进一步给出了一个更具体的创新方向，即可靠性门控的类条件时序自适应方法。该方法尝试把教师网络伪标签、可靠性筛选、类别原型和一致性正则结合起来，以提升跨工况故障诊断中的类条件迁移能力。相较于仅停留在原则层面的改进设想，这一方案已经明确了核心机制、损失函数和验证路径，也为后续实验补充提供了清晰主线。

第六章 总结与展望

6.1 全文工作总结

本文围绕流程工业场景下的领域自适应故障诊断问题，面向 Tennessee Eastman Process Domain Adaptation 数据集，梳理了任务定义、数据集构成和统一实验设定，并在统一 FCN 骨干网络下比较了 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 等典型基线方法。在此基础上，本文进一步提出了可靠性门控的类条件时序自适应方法设计，为后续改进实验提供了明确方向。

6.2 主要结论

本文的主要结论可概括为三个方面。其一，TEP 多工况故障诊断可以被清晰表述为单源域到单目标域的无监督领域自适应问题，并能够在统一实验条件下开展系统比较。其二，在已完成的代表性单源场景上，相较于 Source Only，现有领域自适应方法整体能够获得明显的目标域性能提升，其中 DAN 与 DANN 的平均表现相对更优，说明域对齐机制在该任务中确有必要。其三，现有方法虽然能够提高目标域准确率，但仍存在场景敏感、类别混叠和训练稳定性不足等问题，因此有必要进一步引入可靠目标监督和类条件约束机制。

6.3 不足与未来展望

当前工作仍存在若干不足。首先，由于实验规模较大，按当前阶段定义的 ‘12‘ 个设置与 ‘6‘ 种方法组合形成的 ‘72‘ 次运行尚未全部纳入正文统计，现有结论仍以代表性单源场景和部分多源场景为主。其次，第五章提出的改进方法仍需补充完整的实验结果、消融分析与参数敏感性讨论。最后，当前研究主要面向离线无监督领域自适应设置，对更复杂的多源迁移、在线诊断和工程部署问题尚未深入展开。

后续研究可以从以下几个方向继续展开。其一，完成当前 ‘72‘ 次运行结果的整理与汇总，形成更完整的横向比较、误差分析与图表展示。其二，在现有 CDAN/DANN 主线基础上实现本文提出的 RCTA 方法，并优先在代表性场景上验证其有效性。其三，进一步比较更系统的无标签模型选择策略与当前混合代理策略的差异，并结合消融实验、参数敏感性分析和可视化分析，明确各个新增模块对跨域同类聚合和最终诊断性能的贡献。通过这些工作，可使本文从“完成基线比较与问题归纳”进一步推进到“形成具有明确创新点和实验支撑的流程工业领域自适应故障诊断研究结果”。

参考文献

[1] QIN S J. Survey on data-driven industrial process monitoring and diagnosis[J]. Annual Reviews in Control, 2012, 36(2): 220-234.

[2] PAN S J, YANG Q. A survey on transfer learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2009, 22(10): 1345-1359.

[3] DOWNS J J, VOGEL E F. A plant-wide industrial process control problem[J]. Computers & Chemical Engineering, 1993, 17(3): 245-255.

[4] SUN B, SAENKO K. Deep CORAL: Correlation alignment for deep domain adaptation[C]//Computer Vision – ECCV 2016 Workshops. 2016: 443-450.

[5] LONG M, CAO Y, WANG J, et al. Learning transferable features with deep adaptation networks[C]// Proceedings of the 32nd International Conference on Machine Learning. 2015: 97-105.

[6] GANIN Y, USTINOVA E, AJAKAN H, et al. Domain-adversarial training of neural networks[J]. Journal of Machine Learning Research, 2016, 17(59): 1-35.

[7] LONG M, CAO Z, WANG J, et al. Conditional adversarial domain adaptation[C]//Advances in Neural Information Processing Systems: volume 31. 2018.

[8] DAMODARAN B B, KELLENBERGER B, FLAMARY R, et al. Deepjdot: Deep joint distribution optimal transport for unsupervised domain adaptation[C]//Proceedings of the European Conference on Computer Vision. 2018: 447-463.

附录 A 实验补充材料

A.1 附录说明

本附录用于放置不便完全写入正文、但对理解实验设置和补充分析仍有参考价值的材料，例如关键超参数表、更多实验结果、补充可视化图和必要的实现说明等。

A.2 可补充材料安排

当前附录主要用于承接正文未完全展开的补充内容。随着实验结果持续整理，可进一步补充各方法关键超参数表、更多场景结果、附加混淆矩阵与特征可视化，以及必要的实现细节说明。若附录内容较多，也可继续扩展为多个附录文件。

致　　谢

值此本科毕业论文完成之际，谨向在大学期间关心、指导和帮助过我的老师、学长、同学及家人致以诚挚的感谢。

首先，衷心感谢指导教师王永健教授，在毕业设计选题、研究思路梳理、实验推进和论文撰写过程中给予了我耐心细致的指导与帮助，使我得以顺利完成本论文的研究工作；同时，在个人发展与后续规划等方面给予我的支持与鼓励，也使我深受感激；严谨认真的治学态度和认真负责的工作作风，使我受益匪浅。

其次，感谢蒋徐颢、蔡闻骁、邹滨阳等学长和同学榜样在学习与成长过程中给予我的帮助与示范。他们在专业学习、科研视野和个人规划方面的经验分享，对我产生了积极而深远的影响。

感谢严震霆、周志铭、曲振宁等同学和朋友在本科阶段给予我的陪伴、支持与鼓励。在课题讨论、日常学习和生活交流中，他们给予了我许多真诚的帮助，使我能够更加从容地面对学习和毕业设计过程中的困难与挑战。

最后，衷心感谢我的父母和家人。感谢他们一直以来给予我的理解、包容和支持，使我能够安心完成本科阶段的学习任务与毕业论文工作。