



東南大學

本科毕业设计（论文）报告

基于领域自适应的

工业过程故障诊断方法研究

学号:	08022311
姓名:	陈鲲龙
学院:	自动化
专业:	自动化
指导教师:	王永健、童国道
起止日期:	2025. 12. 20-2026. 6. 3

2026 年 6 月 1 日

东南大学毕业（设计）论文独创性声明

本人声明所呈交的毕业（设计）论文是我个人在导师指导下进行的研究工作及取得的成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签名： 陈鲲龙 日期： 2026 年 6 月 1 日

东南大学毕业（设计）论文使用授权声明

东南大学有权保留本人所送交毕业（设计）论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括刊登）论文的全部或部分内容。论文的公布（包括刊登）授权东南大学教务处办理。

论文作者签名： 陈鲲龙 导师签名： 王永健
日期： 2026 年 6 月 1 日 日期： 2026 年 6 月 1 日

东南大学本科毕业论文（设计）AI 工具使用情况说明表

课题名称	基于领域自适应的工业过程故障诊断方法研究		
学 号	08022311	姓 名	陈鲲龙
是否使用生成式人工智能	☒ 是 ☐ 否		
工具、版本号	使用范围	使用过程	章节（页码）
DeepSeek-V3	☐ 文本生成及内容修改 ☐ 数据、图表分析、代码调试 ☒ 其他：英文语法检查、错别字及格式核对	对英文摘要进行语法与拼写检查，并对文中出现的错别字及格式进行检查。	ABSTRACT（II）
学生诚信申明	本人郑重声明，上述关于生成式人工智能使用情况的陈述真实无误，已对使用此类技术的所有细节进行了全面且诚实的报告。本人深知学术诚信的重要性，如有任何隐瞒或虚假之处，愿承担学术不端行为带来的相关惩处。 学生签名：陈鲲龙 2026 年 6 月 1 日		
指导教师意见	意见：同意。 王永健 指导教师签名： 2026 年 6 月 1 日		

摘 要

田纳西伊斯曼过程在不同生产模式下会出现变量相关结构变化和故障响应形态漂移。源工况训练得到的诊断模型直接用于目标工况时，往往同时面对边缘分布偏移、类别结构变形以及目标故障标签不可用等问题。本文以包含 6 个生产模式的田纳西伊斯曼过程领域自适应数据集为对象，将每个生产模式视为一个领域，在目标域标签仅用于最终评价的约束下，研究单源到单目标和多源到单目标两类跨工况故障诊断任务。

单源部分从 DeepJDOT 的小批量匹配问题出发，提出时序原型非平衡联合分布对齐方法。非平衡传输用于放松批内边际约束，减少目标样本与明显不合适源样本之间的强制匹配；源域类别原型、原始时间窗口统计量和源域监督对比学习则分别补充类别中心、故障动态和源域可分性信息。在此基础上，本文提出多证据置信均衡伪标签方法，用传输语义、固定教师模型预测和源域原型语义共同筛选目标样本，并用动态阈值、类别均衡和强弱增强一致性约束控制伪标签噪声。

多源部分构建源域-故障类别可靠性矩阵，不再只给每个源域一个整体权重，而是从原型距离、类条件传输代价、目标预测熵和源域类别性能等信息中估计不同源域对不同故障类别的贡献。实验中，CBTPU-DeepJDOT 在 6 个单源任务上的平均准确率达到 82.02%，CA-CCSR-WJDOT 在 6 个五源任务上的平均准确率达到 85.50%。在本文设置的迁移任务中，这两类结果共同指向一个结论：跨生产模式故障诊断需要同时处理样本匹配、目标样本筛选和源域类别贡献分配。

关键词：工业过程故障诊断，领域自适应，最优传输，伪标签学习，多源迁移

ABSTRACT

In the Tennessee Eastman process, a change of production mode affects both variable coupling and fault-response dynamics. A diagnostic model trained in one mode therefore cannot be transferred to another mode by assuming an unchanged data distribution. The main difficulties are marginal distribution shift, deformation of class structure, and the lack of target-mode fault labels during training. Using the Tennessee Eastman domain adaptation benchmark with six production modes, this thesis treats each mode as a domain and studies single-source to single-target and multi-source to single-target fault diagnosis. Target labels are reserved for final evaluation only.

For single-source adaptation, the thesis first modifies DeepJDOT from the perspective of mini-batch transport. The proposed temporal-prototype unbalanced joint distribution alignment method relaxes batch-wise marginal constraints and reduces forced matching between target samples and unsuitable source samples. Source-class prototypes, statistics extracted from the original time window, and supervised contrastive learning are incorporated so that the transport cost reflects feature distance, fault dynamics, and class-center relations. A second-stage multi-evidence confidence-balanced pseudo-labeling method is then used to exploit target samples more cautiously. It accepts target pseudo-labels only when transport semantics, fixed-teacher predictions, and source-prototype semantics are sufficiently consistent, with dynamic thresholds, class balancing, and weak-strong consistency used to control pseudo-label noise. For multi-source adaptation, a source-fault reliability matrix is estimated from prototype distance, class-conditional transport cost, target prediction entropy, and source-class performance, allowing source contributions to vary across fault classes. In the experiments, CBTPU-DeepJDOT obtains an average accuracy of 82.02% on six single-source tasks, while CA-CCSR-WJDOT obtains 85.50% on six five-source tasks. These results indicate that cross-mode fault diagnosis benefits from jointly considering sample matching, target-sample selection, and class-level source contribution.

KEY WORDS: Industrial process fault diagnosis, Domain adaptation, Optimal transport, Pseudo-label learning, Multi-source transfer

目 录

摘 要	I
ABSTRACT.....	II
目 录	III
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 工业过程故障诊断研究现状	2
1.2.2 迁移学习研究现状	2
1.2.3 领域自适应研究现状	3
1.3 国内外研究现状总结	3
1.4 核心问题与主要创新	4
1.5 技术路线	5
1.6 论文结构	6
第二章 跨工况领域自适应故障诊断基本方法	8
2.1 引言	8
2.2 基于联合分布最优传输的领域自适应方法	8
2.2.1 深度联合分布最优传输方法	9
2.2.2 多源加权联合分布最优传输方法	10
2.3 基于卷积式时间序列领域自适应的迁移诊断方法	11
2.3.1 卷积式时间序列特征提取方法	12
2.3.2 基于领域对抗学习的特征对齐方法	13
2.4 本章小结	14
第三章 基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法	15
3.1 引言	15
3.2 时序原型非平衡联合分布对齐基本原理	15
3.2.1 非平衡最优传输对齐原理	16
3.2.2 源域类别原型约束原理	17

3.2.3 时间序列统计代价构建原理	18
3.3 基于时序原型非平衡联合分布对齐的诊断模型构建	18
3.3.1 单源跨工况诊断问题建模	18
3.3.2 非平衡联合传输代价构建	19
3.3.3 源域原型与时序统计约束融合	19
3.3.4 源域监督对比特征学习	20
3.3.5 总体目标函数与算法流程	20
3.4 本章小结	21
第四章 基于多证据置信均衡伪标签的单源领域自适应故障诊断方法	22
4.1 引言	22
4.2 多证据置信均衡伪标签学习基本原理	23
4.2.1 目标域伪标签学习原理	23
4.2.2 教师参考模型与一致性学习原理	23
4.2.3 类别均衡约束原理	24
4.3 基于多证据置信均衡伪标签的目标域样本利用策略	24
4.3.1 传输语义分布估计	24
4.3.2 教师预测语义分布估计	25
4.3.3 源域原型语义分布估计	25
4.3.4 多证据一致性筛选机制	25
4.3.5 动态置信阈值与类别均衡机制	26
4.3.6 强弱增强一致性约束	27
4.3.7 教师-学生预测融合策略	27
4.3.8 总体目标函数与算法流程	28
4.4 本章小结	29
第五章 基于类条件源域可靠性加权的多源领域自适应故障诊断方法	30
5.1 引言	30
5.2 类条件源域可靠性加权基本原理	31
5.2.1 多源迁移与负迁移问题	31
5.2.2 源域可靠性度量原理	31

5.2.3 类条件源域权重分配原理	32
5.3 基于类条件源域可靠性加权的多源对齐策略	32
5.3.1 多源跨工况诊断问题建模	32
5.3.2 逐源联合分布最优传输对齐	32
5.3.3 类条件源域可靠性矩阵构建	33
5.3.4 领域对抗特征约束与教师先验约束	34
5.3.5 教师先验保护的诊断结果融合	35
5.3.6 总体目标函数与算法流程	35
5.4 本章小结	36
第六章 实验设计与结果分析	38
6.1 引言	38
6.2 数据集与实验场景	38
6.3 方法有效性验证	43
6.3.1 时序原型非平衡联合分布对齐有效性验证	43
6.3.2 多证据置信均衡伪标签有效性验证	45
6.3.3 类条件源域可靠性加权有效性验证	47
6.4 综合实验结果对比分析	48
6.4.1 单源创新方法相对基线方法的优势分析	49
6.4.2 多源创新方法相对基线方法的优势分析	51
6.5 本章小结	55
第七章 总结与展望	56
7.1 工作总结	56
7.2 不足与边界	56
7.3 未来工作	57
参考文献	58
附录 A 论文符号表	62
附录 B 主要算法参数表	69
B.1 单源方法参数	69
B.2 多源方法参数	72

致 谢	75
--------------	----

第一章 绪论

1.1 研究背景与意义

流程工业装置在负荷、产品规格或控制策略调整后，过程变量之间的相关关系会随之改变。以田纳西伊斯曼过程为例，不同生产模式下的正常运行分布并不完全重合，故障发生后的响应轨迹也可能在幅值、持续时间和变量联动关系上发生变化。跨工况故障诊断因此不能简单理解为“在另一批数据上测试同一分类器”，而需要同时面对分布偏移、类别语义保持和目标工况缺少故障标签等约束。

工业过程故障诊断通常包括两个层次：先识别系统是否偏离正常状态，再判断具体故障类型。流程工业变量数量多，变量之间又存在明显耦合，故障往往表现为多变量在一段时间窗口内的共同变化，而不是单个测点的孤立异常。数据驱动方法能够从历史运行数据中学习这类隐含模式，在精确机理模型难以完整建立或维护成本较高的场景中具有应用价值。近年来，深度学习方法依托端到端表征能力，已经被用于旋转机械、化工过程和其他工业故障诊断任务^[1,2]。

现有监督诊断模型大多默认训练数据和测试数据服从相近分布。跨生产模式时，这一前提容易失效：源模式中相对清晰的故障簇，进入目标模式后可能整体平移，也可能出现尺度变化或局部重叠；原先可用的分类边界随之变得不稳。另一方面，目标工况故障样本的标注代价通常较高，低频故障和危险工况更难通过重复试验获得充足标签。本文关注的问题是，在目标域标签不可见的条件下，如何同时利用源工况有标签样本和目标工况无标签样本，使诊断模型适应新的生产模式。

领域自适应与这一设定较为吻合。该类方法以源域有标签数据和目标域无标签数据为输入，试图缩小二者在特征空间或联合分布上的差异^[2,3]。在工业过程故障诊断中，不同生产模式可以分别视为不同领域；若各模式下的故障类别集合一致，无监督领域自适应便可以对应“源工况有标签、目标工况无标签”的工程条件。

本文选取田纳西伊斯曼过程领域自适应数据集作为研究对象。该数据集是化工过程控制与故障诊断研究中常用的基准数据，包含多个生产模式下的过程变量序列；已有研究指出，不同模式之间在变量相关结构和 Wasserstein 距离上存在可观差异^[4]。围绕该数据集，本文分别研究单源域到单目标域和多源域到单目标域两类任务，并从最优传输、时序原型、置信伪标签和类条件源域可靠性等方面展开方法设计。

1.2 国内外研究现状

1.2.1 工业过程故障诊断研究现状

工业过程故障诊断方法通常可分为基于机理模型、基于信号处理和基于数据驱动三类。机理模型依赖系统方程、残差分析或状态估计，具有较好的物理解释性；但在变量众多、控制回路复杂的流程工业中，精确建模、参数辨识和模型维护均需要较高成本。过程监测领域的综述指出，数据驱动建模已成为复杂流程工业监测的重要路线，其优势在于能够直接利用历史运行数据刻画多变量过程状态^[5,6]。

基于信号处理的方法一般先构造时域、频域或时频域特征，再结合分类器完成故障识别。这类方法在旋转机械和传感器信号分析中应用较多，但特征设计往往依赖人工经验，对设备类型和工况变化较敏感。随着工业数据规模扩大，支持向量机、随机森林、人工神经网络、卷积网络等数据驱动模型逐渐被用于化工过程故障检测与诊断^[1,2,7]。

对于田纳西伊斯曼过程这类多变量时间序列，故障信息常分散在多个变量和多个采样时刻中。真正有助于区分类别的，往往是变量组合在时间窗口内形成的动态响应，而不是某个单点幅值是否异常。全卷积网络、循环网络和注意力结构因此被引入时间序列故障诊断，用于提取局部波动、长时依赖和变量间关系。与此同时，相关研究也指出，深度过程故障诊断在跨工况泛化、类别不均衡和目标域标签不足方面仍存在明显挑战^[8]。

1.2.2 迁移学习研究现状

迁移学习关注的是如何把已有场景中的知识用于数据不足的新场景。按迁移对象划分，可讨论样本迁移、特征迁移、模型迁移和关系迁移等形式；按源任务与目标任务的关系划分，又可进一步区分同构迁移、异构迁移和领域自适应等问题^[3,9]。

在故障诊断领域，迁移学习常用于跨设备、跨负载和跨工况任务。以跨工况诊断为例，源工况故障样本相对充足，而目标工况可能只有正常数据或少量未标注数据，此时重新训练目标域监督模型并不现实。深度迁移学习将神经网络表征能力与知识迁移机制结合起来，使模型先在源域学习可迁移故障特征，再用于目标域诊断^[9]。

需要注意的是，迁移并不总是带来正收益。当源域与目标域差异过大，或源域中某些类别与目标域对应类别并不接近时，模型可能受到误导并产生负迁移。对工业过程而言，同一故障在不同生产模式下可能具有不同的特征中心、变量相关结构和动态响应。因此，跨工况迁移方法除了利用源域信息，还需要判断哪些样本、哪些类别或哪些源域更适合当前目标工况。

1.2.3 领域自适应研究现状

领域自适应是迁移学习中与本文任务最接近的研究方向。其典型设定为源域拥有标签，目标域无标签或仅有少量标签，二者类别空间一致但样本分布不同。本文采用无监督领域自适应设定，即训练过程中不使用目标域标签，仅让目标域无标签样本参与表征学习和分布对齐。

现有领域自适应方法中，基于度量学习的路线通过最大均值差异、相关对齐、条件分布差异或 Wasserstein 距离等度量缩小域间差异。最优传输方法能够保留样本级匹配关系，并从分布几何角度描述源域样本向目标域样本的对应方式^[10]。DeepJDOT 进一步把最优传输放入深度特征与标签预测的联合空间，使对齐过程不仅考虑特征距离，也考虑分类语义约束^[11]。

另一类常用方法是基于对抗学习的特征对齐。领域对抗网络通过领域判别器促使特征提取器学习源域和目标域难以区分的表示；面向时间序列数据，CoDATS 使用卷积式时间序列特征提取器并结合领域对抗学习，可处理传感器序列跨域迁移任务^[12]。在多源场景下，WJDOT 通过逐源联合分布最优传输和源域权重学习，避免把多个源域简单合并为一个大源域^[13]。

针对田纳西伊斯曼过程领域自适应数据集的基准研究表明，不同生产模式确实会造成明显分布偏移，基于最优传输的方法在该基准上总体优于部分基于最大均值差异、H-distance 和对抗学习的基线^[4]。不过，这些结果也暴露出后续研究空间：DeepJDOT 类方法在小批量训练中仍可能受到强制匹配影响；伪标签若只依赖分类器最大概率，容易把早期错误继续放大；多源方法若只学习源域整体权重，则难以描述某个源域只对部分故障类别可靠的情况。

1.3 国内外研究现状总结

现有研究已经说明，工业故障诊断不再只依赖机理模型或人工特征，深度表征学习和迁移诊断正在成为跨工况问题中的常用工具。对本文使用的 TEP 多生产模式数据而言，单纯换用更复杂的分类器并不能解决全部问题。真正影响目标域性能的，是源目标样本在无标签条件下能否匹配到相近故障语义，目标样本何时可以转化为可信伪监督信号，以及多个源域中哪些模式、哪些故障类别更值得迁移。

在单源场景中，联合分布最优传输能够同时使用特征距离和标签预测信息，但其平衡

边际假设与小批量训练并不总是吻合。当一个批次内源域和目标域类别组成差异较大时，传输计划可能为了满足边际约束而保留低质量匹配。进入伪标签阶段后，分类器最大概率也不能直接等同于正确性，尤其在目标边界尚未稳定时，少量错误标签会被后续训练继续放大。多源场景的问题则更细：增加源域数量可以提供更多样本，却也可能把与目标模式相距较远的类别一起带入训练。

因此，本文把方法设计拆成两条相互衔接的路线。单源路线先处理“怎么对齐”的问题：在 DeepJDOT 基础上引入非平衡传输、源域原型和时序统计代价，尽量让匹配关系避开低质量样本对；随后处理“哪些目标样本能用”的问题，用传输、教师模型和原型三类证据共同筛选伪标签。多源路线则不再把源域看成一个整体权重，而是在 CoDATS 和 WJDOT 的基础上估计源域-故障类别关系，使某个源域可以只在它更擅长的类别上发挥作用。

1.4 核心问题与主要创新

本文的研究目标是在目标工况故障标签不可见的条件下，利用源工况有标签数据完成跨生产模式故障诊断。结合 TEP 数据中 6 个生产模式、29 个状态类别以及多变量时间窗口的特点，本文主要围绕以下三个问题展开。

第一，单源跨工况诊断中的类别结构保持问题。DeepJDOT 能够在特征和标签预测联合空间中对齐源域与目标域，但普通平衡传输在小批量类别组成不一致时容易产生错误强制匹配；同时，原始传输代价没有显式利用工业时间序列中的故障动态信息和类别原型结构。对此，本文提出时序原型非平衡联合分布对齐方法，在 DeepJDOT 基础上加入非平衡最优传输、源域类别原型、时间序列统计代价和源域监督对比学习。

第二，目标域伪标签可靠性问题。目标域标签不可用时，伪标签是利用目标样本的重要入口，但单一分类器置信度容易受早期错误预测和类别偏置影响。对此，本文提出多证据置信均衡伪标签方法，从传输计划、教师模型预测和源域原型距离三类证据中筛选目标样本，并配合动态置信阈值、类别均衡和强弱增强一致性约束，降低错误伪标签的传播风险。

第三，多源跨工况诊断中的源域负迁移问题。多源任务虽然提供了更多有标签样本，但不同源域与目标域之间的接近程度并不一致，同一源域对不同故障类别的作用也可能不同。为此，本文提出类条件源域可靠性加权方法，在 CoDATS 的卷积式时间序列表征和

WJDOT 的逐源联合分布传输之上，加入源域-故障类别可靠性矩阵，使多源迁移可以在类别层面选择源域信息。

对应上述问题，本文的主要创新点如下。

（1）提出基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法。该方法利用非平衡最优传输缓解源目标样本错误强制匹配，并通过源域类别原型和时间序列统计代价增强故障结构表达，结合源域监督对比学习提升特征空间类别可分性。

（2）提出基于多证据置信均衡伪标签的单源领域自适应故障诊断方法。该方法融合传输语义、教师预测语义和源域原型语义三类证据，对目标域样本进行一致性筛选，并结合动态置信阈值、类别均衡和强弱增强一致性约束，提高无标签目标样本的使用可靠性。

（3）提出基于类条件源域可靠性加权的多源领域自适应故障诊断方法。该方法构建源域-故障类别可靠性矩阵，使模型能够根据不同源域对不同故障类别的贡献进行选择迁移，从而缓解多源负迁移并提升结果解释性。

1.5 技术路线

本文技术路线按照数据、模型、单源方法、多源方法和实验验证展开。数据层面，本文使用田纳西伊斯曼过程领域自适应数据集，将 6 个生产模式分别作为领域；每个样本为包含 34 个连续过程变量的时间序列窗口，标签覆盖正常状态和 28 类故障。实验中目标域标签只在最终计算指标时使用，不参与训练、参数选择或模型选择。

模型层面，单源任务以 DeepJDOT 为起点，通过深度特征与标签预测的联合传输刻画源目标样本关系；多源任务以 WJDOT 为起点，保留逐源传输统计而不是把所有源域直接合并。考虑到过程数据是多变量时间序列，本文采用一维卷积式特征提取结构，并在多源方法中加入 CoDATS 风格的领域对抗约束作为表征学习补充。

方法层面，第三章针对 DeepJDOT 的平衡传输约束和故障动态利用不足，引入非平衡传输、源域类别原型、时序统计代价和源域监督对比学习。第四章在第三章模型基础上采用固定教师参考模型和三类语义证据，筛选较可信的目标伪标签。第五章面向多源任务，构造源域-故障类别可靠性矩阵，用类别粒度的权重替代单一源域整体权重。

实验层面，本文设置 6 个单源任务、3 个两源任务和 6 个五源任务，使用准确率、宏平均 F1、平衡准确率、混淆矩阵和 t-SNE 可视化进行分析。除平均性能外，实验还单独比较代表迁移方向和源域-类别权重热力图，避免只凭某一个任务的结果判断方法有效性。

1.6 论文结构

本文共分为七章，各章之间的关系如图 1-1 所示。前两章先把跨工况诊断问题和后续用到的领域自适应模型讲清楚；第三章至第五章分别对应单源对齐、单源伪标签和多源可靠性三条方法线；第六章再把这些方法放到统一的 TEP 迁移任务中比较；第七章回到方法边界和后续实验设计。

第一章说明为什么 TEP 多生产模式适合用来讨论跨工况诊断，并梳理工业过程故障诊断、迁移学习和领域自适应的相关工作。第二章则更偏向方法准备，介绍跨工况任务设定、联合分布最优传输、DeepJDOT、WJDOT 和 CoDATS，后文的三个方法章都建立在这些模型之上。

第三章和第四章都处理单源到单目标任务，但分工不同。第三章的 TPU-DeepJDOT 先解决源目标样本如何对齐，重点放在非平衡传输、源域类别原型和时间序列统计代价上；第四章的 CBTPU-DeepJDOT 则接着处理目标样本能不能参与训练的问题，通过传输语义、教师预测语义和源域原型语义筛掉风险较高的伪标签。

第五章转向多源到单目标任务，提出 CA-CCSR-WJDOT 方法。与只学习一个源域整体权重不同，该章把可靠性拆到源域-故障类别层面，并把逐源联合传输、领域对抗约束和教师先验融合放在同一训练框架中。

第六章给出实验协议和结果分析。所有无监督领域自适应方法都遵守同一划分方式，目标域标签只在预测完成后用于评价；实验任务包括 6 个单源任务、3 个两源任务和 6 个五源任务。第七章最后总结三条方法线的结论，也把计算成本、无标签模型选择和真实工业数据适用性等问题单独列出。




图 1-1 论文整体框架

第二章 跨工况领域自适应故障诊断基本方法

2.1 引言

跨工况诊断首先需要明确源工况与目标工况之间的分布差异。以田纳西伊斯曼过程为例，生产模式变化会改变连续变量的统计分布和变量间相关结构，源工况中学习到的分类边界未必能够直接适用于目标工况。由于目标模式下故障标签难以大量获取，本文将该任务建模为无监督领域自适应问题：源域提供有标签样本，目标域只提供无标签样本，训练过程不使用目标域标签。

无监督领域自适应的典型设置是源域与目标域共享相同标签空间，但样本分布不同。设源域为

$$\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}, \quad (2.1)$$

目标域为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}, \quad (2.2)$$

其中 x_i^s 和 x_j^t 表示多变量时间序列样本， y_i^s 表示源域故障类别标签。领域自适应的目标是在不使用目标域标签的条件下学习诊断函数 h ，使其在目标域样本上保持较好的分类性能。由于源域和目标域之间存在分布差异，即

$$P_s(X) \neq P_t(X), \quad (2.3)$$

直接使用源域训练得到的模型通常会出现性能退化。

在这一设定下，最优传输的作用不仅是度量两个经验分布之间的差异，还可以给出样本级跨域匹配关系^[10]。对多变量时间序列而言，特征提取器还需要保留故障动态响应，因此本章同时介绍卷积式时间序列特征提取和领域对抗学习^[14,15]。

本章内容围绕后续章节需要使用的基础方法展开：联合分布最优传输用于说明源目标样本如何匹配，DeepJDOT 给出单源联合对齐形式，WJDOT 给出多源源域加权思路，CoDATS 则提供时间序列表征和领域对抗对齐框架。

2.2 基于联合分布最优传输的领域自适应方法

最优传输以传输计划描述一个经验分布向另一个经验分布的质量搬运过程，并以总代价最小为优化目标。在领域自适应中，传输计划可以解释为源域样本与目标域样本之间的软匹配关系。设源域样本集合为 $\{x_i^s\}_{i=1}^{n_s}$ ，目标域样本集合为 $\{x_j^t\}_{j=1}^{n_t}$ ，二者之间的代价矩

阵为 $C \in \mathbb{R}^{n_s \times n_t}$ ，其中 C_{ij} 表示源样本 i 与目标样本 j 的匹配代价。最优传输问题可写为

$$\gamma^* = \arg \min_{\gamma \in \Pi(a,b)} \sum_{i=1}^{n_s} \sum_{j=1}^{n_t} \gamma_{ij} C_{ij}, \quad (2.4)$$

其中 γ 为传输计划， $\Pi(a, b)$ 表示满足源域边际分布 a 和目标域边际分布 b 的传输计划集合，即

$$\Pi(a, b) = \{\gamma \in \mathbb{R}_+^{n_s \times n_t} \mid \gamma \mathbf{1}_{n_t} = a, \gamma^T \mathbf{1}_{n_s} = b\}. \quad (2.5)$$

因此，传输计划 γ 不仅反映样本之间的距离关系，也给出了源域样本向目标域样本分配传输质量的方式。

在故障诊断场景中，仅对齐边缘特征分布并不足以保证类别判别性。如果源域某一类故障样本与目标域另一类故障样本在特征空间中被错误匹配，模型可能得到领域不变但类别混淆的表示。联合分布最优传输因此同时考虑特征空间距离和标签预测代价，使传输计划既关注源目标样本在表征空间中的接近程度，也关注源域标签与目标域预测结果之间的一致性^[16]。

2.2.1 深度联合分布最优传输方法

深度联合分布最优传输方法（Deep Joint Distribution Optimal Transport, DeepJDOT）是一类面向单源无监督领域自适应的深度最优传输方法^[11]。该方法将深度网络拆分为特征提取器和分类器两部分。为与后文方法记号保持一致，设特征提取器为 $F_\theta(\cdot)$ ，分类器为 $G_\phi(\cdot)$ ，则输入样本 x 的深度特征表示为

$$z = F_\theta(x), \quad (2.6)$$

对应的类别预测概率为

$$\hat{y} = G_\phi(z). \quad (2.7)$$

DeepJDOT 在深度特征和标签预测组成的联合空间中构造传输代价。对于源域样本 (x_i^s, y_i^s) 和目标域样本 x_j^t ，其联合传输代价通常由两部分组成：

$$C_{ij} = \lambda_f \text{dist}(F_\theta(x_i^s), F_\theta(x_j^t)) + \lambda_y \ell(y_i^s, G_\phi(F_\theta(x_j^t))), \quad (2.8)$$

其中 $\text{dist}(\cdot, \cdot)$ 表示特征空间距离， $\ell(\cdot, \cdot)$ 表示标签预测损失， λ_f 和 λ_y 分别为特征代价和标签代价的权重。第一项描述源域与目标域在深度表征空间中的距离，第二项约束目标域样本预测结果与其匹配源域标签之间的一致性。

基于上述代价矩阵，DeepJDOT 的领域自适应损失可表示为

$$\mathcal{L}_{\text{OT}} = \sum_{i=1}^{n_s} \sum_{j=1}^{n_t} \gamma_{ij} C_{ij}, \quad (2.9)$$

其中 γ_{ij} 表示源域样本 i 与目标域样本 j 之间的传输质量。训练模型时还需保留源域监督分类损失：

$$\mathcal{L}_{\text{src}} = \frac{1}{n_s} \sum_{i=1}^{n_s} \ell(y_i^s, G_\phi(F_\theta(x_i^s))). \quad (2.10)$$

因此，DeepJDOT 的总体优化目标可写为

$$\min_{\theta, \phi} \mathcal{L}_{\text{src}} + \lambda_{\text{ot}} \mathcal{L}_{\text{OT}}, \quad (2.11)$$

其中 λ_{ot} 为最优传输对齐损失的权重。

DeepJDOT 的主要特点在于不只对齐源域和目标域的边缘特征分布，而是在特征和标签预测组成的联合空间中进行对齐。这一方式能够在缩小领域差异的同时保留部分类别判别信息，适用于源域有标签、目标域无标签的跨工况故障诊断任务。但在小批量训练中，DeepJDOT 仍存在局限。普通最优传输采用平衡边际约束，要求源域和目标域样本质量均被完整匹配；当源域和目标域批次内类别组成不一致时，目标样本可能被迫与不可靠源样本建立匹配。另一方面，DeepJDOT 的代价主要由深度特征距离和标签预测损失构成，尚未显式利用工业过程时间序列中的故障动态结构和类别原型信息。在目标域预测尚不稳定的训练早期，标签预测代价也可能引入错误对齐。

因此，本文第三章在 DeepJDOT 的基础上进一步引入非平衡最优传输、源域类别原型、时间序列统计代价和源域监督对比学习，以增强单源跨工况故障诊断中的类别结构保持能力。

2.2.2 多源加权联合分布最优传输方法

在多源领域自适应场景中，模型需要利用多个有标签源域适配同一个无标签目标域。设共有 K 个源域，第 k 个源域表示为

$$\mathcal{D}_{s_k} = \{(x_i^{s_k}, y_i^{s_k})\}_{i=1}^{n_k}, \quad k = 1, 2, \dots, K, \quad (2.12)$$

目标域为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}. \quad (2.13)$$

多源领域自适应不仅需要处理源域与目标域之间的分布偏移，还需要处理不同源域之间的分布差异，即

$$P_{s_k}(X) \neq P_t(X), \quad P_{s_k}(X) \neq P_{s_l}(X), \quad k \neq l. \quad (2.14)$$

一种直接做法是将所有源域样本合并为统一源域，再执行单源领域自适应。然而，该策略会弱化源域之间的差异。当某些源域与目标域相距较远时，其样本可能干扰目标域诊断并造成负迁移。多源加权联合分布最优传输方法（Weighted Joint Distribution Optimal Transport, WJDOT）通过为不同源域分配权重，在利用多源数据的同时降低不可靠源域的影响^[13]。

对于第 k 个源域，可构造其与目标域之间的联合传输代价：

$$C_{ij}^{(k)} = \lambda_f \text{dist}(F_\theta(x_i^{s_k}), F_\theta(x_j^t)) + \lambda_y \ell(y_i^{s_k}, G_\phi(F_\theta(x_j^t))). \quad (2.15)$$

对应的最优传输损失为

$$\mathcal{L}_{\text{OT}}^{(k)} = \sum_{i=1}^{n_k} \sum_{j=1}^{n_t} \gamma_{ij}^{(k)} C_{ij}^{(k)}. \quad (2.16)$$

WJDOT 进一步引入源域权重 α_k ，使不同源域对最终目标函数的贡献不同：

$$\mathcal{L}_{\text{WJDOT}} = \sum_{k=1}^K \alpha_k \mathcal{L}_{\text{OT}}^{(k)}, \quad \sum_{k=1}^K \alpha_k = 1, \quad \alpha_k \geq 0. \quad (2.17)$$

其中， α_k 越大，表示第 k 个源域在目标域适配中占据更大权重； α_k 越小，说明该源域可能与目标域差异较大或贡献较弱。

WJDOT 的出发点是承认多个源域并不等价。对田纳西伊斯曼过程而言，不同生产模式与目标模式的接近程度不同，因此逐源建模比直接合并所有源域更符合跨工况诊断特点。

不过，源域整体权重只能回答哪个源域整体更重要，无法说明某个源域对哪一类故障更可靠。一个源模式可能对正常类和部分故障类较接近，却在其他故障类上偏移明显。因此，第五章将在 WJDOT 基础上引入类条件源域可靠性矩阵，将加权粒度推进到源域-故障类别层面。

2.3 基于卷积式时间序列领域自适应的迁移诊断方法

工业过程数据通常表现为多变量时间序列。相比图像数据或普通表格数据，过程序列同时具有时间相关性、动态变化性和变量耦合性。对于田纳西伊斯曼过程，每个样本由多个连续变量在一段时间内的采样值组成，不同故障会在时间维度上呈现不同响应模式。因

此，跨工况故障诊断中的特征提取器不仅要提取单个变量的局部变化，还要捕捉不同时间段和不同变量之间的综合故障信息。

CoDATS 是一种面向时间序列传感器数据的卷积式深度领域自适应方法。它通过卷积式时间序列特征提取器学习可迁移表征，并结合领域对抗学习减小源域与目标域之间的特征分布差异^[12]。与直接采用图像领域自适应网络不同，CoDATS 面向序列数据设计特征提取结构，因此适合作为本文多源跨工况实验中的对比基线和表征基础。

2.3.1 卷积式时间序列特征提取方法

卷积神经网络可通过局部卷积核提取时间序列中的局部动态模式。在多变量时间序列故障诊断中，输入样本可表示为

$$x \in \mathbb{R}^{V \times L}, \quad (2.18)$$

其中 V 表示变量或通道数， L 表示时间窗口长度。对于田纳西伊斯曼过程数据， V 对应连续过程变量数量， L 对应一个样本窗口内的采样时间长度。

一维卷积层通过在时间维度上滑动卷积核提取局部时间特征。设第 l 层输入为 $U^{(l-1)}$ ，卷积核参数为 $W^{(l)}$ ，偏置为 $b^{(l)}$ ，则卷积输出可表示为

$$U^{(l)} = \varphi(W^{(l)} * U^{(l-1)} + b^{(l)}), \quad (2.19)$$

其中 $*$ 表示卷积运算， $\varphi(\cdot)$ 表示非线性激活函数。多层卷积结构逐步扩大感受野，使模型能够从短期局部波动学习到更高层次的故障模式。

在时间序列分类任务中，全卷积网络常由多个一维卷积块和全局平均池化层组成^[14,15]。卷积块负责提取局部动态特征，归一化层用于稳定训练过程，非线性激活函数增强模型表达能力，全局平均池化层则将时间维度特征压缩为固定长度向量。设最后一层卷积输出为 $U \in \mathbb{R}^{d_z \times L'}$ ，全局平均池化可表示为

$$z_r = \frac{1}{L'} \sum_{t=1}^{L'} U_{r,t}, \quad r = 1, 2, \dots, d_z, \quad (2.20)$$

其中 z 为最终时间序列特征表示。

卷积式时间序列特征提取方法适合处理多变量过程数据。卷积核能够捕捉故障发生后过程变量在局部时间范围内的变化趋势，多层卷积结构可以学习较长时间范围内的动态响应。全局平均池化减少了模型参数数量，有助于降低过拟合风险；相比循环神经网络，卷积结构训练效率较高，也更适合较大规模的多变量时间序列实验。

在本文中，卷积式时间序列特征提取器不仅用于对比方法 CoDATS，也为第五章的多

源改良方法提供基础表征。由于最优传输代价依赖样本在特征空间中的距离，特征提取质量会直接影响传输计划的可靠性。若特征表示本身难以区分故障类别，即使后续引入最优传输或源域加权机制，也难以取得稳定适配效果。因此，利用卷积式时间序列网络构建可靠故障表征，是多源跨工况诊断的重要基础。

2.3.2 基于领域对抗学习的特征对齐方法

领域对抗学习是一类典型的深度领域自适应方法。该方法利用领域判别器判断特征来自源域还是目标域，同时训练特征提取器生成使领域判别器难以区分的特征表示。通过这一对抗过程，特征提取器在保持源域分类能力的同时，学习源域和目标域共享的领域不变特征^[17]。

设特征提取器为 $F_\theta(\cdot)$ ，故障分类器为 $G_\phi(\cdot)$ ，领域判别器为 $D_\omega(\cdot)$ 。对于源域样本，分类器根据特征输出故障类别预测；对于源域和目标域样本，领域判别器判断其所属领域。源域分类损失为

$$\mathcal{L}_{\text{src}} = -\frac{1}{n_s} \sum_{i=1}^{n_s} \sum_{c=1}^{N_c} \mathbb{I}(y_i^s = c) \log G_{\phi,c}(F_\theta(x_i^s)), \quad (2.21)$$

其中 N_c 为故障类别数， $G_{\phi,c}(\cdot)$ 表示分类器输出属于第 c 类的概率。

领域判别损失可表示为

$$\mathcal{L}_{\text{dom}} = -\frac{1}{n_s} \sum_{i=1}^{n_s} \log D_\omega(F_\theta(x_i^s)) - \frac{1}{n_t} \sum_{j=1}^{n_t} \log (1 - D_\omega(F_\theta(x_j^t))). \quad (2.22)$$

领域判别器通过最小化 $\mathcal{L}_{\text{dom}}$ 区分源域和目标域；特征提取器则朝相反方向更新，使两域特征在判别器看来尽量接近。该对抗过程可写为

$$\min_{F_\theta, G_\phi} \max_{D_\omega} \mathcal{L}_{\text{src}} - \lambda_d \mathcal{L}_{\text{dom}}, \quad (2.23)$$

其中 λ_d 为领域对抗损失权重。实际训练中通常借助梯度反转思想实现这一目标，使领域判别器倾向于区分源域和目标域，而特征提取器倾向于学习使二者难以区分的共享表示。

CoDATS 将卷积式时间序列特征提取结构与领域对抗学习相结合，用于时间序列传感器数据的领域自适应。对于多源场景，CoDATS 可利用多个源域的有标签数据训练分类器，并通过领域对抗约束缩小源域和目标域之间的特征差异。其优势在于能够直接面向时间序列数据学习深度表征，并通过对抗训练增强跨域泛化能力。

不过，领域对抗学习也存在局限。该方法主要强调源域和目标域整体特征分布难以区分，但不能保证同一故障类别在不同领域之间正确对齐。若过度追求领域不变性，可能削

弱类别判别信息，导致故障类别边界模糊。在多源场景中，不同源域对目标域的贡献并不一致，若领域对抗学习简单合并所有源域，则难以区分有益源域和不可靠源域。此外，领域判别器提供的是整体领域混淆信号，缺少对具体源域和具体故障类别迁移贡献的解释。

第五章便沿着这条思路展开：以 CoDATS 的卷积式时间序列表征和领域对抗约束作为基础，再保留 WJDOT 的逐源传输统计，用类条件可靠性权重刻画源域与故障类别之间的细粒度关系。这样，多源方法不只是让特征“看起来像同一个域”，还可以解释某个源模式主要贡献了哪些故障类别。

2.4 本章小结

本章围绕后续方法用到的三个基础环节展开。首先，最优传输及其联合分布形式给出了源域样本与目标域样本之间的匹配机制；在 DeepJDOT 中，这种匹配同时考虑深度特征距离和标签预测损失，因而比单纯边缘分布对齐更贴近故障分类任务。

其次，WJDOT 将联合分布最优传输扩展到多源设定，通过源域权重区分不同源域对目标域的贡献。该设定适合田纳西伊斯曼过程的多生产模式任务，但源域整体权重仍不足以表达类别层面的可靠性差异。

最后，卷积式时间序列特征提取和领域对抗学习为多变量时间序列提供了基础表征。CoDATS 能够学习跨域共享特征，但整体领域混淆信号不能保证同类故障在不同领域之间正确对齐。第三章至第五章将在这些基础上分别处理小批量错误匹配、目标伪标签可靠性和多源类别级负迁移问题。

第三章 基于时序原型非平衡联合分布对齐的 单源领域自适应故障诊断方法

3.1 引言

第二章已经给出 DeepJDOT 的基本形式：源样本和目标样本不是只在特征空间中比较，而是在深度特征与标签预测组成的联合空间中建立传输关系。这样的设计比单纯边缘分布对齐更有利于保留类别语义^[11,16]。不过，把它直接用于 TEP 跨生产模式诊断时，有两个细节不能忽略。

第一个细节来自数据形态。TEP 样本是多变量时间序列，同一故障换到另一个生产模式后，可能不只是特征中心发生平移，变量波动幅度和一阶变化趋势也会一起变化。若传输代价只看深度特征距离和目标预测损失，原始过程窗口中的动态信息就没有被显式利用。第二个细节来自小批量训练。源域批次和目标域批次的类别组成很难每次都刚好对应，平衡最优传输却要求两侧质量完整匹配；当某一类在批内缺失或目标样本暂时没有合适对应项时，传输计划仍可能把它分配给错误源类。

本章的改动围绕这两个细节展开。首先，将平衡传输替换为非平衡小批量传输，允许低可靠匹配质量被削减；其次，维护源域类别原型，用目标样本到各源类原型的相对距离修正传输代价；同时，从原始过程窗口中提取均值、标准差和一阶差分统计量，补充深度特征中可能被压缩掉的时序信息。训练前期还加入源域监督对比学习，使源域特征先形成较清楚的类内聚集和类间分离。本章方法不使用目标域标签，目标域标签只在最终实验评价阶段使用。方法整体结构如图 3-1 所示。

3.2 时序原型非平衡联合分布对齐基本原理

设源域样本为 $\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$ ，目标域无标签样本为 $\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}$ 。其中， $x \in \mathbb{R}^{V \times L}$ 表示包含 V 个过程变量和 L 个时间步的多变量时间序列窗口， $y_i^s \in \{1, 2, \dots, N_c\}$ 为源域故障类别标签。模型由时间序列特征提取器 F_θ 和分类器 G_ϕ 组成：

$$z = F_\theta(x), \quad p = G_\phi(z). \quad (3.1)$$

其中 z 为深度特征表示， p 为类别预测概率。

本文采用一维全卷积网络作为特征提取器。其结构包括核大小为 9、5、3 的三层一维卷积块，每个卷积块后接归一化和 ReLU 激活，最后在时间维度上进行全局平均池化，得




图 3-1 时序原型非平衡联合分布对齐方法架构示意

到固定维度的样本表示。全卷积网络是时间序列分类中常用且表现稳定的基线结构^[14,15]，适合在 TEP 多变量时间序列上提取局部动态响应和全局故障表征。

3.2.1 非平衡最优传输对齐原理

最优传输从分布几何角度度量两个经验分布之间的差异，是领域自适应中刻画源目标分布偏移的重要工具^[10,18]。给定源域小批量特征 $\{z_i^s\}_{i=1}^{n_s^{\text{bat}}}$ 和目标域小批量特征 $\{z_j^t\}_{j=1}^{n_t^{\text{bat}}}$ ，传统平衡最优传输要求传输计划 γ 同时满足固定源边际和目标边际：

$$\gamma \mathbf{1}_{n_t^{\text{bat}}} = a, \quad \gamma^T \mathbf{1}_{n_s^{\text{bat}}} = b. \quad (3.2)$$

在小批量领域自适应中，该约束可能过强。若当前小批量中源域某些类别样本过多，而目标域对应类别样本不足，平衡约束会要求所有源域质量被完整分配，进而可能产生错误匹配。

非平衡最优传输通过放松边际约束缓解该问题。受非平衡小批量最优传输领域自适应思想启发^[19]，本文在传输目标中加入边际偏离惩罚：

$$\mathcal{L}_{\text{UOT}} = \min_{\gamma \geq 0} \langle \gamma, C \rangle + \varepsilon \text{KL}(\gamma \| ab^T) + \tau_s \text{KL}(\gamma \mathbf{1}_{n_t^{\text{bat}}} \| a) + \tau_t \text{KL}(\gamma^T \mathbf{1}_{n_s^{\text{bat}}} \| b), \quad (3.3)$$

其中 C 为联合传输代价矩阵, ε 为熵正则系数, τ_s 和 τ_t 分别控制源边际与目标边际的放松程度。 τ_s 、 τ_t 越大, 传输计划越接近平衡传输; 二者较小时, 部分不可靠质量可以被削减。小批量传输计划可通过非平衡 Sinkhorn 形式求解, 传输质量、边际偏差和传输熵等量可用于分析源目标匹配状态。

在本文方法中, 非平衡传输并不改变无监督领域自适应的基本设定。目标域标签不参与传输计划求解, 传输计划只由源域标签、源目标特征、目标预测分布、源域原型和时序统计代价共同决定。

3.2.2 源域类别原型约束原理

类别原型通过类内样本特征均值表示类别中心, 是度量学习和小样本学习中的常用思想^[20]。在领域自适应中, 原型结构也常用于缓解伪标签噪声和维护目标域语义结构^[21]。本文并不直接使用目标标签构造目标原型, 而是在训练过程中维护源域类别原型, 并利用源域类别结构约束目标样本的传输匹配。

设第 c 类源域原型为 μ_c 。对于一个源域小批量, 先对源域特征进行归一化, 再按源标签求类均值:

$$\bar{\mu}_c = \frac{1}{|\mathcal{B}_s^c|} \sum_{i: y_i^s = c} \frac{z_i^s}{\|z_i^s\|_2}. \quad (3.4)$$

为降低小批量波动, 本文采用指数滑动平均更新源域原型:

$$\mu_c \leftarrow \frac{\rho \mu_c + (1 - \rho) \bar{\mu}_c}{\|\rho \mu_c + (1 - \rho) \bar{\mu}_c\|_2}, \quad (3.5)$$

其中 ρ 为原型动量系数。若某一类别首次在小批量中出现, 则直接用当前批次均值初始化该类别原型; 若类别在当前批次中缺失, 则保持其历史原型不变。

在构造传输代价时, 本文不是简单地将目标样本到其匹配源类原型的距离作为绝对惩罚, 而是使用相对原型代价。设目标样本 x_j^t 到第 c 类源域原型的距离为

$$d_{cj}^{\text{proto}} = \left\| \frac{z_j^t}{\|z_j^t\|_2} - \mu_c \right\|_2^2. \quad (3.6)$$

若源样本 x_i^s 属于类别 y_i^s , 则相对原型代价定义为

$$r_{ij}^{\text{proto}} = \text{clip} \left(\frac{d_{y_i^s j}^{\text{proto}} - \bar{d}_{-y_i^s, j}^{\text{proto}}}{\sigma_j^{\text{proto}} + \epsilon}, r_{\min}, r_{\max} \right), \quad (3.7)$$

其中 $\bar{d}_{-y_i^s, j}^{\text{proto}}$ 表示目标样本到其他有效源类原型距离的均值, σ_j^{proto} 表示有效类别原型距离的标准差。该设计关注“目标样本是否相对更接近当前源类原型”, 从而比绝对距离更适合跨工况特征尺度变化场景。

3.2.3 时间序列统计代价构建原理

TEP 跨工况诊断数据具有明显的多变量时序特征。相关基准研究指出，不同生产模式之间存在显著分布差异，尤其是不同模式下变量相关结构和 Wasserstein 距离会发生变化^[4]。因此，本文在深度特征和标签预测代价之外，额外构造时间序列统计代价，用于补充原始过程窗口层面的动态信息。

本文的时间序列统计代价面向 TEP 跨工况数据特点提出，其设计受到时间序列深度表征与全卷积分类结构的启发^[14,15]，具体统计描述符及其与非平衡联合传输的结合方式则根据跨工况过程数据的特点进行设计。

对于样本 $x \in \mathbb{R}^{V \times L}$ ，先沿时间维度计算每个变量的均值和标准差：

$$\bar{x}_{\text{seq}}(x) = \frac{1}{L} \sum_{t=1}^L x_{:,t}, \quad \sigma_{\text{seq}}(x) = \sqrt{\frac{1}{L} \sum_{t=1}^L (x_{:,t} - \bar{x}_{\text{seq}}(x))^2}. \quad (3.8)$$

同时计算一阶差分 $\Delta x_{:,t} = x_{:,t} - x_{:,t-1}$ 的均值和标准差：

$$\bar{\Delta}_{\text{seq}}(x) = \frac{1}{L-1} \sum_{t=2}^L \Delta x_{:,t}, \quad \sigma_{\Delta}(x) = \sqrt{\frac{1}{L-1} \sum_{t=2}^L (\Delta x_{:,t} - \bar{\Delta}_{\text{seq}}(x))^2}. \quad (3.9)$$

然后将四类统计量拼接并归一化，得到时序描述符：

$$\psi(x) = \frac{[\bar{x}_{\text{seq}}(x), \sigma_{\text{seq}}(x), \bar{\Delta}_{\text{seq}}(x), \sigma_{\Delta}(x)]}{\|[\bar{x}_{\text{seq}}(x), \sigma_{\text{seq}}(x), \bar{\Delta}_{\text{seq}}(x), \sigma_{\Delta}(x)]\|_2 + \epsilon}. \quad (3.10)$$

源样本与目标样本之间的时序统计代价为

$$c_{ij}^{\text{temp}} = \frac{1}{d_{\psi}} \|\psi(x_i^s) - \psi(x_j^t)\|_2^2, \quad (3.11)$$

其中 d_{ψ} 为描述符维度。该代价能够在不引入目标标签的前提下，使传输计划同时参考故障窗口的水平、波动和变化趋势。

3.3 基于时序原型非平衡联合分布对齐的诊断模型构建

3.3.1 单源跨工况诊断问题建模

本章方法面向一个有标签源工况和一个无标签目标工况的单源领域自适应设置。训练时每一步从源域采样小批量 $\mathcal{B}_s$ ，从目标域采样小批量 $\mathcal{B}_t$ 。源域小批量用于计算监督分类损失和更新源域类别原型，目标域小批量只以无标签形式参与特征对齐。

源域监督分类损失定义为

$$\mathcal{L}_{\text{src}} = -\frac{1}{|\mathcal{B}_s|} \sum_{(x_i^s, y_i^s) \in \mathcal{B}_s} \log p_{\theta, \phi}(y_i^s | x_i^s). \quad (3.12)$$

其中 $p_{\theta,\phi}(\cdot|x)$ 表示由 $G_\phi(F_\theta(x))$ 得到的 softmax 概率。该损失用于保证模型在源工况上具备基本的故障类别识别能力。

在训练调度上，本文设置源域预热阶段和对齐阶段。预热阶段主要优化源域分类损失和监督对比损失，使特征空间先形成相对稳定的类别结构；随后逐步启用最优传输对齐项、原型代价项和时间序列统计代价项，以避免训练初期目标预测不稳定时过早施加强对齐约束。

3.3.2 非平衡联合传输代价构建

对于源样本 x_i^s 和目标样本 x_j^t ，本章方法构造由深度特征代价、标签预测代价、原型相对代价和时序统计代价组成的联合代价：

$$C_{ij} = \lambda_f c_{ij}^f + \lambda_y c_{ij}^y + \lambda_p(\nu) r_{ij}^{\text{proto}} + \lambda_{\text{temp}}(\nu) c_{ij}^{\text{temp}}. \quad (3.13)$$

其中，深度特征代价为

$$c_{ij}^f = \frac{1}{d_z} \|z_i^s - z_j^t\|_2^2, \quad (3.14)$$

d_z 为特征维度。标签预测代价使用源域真实标签与目标域预测概率之间的交叉熵：

$$c_{ij}^y = -\log p_{\theta,\phi}(y_i^s | x_j^t). \quad (3.15)$$

其中 λ_f 和 λ_y 分别控制特征代价与标签预测代价的相对贡献，原型代价权重和时序统计代价权重采用逐步增大的预热调度。

基于联合代价矩阵 C ，本文求解非平衡传输计划 γ^* ，并将其代入训练损失：

$$\mathcal{L}_{\text{align}} = \langle \gamma^*, C^{\text{loss}} \rangle + \varepsilon \text{KL}(\gamma^* \| ab^T) + \tau_s \text{KL}(\gamma^* \mathbf{1} \| a) + \tau_t \text{KL}((\gamma^*)^T \mathbf{1} \| b). \quad (3.16)$$

其中 C^{loss} 与求解传输计划的代价保持一致，但标签项在训练目标中使用交叉熵形式，以便对目标预测形成有效约束。传输计划由当前代价矩阵估计，训练过程主要通过代价项更新特征提取器和分类器。

3.3.3 源域原型与时序统计约束融合

源域原型和时序统计代价并非独立训练分支，而是直接进入非平衡联合传输代价。其作用主要体现在传输计划求解阶段：当目标样本与某个源类原型相对接近，且原始时序统计特征与某个源样本更相似时，对应传输代价会降低；反之则提高匹配代价。

为了保证训练稳定，本文采用延迟启动和线性预热策略。设原型代价基础权重为 λ_p^0 ，

启动步数为 ν_p ，预热步数为 S_p ，则第 ν 个训练步的原型权重为

$$\lambda_p(\nu) = \lambda_p^0 \min \left(\frac{\max(\nu - \nu_p, 0)}{S_p}, 1 \right). \quad (3.17)$$

时序统计代价权重 $\lambda_{\text{temp}}(\nu)$ 采用相同形式。

原型代价和时序统计代价均由启动时刻和预热长度控制：训练早期保持较弱约束，随后线性增大至预设权重。

这种融合方式分别从类别结构和原始时序统计两个层面约束传输计划。原型代价刻画目标样本与源类别的相对关系，有助于缓解联合传输中的类别混淆；时序统计代价补充均值、波动和变化趋势信息，能够在深度特征尚未完全稳定时提供过程动态约束。二者均不依赖目标标签，因此符合无监督领域自适应设定。

3.3.4 源域监督对比特征学习

为进一步增强源域特征空间的类别判别性，本文在训练前期加入源域监督对比学习。监督对比学习通过拉近同类别样本特征、推远不同类别样本特征，提高表示空间的类内紧凑性和类间分离性^[22]。

设一个源域小批量中第 i 个样本的归一化特征为 $\tilde{z}_i$ ，其同类正样本集合为

$$\mathcal{P}(i) = \{k \neq i \mid y_k^s = y_i^s\}. \quad (3.18)$$

源域监督对比损失为

$$\mathcal{L}_{\text{supcon}} = -\frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \frac{1}{|\mathcal{P}(i)|} \sum_{r \in \mathcal{P}(i)} \log \frac{\exp(\tilde{z}_i^T \tilde{z}_r / T_{\text{con}})}{\sum_{a \neq i} \exp(\tilde{z}_i^T \tilde{z}_a / T_{\text{con}})}, \quad (3.19)$$

其中 $\mathcal{I}$ 表示存在至少一个同类正样本的源域样本集合， T_{con} 为对比学习温度系数。该损失只使用源域标签，不使用目标域标签；其主要作用于源域预热阶段，随后保持较小权重，避免对后续跨域对齐产生过强约束。

3.3.5 总体目标函数与算法流程

综上，本章方法的总体目标函数为

$$\mathcal{L}_{\text{TPU}} = \mathcal{L}_{\text{src}} + \lambda_{\text{supcon}}(\nu) \mathcal{L}_{\text{supcon}} + \lambda_{\text{ot}}(\nu) \mathcal{L}_{\text{align}}, \quad (3.20)$$

其中 $\lambda_{\text{supcon}}(\nu)$ 为监督对比损失权重， $\lambda_{\text{ot}}(\nu)$ 为非平衡联合传输对齐权重。 $\lambda_{\text{ot}}(\nu)$ 采用逐步启用调度，并在源域预热阶段保持为零； $\mathcal{L}_{\text{align}}$ 内部还包含逐步启动的原型代价和时序统计代价。

本章方法的训练流程如算法 1 所示。

算法 1: 时序原型非平衡联合分布对齐训练流程

输入: 源域有标签数据 $\mathcal{D}_s$, 目标域无标签数据 $\mathcal{D}_t$, 训练步数 N_{iter}

输出: 特征提取器 F_θ 与分类器 G_ϕ

- 1 初始化特征提取器、分类器和源域类别原型, 原型初始状态标记为未激活
- 2 **循环** $\nu = 1, 2, \dots, N_{\text{iter}}$ **执行**
 - 3 从源域采样有标签小批量 $\mathcal{B}_s$, 从目标域采样无标签小批量 $\mathcal{B}_t$
 - 4 计算源域和目标域深度特征及分类输出
 - 5 根据当前源域小批量更新源域类别原型
 - 6 计算源域分类损失 $\mathcal{L}_{\text{src}}$ 和源域监督对比损失 $\mathcal{L}_{\text{supcon}}$
 - 7 构造深度特征代价、标签预测代价、原型相对代价和时间序列统计代价
 - 8 采用非平衡 Sinkhorn 形式求解小批量传输计划 γ^*
 - 9 计算非平衡联合传输损失 $\mathcal{L}_{\text{align}}$
 - 10 按当前训练步的权重调度组合源域分类、监督对比和传输对齐损失, 并更新模型参数
- 11 **结束循环**

与普通 DeepJDOT 相比, 本文方法在不使用目标标签的前提下, 引入非平衡传输、源域类别原型和原始时间窗口统计代价, 使传输计划能够削减不可靠质量, 并参考类别中心关系和时序动态信息, 因此更适合 TEP 跨工况故障诊断场景。

3.4 本章小结

本章的 TPU-DeepJDOT 主要对 DeepJDOT 做了三处调整。第一, 非平衡 Sinkhorn 传输放松了小批量边际约束, 使一些明显不合适的匹配不必被硬性保留。第二, 源域类别原型被作为类别结构参照, 用目标样本相对接近哪个源类来影响传输代价。第三, 原始窗口的均值、标准差和一阶差分统计量被转化为时序统计代价, 补充故障动态信息。源域预热阶段加入的监督对比学习, 则用于先把源域特征空间整理得更可分。

这一步完成后, 目标域样本仍主要通过传输代价参与训练, 还没有真正成为监督信号。第四章就在这个基础上继续推进: 哪些目标样本可以被赋予伪标签, 哪些样本应该暂时放过, 需要由传输计划、教师模型和源域原型共同判断。

第四章 基于多证据置信均衡伪标签的 单源领域自适应故障诊断方法

4.1 引言

第三章已经改善了单源对齐，但目标域样本在训练中仍然比较“被动”：它们参与传输代价，却没有作为明确的监督样本使用。训练到中后期后，一部分目标样本的预测会变得稳定，这些样本如果完全不用，目标域边界会停留在较粗的对齐结果上；但如果直接采用分类器最大概率作为伪标签，又容易把早期错误固定下来。TEP 跨模式任务类别数较多，模式 2 等目标域与其他模式差异也较明显，伪标签一旦偏向少数高置信类别，后续训练很容易继续放大这种偏置。

本章采用更保守的做法：目标样本能否进入伪标签集合，不由学生分类器单独决定。教师模型由同一迁移场景下训练得到的 TPU-DeepJDOT 阶段模型初始化，并在后续训练中保持固定；学生模型同样从该阶段模型出发，只在多证据伪标签目标下做小幅微调。筛选时同时使用三类语义分布：非平衡传输计划给出的传输语义、固定教师模型给出的预测语义，以及源域原型给出的原型语义。只有当这些证据在类别判断上相互接近，且传输语义熵较低时，目标样本才被纳入伪标签学习。方法整体结构如图 4-1 所示。




图 4-1 多证据置信均衡伪标签方法架构示意

4.2 多证据置信均衡伪标签学习基本原理

4.2.1 目标域伪标签学习原理

伪标签学习将模型对无标签样本的高置信预测作为临时监督信号，以扩大可训练样本集合^[23]。在领域自适应中，伪标签还可以帮助目标域样本形成更清晰的类别结构，但其可靠性会受到源目标分布偏移和模型过置信错误预测影响。原型式目标结构学习和伪标签去噪研究表明，引入类别结构信息有助于缓解伪标签噪声^[21]。

在本文场景中，若仅使用分类器输出的最大概率作为伪标签依据，目标域样本可能因跨工况偏移而被错误地高置信分类；高置信样本的类别分布也可能不均衡，使模型持续强化少数类别。因此，本章不直接采用单一分类器置信度，而是构建由传输、教师和原型三类证据组成的软伪标签分布。

设目标样本 x_j^t 的融合语义分布为 q_j^{mix} ，其伪标签为

$$\hat{y}_j^t = \arg \max_c q_{jc}^{\text{mix}}, \quad (4.1)$$

置信度为

$$\kappa_j = \max_c q_{jc}^{\text{mix}}. \quad (4.2)$$

只有当 κ_j 超过动态阈值且三类证据之间差异较小时，样本才被纳入伪标签集合。

4.2.2 教师参考模型与一致性学习原理

教师模型一致性学习通过比当前学生模型更稳定的预测分布，为无标签样本提供软监督信号。**Mean Teacher** 方法表明，权重平均教师模型可为无标签样本提供更平滑的一致性目标^[24]。在本文单源方法递进关系中，第四章方法进一步利用第三章已经训练得到的 TPU-DeepJDOT 模型作为教师参考模型。设第三章模型参数为 Θ_{TPU} ，则教师模型和学生模型初始化为

$$\bar{\Theta} \leftarrow \Theta_{\text{TPU}}, \quad \Theta \leftarrow \Theta_{\text{TPU}}, \quad (4.3)$$

其中 $\Theta = (\theta, \phi)$ 为学生模型参数集合， $\bar{\Theta} = (\bar{\theta}, \bar{\phi})$ 为教师模型参数集合。教师参考模型不使用目标域标签训练，其来源为前一阶段无监督领域自适应模型；当采用固定教师参考模型时， $\bar{\Theta}$ 在后续训练中保持不变，用于防止伪标签微调破坏第三章已获得的稳定决策边界。

若不引入前序教师参考模型，也可以采用指数滑动平均教师形式：

$$\bar{\Theta} \leftarrow \xi \bar{\Theta} + (1 - \xi) \Theta, \quad (4.4)$$

其中 ξ 为指数滑动平均衰减系数。本文实验以固定的 TPU-DeepJDOT 教师参考模型作为主要设置，指数滑动平均形式仅作为无前序教师模型时的补充形式。

对于目标样本的弱增强视图 $a_w(x_j^t)$ ，教师模型输出预测分布：

$$q_j^{\text{cls}} = \text{softmax} \left(\frac{G_{\bar{\phi}}(F_{\bar{\theta}}(a_w(x_j^t)))}{T_{\text{tea}}} \right), \quad (4.5)$$

其中 T_{tea} 为教师温度系数。该分布作为目标域预测语义证据，同时也用于强弱增强一致性约束。由于教师参考模型来自第三章模型，第四章的伪标签学习是在已有单源对齐结果之上的二阶段细化，而不是从随机初始化重新进行目标域伪标签训练。

4.2.3 类别均衡约束原理

工业故障诊断数据常存在类别不均衡，伪标签集合的不均衡程度可能比源域标签更明显。若高置信伪标签集中在少数类别，模型会进一步偏向这些类别，形成自强化偏差。类别均衡学习通过调整类别权重或类别先验，缓解长尾类别被忽略的问题^[25]。自然不均衡伪标签研究也指出，伪标签偏置会影响无标签学习效果，需要引入去偏置机制^[26]。

本文的类别均衡主要作用于被接受的伪标签集合。设当前被接受样本的伪标签类别频率为 $\hat{\pi}_c$ ，则对强增强目标样本的未归一化预测得分进行对数先验调整：

$$\tilde{u}_{jc} = u_{jc} - \eta_{\text{bal}} \log(\hat{\pi}_c + \epsilon), \quad (4.6)$$

其中 u_{jc} 为强增强视图的原始预测得分， η_{bal} 为类别均衡调整强度。该调整会降低频繁伪标签类别的相对优势，提高稀有伪标签类别被学习的机会。类似的分布对齐思想也在半监督学习和领域自适应统一框架中得到关注^[27,28]，但本文并未使用目标真实类别先验，而是仅根据当前接受的伪标签统计进行训练时校正。

4.3 基于多证据置信均衡伪标签的目标域样本利用策略

4.3.1 传输语义分布估计

第三章的非平衡传输计划不仅给出源目标样本之间的匹配关系，还可以提供目标样本的类别语义分布。设传输计划为 γ ，源样本标签为 y_i^s 。对于目标样本 x_j^t ，来自第 c 类源样本的传输质量为

$$m_{cj}^{\text{ot}} = \sum_{i: y_i^s = c} \gamma_{ij}. \quad (4.7)$$

归一化后得到传输语义分布：

$$q_{jc}^{\text{ot}} = \frac{m_{cj}^{\text{ot}}}{\sum_{c'=1}^{N_c} m_{c'j}^{\text{ot}} + \epsilon}. \quad (4.8)$$

若某个目标样本主要从少数源类接收传输质量，则 q_j^{ot} 熵较低，说明传输计划对该样本的类别语义较明确；若多个源类同时向其传输，则熵较高，说明该样本不适合作为可靠伪标签。本文用归一化熵

$$H(q_j^{\text{ot}}) = -\frac{1}{\log N_c} \sum_{c=1}^{N_c} q_{jc}^{\text{ot}} \log(q_{jc}^{\text{ot}} + \epsilon) \quad (4.9)$$

作为传输语义可靠性指标之一。

4.3.2 教师预测语义分布估计

教师预测语义分布 q_j^{cls} 来自教师模型对目标弱增强样本的预测。在本文实验设定中，该教师模型由第三章 TPU-DeepJDOT 阶段模型得到；若不引入前序教师模型，则可由指数滑动平均教师提供。相比当前正在接受伪标签微调的学生模型，固定教师参考模型保留了前一阶段较稳定的跨域对齐边界，因此 q_j^{cls} 既提供类别预测证据，也作为强增强一致性学习的目标分布。

本文只使用教师模型对目标无标签样本的输入输出关系，不引入目标标签。教师参考模型来自目标标签不可见的第三章训练过程，不直接接受目标标签监督，因此可为目标样本提供较稳定的预测语义证据。

4.3.3 源域原型语义分布估计

源域原型语义分布由目标样本特征到各源类原型的距离计算得到。设源域类别原型为 $\{\mu_c\}_{c=1}^{N_c}$ ，目标弱增强样本特征为 z_j^t 。目标样本到第 c 类源域原型的距离为

$$d_{jc}^{\text{proto}} = \left\| \frac{z_j^t}{\|z_j^t\|_2} - \mu_c \right\|_2^2. \quad (4.10)$$

原型语义分布定义为

$$q_{jc}^{\text{proto}} = \frac{\exp(-d_{jc}^{\text{proto}}/T_{\text{proto}})}{\sum_{c'=1}^{N_c} \exp(-d_{jc'}^{\text{proto}}/T_{\text{proto}})}, \quad (4.11)$$

其中 T_{proto} 为原型温度系数。若某些源类原型尚未被激活，则在计算中对其进行屏蔽，避免未初始化原型影响伪标签判断。

4.3.4 多证据一致性筛选机制

本章的关键设计在于融合传输计划、教师预测和原型距离三类证据，而不是依赖单一置信度来源。具体地，对三个语义分布进行幂加权几何平均：

$$q_{jc}^{\text{mix}} = \frac{(q_{jc}^{\text{ot}})^{\alpha_{\text{ot}}}(q_{jc}^{\text{cls}})^{\alpha_{\text{cls}}}(q_{jc}^{\text{proto}})^{\alpha_{\text{proto}}}}{\sum_{c'=1}^{N_c} (q_{jc'}^{\text{ot}})^{\alpha_{\text{ot}}}(q_{jc'}^{\text{cls}})^{\alpha_{\text{cls}}}(q_{jc'}^{\text{proto}})^{\alpha_{\text{proto}}}}, \quad (4.12)$$

其中 α_{ot} 、 α_{cls} 和 α_{proto} 分别控制三类证据的贡献。该融合也可等价地在对数概率空间中完成加权后再归一化，以提高数值稳定性。

设三类证据的最大概率类别分别为

$$\hat{y}_j^{\text{ot}}, \quad \hat{y}_j^{\text{cls}}, \quad \hat{y}_j^{\text{proto}}. \quad (4.13)$$

若三者完全一致，则该样本具备较强语义一致性。对于三者不完全一致但分布差异很小的样本，本文使用 Jensen–Shannon 差异作为补充筛选标准：

$$D_{\text{JS}} = \frac{1}{3} \sum_{q \in \{q^{\text{ot}}, q^{\text{cls}}, q^{\text{proto}}\}} \text{KL}(q \| \bar{q}), \quad \bar{q} = \frac{q^{\text{ot}} + q^{\text{cls}} + q^{\text{proto}}}{3}. \quad (4.14)$$

最终接受条件为

$$\mathcal{A}_j = [\hat{y}_j^{\text{ot}} = \hat{y}_j^{\text{cls}} = \hat{y}_j^{\text{proto}} \text{ or } D_{\text{JS}} \leq \delta_{\text{JS}}] \wedge \left[\max_c q_{jc}^{\text{mix}} \geq \vartheta(\nu) \right] \wedge [H(q_j^{\text{ot}}) \leq h_{\text{ot}}]. \quad (4.15)$$

其中 δ_{JS} 为分布差异阈值， h_{ot} 为传输语义熵阈值。该机制在传输、教师和原型三类证据融合的基础上形成目标样本筛选规则，用于降低单一预测来源带来的伪标签偏差。

4.3.5 动态置信阈值与类别均衡机制

伪标签阈值采用动态下降策略。设伪标签启动步数为 ν_0 ，阈值从 ϑ_{start} 逐步下降到 ϑ_{end} ：

$$\vartheta(\nu) = \vartheta_{\text{start}} + \min \left(\frac{\max(\nu - \nu_0, 0)}{S_{\vartheta}}, 1 \right) (\vartheta_{\text{end}} - \vartheta_{\text{start}}). \quad (4.16)$$

训练早期阈值较高，只接受最可靠目标样本；随着模型稳定，阈值逐渐降低，使更多目标样本参与训练。

为避免一次迭代中接受过多低质量伪标签，本文设置最大接受比例限制。若满足条件的样本数超过该比例，则根据融合置信度、JS 差异和传输熵构造排序分数，只保留得分最高的一部分样本。

对于被接受样本集合 $\mathcal{A}$ ，伪标签学习使用软目标交叉熵：

$$\mathcal{L}_{\text{pl}} = -\frac{1}{|\mathcal{A}|} \sum_{j \in \mathcal{A}} \sum_{c=1}^{N_c} q_{jc}^{\text{mix}} \log \text{softmax}_c(\tilde{u}_j), \quad (4.17)$$

其中 $\tilde{u}_j$ 为经过类别频率对数调整后的强增强预测得分。若当前小批量中没有目标样本通过筛选，则令 $\mathcal{L}_{\text{pl}} = 0$ 。该损失只对通过多证据筛选的目标样本生效，因此比直接对全部目标样本施加伪标签约束更保守。

4.3.6 强弱增强一致性约束

强弱增强一致性是半监督学习中的重要机制。FixMatch 通过弱增强产生高置信伪标签，并要求强增强视图保持一致预测^[29]。本文借鉴这一思想，但结合工业过程时间序列特点设计增强方式：弱增强包括小幅随机扰动和幅值缩放；强增强在此基础上进一步加入时间片段遮蔽和通道随机遮蔽。

设目标样本的弱增强和强增强分别为 $a_w(x_j^t)$ 和 $a_s(x_j^t)$ 。教师模型在弱增强上产生 q_j^{cls} ，学生模型在强增强上产生预测 $p_{\theta,\phi}(a_s(x_j^t))$ 。一致性损失定义为

$$\mathcal{L}_{\text{cons}} = \frac{1}{|\mathcal{S}_{\text{cons}}|} \sum_{j \in \mathcal{S}_{\text{cons}}} \text{KL}(q_j^{\text{cls}} \| p_{\theta,\phi}(a_s(x_j^t))), \quad (4.18)$$

其中 $\mathcal{S}_{\text{cons}}$ 包括被接受的高置信伪标签样本，以及部分融合置信度达到中等阈值且传输熵较低的目标样本。该设置使未达到伪标签训练标准但仍具有一定稳定性的样本参与一致性约束。

4.3.7 教师-学生预测融合策略

第四章方法在训练阶段通过伪标签损失和一致性损失微调学生模型，但最终预测仍需要避免学生模型因局部伪标签噪声而偏离第三章教师参考模型。为此，本文在推理阶段采用不使用目标标签的教师-学生预测融合策略。设学生预测概率为 p_j^{stu} ，教师参考模型预测概率为 p_j^{tea} ，二者的最大置信度分别为 s_j^{stu} 和 s_j^{tea} 。

默认的安全置信融合规则为

$$p_j^{\text{final}} = \begin{cases} p_j^{\text{stu}}, & s_j^{\text{stu}} \geq s_j^{\text{tea}} + \Delta_{\text{conf}}, \\ p_j^{\text{tea}}, & \text{otherwise}, \end{cases} \quad (4.19)$$

其中 Δ_{conf} 为固定置信裕度。该规则只有在学生模型明显更有把握时才采用学生预测，否则采用教师参考模型预测。

对于少数迁移方向，本文还使用固定的概率混合或置信差分带融合。概率混合形式为

$$p_j^{\text{final}} = (1 - \omega_{\text{mix}})p_j^{\text{tea}} + \omega_{\text{mix}}p_j^{\text{stu}}, \quad (4.20)$$

其中 ω_{mix} 为预设学生权重。置信差分带融合则在

$$\Delta_{\text{min}} \leq s_j^{\text{stu}} - s_j^{\text{tea}} \leq \Delta_{\text{max}} \quad (4.21)$$

时采用学生预测，否则采用教师预测。上述阈值和权重均在实验设定中预先固定，不根据目标域测试准确率进行后验选择，因此仍符合目标域标签不可见的无监督领域自适应设

定。

4.3.8 总体目标函数与算法流程

本章方法的总损失为

$$\mathcal{L}_{\text{CBTPU}} = \mathcal{L}_{\text{src}} + \lambda_{\text{supcon}}(\nu)\mathcal{L}_{\text{supcon}} + \lambda_{\text{ot}}(\nu)\mathcal{L}_{\text{align}} + \lambda_{\text{pl}}(\nu)\mathcal{L}_{\text{pl}} + \lambda_{\text{cons}}(\nu)\mathcal{L}_{\text{cons}} + \lambda_{\text{im}}(\nu)\mathcal{L}_{\text{im}}. \quad (4.22)$$

其中前三项与第三章一致， $\mathcal{L}_{\text{pl}}$ 为多证据伪标签损失， $\mathcal{L}_{\text{cons}}$ 为强弱增强一致性损失。 $\mathcal{L}_{\text{im}}$ 为可选的信息最大化正则项，用于鼓励目标预测个体低熵且批次类别分布不过度坍缩；其权重较小，仅作为辅助稳定项。

本章方法训练流程如算法 2 所示。

算法 2: 多证据置信均衡伪标签训练流程

输入: 源域有标签数据 $\mathcal{D}_s$ ，目标域无标签数据 $\mathcal{D}_t$ ，训练步数 N_{iter}

输出: 学生模型参数 Θ 与教师模型参数 $\bar{\Theta}$

- 1 初始化学生模型、教师模型和源域类别原型；若存在 TPU-DeepJDOT 阶段模型，则以其作为固定教师参考模型并初始化学生模型
 - 2 **循环** $\nu = 1, 2, \dots, N_{\text{iter}}$ **执行**
 - 3 采样源域有标签小批量和目标域无标签小批量
 - 4 对目标样本生成弱增强视图和强增强视图
 - 5 使用学生模型计算源域分类输出、目标弱增强输出和目标强增强输出
 - 6 使用教师模型计算目标弱增强语义分布 q^{cls}
 - 7 更新源域类别原型，计算源域分类损失、监督对比损失和非平衡联合传输损失
 - 8 由传输计划得到 q^{ot} ，由源域原型距离得到 q^{proto}
 - 9 对 q^{ot} 、 q^{cls} 和 q^{proto} 进行幂加权融合，得到 q^{mix}
 - 10 依据语义一致性、JS 差异、融合置信度和传输熵筛选目标样本
 - 11 对接受样本计算类别均衡软伪标签损失，对接受样本和中等置信样本计算强弱增强一致性损失
 - 12 组合各项损失更新学生模型参数；若采用滑动平均教师形式，则用学生参数更新教师模型参数
 - 13 **结束循环**
-

该流程使目标域样本的利用建立在多证据一致性基础上。与单一高置信伪标签方法相比，本章方法能够同时利用传输计划的跨域匹配信息、教师模型的稳定预测和源域原型的类别结构信息，从而降低错误伪标签传播风险。

4.4 本章小结

本章的 CBTPU-DeepJDOT 不是重新训练一个完全不同的模型，而是在第三章模型已经完成初步对齐之后，进一步利用目标域中较可信的样本。筛选规则由三类证据共同决定：传输计划说明目标样本主要接收哪些源类质量，固定教师模型保留第三章得到的稳定边界，源域原型则提供类别中心参照。三者一致或差异足够小时，再结合融合置信度和传输熵决定是否接受该样本。对已经接受的伪标签，本章还加入类别频率校正，避免少数高置信类别在微调中继续占据主导。

强弱增强一致性用于检查目标时序样本在扰动下是否仍保持相近预测。最终推理时，学生模型并不会无条件替代教师模型，而是只有在置信度明显更高时才被采用。整个训练和融合过程不使用目标域标签，目标域标签仅在第六章中用于最终性能评价。

第五章 基于类条件源域可靠性加权的 多源领域自适应故障诊断方法

5.1 引言

第三章和第四章只考虑一个源工况到一个目标工况。实际跨生产模式诊断中，源域往往不止一个：除目标模式以外，其余生产模式都可能提供有标签样本。多源数据看起来更充足，但并不天然更可靠。一个源模式可能整体接近目标模式，却只在部分类别上有帮助；另一个源模式整体较远，也可能恰好对某些故障类别提供有用参照。若把多个源域简单合并，模型会同时吸收有益信息和噪声信息，负迁移反而更难定位。

本章因此把源域权重拆到故障类别层面。方法沿用 CoDATS 的时间序列表征和 WJDOT 的逐源传输思路，但不只学习一个源域整体权重，而是在每个源域与目标域之间分别统计类条件传输代价，再结合源目标原型距离、目标预测熵和源域类别召回误差，形成源域-故障类别可靠性矩阵。训练和模型选择过程中不使用目标域标签，目标域标签仅用于最终评价。方法整体结构如图 5-1 所示。




图 5-1 类条件源域可靠性加权多源方法架构示意

5.2 类条件源域可靠性加权基本原理

5.2.1 多源迁移与负迁移问题

设共有 K 个源域，源域集合为

$$\mathcal{D}_{s_k} = \{(x_i^{s_k}, y_i^{s_k})\}_{i=1}^{n_k}, \quad k = 1, 2, \dots, K, \quad (5.1)$$

目标域无标签样本为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}. \quad (5.2)$$

多源领域自适应的目标是在目标标签不可用的条件下，利用多个源域的有标签数据学习目标域诊断模型。

源域数量增加并不必然带来性能提升。负迁移研究指出，当源域知识与目标域分布或任务结构不匹配时，迁移学习可能降低目标域性能^[30]。在 TEP 多生产模式故障诊断中，某个源模式可能整体接近目标模式，但对部分故障类别仍存在明显偏移；也可能某个源模式整体较远，却对特定故障类别具有较高参考价值。因此，仅使用源域整体权重难以刻画这种细粒度迁移关系。

本文将多源负迁移问题细化为类条件可靠性问题：对于每个源域 s_k 和每个故障类别 c ，估计该源域在该类别上是否适合迁移到目标域。估计结果形成可靠性矩阵 $R \in \mathbb{R}^{K \times N_c}$ ，并进一步转化为类条件源域权重矩阵 $\alpha \in \mathbb{R}^{K \times N_c}$ 。

5.2.2 源域可靠性度量原理

WJDOT 通过源域加权联合分布最优传输为多源领域自适应提供了基础，其思路是在多个源域之间分配权重，使更可靠源域对目标域适配贡献更大^[13]。多源专家融合方法也表明，不同源域或不同专家可以根据目标样本特征进行差异化组合^[31]。本文受这些研究启发，但不采用多个独立专家结构，而是在共享时间序列表征和共享 CoDATS 分类头下，对每个源域分别计算传输统计，并进一步构造类条件可靠性矩阵。

源域可靠性可以从多个角度估计。若某一源域某一类别原型与目标域对应类别原型距离较近，说明该源类别特征结构可能更适合迁移；若该源域某一类别到目标域的传输代价较低，说明联合特征-标签空间匹配较好；若该源域对目标样本的预测熵较低，说明其目标预测更确定；若源域自身在该类别上的召回误差较小，则说明该源域对该类别的监督学习质量较高。本文将这些信息组合为源域-类别可靠性分数。

5.2.3 类条件源域权重分配原理

多源领域自适应中的矩匹配方法强调不同源域与目标域之间的分布统计关系^[32]，WJ-DOT 则强调通过联合分布传输学习源域权重^[13]。本文进一步将源域权重从全局源域级别扩展到故障类别级别。对于每个类别 c ，所有源域在该类别上的权重满足

$$\sum_{k=1}^K \alpha_{kc} = 1, \quad \alpha_{kc} \geq 0. \quad (5.3)$$

其中 α_{kc} 越大，表示第 k 个源域对第 c 类故障更可靠。

该类条件源域可靠性矩阵受源域重加权、多源专家融合和负迁移抑制思想启发，重点在于将源域可靠性从整体域级别细化到故障类别级别。该矩阵不仅参与训练中的类条件传输损失聚合，也可用于解释性分析，以考察不同源模式对不同故障类别的贡献。

5.3 基于类条件源域可靠性加权的多源对齐策略

5.3.1 多源跨工况诊断问题建模

本章方法采用共享特征提取器 F_θ 和共享分类器 G_ϕ 。特征提取器仍为一维全卷积网络，分类器采用 CoDATS 风格的两层隐藏层分类头，以增强时间序列诊断表征能力。对于第 k 个源域样本，模型输出

$$z_i^{s_k} = F_\theta(x_i^{s_k}), \quad p_i^{s_k} = G_\phi(z_i^{s_k}). \quad (5.4)$$

对于目标样本，模型输出

$$z_j^t = F_\theta(x_j^t), \quad p_j^t = G_\phi(z_j^t). \quad (5.5)$$

源域监督分类损失对所有源域求平均或按源域权重聚合：

$$\mathcal{L}_{\text{src}} = \frac{1}{K} \sum_{k=1}^K \frac{1}{|\mathcal{B}_{s_k}|} \sum_{(x_i^{s_k}, y_i^{s_k}) \in \mathcal{B}_{s_k}} \ell(y_i^{s_k}, G_\phi(F_\theta(x_i^{s_k}))). \quad (5.6)$$

同时可引入源域类别均衡权重，用于缓解源域小批量内部类别数量不均衡。

5.3.2 逐源联合分布最优传输对齐

对于每个源域 s_k ，本文分别构造其与目标域之间的联合传输代价：

$$C_{ij}^{(k)} = \lambda_f \|z_i^{s_k} - z_j^t\|_2^2 + \lambda_y \ell(y_i^{s_k}, p_j^t). \quad (5.7)$$

其中标签预测代价使用源域标签与目标预测之间的交叉熵。与直接合并所有源域不同，逐源传输为每个源域保留独立的传输计划：

$$\gamma_k^* = \arg \min_{\gamma_k \in \Pi(a_k, b)} \langle \gamma_k, C^{(k)} \rangle. \quad (5.8)$$

本文采用 Sinkhorn 形式求解平衡传输计划，并分别计算每个源域的传输损失、各类别传输质量和各类别平均传输代价。

第 k 个源域第 c 类的传输质量为

$$M_{kc}^{\text{ot}} = \sum_{i: y_i^{sk} = c} \sum_j \gamma_{k,ij}, \quad (5.9)$$

对应的类条件传输代价为

$$D_{kc}^{\text{ot}} = \frac{\sum_{i: y_i^{sk} = c} \sum_j \gamma_{k,ij} C_{ij}^{(k)}}{M_{kc}^{\text{ot}} + \epsilon}. \quad (5.10)$$

该矩阵是后续类条件可靠性评估的重要组成部分。

5.3.3 类条件源域可靠性矩阵构建

本文从四类证据构建源域-类别可靠性矩阵。

第一，源目标原型距离。对每个源域按源标签计算源域类别原型 μ_{kc}^s 。目标域类别原型 μ_c^t 由目标无标签样本的预测分布估计：若某一类别存在足够数量的高置信目标样本，则使用这些样本特征均值作为目标原型；否则使用目标预测概率或传输质量形成的软重心作为补充。源目标原型距离为

$$D_{kc}^{\text{proto}} = \|\mu_{kc}^s - \mu_c^t\|_2^2. \quad (5.11)$$

第二，类条件传输代价 D_{kc}^{ot} 。该项来自逐源联合分布最优传输，反映第 k 个源域第 c 类在特征-标签联合空间中与目标域匹配的难度。

第三，目标预测熵。设第 k 个源域对应的目标预测分布为 p_{kj}^t 。对于当前暂定属于第 c 类的目标样本集合 $\mathcal{T}_c$ ，计算归一化预测熵均值：

$$H_{kc}^{\text{pred}} = \frac{1}{|\mathcal{T}_c|} \sum_{j \in \mathcal{T}_c} \left(-\frac{1}{\log N_c} \sum_{r=1}^{N_c} p_{kjr}^t \log(p_{kjr}^t + \epsilon) \right). \quad (5.12)$$

熵越低，说明该源域对目标样本的预测越确定。若当前小批量中 $\mathcal{T}_c$ 为空，则该类别的预测熵项在本次可靠性更新中暂不计入，并在归一化时按有效类别集合处理。

第四，源域类别召回误差。对第 k 个源域当前小批量或评估批次，计算第 c 类源域样本召回率 Recall_{kc}^s ，并定义

$$E_{kc}^s = 1 - \text{Recall}_{kc}^s. \quad (5.13)$$

该项用于避免源域自身尚未学好的类别被赋予过高迁移权重。

四类证据在每个类别维度上分别进行 min-max 归一化后线性组合：

$$R_{kc} = w_p \tilde{D}_{kc}^{\text{proto}} + w_o \tilde{D}_{kc}^{\text{ot}} + w_h \tilde{H}_{kc}^{\text{pred}} + w_e \tilde{E}_{kc}^s. \quad (5.14)$$

可靠性分数越小，表示源域 k 对类别 c 越可靠。随后按类别维度进行 softmax 转换：

$$\alpha_{kc} = \frac{\exp(-R_{kc}/T_{\text{rel}})}{\sum_{k'=1}^K \exp(-R_{k'c}/T_{\text{rel}})}. \quad (5.15)$$

为避免权重过度集中，本文在权重分配中引入最小权重约束、高可靠源域保留策略以及逐步启用机制。逐步启用机制用于在训练早期保持接近均匀权重，待源域传输和目标预测更稳定后再逐渐启用类条件权重：

$$\alpha_{kc}(\nu) = (1 - r_{\text{rel}}(\nu)) \frac{1}{K} + r_{\text{rel}}(\nu) \alpha_{kc}, \quad (5.16)$$

其中 $r_{\text{rel}}(\nu) \in [0, 1]$ 为可靠性启用进度， T_{rel} 为可靠性权重的 softmax 温度。

基于类条件源域权重，类条件传输损失为

$$\mathcal{L}_{\text{CCSR}} = \frac{1}{|\mathcal{C}_{\text{act}}|} \sum_{c \in \mathcal{C}_{\text{act}}} \sum_{k=1}^K \mathbb{I}_{kc} \alpha_{kc} D_{kc}^{\text{ot}}, \quad (5.17)$$

其中 $\mathbb{I}_{kc}$ 表示源域 k 是否存在第 c 类样本， $\mathcal{C}_{\text{act}}$ 为当前至少有源域支持的类别集合。

5.3.4 领域对抗特征约束与教师先验约束

为了获得更稳定的时间序列跨域表征，本章方法在逐源传输和类条件可靠性之外，引入 CoDATS 风格的领域对抗特征约束。领域对抗学习通过梯度反转层训练特征提取器，使领域判别器难以区分源域和目标域特征^[17]。CoDATS 将该思想应用于时间序列传感器数据，并使用适合时间序列任务的分类头结构^[12]。

设领域判别器为 D_{ω} ，源域特征集合为 Z_s ，目标域特征集合为 Z_t 。领域对抗损失为

$$\mathcal{L}_{\text{dom}} = -\frac{1}{|Z_s|} \sum_{z \in Z_s} \log D_{\omega}(z) - \frac{1}{|Z_t|} \sum_{z \in Z_t} \log(1 - D_{\omega}(z)). \quad (5.18)$$

通过梯度反转层，判别器最小化该损失，而特征提取器接收反向梯度，从而学习更难区分源目标领域的表示。领域对抗权重采用逐步启用调度，避免训练初期对抗信号过强。

此外，本章引入教师先验约束，用于防止多源传输和类条件加权造成目标预测漂移。教师模型由同一多源任务中的 CoDATS 风格基础诊断模型给出，该模型只使用源域标签和目标域无标签数据训练，不使用目标域真实标签；在本章类条件可靠性训练阶段，教师参数保持固定。知识蒸馏研究表明，教师模型的软概率可以携带比硬标签更丰富的类别相似性信息^[33]；Mean Teacher 思想也说明稳定教师有助于无标签训练^[24]。本文将教师输出作为目标域先验保护项，而不是目标标签监督。

设教师模型在目标样本上的未归一化预测得分为 u_j^{tea} ，学生模型的未归一化预测得分

为 u_j^{stu} 。教师先验约束可写为

$$\mathcal{L}_{\text{tea}} = \frac{T_{\text{dist}}^2}{|\mathcal{B}_t|} \sum_{x_j^t \in \mathcal{B}_t} \text{KL} \left(\text{softmax} \left(\frac{u_j^{\text{tea}}}{T_{\text{dist}}} \right) \parallel \text{softmax} \left(\frac{u_j^{\text{stu}}}{T_{\text{dist}}} \right) \right), \quad (5.19)$$

其中 T_{dist} 为蒸馏温度， $\mathcal{B}_t$ 为当前目标域小批量。也可引入归一化特征均方误差作为辅助教师参考约束项。

5.3.5 教师先验保护的诊断结果融合

训练结束后，本文进一步采用教师先验保护的诊断结果融合策略。该阶段先固定学生模型和教师模型输出，再根据无标签目标样本上的置信度、熵和教师-学生一致性确定融合系数。目标域评估标签仅在预测结果确定后用于计算准确率、宏平均 F1 和混淆矩阵，不参与训练或预测阶段的融合规则确定。

设学生预测概率为 p_j^{stu} ，教师预测概率为 p_j^{tea} 。基础融合形式为

$$p_j^{\text{final}} = (1 - \zeta_j) p_j^{\text{stu}} + \zeta_j p_j^{\text{tea}}, \quad (5.20)$$

其中 $\zeta_j \in [0, 1]$ 由教师和学生的最大概率类别是否一致、两者置信度差异以及预测熵差异确定。当教师与学生预测一致时，融合系数较小，主要用于平滑预测；当二者不一致且教师置信度更高、熵更低时，允许教师以较大权重参与最终概率。在先验均衡形式下，先混合教师和学生概率，再根据预测批次的类别先验进行无标签概率校正：

$$p_j^{\text{pb}} = \frac{p_j^{\text{base}} / (\bar{p}^{\text{base}})^{\beta}}{\sum_c p_{jc}^{\text{base}} / (\bar{p}_c^{\text{base}})^{\beta}}, \quad (5.21)$$

其中 $\bar{p}^{\text{base}}$ 为当前目标批次平均预测分布， β 为先验均衡强度。该机制用于缓解目标预测类别数量坍塌，同样不使用目标真实标签。

教师先验融合用于保护已有稳定教师预测，同时允许学生模型在更高置信、更低熵时替代教师预测。该机制与训练中的类条件源域可靠性矩阵互补，为最终诊断结果提供保守校正。

5.3.6 总体目标函数与算法流程

本章训练阶段的总体目标函数为

$$\mathcal{L}_{\text{CA-CCSR}} = \lambda_s \mathcal{L}_{\text{src}} + \lambda_d(\nu) \mathcal{L}_{\text{dom}} + \lambda_{\text{ot}} r_{\text{ot}}(\nu) \mathcal{L}_{\text{WJDOT}} + \lambda_{\text{ccsr}} r_{\text{ccsr}}(\nu) \mathcal{L}_{\text{CCSR}} + \lambda_{\text{tea}}(\nu) \mathcal{L}_{\text{tea}}. \quad (5.22)$$

其中 $\mathcal{L}_{\text{WJDOT}}$ 为逐源传输损失的源域级聚合， $\mathcal{L}_{\text{CCSR}}$ 为类条件可靠性加权传输损失， $\mathcal{L}_{\text{dom}}$ 为领域判别损失， $\mathcal{L}_{\text{tea}}$ 为教师先验约束。各权重均采用逐步启用调度控制。

本章方法训练流程如算法 3 所示。

算法 3: 类条件源域可靠性加权多源训练流程

输入: 多源有标签数据 $\{\mathcal{D}_{s_k}\}_{k=1}^K$, 目标域无标签数据 $\mathcal{D}_t$, 训练步数 N_{iter}

输出: 多源领域自适应诊断模型及目标域预测结果

- 1 初始化共享一维全卷积特征提取器、CoDATS 分类头、领域判别器和固定教师模型
- 2 **循环** $\nu = 1, 2, \dots, N_{\text{iter}}$ **执行**
 - 3 从多个源域分别采样有标签小批量, 并从目标域采样无标签小批量
 - 4 **遍历** 源域 s_k **执行**
 - 5 计算源域分类损失、源域类别原型和源域类别召回误差
 - 6 构造该源域到目标域的联合传输代价并求解传输计划 γ_k^*
 - 7 计算源域级传输损失、类条件传输质量和类条件传输代价
 - 8 **结束遍历**
 - 9 根据目标预测构建目标类别原型
 - 10 融合原型距离、传输代价、预测熵和源域召回误差, 得到类条件源域可靠性矩阵
 - 11 将可靠性矩阵转化为类条件源域权重, 计算类条件传输损失 $\mathcal{L}_{\text{CCSR}}$
 - 12 计算 CoDATS 风格领域对抗损失和教师先验约束
 - 13 组合总损失并更新学生模型参数
- 14 **结束循环**
- 15 固定学生和教师输出, 根据教师先验保护融合规则生成最终目标域预测
- 16 目标域标签只在预测确定后用于评价指标计算

通过这一流程, 多个源域的作用被拆到类别层面, 而不是在训练开始时就被合并成一个大源域。

5.4 本章小结

本章的 CA-CCSR-WJDOT 把多源负迁移问题拆成了更具体的源域-类别可靠性问题。可靠性矩阵同时使用源目标原型距离、类条件传输代价、目标预测熵和源域类别召回误差, 并在每个类别内部转换为源域权重。这样, 一个源域可以在某些故障类别上占较大权重,

在另一些类别上退到次要位置。

方法中还保留了 CoDATS 风格的时间序列领域对抗表征，并用固定教师先验约束防止学生模型在多源传输中发生过度漂移。最终诊断阶段采用教师先验融合进行无标签置信校正。训练和融合过程均不使用目标域真实标签，目标标签仅用于最终实验评价。

第六章 实验设计与结果分析

6.1 引言

前几章围绕单源和多源跨工况故障诊断问题，提出了时序原型非平衡联合分布对齐、多证据置信均衡伪标签学习以及类条件源域可靠性加权等方法。这些方法均以目标生产模式缺少标签为前提，利用源生产模式的有标签故障样本和目标生产模式的无标签样本，提高模型在目标工况下的故障识别能力。为评价所提方法，需要在统一的数据划分、训练协议和评价指标下开展实验，并与源域直接迁移、典型领域自适应方法以及目标域监督参考方法进行比较。

本章在田纳西伊斯曼过程领域自适应数据集上验证前文方法。实验先说明数据来源、生产模式、样本组织形式、变量选择和预处理方式，再给出固定第一折的数据划分、目标域无标签训练协议和评价指标。任务设置分为两类：一类是模式 1、模式 2 和模式 5 之间的单源双向迁移，另一类是两源域和五源域条件下的多源迁移。所有方法在相同协议下比较，并用准确率、宏平均 F1、平衡准确率、混淆矩阵和跨域特征可视化共同分析结果。

除 Target-ref 外，本文所有领域自适应方法在训练、伪标签筛选、超参数选择和模型选择过程中都不使用目标域真实标签；目标域标签只在最终预测完成后用于计算指标。由于不同生产模式之间的偏移程度并不相同，多源场景下源域贡献也可能随故障类别变化，本章不会只报告平均值，还会单独分析困难迁移方向、类别混淆和源域可靠性差异。

本文方法名称按全文统一约定书写。第三章方法记为 TPU-DeepJDOT，第四章方法记为 CBTPU-DeepJDOT，第五章方法记为 CA-CCSR-WJDOT。对比方法中，SourceOnly 表示仅使用源域有标签样本训练后直接迁移到目标域的基线；DSAN 采用 Deep Subdomain Adaptation Network 的局部最大均值差异对齐思想^[34]；CDAN-TS 是基于条件对抗领域自适应思想的时间序列适配基线^[35]；CoDATS、DeepJDOT 和 WJDOT 分别作为时间序列领域对抗、单源联合分布最优传输和多源加权联合分布最优传输基线^[11-13]。Target-ref 使用目标域训练部分标签进行监督训练，仅作为有标签参考结果，不参与无监督领域自适应方法的公平排序。

6.2 数据集与实验场景

田纳西伊斯曼过程领域自适应数据集

本文实验采用田纳西伊斯曼过程领域自适应数据集作为跨工况领域自适应故障诊断

基准数据集。该数据集由田纳西伊斯曼过程（TEP）仿真数据整理形成，相关研究对数据生成、预处理流程和领域自适应基准实验进行了系统说明^[4]。TEP 最早由 Downs 和 Vogel 提出，是化工过程控制、过程监测和故障诊断研究中常用的复杂工业过程基准系统^[36]。该过程包含反应器、冷凝器、气液分离器、循环压缩机和汽提塔等主要单元，能够模拟多变量耦合、非线性动态和多种故障扰动，可作为工业过程故障诊断算法研究的基准模型。后续扩展 TEP 仿真数据集也进一步推动了该基准在故障检测和决策支持研究中的使用^[37]。




图 6-1 田纳西伊斯曼过程流程示意图

从领域自适应角度看，TEP 数据集的主要特点是包含多个生产模式。不同生产模式对应不同的产品质量比和生产率，会改变过程变量之间的统计关系和数据概率分布。因此，在某一生产模式下训练得到的模型，直接迁移到另一生产模式时可能出现明显性能退化。配套基准研究通过变量相关矩阵和模式间 Wasserstein 距离分析表明，不同生产模式会造成可观的分布偏移^[4]。因此，该数据集适合用于构造单源和多源跨工况领域自适应故障诊断任务。

数据集共包含 6 个生产模式，每个生产模式可视为一个领域。本文沿用基准文献的编号方式，将第 r 个生产模式在公式和实验场景表中简记为 m_r ，其中 $r = 1, 2, \dots, 6$ 。各生产模式的产品质量比、生产率和样本数如表 6.1 所示。

在上述编号体系下，配套基准研究进一步指出，模式 2 与其他模式的分布差异相对较

表 6.1 田纳西伊斯曼过程领域自适应数据集中各生产模式信息

生产模式	G/H 质量比	生产率	样本数
模式 1	50/50	7038 kg/h G 和 7038 kg/h H	2900
模式 2	10/90	1408 kg/h G 和 12669 kg/h H	2845
模式 3	90/10	10000 kg/h G 和 1111 kg/h H	2899
模式 4	50/50	最大生产率	2865
模式 5	10/90	最大生产率	2883
模式 6	90/10	最大生产率	2897
合计	—	—	17289

大，而模式 3 与模式 6、模式 1 与模式 4、模式 5 之间具有相对更接近的统计特性^[4]。

数据集按照生产模式组织为多个领域，每个样本由多变量过程时间序列及其故障类别组成。对于第 m 个生产模式，其样本集合可表示为

$$\mathbf{X}^{(m)} \in \mathbb{R}^{N_m \times 600 \times 34}, \quad (6.1)$$

其中 N_m 表示该模式下的样本数量，600 表示每个样本包含的时间步数，34 表示连续过程变量数量。标签空间为

$$\mathcal{Y} = \{0, 1, 2, \dots, 28\}, \quad (6.2)$$

其中标签 0 表示正常状态，标签 1 至 28 分别表示 28 种故障类型。本文将每个样本视为一个多变量时间序列故障诊断样本，不同生产模式之间的同类故障样本构成跨工况迁移学习中的源域和目标域样本。

原始 TEP 仿真环境包含 53 个变量，其中部分变量为非连续变量。相关基准研究按照数据预处理规则选取 34 个连续变量作为诊断特征，包括测量变量 XME(1) 至 XME(22) 以及操纵变量 XMV(1) 至 XMV(12)^[4]。由于不同过程变量的量纲和数值范围差异较大，本文对每个生产模式内部的每个变量进行标准化处理。对于生产模式 m 中第 j 个变量，其标准化过程为

$$\tilde{x}_{i,t,j}^{(m)} = \frac{x_{i,t,j}^{(m)} - \bar{x}_j^{(m)}}{\sigma_j^{(m)} + \epsilon}, \quad (6.3)$$

其中 $x_{i,t,j}^{(m)}$ 表示第 m 个生产模式中第 i 个样本在时间步 t 、变量 j 上的原始取值， $\bar{x}_j^{(m)}$ 和 $\sigma_j^{(m)}$ 分别表示该生产模式下第 j 个变量在所有样本和时间步上的均值与标准差， ϵ 为防止标准差为零导致数值不稳定的极小常数。该标准化过程仅使用样本统计量，不使用目标域标签信息。

数据划分与训练协议

数据集提供五折样本划分。为控制实验规模并保证不同方法、不同迁移任务之间的可比性，本文采用固定第一折评估方式：目标域中属于第一折的样本作为测试集，仅在最终评价阶段使用其标签；目标域中不属于第一折的样本作为无标签目标训练数据参与领域自适应训练。源域样本则使用相同划分编号对应的训练部分及其标签参与源域监督训练。对于多源场景，所有源域均按照第一折对应训练部分构造有标签源域训练集，目标域仍以无标签形式参与训练。正文结果均在统一数据划分和统一随机性控制下获得，以保证不同方法之间的比较口径一致。

以单源任务 $m_s \rightarrow m_t$ 为例，训练过程中可访问的数据包括源域有标签样本

$$\mathcal{D}_s^{\text{train}} = \{(x_i^s, y_i^s)\}, \quad (6.4)$$

以及目标域无标签样本

$$\mathcal{D}_t^{\text{train}} = \{x_j^t\}. \quad (6.5)$$

目标域测试集记为

$$\mathcal{D}_t^{\text{test}} = \{(x_u^t, y_u^t)\}, \quad (6.6)$$

其中 y_u^t 只用于最终计算评价指标，禁止在模型训练、伪标签筛选、超参数选择和早停过程中使用。多源任务 $m_{s_1} + m_{s_2} + \dots + m_{s_K} \rightarrow m_t$ 的设置与单源任务类似，只是源域由一个扩展为多个。

目标域监督参考方法使用目标域训练部分的标签进行监督训练，不属于无监督领域自适应方法，也不参与无监督领域自适应方法的公平比较。由于其训练数据量、模型结构和训练设置可能与多源方法存在差异，本文不将其视为所有场景下的严格上界，而仅作为目标域有标签条件下的参考结果。

本文主要采用诊断准确率、宏平均 F1 值和平衡准确率作为评价指标。诊断准确率用于衡量整体分类正确比例；宏平均 F1 值对每个类别的 F1 值进行等权平均，更能反映多类别故障诊断中的少数类性能；平衡准确率对各类别召回率进行平均，可降低类别样本数量差异对评价结果的影响。对于目标域故障诊断任务，本文同时结合混淆矩阵和跨域特征可视化结果分析模型的类别混淆情况和特征对齐效果。

单源跨工况实验场景

单源跨工况实验用于验证第三章和第四章提出的单源领域自适应方法。本文选取模式 1、模式 2 和模式 5 构成单源实验子集，并按照双向迁移原则构造任务，即任意两个生产

模式之间均进行双向迁移，每个模式既作为源域，也作为目标域。选择模式 1、模式 2 和模式 5 的原因是：模式 1 与模式 5 在基准研究中属于相对接近的模式组，可用于分析分布偏移较弱任务中的方法增益；模式 2 与其他模式差异较大，可用于检验方法在困难跨工况任务中的适应能力^[4]。

单源实验共包含 6 个任务，如表 6.2 所示，其中 m_1 、 m_2 和 m_5 的含义沿用上述生产模式记号。

表 6.2 单源跨工况实验场景

序号	源域	目标域
1	m_1	m_2
2	m_2	m_1
3	m_1	m_5
4	m_5	m_1
5	m_2	m_5
6	m_5	m_2

在每个单源任务中，源域样本带有故障类别标签，目标域训练样本不提供标签。实验先用源域直接迁移方法评估直接跨工况泛化能力，再与典型领域自适应基线以及第三章、第四章方法进行比较，以验证时序原型非平衡联合分布对齐和多证据置信均衡伪标签学习对目标域诊断性能的影响。

多源跨工况实验场景

多源跨工况实验用于验证第五章提出的类条件源域可靠性加权方法。与单源场景不同，多源领域自适应可以利用多个源域的有标签数据适配同一个目标域。多源设置能够提供更丰富的故障样本和生产模式信息，但也可能引入源域间分布差异和负迁移问题。因此，多源实验不仅关注模型是否能够利用更多源域数据，还关注模型是否能够识别不同源域对不同故障类别的可靠性差异。

本文多源实验包含两类任务。第一类为模式 1、模式 2 和模式 5 之间的两源域跨工况任务，用于考察小规模多源条件下的迁移效果。该设置与单源双向迁移场景保持一致，只是每次选择两个模式作为源域，剩余一个模式作为目标域。具体任务如表 6.3 所示。

第二类为 6 个生产模式之间的五源域跨工况任务。该设置每次选择其中 1 个生产模式作为目标域，其余 5 个生产模式作为源域。该实验能够更全面地评估多源领域自适应方法在不同目标生产模式上的适用性，也更适合分析类条件源域可靠性矩阵是否能够刻画不同源域对不同故障类别的贡献。具体任务如表 6.4 所示。

表 6.3 生产模式 1、生产模式 2 和生产模式 5 之间的两源域跨工况实验场景

序号	源域	目标域
1	$m_1 + m_2$	m_5
2	$m_2 + m_5$	m_1
3	$m_1 + m_5$	m_2

表 6.4 6 个生产模式之间的五源域跨工况实验场景

序号	源域	目标域
1	$m_2 + m_3 + m_4 + m_5 + m_6$	m_1
2	$m_1 + m_3 + m_4 + m_5 + m_6$	m_2
3	$m_1 + m_2 + m_4 + m_5 + m_6$	m_3
4	$m_1 + m_2 + m_3 + m_5 + m_6$	m_4
5	$m_1 + m_2 + m_3 + m_4 + m_6$	m_5
6	$m_1 + m_2 + m_3 + m_4 + m_5$	m_6

在多源实验中，源域直接迁移方法用于衡量不进行领域自适应时的多源泛化能力，CoDATs 用于衡量卷积式时间序列领域自适应基线性能，WJDOT 用于衡量基于多源加权联合分布最优传输的基线性能，本文第五章方法用于验证类条件源域可靠性加权机制的有效性。通过两源域和五源域两组实验，可以分别分析源域数量较少和源域数量较多时，源域可靠性建模对目标域故障诊断结果的影响。

6.3 方法有效性验证

本节按照第三章、第四章和第五章方法的递进关系组织代表场景分析。第 6.3.1 节验证 SourceOnly $\rightarrow$ DeepJDOT $\rightarrow$ TPU-DeepJDOT 的递进关系；第 6.3.2 节验证 TPU-DeepJDOT $\rightarrow$ CBTPU-DeepJDOT 的伪标签细化效果；第 6.3.3 节验证 SourceOnly $\rightarrow$ CA-CCSR-WJDOT 的多源选择性迁移效果。为避免将全局热力图和局部图像证据混在一起，本节只使用混淆矩阵、域 t-SNE 和类 t-SNE 三类图像进行对比；跨迁移任务的整体性能与基线优势留到第 6.4 节集中讨论。

单源代表场景按验证目标分别选取：第 6.3.1 节采用 $m_5 \rightarrow m_2$ 任务，用于观察第三章方法相对 SourceOnly 和 DeepJDOT 的主线增益；第 6.3.2 节采用 $m_5 \rightarrow m_1$ 任务，用于观察第四章伪标签细化阶段的补充收益。多源代表场景选取五源域跨工况任务 $\{m_1, m_3, m_4, m_5, m_6\} \rightarrow m_2$ ，用于观察引入多个源域后类条件源域可靠性建模的作用。

6.3.1 时序原型非平衡联合分布对齐有效性验证

本小节验证第三章方法的核心问题：在单源跨工况诊断中，SourceOnly 缺少领域对齐，DeepJDOT 引入联合分布最优传输，TPU-DeepJDOT 进一步加入非平衡传输、源域类别原

型和时序统计代价。若第三章方法有效，则代表场景中应当出现 $\text{SourceOnly} < \text{DeepJDOT} < \text{TPU-DeepJDOT}$ 的递进趋势，即目标域混淆减少、源目标域分布更加接近、类别结构更加清晰。

图 6-2 给出 $m_5 \rightarrow m_2$ 任务中三种方法的目标域混淆矩阵。SourceOnly 的非对角元素较分散，说明仅依赖源域监督训练难以直接适应目标生产模式；DeepJDOT 缓解了部分误判，但仍有若干类别被吸收到错误预测类别；TPU-DeepJDOT 的对角线响应更集中，说明时序原型非平衡联合分布对齐削弱了低质量强制匹配对类别边界的干扰。该代表场景中，三者准确率分别为 56.08%、67.20% 和 83.60%，形成明显递进关系。




图 6-2 单源任务 $m_5 \rightarrow m_2$ 中 SourceOnly、DeepJDOT 和 TPU-DeepJDOT 的目标域混淆矩阵对比

图 6-3 从域分布角度展示同一任务的 t-SNE 结果。SourceOnly 下源域与目标域特征仍存在明显分离；DeepJDOT 缩短了部分源目标特征距离，但目标域样本仍有较多游离区域；TPU-DeepJDOT 使更多目标样本进入源域类别结构附近。该现象说明 TPU-DeepJDOT 的提升不是单纯依赖分类器输出校正，而是在特征层面改善了跨域对齐状态。




图 6-3 单源任务 $m_5 \rightarrow m_2$ 中 SourceOnly、DeepJDOT 和 TPU-DeepJDOT 的域 t-SNE 对比

图 6-4 进一步从类别聚集角度比较三种方法。SourceOnly 的部分类别簇边界混杂，目标样本难以稳定落入正确类别区域；DeepJDOT 形成了一定类别聚集结构，但局部类别仍交叠；TPU-DeepJDOT 的类别簇更紧凑，且不同故障类别之间的分离度更好。这与第三章方法引入源域类别原型、时序统计代价和源域监督对比学习的设计目标一致。




图 6-4 单源任务 $m_5 \rightarrow m_2$ 中 SourceOnly、DeepJDOT 和 TPU-DeepJDOT 的类 t-SNE 对比

混淆矩阵、域 t-SNE 和类 t-SNE 指向同一个现象：TPU-DeepJDOT 相比 DeepJDOT 的收益主要来自类别结构保持。非平衡传输削减低可靠匹配质量，原型代价和时序统计代价则让传输计划不再只依赖瞬时特征距离，从而在目标域无标签条件下减少错误对齐。

6.3.2 多证据置信均衡伪标签有效性验证

本小节验证第四章方法的核心问题：在 TPU-DeepJDOT 已经建立较可靠源目标对齐关系之后，CBTPU-DeepJDOT 是否能够通过多证据置信筛选和类别均衡伪标签学习进一步改善目标域决策边界。与第 6.3.1 节不同，本小节不再重复 SourceOnly 和 DeepJDOT 的完整递进链，而是直接比较 TPU-DeepJDOT 与 CBTPU-DeepJDOT。

图 6-5 展示两种方法在 $m_5 \rightarrow m_1$ 任务上的混淆矩阵。CBTPU-DeepJDOT 相比 TPU-DeepJDOT 的代表场景准确率由 77.59% 提升到 81.38%，宏平均 F1 由 76.06% 提升到 81.10%，平衡准确率由 77.59% 提升到 81.38%。该提升幅度小于第 6.3.1 节中 DeepJDOT 到 TPU-DeepJDOT 的跃升，但混淆矩阵中局部非对角误判继续减弱，说明伪标签阶段主要承担细化目标域边界的作用。

图 6-6 从域 t-SNE 角度比较 TPU-DeepJDOT 与 CBTPU-DeepJDOT。两者都已经形成较好的源目标融合结构，这说明第四章方法并不是重新建立跨域对齐，而是在第三章对齐基础上进行保守微调。CBTPU-DeepJDOT 中部分目标样本在主簇附近更加紧凑，反映出高置信目标样本被逐步纳入训练后，对目标域局部边界产生了细化作用。




 图 6-5 单源任务 $m_5 \rightarrow m_1$ 中 TPU-DeepJDOT 和 CBTPU-DeepJDOT 的目标域混淆矩阵对比

 图 6-6 单源任务 $m_5 \rightarrow m_1$ 中 TPU-DeepJDOT 和 CBTPU-DeepJDOT 的域 t-SNE 对比

图 6-7 给出类 t-SNE 对比。CBTPU-DeepJDOT 在保持 TPU-DeepJDOT 类别结构的同时，使部分目标样本进一步靠近对应类别簇。由于第四章方法只接受传输语义、教师预测语义和原型语义相对一致的目标样本，该变化体现出“保守使用目标域样本”的特点：其目标不是扩大伪标签覆盖率，而是降低错误伪标签进入训练目标的风险。

CBTPU-DeepJDOT 的作用更应理解为第二阶段修正：TPU-DeepJDOT 已经把源目标结构拉近，伪标签阶段再利用固定教师、传输计划、源域原型和类别均衡机制挑出可信目标样本，对目标域决策边界做小幅但稳定的调整。




图 6-7 单源任务 $m_5 \rightarrow m_1$ 中 TPU-DeepJDOT 和 CBTPU-DeepJDOT 的类 t-SNE 对比

6.3.3 类条件源域可靠性加权有效性验证

本小节验证第五章方法的核心问题：多源设置中仅增加源域数量并不必然带来可靠迁移，模型还需要识别不同源域对不同故障类别的贡献差异。为突出 CA-CCSR-WJDOT 相对直接多源训练的作用，本小节比较五源 SourceOnly 与 CA-CCSR-WJDOT。完整的 CoDATS、WJDOT 等基线优势在第 6.4.2 节结合热力图、平均柱状图和平均性能表讨论。

图 6-8 展示五源域跨工况任务 $\{m_1, m_3, m_4, m_5, m_6\} \rightarrow m_2$ 中 SourceOnly 与 CA-CCSR-WJDOT 的混淆矩阵。SourceOnly 虽然使用了多个源域的有标签样本，但目标域准确率只有 64.02%，说明简单合并多源数据仍会受到跨工况偏移和源域差异影响。CA-CCSR-WJDOT 的目标域准确率达到 82.89%，宏平均 F1 和平衡准确率分别达到 81.77% 和 82.57%，混淆矩阵中对角线响应明显增强，表明类条件源域可靠性加权能够显著减少目标域误判。

图 6-9 展示两种方法的域 t-SNE 对比。SourceOnly 中目标域样本在多个区域与源域簇保持距离，说明多源监督训练本身不足以消除目标域偏移。CA-CCSR-WJDOT 中目标域样本更稳定地靠近多源特征结构，说明逐源联合分布对齐与类条件源域加权共同改善了目标域样本的位置。

图 6-10 从类别结构角度进一步说明该差异。SourceOnly 的部分类别簇存在交叠，目标样本分布较分散；CA-CCSR-WJDOT 中类别簇结构更清晰，目标样本与对应类别区域的关系更稳定。这说明第五章方法的收益不仅来自更多源域样本，也来自对源域-故障类别可靠性的细粒度建模。




图 6-8 五源域跨工况任务 $\{m_1, m_3, m_4, m_5, m_6\} \rightarrow m_2$ 中 SourceOnly 和 CA-CCSR-WJDOT 的目标域混淆矩阵对比




图 6-9 五源域跨工况任务 $\{m_1, m_3, m_4, m_5, m_6\} \rightarrow m_2$ 中 SourceOnly 和 CA-CCSR-WJDOT 的域 t-SNE 对比

这组三类图像说明，CA-CCSR-WJDOT 相比多源 SourceOnly 改善的不只是最终分类结果，域间融合和类别聚集结构也同步变清楚了。第五章的基本判断在这里得到支持：多源跨工况诊断不能只看源域数量，还要判断每个源域在具体故障类别上的可靠性。

6.4 综合实验结果对比分析

第 6.3 节从代表场景出发，分别验证三类方法自身的有效性；本节回到全部迁移任务，使用逐任务热力图、平均准确率柱状图和平均性能表说明本文创新方法相对其他基线方法




图 6-10 五源域跨工况任务 $\{m_1, m_3, m_4, m_5, m_6\} \rightarrow m_2$ 中 SourceOnly 和 CA-CCSR-WJDOT 的类 t-SNE 对比

的整体优势。正文结果均采用固定随机种子、固定第一折划分和统一实验协议；表中“均值 $\pm$ 标准差”表示不同迁移任务或目标域之间的均值与场景标准差。Target-ref 使用目标域训练部分标签进行监督训练，仅作为有标签参考，不参与无监督方法公平排序。表中“无监督第一数”统计对应方法在迁移任务中取得无监督方法最高准确率次数，Target-ref 不纳入该计数。

6.4.1 单源创新方法相对基线方法的优势分析

图 6-11 给出 6 个单源迁移任务上的逐任务准确率热力图。横轴包含 SourceOnly、DSAN、CDAN-TS、CoDATS、DeepJDOT、TPU-DeepJDOT、CBTPU-DeepJDOT 和 Target-ref 共 8 种方法，因此可以观察方法在不同源目标模式组合上的波动，而不只依赖代表场景。SourceOnly 在多数任务中偏低；DSAN、CDAN-TS 和 CoDATS 有一定领域自适应收益；DeepJDOT 在部分任务上继续改善，但平衡传输和类别结构保持仍限制了结果。TPU-DeepJDOT 和 CBTPU-DeepJDOT 的优势在热力图中更加稳定。

图 6-12 进一步以柱状图形式汇总单源任务的平均目标域准确率。该图与表 6.5 相互补充：柱状图便于观察方法间整体差距，表格则同时给出宏平均 F1、平衡准确率和无监督第一数。

表 6.5 给出单源跨工况实验的平均诊断性能。TPU-DeepJDOT 的平均准确率达到 80.54%，相比 DeepJDOT 的 68.88% 提升 11.66 个百分点，宏平均 F1 和平衡准确率分别提升 12.78 和 11.56 个百分点。CBTPU-DeepJDOT 的平均准确率进一步达到 82.02%，相较




图 6-11 单源跨工况 8 种方法逐任务目标域准确率热力图




图 6-12 单源跨工况 8 种方法平均目标域准确率柱状图

TPU-DeepJDOT 继续提升 1.48 个百分点，并在 6 个单源迁移方向上均取得无监督方法第一。该结果说明，第三章方法贡献了主要性能跃升，第四章方法在可靠对齐基础上进一步稳定细化目标域决策边界。

从单源热力图、平均柱状图和平均表可以得到两点结论。第一，单源方法符合 $\text{SourceOnly} < \text{DeepJDOT} < \text{TPU-DeepJDOT} < \text{CBTPU-DeepJDOT}$ 的总体趋势，说明本文方法并非只在单个代表任务上有效。第二，CBTPU-DeepJDOT 在 6/6 任务中均为无监督方法第一，说明多证据置信均衡伪标签学习的增益虽然幅度相对较小，但跨迁移方向具有一致性。

表 6.5 单源跨工况主结果的平均诊断性能

方法	准确率	宏平均 F1	平衡准确率	无监督第一数
SourceOnly	55.88±7.67	49.97±7.96	55.83±7.79	0/6
DSAN	62.42±13.35	58.45±15.51	62.41±13.67	0/6
CDAN-TS	67.76±9.99	64.25±11.51	67.61±9.91	0/6
CoDATS	74.30±4.62	72.34±5.72	74.33±4.71	0/6
DeepJDOT	68.88±1.76	66.04±1.46	69.08±1.62	0/6
TPU-DeepJDOT	80.54±2.20	78.82±2.18	80.64±2.28	0/6
CBTPU-DeepJDOT	82.02±1.64	80.73±1.54	82.12±1.71	6/6
Target-ref	90.92±1.42	90.67±1.66	90.98±1.41	—

6.4.2 多源创新方法相对基线方法的优势分析

图 6-13 给出 3 个两源域跨工况任务上的逐任务准确率热力图。该图用于观察源域数量较少时，不同方法在目标生产模式变化下的稳定性。SourceOnly 说明直接合并两个源域的有标签样本仍不足以消除跨工况偏移；CoDATS 能够提供一定领域对抗适配收益；WJDOT 引入逐源联合分布传输，但全局源域权重仍难以刻画类别级差异。CA-CCSR-WJDOT 在 3 个两源域跨工况任务中均取得无监督方法最高准确率，说明类条件源域可靠性加权在两源域跨工况场景下已经能够提供更稳定的选择性迁移。




图 6-13 两源域跨工况任务逐任务目标域准确率热力图

图 6-14 给出两源域跨工况任务的平均目标域准确率柱状图。与逐任务热力图相比，该图更直观地呈现不同方法在两源域跨工况场景中的总体差距；完整指标仍以表 6.6 为准。

表 6.6 给出两源域跨工况任务的平均诊断性能。CA-CCSR-WJDOT 在 3 个两源域跨工况任务上均取得无监督方法第一，平均准确率达到 81.21%，分别高于 CoDATS 和 WJDOT




图 6-14 两源域跨工况任务平均目标域准确率柱状图

3.99 和 8.80 个百分点。

表 6.6 两源域跨工况主结果的平均诊断性能

方法	准确率	宏平均 F1	平衡准确率	无监督第一数
SourceOnly	66.51±8.20	62.00±7.06	66.58±8.21	0/3
CoDATS	77.22±6.22	75.58±6.95	77.28±6.28	0/3
WJDOT	72.41±4.96	69.07±5.40	72.50±4.96	0/3
CA-CCSR-WJDOT	81.21±4.12	79.97±4.50	81.32±4.20	3/3
Target-ref	91.94±1.44	91.49±0.92	91.98±1.42	—

图 6-15 给出 6 个五源域跨工况任务上的逐任务准确率热力图。五源域跨工况设置覆盖所有目标生产模式，能够更全面地检验多源可靠性建模在源域数量增加后的稳定性。CA-CCSR-WJDOT 在 6 个五源域跨工况任务中均取得无监督方法最高准确率，说明其收益并非依赖单一目标域，而是能够在不同目标生产模式下保持较稳定的多源选择性迁移效果。

图 6-16 给出五源域跨工况任务的平均目标域准确率柱状图。该图显示 CA-CCSR-WJDOT 在五源域跨工况场景下整体高于 CoDATS 和 WJDOT；表 6.7 进一步给出宏平均 F1、平衡准确率和无监督第一数。

表 6.7 给出五源域跨工况任务的平均诊断性能。CA-CCSR-WJDOT 在 6 个目标生产模式上均取得无监督方法第一，平均准确率达到 85.50%，高于 CoDATS 的 83.44% 和 WJDOT 的 78.37%。宏平均 F1 和平衡准确率也呈现相同趋势，说明该方法的收益并非只来自样本数量较多的类别。

为解释五源域跨工况热力图中的稳定优势，图 6-17 以第 6.3.3 节的五源域代表任务为例，给出 CA-CCSR-WJDOT 的源域-类别权重。不同故障类别并不依赖同一个源域：部分




图 6-15 五源域跨工况任务逐任务目标域准确率热力图




图 6-16 五源域跨工况任务平均目标域准确率柱状图

表 6.7 五源域跨工况主结果的平均诊断性能

方法	准确率	宏平均 F1	平衡准确率	无监督第一数
SourceOnly	71.63±10.88	68.04±12.61	71.48±11.15	0/6
CoDATS	83.44±3.19	82.46±3.42	83.21±3.53	0/6
WJDOT	78.37±4.30	75.70±5.30	78.47±4.35	0/6
CA-CCSR-WJDOT	85.50±2.50	84.30±2.58	85.51±2.54	6/6
Target-ref	92.24±1.07	91.46±1.21	92.28±1.09	—

类别更偏向 m_1 ，部分类别更偏向 m_4 或 m_6 ，也有若干类别由多个源域共同提供信息。该结果说明，方法的优势不是简单平均多个源域，而是在“源域-故障类别”层面重新分配迁移贡献。




图 6-17 五源域跨工况任务 $\{m_1, m_3, m_4, m_5, m_6\} \rightarrow m_2$ 中 CA-CCSR-WJDOT 的源域-类别权重热力图

为验证方法提升是否具有跨迁移场景的一致性，本文采用 Wilcoxon signed-rank test 对相邻方法进行配对检验。这里的配对单位是迁移场景，而不是多随机种子重复实验，因此检验结论表述为“跨迁移场景配对显著性”。为使表格含义更加直观，表 6.8 同时列出相邻方法在对应任务范围内的平均准确率提升，其中 $\uparrow$ 表示左侧改进方法相对右侧基线方法的提升幅度，单位为百分点。为控制表格宽度，表中 TPU-~ 表示 TPU-DeepJDOT。

表 6.8 相邻方法准确率提升与跨迁移场景配对显著性检验结果

配对比较	任务范围	平均准确率提升 (百分点)	正向场景数	Wilcoxon p 值
TPU-DeepJDOT 相对 DeepJDOT	单源 6 任务	$\uparrow 11.66$	6/6	0.015625
CBTPU-DeepJDOT 相对 TPU-~	单源 6 任务	$\uparrow 1.48$	6/6	0.015625
CA-CCSR-WJDOT 相对 WJDOT	多源共 9 任务	$\uparrow 7.69$	9/9	0.001953

表 6.8 表明，三组相邻方法不仅在平均准确率上取得提升，而且在对应迁移场景中均保持正向增益。具体而言，TPU-DeepJDOT 相比 DeepJDOT 平均提升 11.66 个百分点，CBTPU-DeepJDOT 相比 TPU-DeepJDOT 平均继续提升 1.48 个百分点，CA-CCSR-WJDOT 相比 WJDOT 在多源任务上平均提升 7.69 个百分点；三组比较的 Wilcoxon p 值均小于 0.05，说明这些提升在跨迁移场景配对比较下具有统计显著性。

6.5 本章小结

本章把第三章至第五章的方法放到同一套 TEP 跨工况协议下比较。单源实验中，TPU-DeepJDOT 相比 DeepJDOT 明显提高了平均准确率、宏平均 F1 和平衡准确率，说明非平衡传输、原型约束和时序统计代价确实改善了单源对齐质量。CBTPU-DeepJDOT 在 TPU-DeepJDOT 的基础上继续取得 6/6 个任务的无监督第一，说明伪标签阶段虽然增益幅度不如第三章大，但方向稳定。

多源实验中，CA-CCSR-WJDOT 在 3 个两源任务和 6 个五源任务上都取得无监督方法第一；五源任务的平均准确率为 $85.50 \pm 2.50\%$ ，高于 CoDATS 和 WJDOT。这个结果也解释了为什么只学习源域整体权重还不够：有些源域不是整体可靠或整体不可靠，而是只在部分类别上更有参考价值。

本章没有只保留平均表，而是同时给出逐任务热力图、代表场景混淆矩阵、域 t-SNE、类 t-SNE、源域-类别权重热力图和配对显著性检验。这样做是为了区分两件事：一是方法是否真的提升了目标域诊断性能，二是提升是否来自更合理的跨域结构，而不是某个任务上的偶然数值波动。

第七章 总结与展望

7.1 工作总结

本文围绕田纳西伊斯曼过程的跨生产模式故障诊断展开。与普通测试集泛化不同，跨生产模式会同时引入分布偏移、目标故障标签不可见和多源负迁移等问题。围绕这些约束，全文形成了三条方法链：单源联合对齐、单源伪标签利用和多源可靠性加权。

第三章对应单源联合对齐。DeepJDOT 能够在特征和标签预测联合空间中建立匹配，但小批量平衡传输会保留部分低质量配对。本文引入非平衡传输以削弱这类匹配，并利用源域类别原型、时间序列统计代价和源域监督对比学习，从类别中心、原始动态和源域可分性三个方面约束对齐过程。

第四章对应单源伪标签利用。第三章完成初步对齐后，目标样本仍不能直接全部纳入监督训练，因为高置信度有时只是错误边界上的过度自信。本文将传输计划、固定教师模型和源域原型作为三类证据；只有它们给出的类别语义足够接近时，目标样本才进入伪标签集合。动态阈值、类别均衡和强弱增强一致性约束则用于控制伪标签偏置。

第五章对应多源可靠性加权。多源设定下，源域数量增加并不必然带来更好结果；一个源域整体接近目标域，也不代表它对 29 个状态类别都同样适合迁移。本文在 WJDOT 的逐源传输基础上构造源域-故障类别可靠性矩阵，把源域贡献从整体权重细化到类别层面，并结合卷积式时间序列表征、领域对抗约束和教师先验保护机制完成多源诊断。

第六章的实验结果与上述方法链基本对应。单源任务中，性能提升主要来自时序原型非平衡联合分布对齐，伪标签阶段在此基础上继续修正目标域边界；多源任务中，类条件源域可靠性加权缓解了简单合并源域带来的负迁移。混淆矩阵、t-SNE 可视化和源域可靠性分析也说明，方法收益不只是平均准确率的变化，还体现在类别结构和源域贡献的可解释变化上。

7.2 不足与边界

本文方法仍存在若干边界。源工况与目标工况差异过大时，源域原型、传输计划和教师预测都会受到偏移影响，目标域语义证据可能同时变得不稳定。非平衡传输和多证据筛选可以降低风险，但不能保证在所有强偏移任务中都获得充分提升。

方法复杂度也是一个现实限制。本文同时使用最优传输、原型代价、对比学习、教师模型、伪标签筛选和源域-类别可靠性估计；与源域直接迁移或简单对抗对齐相比，这些

机制提高了表达能力，也增加了计算和调参成本。当前实验主要验证诊断效果，对训练耗时、显存占用和机制裁剪后的效率收益讨论仍不充分。

目标域无标签条件下的模型选择仍然困难。本文训练过程不使用目标域评估标签，只能依靠源域性能、目标预测分布、教师先验等间接信号判断模型状态。当目标域预测发生类别坍塌或局部过置信时，这些无标签指标可能与真实目标域性能不完全一致。

本文实验主要基于田纳西伊斯曼过程领域自适应数据集。该数据集适合分析多模式化工过程跨域诊断，但仍属于仿真基准。若面对真实工业现场中更复杂的噪声、漂移、缺失变量和未知故障类型，本文方法的泛化规律还需要进一步验证。

7.3 未来工作

后续工作宜围绕可验证实验继续推进，而不是仅扩展方法形式。

一是开展少量目标标签的标签预算实验。例如分别给每个故障类别提供 1、3、5 个目标样本，比较本文无监督方法、少样本微调方法和半监督领域自适应方法的性能变化。若多证据伪标签能够稳定利用目标样本，它应当在低标签预算下与少量真实标签形成互补。

二是开展连续目标批次的测试时自适应实验。具体做法是将目标工况样本按时间顺序或批次顺序输入模型，只允许使用当前批次无标签数据更新归一化统计、教师预测或伪标签阈值，再与固定模型比较。该实验能够检验本文方法面对目标模式缓慢漂移时是否仍然有效。

三是进一步验证源域-类别可靠性矩阵的可解释性。可在多源任务中进行 leave-one-source-out、类别遮蔽或源域类别重加权扰动实验，观察矩阵中高权重源域被移除后，对应故障类别性能是否下降更明显。若这种对应关系成立，可靠性矩阵才不只是可视化结果，而是具有可检验的诊断解释价值。

四是补充计算效率和机制裁剪实验。对非平衡传输、原型代价、对比学习、教师先验和可靠性矩阵逐项裁剪，记录准确率、宏平均 F1、训练时间和显存占用。这样可以判断哪些机制是性能提升的主要来源，哪些机制更适合在计算资源受限的工业部署中简化。

五是在更接近真实现场的数据上验证鲁棒性，包括含缺失变量、强噪声、工况连续漂移或未见故障类型的场景。若本文方法要进一步面向实际应用，还需要证明其不只适用于固定基准任务，也能在数据质量和故障集合都不稳定的条件下保持可解释的诊断行为。

参考文献

- [1] LEI Y, YANG B, JIANG X, et al. Applications of machine learning to machine fault diagnosis: A review and roadmap[J]. Mechanical Systems and Signal Processing, 2020, 138: 106587.
- [2] WANG C, WANG Z, LIU Q, et al. A comprehensive survey on domain adaptation for intelligent fault diagnosis[J]. Knowledge-Based Systems, 2025, 327: 114109.
- [3] PAN S J, YANG Q. A survey on transfer learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359.
- [4] MONTESUMA E F, MULAS M, MBOULA F N, et al. Benchmarking domain adaptation for chemical processes on the Tennessee Eastman Process[EB]. (2024-07-29). <https://arxiv.org/abs/2308.11247v2>.
- [5] QIN S J. Survey on data-driven industrial process monitoring and diagnosis[J]. Annual Reviews in Control, 2012, 36(2): 220-234.
- [6] GE Z. Review on data-driven modeling and monitoring for plant-wide industrial processes[J]. Chemometrics and Intelligent Laboratory Systems, 2017, 171: 16-25.
- [7] TAQVIS A A, ZABIRI H, TUFA L D, et al. A review on data-driven learning approaches for fault detection and diagnosis in chemical processes[J]. ChemBioEng Reviews, 2021, 8(3): 239-259.
- [8] YU J, ZHANG Y. Challenges and opportunities of deep learning-based process fault detection and diagnosis: A review[J]. Neural Computing and Applications, 2023, 35(1): 211-252.
- [9] LI W, HUANG R, LI J, et al. A perspective survey on deep transfer learning for fault diagnosis in industrial scenarios: Theories, applications and challenges[J]. Mechanical Systems and Signal Processing, 2022, 167: 108487.
- [10] COURTY N, FLAMARY R, TUIA D, et al. Optimal transport for domain adaptation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(9): 1853-1865.
- [11] DAMODARAN B B, KELLENBERGER B, FLAMARY R, et al. DeepJDOT: Deep joint distribution optimal transport for unsupervised domain adaptation[C]//Computer Vision – ECCV 2018. Cham: Springer International Publishing, 2018: 467-483.
- [12] WILSON G, DOPPA J R, COOK D J. Multi-source deep domain adaptation with weak supervision for time-series sensor data[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. ACM, 2020: 1768-1778.

- [13] TURRISI R, FLAMARY R, RAKOTOMAMONJY A, et al. Multi-source domain adaptation via weighted joint distributions optimal transport[C]//Proceedings of the Thirty-Eighth Conference on Uncertainty in Artificial Intelligence. PMLR, 2022: 1970-1980.
- [14] WANG Z, YAN W, OATES T. Time series classification from scratch with deep neural networks: A strong baseline[C]//2017 International Joint Conference on Neural Networks. IEEE, 2017: 1578-1585.
- [15] FAWAZ H I, FORESTIER G, WEBER J, et al. Deep learning for time series classification: A review[J]. Data Mining and Knowledge Discovery, 2019, 33(4): 917-963.
- [16] COURTY N, FLAMARY R, HABRARD A, et al. Joint distribution optimal transportation for domain adaptation[C]//Advances in Neural Information Processing Systems (NeurIPS). Curran Associates, Inc., 2017: 3730-3739.
- [17] GANIN Y, USTINOVA E, AJAKAN H, et al. Domain-adversarial training of neural networks[J]. Journal of Machine Learning Research, 2016, 17(59): 1-35.
- [18] PEYRÉ G, CUTURI M. Computational optimal transport: With applications to data science[M]. Now Publishers, 2019.
- [19] FATRAS K, SÉJOURNÉ T, COURTY N, et al. Unbalanced minibatch optimal transport; applications to domain adaptation[C]//Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021: 3186-3197.
- [20] SNELL J, SWERSKY K, ZEMEL R S. Prototypical networks for few-shot learning[C]//Advances in Neural Information Processing Systems. Curran Associates, Inc., 2017: 4077-4087.
- [21] ZHANG P, ZHANG B, ZHANG T, et al. Prototypical pseudo label denoising and target structure learning for domain adaptive semantic segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2021: 12414-12424.
- [22] KHOSLA P, TETERWAK P, WANG C, et al. Supervised contrastive learning[C]//Advances in Neural Information Processing Systems. Curran Associates, Inc., 2020: 18661-18673.
- [23] LEE D H. Pseudo-Label: The simple and efficient semi-supervised learning method for deep neural networks[C]//ICML 2013 Workshop: Challenges in Representation Learning (WREPL). Atlanta, Georgia, USA, 2013.
- [24] TARVAINEN A, VALPOLA H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[C]//Advances in Neural Information Processing Systems

- (NeurIPS). Curran Associates, Inc., 2017: 1195-1204.
- [25] CUI Y, JIA M, LIN T Y, et al. Class-balanced loss based on effective number of samples[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2019: 9268-9277.
- [26] WANG X, WU Z, LIAN L, et al. Debaised learning from naturally imbalanced pseudo-labels[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2022: 14647-14657.
- [27] BERTHELOT D, CARLINI N, CUBUK E D, et al. ReMixMatch: Semi-supervised learning with distribution alignment and augmentation anchoring[C]//International Conference on Learning Representations. 2020.
- [28] BERTHELOT D, ROELOFS R, SOHN K, et al. AdaMatch: A unified approach to semi-supervised learning and domain adaptation[C]//International Conference on Learning Representations. 2022.
- [29] SOHN K, BERTHELOT D, LI C L, et al. FixMatch: Simplifying semi-supervised learning with consistency and confidence[C]//Advances in Neural Information Processing Systems. Curran Associates, Inc., 2020: 596-608.
- [30] ZHANG W, DENG L, ZHANG L, et al. A survey on negative transfer[J]. IEEE/CAA Journal of Automatica Sinica, 2023, 10(2): 305-329.
- [31] GUO J, SHAH D, BARZILAY R. Multi-source domain adaptation with mixture of experts[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2018: 4694-4703.
- [32] PENG X, BAI Q, XIA X, et al. Moment matching for multi-source domain adaptation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2019: 1406-1415.
- [33] HINTON G, VINYALS O, DEAN J. Distilling the knowledge in a neural network[EB]. (2015-03-09). <https://arxiv.org/abs/1503.02531>.
- [34] ZHU Y, ZHUANG F, WANG J, et al. Deep subdomain adaptation network for image classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(4): 1713-1722.
- [35] LONG M, CAO Z, WANG J, et al. Conditional adversarial domain adaptation[C]//Advances in Neural Information Processing Systems (NeurIPS). Curran Associates, Inc., 2018: 1647-1657.
- [36] DOWNS J J, VOGEL E F. A plant-wide industrial process control problem[J]. Computers & Chemical Engineering, 1993, 17(3): 245-255.

- [37] REINARTZ C, KULAHCI M, RAVN O. An extended Tennessee Eastman simulation dataset for fault-detection and decision support systems[J]. Computers & Chemical Engineering, 2021, 149: 107281.

附录 A 论文符号表

为避免正文中同一符号表示不同含义，本文将主要数学符号统一整理如表 A.1 所示。上标 s 、 t 和 s_k 分别表示源域、目标域和第 k 个源域；未列入表中的局部求和下标仅在其所在公式附近使用。

表 A.1 论文主要符号表

符号	含义	说明
数据、领域与类别		
$\mathcal{D}_s, \mathcal{D}_t, \mathcal{D}_{s_k}$	源域、目标域、第 k 个源域数据集	单源或多源领域自适应设定
$\mathcal{D}_s^{\text{train}}, \mathcal{D}_t^{\text{train}}, \mathcal{D}_t^{\text{test}}$	源域训练集、目标域无标签训练集、目标域测试集	目标域测试标签仅用于最终评价
$\mathcal{B}_s, \mathcal{B}_t, \mathcal{B}_{s_k}$	源域小批量、目标域小批量、第 k 个源域小批量	训练迭代中采样得到
$\mathcal{B}_s^c$	源域小批量中第 c 类样本集合	用于源域原型更新
$x, x_i^s, x_j^t, x_i^{s_k}, x_u^t$	通用样本、源域样本、目标域样本、第 k 源域样本、目标测试样本	均表示多变量时间序列窗口
$y_i^s, y_i^{s_k}, y_u^t$	源域标签、第 k 源域标签、目标域测试标签	y_u^t 不参与训练
h	目标域诊断函数	由训练后的诊断模型给出
$P_s(X), P_t(X), P_{s_k}(X), P_{s_l}(X)$	源域、目标域及不同源域的数据分布	用于描述分布偏移
$\mathbf{X}^{(m)}$	第 m 个生产模式的数据张量	维度为 $N_m \times 600 \times 34$
V, L, L'	过程变量数量、输入时间窗口长度、卷积输出时间长度	L' 仅用于全局平均池化
n_s, n_t, n_k, N_m	源域样本数、目标域样本数、第 k 源域样本数、第 m 模式样本数	数据集规模
$n_s^{\text{bat}}, n_t^{\text{bat}}$	源域小批量大小与目标域小批量大小	非平衡传输公式中的批量维度

续表 A.1

符号	含义	说明
K, N_c	源域数量、故障类别数量	TEP 数据集中 $N_c = 29$
$\mathcal{Y}$	标签空间	$\{0, 1, \dots, 28\}$
$m_1, \dots, m_6$	TEP 生产模式编号	实验场景中的领域标识
$m_s, m_t, m_{s_1}, \dots, m_{s_K}$	源模式、目标模式、多个源模式	用于迁移任务表示
$x_{i,t,j}^{(m)}, \tilde{x}_{i,t,j}^{(m)}$	原始样本取值与标准化后取值	第 m 模式、第 i 样本、第 t 时间步、第 j 变量
$\bar{x}_j^{(m)}, \sigma_j^{(m)}$	第 m 模式第 j 个变量的均值与标准差	用于模式内标准化
ϵ	数值稳定常数	防止除零或对数为零
ν, N_{iter}	训练步索引与总训练步数	ν 不再表示时间序列下标
模型、特征与预测		
$F_\theta(\cdot)$	特征提取器	参数为 θ
$G_\phi(\cdot)$	故障分类器	参数为 ϕ
$G_{\phi,c}(\cdot)$	分类器输出第 c 类概率的分量	领域对抗基线公式中使用
$D_\omega(\cdot)$	领域判别器	参数为 ω
$\Theta, \bar{\Theta}, \Theta_{\text{TPU}}$	学生模型、教师模型和 TPU-DeepJDOT 阶段模型参数集合	$\Theta = (\theta, \phi)$, $\bar{\Theta} = (\bar{\theta}, \bar{\phi})$
ξ	指数滑动平均教师衰减系数	仅在滑动平均教师形式下用于更新 $\bar{\Theta}$
$z, z_i^s, z_j^t, z_i^{s_k}, \tilde{z}_i$	深度特征、源特征、目标特征、多源特征、归一化特征	由 F_θ 输出或归一化得到
d_z, d_ψ	深度特征维度与时序描述符维度	用于代价归一化
$p, p_i^{s_k}, p_j^t, p_{k_j}^t, p_{k_j r}^t, p_{jc}$	类别预测概率分布及其分量	$p_{k_j r}^t$ 和 p_{jc} 表示对应类别分量

续表 A.1

符号	含义	说明
$p_{\theta, \phi}(\cdot x)$	学生模型对样本 x 的 softmax 概率	等价于 $G_{\phi}(F_{\theta}(x))$ 的概率输出
$p_j^{\text{stu}}, p_j^{\text{tea}}, p_j^{\text{final}}$	学生预测、教师预测和最终融合预测概率	教师-学生预测融合使用
$s_j^{\text{stu}}, s_j^{\text{tea}}, \Delta_{\text{conf}}, \Delta_{\text{min}}, \Delta_{\text{max}}, \omega_{\text{mix}}$	学生/教师置信度与融合参数	第四章教师-学生预测融合使用
$p_j^{\text{base}}, p_j^{\text{pb}}, \bar{p}^{\text{base}}$	基础混合预测、先验均衡预测、批次平均预测	无标签概率校正使用
$\hat{y}, \hat{y}_j^t$	预测类别或伪标签类别	由概率分布的最大分量确定
$u_{jc}, \tilde{u}_{jc}, \tilde{u}_j$	原始预测得分、类别均衡后得分及其向量形式	伪标签类别均衡使用
$u_j^{\text{tea}}, u_j^{\text{stu}}$	教师模型和学生模型的未归一化预测得分	教师先验约束使用
$a_w(\cdot), a_s(\cdot)$	弱增强与强增强变换	用于目标域一致性学习
$U^{(l-1)}, U^{(l)}, U, U_{r,t}, z_r, W^{(l)}, b^{(l)}$	卷积层输入/输出、最终卷积输出元素、池化后特征元素、卷积核与偏置	卷积式时间序列特征提取
$\varphi(\cdot)$	非线性激活函数	与标准差 σ 区分
Z_s, Z_t	源域特征集合与目标域特征集合	领域对抗损失中使用
最优传输与对齐		
$C, C_{ij}, C_{ij}^{(k)}, C^{(k)}, C^{\text{loss}}$	传输代价矩阵、代价元素、第 k 源域代价、 C 专用于代价矩阵矩阵形式、训练代价	
$\gamma, \gamma^*, \gamma_{ij}, \gamma_{ij}^{(k)}, \gamma_k, \gamma_k^*, \gamma_{k,ij}$	传输计划、最优传输计划及其元素、第 k 源域传输计划及其元素	表示源目标样本匹配质量
$\Pi(a, b), \Pi(a_k, b)$	满足边际分布的传输计划集合	a_k 为第 k 源域边际
a, b, a_k	源域边际、目标域边际、第 k 源域边际	传输计划的边际质量

续表 A.1

符号	含义	说明
$\mathbf{1}$	全 1 向量	下标表示向量长度
ε	熵正则系数	非平衡 Sinkhorn 求解中使用
τ_s, τ_t	源边际与目标边际的松弛强度	仅用于非平衡最优传输
$\text{KL}(\cdot\ \cdot), \langle \cdot, \cdot \rangle$	KL 散度与矩阵内积	传输目标和一致性损失中使用
$\mathcal{L}_{\text{UOT}}$	非平衡最优传输目标	用于说明非平衡传输原理
$c_{ij}^f, c_{ij}^y, c_{ij}^{\text{temp}}$	特征代价、标签预测代价和时序统计代价	组成联合传输代价
$\text{dist}(\cdot, \cdot)$	特征空间距离函数	避免与维度 d_z 混淆
$\ell(\cdot, \cdot)$	分类或标签预测损失	通常为交叉熵
λ_f, λ_y	特征代价与标签代价权重	传输代价中的权重
$\lambda_{\text{ot}}, \lambda_{\text{ot}}(\nu)$	最优传输对齐损失权重	后者表示随训练步变化的调度权重
$\lambda_p(\nu), \lambda_{\text{temp}}(\nu), \lambda_p^0$	原型代价权重、时序统计代价权重、原型代价基础权重	延迟启动并线性预热
ν_p, S_p	原型代价启动步数与预热步数	时序统计代价采用相同形式
原型、伪标签与一致性		
$\mu_c, \bar{\mu}_c, \mu_{kc}^s, \mu_c^t$	源域类别原型、小批量源类均值、第 k 源域原型、目标域原型	用于类别结构建模
ρ	源域原型动量系数	原型指数滑动平均
$d_{cj}^{\text{proto}}, d_{jc}^{\text{proto}}$	目标样本到源域类别原型的距离	分别服务于传输代价和原型语义分布

续表 A.1

符号	含义	说明
$\bar{d}_{-y_i^s, j}^{\text{proto}}, \sigma_j^{\text{proto}}$	目标样本到其他有效源类原型距离的均值与标准差	相对原型代价归一化
$r_{ij}^{\text{proto}}, r_{\min}, r_{\max}$	相对原型代价及其裁剪下界和上界	衡量目标样本相对接近源类别的程度
$\bar{x}_{\text{seq}}(x), \sigma_{\text{seq}}(x)$	样本时间维度均值与标准差	时序描述符的一部分
$\bar{\Delta}_{\text{seq}}(x), \sigma_{\Delta}(x)$	一阶差分均值与标准差	时序描述符的一部分
$\Delta x_{:,t}$	样本在时间维度上的一阶差分	时序描述符的一部分
$\psi(x)$	时间序列统计描述符	由均值、标准差和一阶差分统计量拼接得到
$\mathcal{P}(i), \mathcal{I}$	样本 i 的同类正样本集合、存在正样本的索引集合	源域监督对比学习
T_{con}	监督对比学习温度	与可靠性和蒸馏温度区分
$q_j^{\text{ot}}, q_j^{\text{cls}}, q_j^{\text{proto}}, q_j^{\text{mix}}$	传输语义、教师预测语义、原型语义和融合语义分布	多证据伪标签筛选
m_{cj}^{ot}	第 c 类源样本传向目标样本 j 的传输质量	归一化后得到 q_j^{ot}
$\hat{y}_j^{\text{ot}}, \hat{y}_j^{\text{cls}}, \hat{y}_j^{\text{proto}}$	三类语义证据各自的最大概率类别	多证据一致性判断使用
κ_j	目标样本融合语义置信度	$\kappa_j = \max_c q_{jc}^{\text{mix}}$
$\alpha_{\text{ot}}, \alpha_{\text{cls}}, \alpha_{\text{proto}}$	三类语义证据的融合指数	用于幂加权几何平均
$D_{\text{JS}}, \bar{q}, \delta_{\text{JS}}$	Jensen–Shannon 差异、三证据均值分布及差异阈值	多证据一致性筛选
$H(q), h_{\text{ot}}$	归一化熵及传输语义熵阈值	衡量语义分布确定性
$\mathcal{A}_j, \mathcal{A}$	目标样本接受指示与被接受样本集合	伪标签学习使用

续表 A.1

符号	含义	说明
$\vartheta(\nu)$ 、 ϑ_{start} 、 ϑ_{end}	动态伪标签置信阈值及其起止值	与非平衡传输松弛 τ_s, τ_t 区分
ν_0, S_ϑ	伪标签启动步数与阈值下降步数	动态阈值调度参数
$\hat{\pi}_c$	被接受伪标签集合中第 c 类频率	类别均衡调整
η_{bal}	类别均衡调整强度	对强增强预测得分进行对数先验调整
S_{cons}	参与一致性损失的目标样本集合	包括高置信和部分中等置信目标样本
$T_{\text{tea}}, T_{\text{proto}}$	教师预测温度与原型语义温度	伪标签语义分布估计
多源可靠性与损失函数		
$R \in \mathbb{R}^{K \times N_c}$	源域-故障类别可靠性矩阵	数值越小表示越可靠
$R_{kc}, \alpha_{kc}, \alpha_{kc}(\nu)$	第 k 源域第 c 类可靠性分数、类条件权重及其训练步调度形式	$\sum_k \alpha_{kc} = 1$
α_k	第 k 个源域的全局源域权重	WJDOT 中使用
$D_{kc}^{\text{proto}}, D_{kc}^{\text{ot}}$	源目标原型距离和类条件传输代价	构成可靠性矩阵
$H_{kc}^{\text{pred}}, E_{kc}^s, \text{Recall}_{kc}^s$	目标预测熵、源域类别召回误差、源域类别召回率	构成可靠性矩阵
M_{kc}^{ot}	第 k 个源域第 c 类传输质量	计算类条件传输代价
$\mathcal{T}_c$	当前暂定属于第 c 类的目标样本集合	用于目标预测熵估计
$\tilde{D}_{kc}^{\text{proto}}, \tilde{D}_{kc}^{\text{ot}}, \tilde{H}_{kc}^{\text{pred}}, \tilde{E}_{kc}^s$	归一化后的可靠性证据	按类别维度 min-max 归一化
w_p, w_o, w_h, w_e	原型距离、传输代价、预测熵和源域误差的组合权重	可靠性分数线性组合
T_{rel}	可靠性权重 softmax 温度	类条件源域权重分配
α_{min}	类条件源域权重下界	防止权重过度集中

续表 A.1

符号	含义	说明
$r_{\text{rel}}(\nu)$	可靠性权重启用进度	从均匀权重过渡到类条件权重
$\mathbb{I}(\cdot)$ 、 $\mathbb{I}_{kc}$ 、 $\mathcal{C}_{\text{act}}$	指示函数、源域类别存在指示、当前活跃类别集合	分类和类条件传输损失中使用
T_{dist}	教师先验蒸馏温度	多源教师先验约束
ζ_j	教师—学生预测融合系数	最终目标域诊断结果融合
β	先验均衡强度	无标签概率校正
$\mathcal{L}_{\text{src}}$ 、 $\mathcal{L}_{\text{OT}}$ 、 $\mathcal{L}_{\text{align}}$ 、 $\mathcal{L}_{\text{dom}}$	源域分类损失、最优传输损失、非平衡联合传输对齐损失、领域判别损失	基础训练目标
$\mathcal{L}_{\text{supcon}}$ 、 $\mathcal{L}_{\text{pl}}$ 、 $\mathcal{L}_{\text{cons}}$ 、 $\mathcal{L}_{\text{im}}$	源域监督对比损失、伪标签损失、一致性损失、信息最大化正则项	单源改进方法中使用
$\mathcal{L}_{\text{tea}}$ 、 $\mathcal{L}_{\text{WJDOT}}$ 、 $\mathcal{L}_{\text{CCSR}}$	教师先验约束、逐源传输聚合损失和类条件传输损失	多源方法中使用
$\mathcal{L}_{\text{TPU}}$ 、 $\mathcal{L}_{\text{CBTPU}}$ 、 $\mathcal{L}_{\text{CA-CCSR}}$	第三章、第四章和第五章方法的总体损失	分别对应三类方法
$\lambda_{\text{supcon}}(\nu)$ 、 $\lambda_{\text{pl}}(\nu)$ 、 $\lambda_{\text{cons}}(\nu)$ 、 $\lambda_{\text{im}}(\nu)$	监督对比、伪标签、一致性和信息最大化损失权重	单源调度权重
λ_d 、 $\lambda_d(\nu)$ 、 λ_s 、 λ_{ccsr} 、 $\lambda_{\text{tea}}(\nu)$	领域判别、源域分类、类条件传输和教师约束权重	领域对抗和多源方法中使用
$r_{\text{ot}}(\nu)$ 、 $r_{\text{ccsr}}(\nu)$	WJDOT 与 CCSR 损失的启用进度	多源训练调度参数
λ	其他损失项或代价项的权重	具体下标与对应损失或代价一致

附录 B 主要算法参数表

本附录只列出本文三条主要创新方法在主实验中采用的主要算法参数。表中符号与正文第三章至第五章保持一致；目标域标签仅用于最终评价，不参与训练、早停、模型选择或参数确定。

为避免附录冗长，表中只列出影响三类创新方法的主要数值参数。若某一参数在特定场景中有单独取值，则以场景参数表为准；未列出的基线方法参数不属于本文创新方法参数，故不在本附录展开。

表 B.1 主实验公共参数

参数含义	符号	取值
随机种子	s_{rand}	42
目标域标签可见性	y^t	无监督领域自适应方法训练、早停、模型选择和参数确定阶段不可见；仅 Target-ref 有标签参考及最终评价使用
故障类别数	N_c	29
固定数据划分	F_s, F_t	源域与目标域均采用第 1 折
评估间隔	I_{eval}	5 个训练轮
模型选择间隔	I_{sel}	5 个训练轮
早停检查间隔	I_{es}	5 个训练轮
单源早停最小轮数	$E_{\text{es,min}}^{\text{single}}$	120
多源早停最小轮数	$E_{\text{es,min}}^{\text{multi}}$	80

B.1 单源方法参数

表 B.2 TPU-DeepJDOT 与 CBTPU-DeepJDOT 主参数

参数含义	符号	TPU-DeepJDOT	CBTPU-DeepJDOT
训练轮数	E	120	80
批量大小	B	64	64

续表 B.2

参数含义	符号	TPU-DeepJDOT	CBTPU-DeepJDOT
学习率	η_{lr}	1.0×10^{-4}	6.0×10^{-5}
梯度裁剪阈值	$g_{\max}$	5.0	5.0
对齐损失基础权重	λ_{ot}^0	0.58	0.52
对齐启动步数	ν_{align}	450	200
Sinkhorn 熵正则	ε	0.05	0.05
Sinkhorn 最大迭代	N_{Sink}	200	200
非平衡源边际松弛	τ_s	1.0	1.0
非平衡目标边际松弛	τ_t	1.0	1.0
监督对比权重	λ_{supcon}^0	0.045	0.030
监督对比温度	T_{con}	0.10	0.10
源域原型动量	ρ	0.95	0.95
相对原型代价裁剪	$r_{\min}, r_{\max}$	-1.0, 3.0	-1.0, 3.0
原型代价权重	λ_p^0	0.020	0.018
原型代价启动/预热	ν_p, S_p	450, 750	200, 500
时序代价权重	λ_{temp}^0	0.012	0.010
时序代价启动/预热	ν_{temp}, S_{temp}	450, 750	200, 500
教师温度	T_{tea}	—	1.0
原型语义温度	T_{proto}	—	0.18
指数滑动平均教师衰减	ξ	—	0.996, 固定教师设定下 不更新
三证据融合指数	$\alpha_{ot}, \alpha_{cls}, \alpha_{proto}$	—	1.0, 1.0, 1.0
伪标签权重	λ_{pl}^0	—	0.012
伪标签启动/预热	ν_{pl}, S_{pl}	—	250, 700
动态阈值起止	$\vartheta_{start}, \vartheta_{end}$	—	0.92, 0.84
阈值下降步数	S_{ϑ}	—	1100
最大伪标签接收率	$a_{\max}$	—	0.55

续表 B.2

参数含义	符号	TPU-DeepJDOT	CBTPU-DeepJDOT
传输语义熵阈值	h_{ot}	—	0.76
JS 差异阈值	δ_{JS}	—	0.075
一致性权重	λ_{cons}^0	—	0.020
一致性启动/预热	ν_{cons}, S_{cons}	—	250, 700
中等置信一致性阈值	τ_{mid}	—	0.52
类别均衡强度	η_{bal}	—	0.10
信息最大化权重	λ_{im}^0	—	0.0015
信息最大化启动比例/预热	r_{im}, S_{im}	—	0.75, 500
热			
弱增强抖动/缩放	$\sigma_w^{jit}, \sigma_w^{scale}$	—	0.006, 0.006
强增强抖动/缩放	$\sigma_s^{jit}, \sigma_s^{scale}$	—	0.016, 0.016
强增强时间遮挡率/通道 丢弃率	p_{mask}, p_{drop}	—	0.08, 0.06

表 B.3 单源场景级参数取值

场景	参数符号	场景取值
$m_1 \rightarrow m_2$	TPU-DeepJDOT: $\lambda_{ot}^0, \nu_{align}, \nu_p, S_p, \nu_{temp}, S_{temp};$ CBTPU-DeepJDOT: $\lambda_{ot}^0, \lambda_{pl}^0, \vartheta_{start}, \vartheta_{end}, a_{max}, \lambda_{cons}^0$	TPU-DeepJDOT: 0.62, 700, 700, 900, 700, 900; CBTPU-DeepJDOT: 0.50, 0.008, 0.94, 0.88, 0.40, 0.014
$m_1 \rightarrow m_5$	$\omega_{mix}, \lambda_{ot}^0, \lambda_{pl}^0, \vartheta_{start}, \vartheta_{end}, a_{max}, h_{ot}$	0.10, 0.50, 0.010, 0.94, 0.87, 0.45, 0.72
$m_2 \rightarrow m_1$	$\omega_{mix}, \lambda_{ot}^0, \lambda_{pl}^0, \lambda_{cons}^0, \alpha_{cls}, \alpha_{proto}$	0.12, 0.50, 0.010, 0.016, 1.25, 0.85
$m_2 \rightarrow m_5$	$\Delta_{min}, \Delta_{max}; \lambda_{ot}^0, \lambda_{pl}^0; \vartheta_{start}, \vartheta_{end};$ $a_{max}, \lambda_{cons}^0$	−0.40, 0.10; 0.50, 0.008; 0.95, 0.88; 0.38, 0.012
$m_5 \rightarrow m_1$	—	采用表 B.2 通用取值

续表 B.3

场景	参数符号	场景取值
$m_5 \rightarrow m_2$	$\Delta_{\min}, \Delta_{\max}$	-0.40, 0.04; 其余采用表 B.2 通用取值

B.2 多源方法参数

表 B.4 列出 CA-CCSR-WJDOT 在二源和五源实验中的核心算法参数。二源实验采用统一参数；五源实验的目标域相关场景取值见表 B.5。

表 B.4 CA-CCSR-WJDOT 主参数

参数含义	符号	二源	五源通用
训练轮数	E	28	28
批量大小	B	32	32
学习率	η_{lr}	4.0×10^{-5}	4.0×10^{-5}
梯度裁剪阈值	$g_{\max}$	3.0	3.0
WJDOT 调度基础权重	r_{ot}^0	0.48	0.48
源域分类权重	λ_s	0.75	0.75
特征代价权重	λ_f	0.06	0.06
标签代价权重	λ_y	1.0	1.0
Sinkhorn 熵正则	ε	0.05	0.05
Sinkhorn 最大迭代	N_{Sink}	70	70
对齐启动/预热	$\nu_{\text{align}}, S_{\text{align}}$	0, 350	0, 350
可靠性启动比例	$r_{\text{rel},0}$	0.25	0.25
可靠性预热比例	$r_{\text{rel},S}$	0.30	0.30
可靠性总步数	N_{rel}	1800	1800
类条件温度	T_{rel}	0.45	0.45
类条件权重下界	$\alpha_{\min}$	0.02	0.02
每类候选样本数	M_{top}	3	3
原型阈值	τ_{proto}	0.84	0.84

续表 B.4

参数含义	符号	二源	五源通用
最小原型样本数	$n_{\min}^{\text{proto}}$	3	3
可靠性证据权重	w_p, w_o, w_h, w_e	0.34, 0.36, 0.18, 0.12	0.34, 0.36, 0.18, 0.12
领域对抗权重	λ_d	0.12	0.12
WJDOT 损失权重	λ_{WJDOT}	0.055	0.055
CCSR 损失权重	λ_{CCSR}	0.055	0.055
教师约束权重	λ_{tea}	0.12	0.12
教师约束预热步数	S_{tea}	400	400
领域自适应最大步数	N_{da}	700	700
梯度反转系数	λ_{grl}	0.45	0.45
梯度反转最大迭代	N_{grl}	700	700
先验均衡强度	β	1.30	0.80
学生混合比例	ω_{mix}	0.35	0.35
最小先验概率	$\pi_{\min}$	10^{-4}	10^{-4}
同类融合系数	λ_{same}	0.04	0.04
替代融合系数	$\lambda_{\text{override}}$	0.35	0.35
替代置信/熵裕度	$\Delta_{\text{conf}}, \Delta_H$	0.08, 0.04	0.08, 0.04
融合系数范围	$\eta_{\min}, \eta_{\max}$	0, 0.45	0, 0.45
学生保护裕度	$\Delta_{\text{guard}}^{\text{conf}}, \Delta_{\text{guard}}^H$	—	0.05, 0.02
WJDOT 参考融合权重	α_{anchor}	0.28	0.41

表 B.5 五源 CA-CCSR-WJDOT 场景级参数取值

目标域	场景参数取值
m_1	采用表 B.4 五源通用取值。

续表 B.5

目标域	场景参数取值
m_2	$E = 32$, $\eta_{lr} = 5.0 \times 10^{-5}$, $\lambda_s = 0.70$, $\lambda_d = 0.10$, $\lambda_{WJDOT} = \lambda_{CCSR} = 0.070$, $\lambda_{tea} = 0.08$, $(w_p, w_o, w_h, w_e) = (0.30, 0.42, 0.18, 0.10)$, $\lambda_{same} = \lambda_{override} = 0$, $(\Delta_{conf}, \Delta_H) = (0.04, 0.02)$, $(\eta_{min}, \eta_{max}) = (0, 0.70)$ 。
m_3	$E = 20$, $\eta_{lr} = 3.0 \times 10^{-5}$, $r_{ot}^0 = 0.45$, $\lambda_s = 0.70$, $S_{align} = 300$, $N_{rel} = 1440$, $(w_p, w_o, w_h, w_e) = (0.30, 0.35, 0.20, 0.15)$, $\lambda_d = 0.15$, $\lambda_{WJDOT} = \lambda_{CCSR} = 0.04$, $\lambda_{tea} = 0.20$, $\lambda_{same} = 0.05$, $\lambda_{override} = 0.60$, $(\eta_{min}, \eta_{max}) = (0, 0.70)$ 。
m_4	采用表 B.4 五源通用取值。
m_5	沿用 m_3 的场景参数，但 $\lambda_{same} = \lambda_{override} = 0$ 。
m_6	$E = 30$, $\lambda_s = 0.82$, $\lambda_d = 0.10$, $\lambda_{WJDOT} = \lambda_{CCSR} = 0.060$, $\lambda_{tea} = 0.08$ ；融合参数采用 m_2 的场景取值。

以上参数表仅用于说明本文主要实验中的算法超参数取值；未在表中列出的量按正文算法定义取值。

致 谢

值此本科毕业论文完成之际，谨向在大学期间关心、指导和帮助过我的老师、学长、同学及家人表示诚挚感谢。

感谢指导教师王永健老师在毕业设计选题、研究思路梳理、实验推进和论文撰写过程中给予我耐心细致的指导与帮助，使我得以顺利完成本论文的研究工作。老师在个人发展与后续规划等方面给予我的支持与鼓励，也给了我很大帮助；老师严谨认真的治学态度和认真负责的工作作风，将继续影响我今后的学习与工作。

感谢蒋徐颢、蔡闻骁、邹滨阳等学长和同学在学习与成长过程中给予我的帮助与示范。他们在专业学习、科研视野和个人规划方面的经验分享，使我受益良多。

感谢严震霆、周志铭、曲振宁等同学和朋友在本科阶段给予我的陪伴、支持与鼓励。在课题讨论、日常学习和生活交流中，他们给予了我许多真诚的帮助，使我能够更加从容地面对学习和毕业设计过程中的困难与挑战。

感谢我的父母和家人一直以来给予我的理解、包容和支持，使我能够安心完成本科阶段的学习任务与毕业论文工作。

止於至善



SOUTHEAST UNIVERSITY