# 本科毕业设计（论文）报告

题 目：基于领域自适应的工业过程故障诊断方法研究

学　　号：08022311

姓　　名：陈鲲龙

学　　院：自动化

专　　业：自动化

指导教师：王永健、童国道

起止日期：2026 年 3 月 ~2026 年 6 月

# 东南大学毕业（设计）论文独创性声明

本人声明所呈交的毕业（设计）论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签名：_____　　日期：__2026__年__6__月_____日

# 东南大学毕业（设计）论文使用授权声明

东南大学有权保留本人所送交毕业（设计）论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括刊登）论文的全部或部分内容。论文的公布（包括刊登）授权东南大学教务处办理。

论文作者签名：_____　　导师签名：_____

日期：__2026__年__6__月_____日　　日期：__2026__年__6__月_____日

# 摘　　要

工业过程故障诊断对于保障生产安全、降低非计划停机损失和提升过程运行可靠性具有重要意义。然而，在真实流程工业现场中，不同操作模式、负载水平和控制阶段往往对应不同的数据分布，使得仅在历史工况上训练得到的诊断模型难以直接迁移到新工况。面向这一问题，本文以 Tennessee Eastman Process Domain Adaptation 数据集为对象，研究跨工况无监督领域自适应故障诊断，并围绕统一 benchmark 构建、典型方法比较和改进方法设计展开系统研究。

本文首先构建了面向 TEP 跨工况迁移诊断的统一实验流程，统一了数据组织方式、归一化策略、共享骨干网络、模型选择规则和结果管理方式，并据此组织包含 11 个迁移场景和 8 种方法的 fixed-fold benchmark。该 benchmark 同时覆盖单源到单目标和多源到单目标场景，可为不同领域自适应方法提供可复现的横向比较基础。

在此基础上，本文提出可靠性门控的类条件时序自适应方法 RCTA。该方法以强对齐分支为底座，引入 EMA 教师网络、弱强双视图时序增强、多因素可靠性门控、双原型记忆以及课程化优化与置信保护型模型选择策略，以实现更稳定的目标域伪监督利用和更清晰的类条件结构建模。与将多种技巧简单并列不同，本文将上述机制分别对应到“目标域样本如何进入训练”“哪些目标样本可信”“如何保持类条件结构”“多项约束何时进入优化”四类具体痛点，形成了面向工业多类别时序迁移任务的机制性集成方案。

当前版本已完成方法章节扩写、benchmark 结果表与图件占位整理，并将论文实验口径与正式运行配置对齐。待最终 benchmark 数据与图件回填后，可进一步形成完整的定量比较、定性分析与模块级消融论证。总体而言，本文形成了从统一实验基准构建到改进方法验证的完整研究链路，可为流程工业无监督领域自适应故障诊断研究提供可复现的比较基础和有效的方法参考。

关键词：故障诊断，领域自适应，TEP，无监督领域自适应

# ABSTRACT

Industrial fault diagnosis is important for production safety, reducing unplanned downtime, and ensuring reliable process operation. In real industrial processes, however, data collected under different operating modes, load levels, and control stages often follow different distributions. Consequently, diagnostic models trained in single-source, multi-source, and more general cross-domain settings often generalize poorly to new operating conditions. To address this problem, this thesis investigates unsupervised domain adaptation for cross-mode fault diagnosis on the Tennessee Eastman Process Domain Adaptation dataset, focusing on unified benchmark construction, baseline comparison, and method improvement.

This work first establishes a unified and reproducible experimental pipeline for cross-mode transfer fault diagnosis on TEP. The pipeline standardizes data organization, normalization, shared backbone design, model selection, and result management, and organizes a fixed-fold benchmark with 11 transfer scenarios and 8 methods. The benchmark covers both single-source-to-single-target and multi-source-to-single-target settings, providing a consistent basis for fair comparison.

On this basis, the thesis proposes a Reliability-Gated Class-Conditional Temporal Adaptation method, denoted as RCTA. Built on a strong alignment baseline, the method integrates an EMA teacher, weak and strong temporal augmentations, multi-factor reliability gating, dual prototype memories, curriculum optimization, and confidence-guarded checkpoint selection to achieve more stable target-domain pseudo supervision and clearer class-conditional structure. Rather than claiming a brand-new adaptation theory, the contribution is positioned as a task-oriented, mechanism-level integration for multi-class industrial time-series transfer.

In the current draft, the method chapters and the benchmark-oriented experiment chapter have been fully expanded and aligned with the executable benchmark configuration, while quantitative tables and figures remain structured placeholders to be filled in after the final runs are completed. Overall, this thesis develops a coherent research line from unified benchmark construction to improved method validation, providing both a reproducible comparison basis and an effective methodological reference for unsupervised domain adaptation in industrial process fault diagnosis.


KEY WORDS: Fault Diagnosis, Domain Adaptation, TEP, Unsupervised Domain Adaptation

# 目　　录

摘　　要 ..... I
ABSTRACT ..... II
目　　录 ..... III
第一章　绪论 ..... 1
1.1 研究背景与意义 ..... 1
1.2 国内外研究现状 ..... 2
1.2.1 工业过程故障诊断研究进展 ..... 2
1.2.2 迁移学习与领域自适应研究进展 ..... 2
1.2.3 TEP 跨工况迁移诊断研究现状 ..... 3
1.3 研究内容与技术路线 ..... 3
1.4 研究问题、核心挑战与创新点 ..... 4
1.4.1 创新定位说明 ..... 5
1.5 论文结构安排 ..... 6
第二章　跨工况迁移诊断的基准脉络 ..... 7
2.1 任务定义与统一任务边界 ..... 7
2.2 基准构建原则 ..... 7
2.3 域定义与统一输入表示 ..... 8
2.4 共享骨干网络 ..... 9
2.5 基础训练目标 ..... 9
2.6 典型基线方法与参考方法 ..... 10
2.6.1 Source Only ..... 10
2.6.2 Target Only ..... 10
2.6.3 分布对齐方法 ..... 10
2.6.4 对抗式方法 ..... 10
2.6.5 最优传输方法 ..... 11
2.7 评价指标与模型选择 ..... 11
2.8 本章小结 ..... 12

第三章　教师–学生时序一致性自适应 ..... 13
3.1 模块定位 ..... 13
3.2 失效模式分析与设计思路 ..... 13
3.3 RCTA 总体框架中的 A 模块 ..... 13
3.4 EMA 教师网络 ..... 14
3.5 弱强双视图时序增强 ..... 15
3.6 一致性损失及其与对齐分支的协同 ..... 15
3.7 模块收益、边界与实现对应 ..... 16
3.8 本章小结 ..... 16
第四章　可靠性门控的伪标签学习 ..... 18
4.1 模块定位 ..... 18
4.2 伪标签误差传播分析 ..... 18
4.3 多因素可靠性评分 ..... 19
4.4 按类门控与样本接纳课程 ..... 19
4.5 分层利用：可靠、半可靠与不可靠样本 ..... 20
4.6 可靠性加权伪标签损失与辅助正则 ..... 20
4.7 与前后模块的耦合关系 ..... 21
4.8 本章小结 ..... 21
第五章　双原型记忆的类条件结构约束 ..... 22
5.1 模块定位 ..... 22
5.2 类条件结构缺失的表现 ..... 22
5.3 源域原型记忆 ..... 22
5.4 目标域原型记忆 ..... 23
5.5 参考原型构造 ..... 23
5.6 原型吸引损失 ..... 24
5.7 原型分离损失 ..... 24
5.8 模块作用分析与局限性 ..... 25
5.9 本章小结 ..... 25
第六章　课程化优化与完整训练流程 ..... 26

6.1 模块定位 ..... 26
6.2 两级课程机制 ..... 26
6.2.1 门控课程 ..... 26
6.2.2 损失课程 ..... 26
6.3 完整目标函数 ..... 27
6.4 置信保护型模型选择与早停 ..... 27
6.5 训练流程表 ..... 28
6.6 递进验证中的 D 模块含义 ..... 28
6.7 本章小结 ..... 29
第七章 实验设计与结果组织 ..... 30
7.1 实验章节定位 ..... 30
7.2 数据集与 benchmark 场景 ..... 30
7.2.1 TEP 领域自适应数据集 ..... 30
7.2.2 11 个场景的 fixed-fold benchmark ..... 31
7.3 统一实验协议 ..... 31
7.3.1 输入预处理与归一化 ..... 31
7.3.2 方法集合与训练设置 ..... 32
7.3.3 运行命令与结果产物 ..... 32
7.4 总体 benchmark 结果占位 ..... 33
7.4.1 8 个单源场景的结果表 ..... 33
7.4.2 3 个多源场景的结果表 ..... 33
7.4.3 方法总体汇总表 ..... 33
7.5 定性分析图件占位 ..... 34
7.6 模块递进验证的后续占位 ..... 35
7.7 本章小结 ..... 35
第八章 总结与展望 ..... 36
8.1 全文工作总结 ..... 36
8.2 主要结论与阶段性认识 ..... 36
8.3 当前不足 ..... 37

8.4 面向更强创新性的升级方向 ..... 37
8.5 后续工作安排 ..... 38
8.6 本章小结 ..... 38
参考文献 ..... 39
附录 A 实验补充材料 ..... 42
A.1 附录说明 ..... 42
A.2 基线与参考方法关键超参数 ..... 42
A.3 RCTA fixed-fold 配置摘要 ..... 42
A.4 benchmark 复现实验命令 ..... 42
A.5 完整结果表占位 ..... 43
A.5.1 单源场景完整结果 ..... 43
A.5.2 多源场景完整结果 ..... 43
A.6 补充说明 ..... 43
致 谢 ..... 44

# 第一章 绪论

## 1.1 研究背景与意义

流程工业广泛存在于化工、能源、冶金、制药、环保和材料制造等关键行业，其生产过程通常具有连续运行、变量耦合紧密、动态响应复杂、控制回路交织以及安全代价高昂等特点。一旦关键设备或工艺环节发生异常，不仅会导致产品质量波动、能耗升高和非计划停机，还可能进一步诱发连锁故障甚至安全事故。因此，如何及时、准确、稳定地识别工业过程中的故障，一直是过程监测、运行优化和安全保障中的核心问题[1,2]。

随着分布式控制系统、工业互联网和边缘采集装置的普及，工业现场能够持续积累大规模、多变量、高频率的运行数据。与早期依赖机理模型、阈值规则和专家知识的诊断方法相比，数据驱动方法能够在较弱先验条件下从历史数据中自动提取异常模式，因此已经成为工业故障诊断的重要技术路线之一[3,4]。尤其是在深度学习方法进入故障诊断领域之后，一维卷积网络、循环网络和时序注意力模型显著增强了模型对复杂动态模式的表征能力，使得跨变量耦合和局部时序特征能够被更有效地学习[5]。

然而，工业故障诊断面临的一个长期难题在于训练分布与部署分布往往并不一致。设备老化、原料组成变化、环境扰动、控制参数重整定、负载切换以及生产阶段变更等因素，都会造成不同时间段、不同工况乃至不同装置上的过程数据分布发生偏移。设训练阶段的数据分布为 $P_s(x,y)$，部署阶段的数据分布为 $P_t(x,y)$，在很多真实工业场景下有

$$P_s(x,y) \neq P_t(x,y). \tag{1.1}$$

当模型仅依赖源域标注样本训练时，即使其在源域上取得很高准确率，也可能在目标域工况中出现显著性能下降。这一问题在流程工业中尤为突出，因为目标域故障样本通常稀缺、获取成本高且伴随安全风险，重新采集并人工标注大量目标域故障数据通常并不可行[6,7]。

领域自适应作为迁移学习的重要分支，正是为缓解上述分布偏移问题而提出。其核心思想是在源域有标签、目标域少标签甚至无标签的条件下，通过统计分布对齐、对抗学习、类别结构约束或样本匹配等方式提升模型在目标域上的泛化能力。对于流程工业而言，如果能够在不依赖目标域大量标注样本的前提下稳定提升跨工况故障识别性能，将对缩短模型部署周期、降低迁移成本和增强工程可用性具有直接意义[8,9]。

Tennessee Eastman Process（TEP）是过程系统工程领域广泛使用的经典工业过程仿真平台，由 Downs 和 Vogel 提出[10]。围绕 TEP 构造的领域自适应数据集将不同运行模式组

织为不同领域，使得“跨工况故障诊断”能够被清晰表述为无监督领域自适应问题。该数据集既保留了工业多变量时序数据的动态特征，又提供了相对规范的域划分和故障标签，因此非常适合用于构建统一实验基准、比较典型方法并验证改进方法的有效性[11]。

## 1.2 国内外研究现状

### 1.2.1 工业过程故障诊断研究进展

工业过程故障诊断的早期研究较多依赖过程机理、专家经验和手工规则。典型思路包括基于观测器或残差生成的模型方法、故障树分析、专家系统以及软测量建模等。这类方法在对象机理明确、系统结构相对稳定的场景下具有较好的解释性，但对大型流程工业而言，完整建立高精度机理模型并不容易；同时，实际运行中设备磨损、原料波动和控制策略调整会不断改变系统行为，使得纯机理方法在长期应用中面临维护成本高和泛化性不足的问题。

随着工业信息化水平提高，数据驱动方法逐渐成为流程工业故障诊断的主流研究方向。主成分分析、偏最小二乘、动态 PCA 和动态 PLS 等统计过程监测方法长期是流程工业故障检测的重要工具；支持向量机、近邻分类器、决策树和集成学习等浅层机器学习方法也被广泛用于故障分类任务[1,2]。近年来，深度学习方法通过多层非线性映射自动学习故障相关表征，一维卷积网络能够从多变量时序窗口中提取局部动态模式，循环网络与注意力结构则在捕捉长时依赖关系方面具有优势[3,5]。然而，当工况切换导致训练集与测试集分布不一致时，仅依赖源域监督学习得到的深度模型仍会暴露出显著的跨域泛化不足。

### 1.2.2 迁移学习与领域自适应研究进展

迁移学习旨在利用已有任务或已有域中的知识提升目标任务的学习效果。Pan 和 Yang 将迁移学习系统地定义为：在源域与目标域分布或任务不同的情况下，通过知识迁移改善目标任务学习性能的过程[6]。当源域与目标域任务相同但数据分布不同，即

$$\mathcal{Y}_s = \mathcal{Y}_t, \qquad P_s(x) \neq P_t(x), \tag{1.2}$$

便得到领域自适应问题。按照目标域是否具有标签，领域自适应可分为监督式、半监督式和无监督式等多种设置，本文重点关注目标域无标签的无监督领域自适应。

现有无监督领域自适应方法大体可以分为四类。第一类是统计分布对齐方法，例如 CORAL 通过协方差匹配减小二阶统计差异[12]，DAN 通过最大均值差异在核空间中逼近边缘分布对齐[13]。第二类是对抗式方法，例如 DANN 通过域判别器和梯度反转层学习域

不变特征[14]，CDAN 进一步将类别预测引入条件对齐过程，从而增强对类条件信息的感知[15]。第三类是最优传输方法，例如 DeepJDOT 联合考虑特征距离与类别预测代价，在样本级别建立跨域匹配关系[16]。第四类则更强调目标域伪监督与类别结构，例如基于伪标签、一致性训练、类原型和聚类约束的自训练方法[17–19]。

总体来看，上述方法已经为跨工况诊断提供了坚实基础，但针对流程工业多类别时序任务仍存在三个明显缺口。其一，很多方法更偏向削弱整体域差异，而对目标域无标签样本如何稳定进入训练闭环讨论不足；其二，伪标签方法往往依赖单一置信度阈值，容易受到高置信错误和类别不均衡影响；其三，全局对齐虽然能够缩小源域和目标域的整体距离，却不能自动保证跨域同类样本聚合、异类样本分离，因而在多故障类别任务中容易出现类别混叠。

### 1.2.3 TEP 跨工况迁移诊断研究现状

Tennessee Eastman Process 由于过程结构完整、变量丰富、耦合复杂且具有较强代表性，长期被用于过程监测、故障检测和故障诊断算法评估[10]。近年的研究开始把 TEP 扩展为跨域场景，将不同操作模式组织为不同领域，从而自然构造“跨工况迁移诊断”任务[7,9,11]。相关工作已经表明，不同模式之间的分布偏移会显著影响模型迁移效果，而统一任务定义、数据划分、归一化方式、骨干网络结构和模型选择策略，对于公平比较不同领域自适应方法至关重要。

已有研究在 TEP 跨工况迁移诊断中取得了不少进展，但仍常见以下问题：不同工作采用的数据划分和训练协议不完全一致，导致横向比较困难；部分方法只关注少量场景，难以判断其是否具有跨场景稳定性；一些改进方法虽然能在个别任务上取得收益，但对“为什么有效、在哪些场景有效、哪些模块真正发挥作用”的分析仍然不足。基于这些现实缺口，本文将研究重点放在两条主线上：一是构建面向当前工作区实现的统一 benchmark 组织方式，二是围绕多类别工业时序迁移中的稳定伪监督与类条件结构建模提出任务导向的改进方法。

## 1.3 研究内容与技术路线

围绕跨工况无监督领域自适应故障诊断问题，本文的研究内容主要包括以下五个方面。

1. 面向 TEP 多工况迁移诊断任务，建立统一的数据读取、预处理、训练、评估、结果

导出与图表汇总流程，在共享协议下组织领域自适应实验；

2. 基于固定折划分构建包含 11 个迁移场景、8 种方法的 benchmark，其中既包含 8 个单源到单目标场景，也包含 3 个多源到单目标场景，从而兼顾横向比较广度与训练成本可控性；
3. 在统一 FCN 骨干网络和统一结果产物结构下，比较 Source Only、Target Only、CORAL、DAN、DANN、CDAN、DeepJDOT 与 RCTA 的表现，形成可复现的实验基线；
4. 针对基线比较中暴露出的目标域伪标签噪声、类别混叠以及训练阶段不稳定问题，提出可靠性门控的类条件时序自适应方法 RCTA，并将其拆解为教师–学生时序一致性、可靠性门控、双原型记忆和课程化优化四个递进章节；
5. 在实验章节中，将“当前已需完成的 88-run benchmark”和“后续模块级消融计划”加以区分：前者用于形成主结果，后者用于在有额外算力预算时进一步验证各模块的独立贡献。

本文的技术路线可以概括为如下四步。首先，结合 TEP 领域自适应数据集明确域定义、输入表示、归一化方式、模型选择准则和固定折策略，为后续比较设定统一边界。其次，在共享骨干和统一训练脚手架下复现代表性领域自适应方法，观察不同对齐机制在 11 个 benchmark 场景中的表现。再次，根据基线方法的共性问题，梳理“目标域样本如何稳定进入训练”“哪些目标样本可信”“如何保持类条件结构”“多项约束如何按节奏进入优化”四个关键问题。最后，围绕上述问题设计 RCTA 的四个模块，并在统一 benchmark 上验证完整方法的收益，同时为后续严格消融预留结构化接口。

## 1.4 研究问题、核心挑战与创新点

基于前述研究现状，本文关注的核心问题是：在目标域缺少故障标签的条件下，如何利用源域标注样本与目标域无标注样本，训练一个能够跨工况迁移的故障诊断模型。本文的方法推导以单源到单目标无监督领域自适应为主线，同时在实验上引入少量多源到单目标场景，以观察方法在更复杂源域组合下的迁移稳定性。

为了使创新点与问题痛点形成一一对应，本文将核心挑战与后文创新章节组织如下。

1. **挑战一：跨工况全局分布偏移显著，但单纯对齐不足以稳定利用目标域时序样本。**不同运行模式下的负载水平、控制策略和动态响应不同，目标域样本虽然可见但无标签，模型难以直接获得目标域分类监督。针对这一痛点，第三章在强对齐底座上引

入 EMA 教师网络和弱强双视图增强，使目标域样本以更平滑的方式进入训练闭环。

2. **挑战二：目标域伪标签容易受噪声和类别不均衡影响。**在 29 类故障诊断任务中，若直接使用高置信伪标签，容易放大早期错误并让少数容易类别占据伪监督预算。针对这一痛点，第四章提出多因素可靠性评分、按类门控与样本分层利用机制，尽可能把目标域监督集中到更可信的样本上。
3. **挑战三：全局域对齐容易带来类别混叠，难以保证跨域同类样本聚合、异类样本分离。**对于类间边界复杂的工业时序任务，简单缩小整体域差异可能引发负迁移。针对这一痛点，第五章提出双原型记忆驱动的类条件结构约束，通过源域原型、目标域原型和参考原型共同塑造几何结构。
4. **挑战四：多个辅助目标的作用时机不同，若同时强行注入可能破坏训练稳定性。**伪标签、一致性和原型约束都依赖模型阶段性质量，过早或过强施加会干扰基础分类边界。针对这一痛点，第六章提出课程化优化与置信保护型模型选择策略，使各模块按“先搭底座、再引入目标域监督、最后强化类条件结构”的顺序逐步发挥作用。

### 1.4.1 创新定位说明

需要强调的是，本文的创新并非宣称在领域自适应理论上提出了完全全新的基础范式，而是属于**面向工业多类别时序迁移任务的机制性集成创新**。其价值主要体现在以下三个层面。

1. **问题驱动的模块组合。**本文不是简单堆叠已有技巧，而是围绕目标域样本引入、伪标签筛选、类条件结构约束和训练节奏控制四个具体失效点，构造出有前后依赖关系的完整链条。
2. **实现对齐与可复现比较。**所有方法均在同一套骨干网络、训练脚手架、固定折策略和结果导出结构下运行，使得方法比较尽量聚焦于自适应机制本身，而非实现细节差异。
3. **面向工程任务的边界控制。**本文在写作与设计上刻意避免夸大“单一模块的理论创新”，而更强调“任务痛点识别准确、方法设计闭环清晰、实验协议可复现、改进收益可验证”这一类本科论文更稳健的贡献形式。

据此，本文的主要创新点可概括为：

1. 构建面向当前工作实现的 TEP 固定折 benchmark，将 11 个跨工况场景和 8 种方法纳入同一实验协议，提供可复现的横向比较基础；

2. 提出教师–学生时序一致性机制，通过 EMA 教师与弱强双视图增强，为目标域样本提供更平滑的伪监督入口；
3. 提出多因素可靠性门控和分层利用策略，从置信、熵、一致性和原型相似度四个维度联合评估伪标签质量；
4. 提出双原型记忆驱动的类条件结构约束，用参考原型、吸引损失和分离损失缓解类别混叠；
5. 提出课程化优化与置信保护型选择策略，将门控课程、损失预热和 checkpoint 选择统一纳入完整训练流程。

## 1.5 论文结构安排

全文共分为八章，各章内容安排如下。

第一章为绪论，介绍研究背景、国内外研究现状、研究内容、核心挑战以及本文创新点，并明确本文的创新定位。第二章为跨工况迁移诊断的基准脉络，说明任务定义、统一协议、共享骨干网络、典型基线方法和模型选择原则。第三章为教师–学生时序一致性自适应，阐述 RCTA 的总体框架、EMA 教师网络以及弱强双视图一致性机制。第四章为可靠性门控的伪标签学习，说明多因素可靠性评分、按类门控和样本分层利用方式。第五章为双原型记忆的类条件结构约束，介绍源域/目标域原型记忆、参考原型构造以及吸引与分离机制。第六章为课程化优化与完整训练流程，给出门控课程、损失预热、模型选择策略和算法流程。第七章为实验设计与结果组织，围绕当前需要执行的 88-run fixed-fold benchmark 展开，并预留后续模块消融位置。第八章为总结与展望，对全文工作进行归纳，并讨论后续更强创新方向的升级路径。

# 第二章 跨工况迁移诊断的基准脉络

## 2.1 任务定义与统一任务边界

本文研究的核心任务是跨工况无监督领域自适应故障诊断。设源域训练样本为

$$\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}, \tag{2.1}$$

其中 $x_i^s$ 为源域样本，$y_i^s \in \mathcal{Y}$ 为故障类别标签；目标域训练样本为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}, \tag{2.2}$$

其中目标域标签在训练阶段不可用。本文的目标是在利用源域有标签样本和目标域无标签样本的条件下，学习一个诊断模型

$$f(x) = h(\phi(x)), \tag{2.3}$$

使其在目标域测试集上的风险尽可能小，其中 $\phi(\cdot)$ 表示特征提取器，$h(\cdot)$ 表示分类头。

若将目标域真实风险记为

$$R_t(f) = \mathbb{E}_{(x,y)\sim P_t(x,y)}[\ell(f(x), y)], \tag{2.4}$$

则无监督领域自适应的困难在于训练阶段无法直接最小化 $R_t(f)$。因此，实际训练通常采用

$$\mathcal{L} = \mathcal{L}_{cls}^s + \lambda \mathcal{L}_{adapt} + \mathcal{L}_{aux} \tag{2.5}$$

的形式，其中 $\mathcal{L}_{cls}^s$ 为源域监督分类损失，$\mathcal{L}_{adapt}$ 为领域对齐损失，$\mathcal{L}_{aux}$ 为伪标签、一致性、原型或其他辅助约束项。

虽然本文的方法推导主要采用单源到单目标记号，但当前 benchmark 同时包含少量多源场景。对多源到单目标任务，可将源域集合记为

$$\mathcal{D}_s^{multi} = \{\mathcal{D}_s^{(m)}\}_{m=1}^{M}, \tag{2.6}$$

其中 $M \geq 2$ 表示源域个数。训练时可将多个源域小批量分别采样后在统一骨干上进行融合，从而在不改变主要记号体系的前提下兼容多源场景。

## 2.2 基准构建原则

与只追求某个模型单次最优结果不同，本文首先把 benchmark 视为研究工作的基础设施。一个可信的跨工况迁移诊断 benchmark，至少应满足以下四项原则。

1. **任务边界明确。**必须清楚区分源域、目标域、是否允许使用目标域标签、是否固定折划分、是否包含多源场景等设置，避免不同论文之间“名义相同、协议不同”的比较误差。
2. **实现条件统一。**不同方法应尽量共享相同的数据输入形式、归一化方式、骨干网络和结果导出结构，使比较聚焦于自适应机制，而非数据处理或骨干差异。
3. **模型选择可解释。**无监督领域自适应缺少目标域验证标签，checkpoint 选择与早停策略本身就会影响结论，因此必须将其纳入实验协议而非隐含处理。
4. **结果产物可追踪。**每次运行应统一保存指标、分析中间量、图件和 review 摘要，便于后续批量汇总、论文回填和误差追查。

本文的 benchmark 设计正是围绕上述原则展开：在共享 FCN 骨干与统一数据协议下，将 11 个迁移场景和 8 种方法纳入同一 fixed-fold 实验计划，并通过统一脚手架输出 `result.json`、`review.json`、混淆矩阵、t-SNE 图以及汇总表格。

## 2.3 域定义与统一输入表示

在本文实验设定中，不同 TEP 操作模式被视为不同领域，即

$$\mathcal{M} = \{\text{mode1}, \text{mode2}, \ldots, \text{mode6}\}. \tag{2.7}$$

源域与目标域共享相同的标签空间，

$$\mathcal{Y} = \{0, 1, \ldots, 28\}, \tag{2.8}$$

但样本分布并不一致。输入样本采用多变量过程时序片段表示，原始形状为 $(T, C)$，其中 $T = 600$ 表示时间窗口长度，$C = 34$ 表示过程变量通道数；进入网络前转置为 channels-first 形式：

$$x' = \text{Transpose}(x) \in \mathbb{R}^{C \times T}. \tag{2.9}$$

模型输出为 29 类工况与故障类别的预测概率。

当前 88-run benchmark 采用“两簇场景”的组织思路：一簇为 mode3 与 mode6 的互迁，另一簇为 mode1、mode2、mode5 之间的互迁与多源组合。这样的设计并不试图穷尽全部 30 个有向单源场景，而是在算力与实验广度之间取得折中，使 benchmark 既能覆盖不同迁移难度，也能在当前论文周期内完成运行与分析。

## 2.4 共享骨干网络

为降低骨干结构差异对实验结论的干扰，本文所有方法共享同一套一维全卷积网络（FCN）编码器和统一分类头。编码器由三层一维卷积构成，其计算过程可写为

$$z^{(1)} = \mathrm{ReLU}(\mathrm{Norm}(\mathrm{Conv1D}_{9,128}(x))), \tag{2.10}$$

$$z^{(2)} = \mathrm{ReLU}(\mathrm{Norm}(\mathrm{Conv1D}_{5,256}(z^{(1)}))), \tag{2.11}$$

$$z^{(3)} = \mathrm{ReLU}(\mathrm{Norm}(\mathrm{Conv1D}_{3,128}(z^{(2)}))), \tag{2.12}$$

其中卷积核长度依次为 9、5 和 3，输出通道数依次为 128、256 和 128，当前实现默认采用实例归一化。随后对时间维执行全局平均池化，得到紧凑特征向量

$$f = \frac{1}{T'} \sum_{t=1}^{T'} z_{:,t}^{(3)} \in \mathbb{R}^{128}. \tag{2.13}$$

分类头采用一层隐藏维度为 128 的全连接网络：

$$p(x) = \mathrm{softmax}(W_2\, \mathrm{ReLU}(W_1 f + b_1) + b_2). \tag{2.14}$$

该结构具备三个优点。其一，一维卷积对多变量时间窗口的局部动态模式具有较强建模能力；其二，参数规模适中，便于在 88 次 benchmark 运行中控制计算成本；其三，结构简单、变量少，更适合作为公平比较的公共底座。

## 2.5 基础训练目标

源域监督分类损失统一采用交叉熵形式：

$$\mathcal{L}_{cls}^{s} = -\frac{1}{n_s} \sum_{i=1}^{n_s} \sum_{k=1}^{K} \mathbf{1}[y_i^s = k] \log p_k(x_i^s), \tag{2.15}$$

其中 $K = 29$，$p_k(x)$ 为模型对第 $k$ 类的预测概率。不同领域自适应方法在此基础上分别引入协方差对齐、MMD 对齐、域对抗损失、条件对抗损失或最优传输损失；本文提出的 RCTA 则进一步加入伪标签、一致性和原型约束。

在训练脚手架层面，本文统一采用 Adam 优化器，基础学习率保持在 $10^{-4}$ 数量级，权重衰减设为 0；对于对抗式或更敏感的方法，额外采用梯度裁剪以降低训练波动。需要指出的是，本文不再把“所有方法完全同轮数训练”作为僵硬前提，而是允许在统一协议下通过 experiment config 对不同方法设置更合理的训练轮数和权重，这种做法更符合 benchmark 的实际目标，即比较方法机制而非人为限制超参数。

## 2.6 典型基线方法与参考方法

本节对当前 benchmark 涉及的典型方法进行简要说明，具体实验结果统一在第七章呈现。

### 2.6.1 Source Only

Source Only 仅依赖源域监督分类损失训练模型，不显式处理源域与目标域之间的分布偏移，其优化目标可写为

$$\mathcal{L}_{SO} = \mathcal{L}_{cls}^{s}. \tag{2.16}$$

该方法构成所有领域自适应方法的基础对照组。若某一领域自适应方法在目标域上不能稳定优于 Source Only，则说明其对齐策略尚未真正缓解跨工况迁移带来的分布差异问题。

### 2.6.2 Target Only

Target Only 直接利用目标域标注样本进行监督训练，其目标为

$$\mathcal{L}_{TO} = \mathcal{L}_{cls}^{t}. \tag{2.17}$$

该方法不属于无监督领域自适应范畴，而是作为**监督参考上界**纳入 benchmark，用于帮助判断跨域方法距离“目标域可监督训练”还有多大差距。将其与真正的无监督方法混为同类 baseline 并不合适，因此后文会明确标注其参考性质。

### 2.6.3 分布对齐方法

CORAL 通过约束源域与目标域特征协方差矩阵的一致性减小二阶统计差异[12]。设源域与目标域特征分别为 $F_s \in \mathbb{R}^{n_s \times d}$ 和 $F_t \in \mathbb{R}^{n_t \times d}$，对应协方差矩阵为 $C_s, C_t$，则 CORAL 损失为

$$\mathcal{L}_{coral} = \frac{\|C_s - C_t\|_F^2}{4d^2}. \tag{2.18}$$

DAN 使用多核最大均值差异约束源域与目标域特征分布，在核空间中实现边缘分布对齐[13]。给定核映射 $\varphi(\cdot)$，其损失可表示为

$$\mathcal{L}_{mmd} = \left\| \frac{1}{n_s} \sum_{i=1}^{n_s} \varphi(f_i^s) - \frac{1}{n_t} \sum_{j=1}^{n_t} \varphi(f_j^t) \right\|_{\mathcal{H}}^2. \tag{2.19}$$

这两类方法结构较直接、训练相对稳定，因此适合作为全局统计对齐的参考。

### 2.6.4 对抗式方法

DANN 在共享特征提取网络之后加入域判别器，并利用梯度反转层实现特征表示与域分类之间的对抗学习，从而逼近域不变特征[14]。设域标签 $d = 1$ 表示源域，$d = 0$ 表示目

标域，域判别器为 $D(\cdot)$，则对抗损失可写为

$$\mathcal{L}_{adv} = -\frac{1}{n_s}\sum_{i=1}^{n_s}\log D(f_i^s) - \frac{1}{n_t}\sum_{j=1}^{n_t}\log(1 - D(f_j^t)). \tag{2.20}$$

CDAN 在 DANN 基础上进一步引入类别条件信息，使域判别器感知特征与类别预测的联合结构[15]。若记分类器输出概率为 $p(x)$，则可构造条件映射

$$g(x) = f(x) \otimes p(x), \tag{2.21}$$

其中 $\otimes$ 表示多线性组合。对抗式方法通常具有较强适应能力，但训练稳定性和超参数敏感性也更值得关注。

### 2.6.5 最优传输方法

DeepJDOT 通过联合建模特征距离与类别预测差异，构建源域与目标域样本之间的运输代价，在深度特征学习过程中同时优化分类与跨域匹配[16]。设 $\gamma$ 为源域和目标域样本间的运输矩阵，则其代价函数可写为

$$\mathcal{L}_{OT} = \min_{\gamma\in\Pi(a,b)}\sum_{i,j}\gamma_{ij}\left(\alpha\|f_i^s - f_j^t\|_2^2 + \beta\ell(y_i^s, p_j^t)\right). \tag{2.22}$$

该方法能够提供样本级跨域关系约束，但计算开销、批大小敏感性和代价尺度设置都更值得注意。

## 2.7 评价指标与模型选择

本文重点比较各方法的目标域诊断性能。评价指标主要包括目标域准确率、目标域平衡准确率、混淆矩阵，以及反映域对齐程度和类别结构清晰度的特征可视化结果。目标域准确率定义为

$$\mathrm{Acc}_t = \frac{1}{N_t^{eval}}\sum_{i=1}^{N_t^{eval}}\mathbf{1}[\hat{y}_i = y_i], \tag{2.23}$$

平衡准确率定义为

$$\mathrm{BA}_t = \frac{1}{K}\sum_{k=1}^{K}\frac{\mathrm{TP}_k}{\mathrm{TP}_k + \mathrm{FN}_k}, \tag{2.24}$$

其中 $\mathrm{TP}_k$ 和 $\mathrm{FN}_k$ 分别表示第 $k$ 类的真正例和假负例数量。相较于普通准确率，平衡准确率更能稳定反映多类别任务下不同类别的平均识别水平。

由于无监督领域自适应缺少可直接使用的目标域验证标签，checkpoint 选择与早停本身就是 benchmark 协议的重要组成部分。当前 benchmark 中，多数方法采用“源域评估准

确率 + 目标域平均置信度”的混合选择指标：

$$S_{\text{hyb}} = w_s \cdot \text{Acc}_s^{eval} + w_c \cdot \bar{q}_t, \tag{2.25}$$

其中 $\bar{q}_t$ 表示目标域训练集的平均预测置信度。对于更容易出现目标域过度自信的 RCTA，还会进一步加入过度自信惩罚与域判别偏离惩罚，这一点将在第六章展开说明。将模型选择规则显式写入 experiment config，而不是在训练后凭经验挑选结果，是本文 benchmark 设计中的关键环节。

## 2.8 本章小结

本章围绕后续方法与实验所需的共同前提，说明了跨工况迁移诊断的任务定义、benchmark 构建原则、域定义与输入表示、共享骨干网络、基础训练目标、典型基线方法和评价指标。与将“相关基础”孤立成章的写法不同，本章更强调后续方法设计与实验比较所依赖的统一前提，从而为第三章到第七章建立共同语境。

# 第三章 教师–学生时序一致性自适应

## 3.1 模块定位

第二章中的基准方法主要解决源域与目标域之间的整体分布差异，但目标域样本在训练阶段没有标签，模型无法直接获得目标域分类监督。若只依赖全局域对齐，目标域特征虽然可能逐步靠近源域特征，却不一定形成稳定的类别边界；而若过早直接使用学生网络当前预测作为伪标签，又容易受到瞬时噪声和训练波动影响。对于多类别工业时序任务而言，目标域样本并不是“能看见就能放心使用”的资源。

本章对应第一章提出的挑战一：跨工况全局分布偏移显著，但单纯对齐不足以稳定利用目标域时序样本。其核心任务不是替代域对齐，而是在强对齐底座之上，为目标域样本建立一个更平滑、更鲁棒的进入训练入口，使后续可靠性门控和原型结构约束有稳定的概率输出可用。

## 3.2 失效模式分析与设计思路

从训练过程看，目标域样本在无监督领域自适应中主要存在两类失效模式。

1. **单步预测抖动。**学生网络的参数在每个 mini-batch 后都会更新，若直接把当前时刻的预测当作监督信号，则伪标签会随优化轨迹快速波动，早期错误很容易被放大。
2. **视图不一致带来的脆弱性。**工业时序数据中存在传感噪声、量纲波动和局部片段缺失，模型若仅对单一“干净视图”拟合，部署时会对轻微扰动表现出不稳定。

为缓解上述问题，RCTA 在对齐分支之上引入教师–学生时序一致性机制，其基本思路可以概括为“教师看更稳定的视图，学生学更困难的视图；教师参数变化更慢，学生参数负责快速优化”。这样做的收益有三点：第一，教师网络通过指数滑动平均抑制短期梯度噪声；第二，弱强双视图增强迫使模型在轻度扰动和较强扰动之间保持预测一致；第三，该模块给后续门控提供了更平滑的概率来源，从而减少伪标签质量评估时的随机性。

## 3.3 RCTA 总体框架中的 A 模块

设学生网络由编码器 $\phi(\cdot)$ 与分类器 $h(\cdot)$ 构成，教师网络由参数的指数滑动平均版本 $\phi_{\text{tea}}(\cdot)$ 和 $h_{\text{tea}}(\cdot)$ 构成。对于一个源域小批量

$$\mathcal{B}_s = \{(x_i^s, y_i^s)\}_{i=1}^{m_s} \tag{3.1}$$

和一个目标域小批量

$$\mathcal{B}_t = \{x_j^t\}_{j=1}^{m_t}, \tag{3.2}$$

当前实现中的 RCTA 一次训练迭代可概括为以下环节：

1. 源域样本经学生网络前向传播，计算监督分类损失；
2. 目标域样本生成弱增强视图与强增强视图，弱增强视图同时供教师分支和对齐分支使用；
3. 教师网络在弱增强视图上生成软标签分布，学生网络在强增强视图上生成对应预测；
4. 基于教师预测、学生强增强预测和参考原型计算可靠性得分；
5. 通过门控和课程策略决定哪些目标样本进入伪标签与原型约束；
6. 通过 EMA 更新教师参数，并在训练后更新原型记忆。

若将本章模块记为 A，则 A 模块在整体方法中的定位是“**提供稳定的目标域预测来源**”。它本身并不直接决定哪些样本最终被采纳，也不单独负责塑造类别结构，而是负责把目标域样本以一种可被后续模块消费的形式送入训练闭环。

当前 benchmark 采用的完整 RCTA 配置以 DANN 作为基础对齐分支，并同时引入 MCC 正则，因此其整体目标可写为

$$\mathcal{L}_{\text{RCTA}} = \mathcal{L}_{cls}^{s} + \lambda_{align}\mathcal{L}_{align} + \lambda_{mcc}\mathcal{L}_{mcc} + \lambda_{pl}(t)\mathcal{L}_{pl} + \lambda_{proto}(t)\mathcal{L}_{proto} + \lambda_{cons}(t)\mathcal{L}_{cons}. \tag{3.3}$$

其中 $\mathcal{L}_{cons}$ 就是本章关注的核心一致性项。它与对齐分支之间不是替代关系，而是“全局对齐负责建底座，一致性负责稳目标域入口”的互补关系。

## 3.4 EMA 教师网络

为减轻目标域伪标签的瞬时波动，RCTA 不直接使用学生网络当前时刻的预测作为监督，而是引入教师网络生成更平滑的目标域概率分布[18]。教师参数通过学生参数的指数滑动平均更新：

$$\theta_{\text{tea}} \leftarrow \mu\theta_{\text{tea}} + (1-\mu)\theta_{\text{stu}}, \tag{3.4}$$

其中 $\mu$ 为 EMA 衰减系数。在当前 fixed-fold benchmark 配置中，$\mu = 0.992$。相较于直接复制学生参数，EMA 更新等价于在参数空间中执行低通滤波，使教师预测对单步梯度波动不那么敏感，更适合作为目标域软伪标签来源。

对目标域样本 $x_j^t$，教师网络给出的软标签分布为

$$p_j^{tea} = \mathrm{softmax}\left(\frac{h_{\mathrm{tea}}(\phi_{\mathrm{tea}}(\tilde{x}_{j,w}^t))}{T_{tea}}\right), \tag{3.5}$$

其中 $T_{tea}$ 为教师温度参数，$\tilde{x}_{j,w}^t$ 为弱增强视图。当前 benchmark 配置中 $T_{tea} = 1.3$，对应的伪标签为

$$\hat{y}_j^t = \arg\max p_j^{tea}. \tag{3.6}$$

相比温度过低导致的过度自信，适度升温后的教师分布更平滑，有助于在后续可靠性评估中区分“真正可靠”与“仅仅很尖锐”的样本。

## 3.5 弱强双视图时序增强

RCTA 在目标域上采用保守的弱增强与相对困难的强增强[20]。设随机增强算子分别为 $\mathcal{A}_w$ 与 $\mathcal{A}_s$，则有

$$\tilde{x}_{j,w}^t = \mathcal{A}_w(x_j^t), \qquad \tilde{x}_{j,s}^t = \mathcal{A}_s(x_j^t). \tag{3.7}$$

当前实现中，弱增强主要包含轻微抖动和缩放；强增强则进一步加入更大的抖动与缩放、时间屏蔽以及通道 dropout。以 fixed-fold benchmark 配置为例，弱增强抖动与缩放标准差均为 0.005，强增强抖动与缩放标准差均为 0.012，同时采用 0.05 的时间屏蔽比例和 0.05 的通道 dropout 概率。

这样的设计遵循“教师看更清晰视图，学生学更困难视图”的思路，尤其适合工业时序数据。其原因在于，流程变量的扰动不能像图像任务那样使用大幅几何变换，否则会破坏工艺语义；但完全不做增强又无法提升模型对噪声、局部缺失和轻微幅值变化的鲁棒性。当前增强策略保持在局部扰动范围内，其中抖动用于模拟传感噪声，缩放用于模拟量纲与负载轻微变化，时间屏蔽用于提升局部片段缺失鲁棒性，通道 dropout 则缓解模型对少数变量的过度依赖。

## 3.6 一致性损失及其与对齐分支的协同

设学生网络在强增强视图上的输出概率为

$$p_j^{stu} = \mathrm{softmax}\big(h(\phi(\tilde{x}_{j,s}^t))\big). \tag{3.8}$$

与一些直接采用 KL 散度的写法不同，当前实现中的一致性项采用概率分布之间的均方差形式：

$$\mathcal{L}_{cons} = \frac{1}{m_t} \sum_{j=1}^{m_t} w_j^{cons} \left\| p_j^{stu} - p_j^{tea} \right\|_2^2, \tag{3.9}$$

其中 $w_j^{cons}$ 为与可靠性得分相关的样本权重。在当前配置下，一致性项主要对门控样本施加显式约束，并对可靠性较高的样本分配更大的训练权重。

从优化作用看，一致性项与基础对齐分支是互补的。对齐损失主要负责缩小源域和目标域整体分布差异，使目标域特征有机会进入与源域相兼容的表示空间；一致性损失则进一步约束模型在不同扰动视图下输出稳定预测，减少因扰动引起的类别边界抖动。二者协同作用时，目标域样本既不会完全脱离源域语义锚点，也不会因为单视图预测噪声而过早污染后续门控。

## 3.7 模块收益、边界与实现对应

本章模块的预期收益主要体现在三个方面。其一，它降低了目标域伪标签对单步优化噪声的敏感性，为后续门控提供更平滑的概率来源。其二，它通过弱强双视图一致性增强了模型对局部扰动的鲁棒性。其三，它为第四章和第五章提供了统一接口，使可靠性评分与原型相似度能够基于同一套教师特征与概率输出进行计算。

与此同时，本章模块也存在边界。第一，EMA 教师并不自动保证伪标签正确，只是使预测更平滑，因此仍需要第四章的可靠性筛选。第二，若增强过强，工业时序的工艺语义可能被破坏，因此增强策略必须保持保守。第三，一致性训练更像是“稳定器”而非“主驱动力”，若基础对齐底座过弱，一致性本身并不能解决严重的域间错位问题。

从代码实现看，本章所有机制都与当前工作区中的方法实现一一对应：教师参数由学生参数的 EMA 更新得到；弱增强和强增强由保守的时序扰动模块生成；一致性损失使用概率均方差形式计算；而教师概率、学生强增强概率和教师特征则会被后续章节用于可靠性门控与原型约束。这种“先稳定预测来源，再决定如何利用”的组织方式，是 RCTA 后续模块能够成立的前提。

## 3.8 本章小结

本章围绕教师–学生时序一致性自适应展开，说明了其在 RCTA 中的模块定位、失效模式分析、EMA 教师网络、弱强双视图增强以及与基础对齐分支的协同关系。该模块的贡献不在于单独解决全部跨域问题，而在于为目标域样本建立稳定入口，为第四章的可靠

性门控和第五章的双原型结构约束提供更可信的概率与特征基础。

# 第四章 可靠性门控的伪标签学习

## 4.1 模块定位

第三章解决了目标域样本如何通过教师–学生一致性进入训练的问题，但目标域伪标签本身仍可能存在噪声。对于 29 类流程工业故障诊断任务，简单采用最大概率作为伪标签采纳依据，容易把高置信错误样本引入训练，并进一步造成错误监督的累积。与此同时，不同故障类别在目标域上的预测置信度并不均衡，若采用单一全局阈值，伪标签预算很可能被少数容易类别占据。

本章对应第一章提出的挑战二：目标域伪标签容易受噪声和类别不均衡影响。为此，RCTA 在教师–学生一致性的基础上进一步引入多因素可靠性评分、按类门控和分层利用机制，使目标域伪监督从“看到样本就直接使用”转变为“对样本质量分层评估、分层利用”。

## 4.2 伪标签误差传播分析

在流程工业多类别诊断中，伪标签误差传播通常来自以下三个来源。

1. **过度自信错误。**某些目标样本虽然预测最大概率较高，但实质上位于错误类别簇附近，此时单纯以置信度作为采纳依据会把错误监督以高权重注入训练。
2. **边界样本不稳定。**对于靠近类别边界或跨域偏移较大的样本，弱增强和强增强视图下的预测可能并不一致，若忽略这种不稳定性，伪监督容易放大边界噪声。
3. **类别预算失衡。**在 29 类任务中，一些容易类别会较早形成较高置信度，若采用全局 top-k 或单一阈值，少数类别可能占满伪标签预算，导致困难类别长期得不到纠偏机会。

因此，可靠性门控模块的核心目标不是简单“筛掉低分样本”，而是在训练不同阶段尽可能用有限的目标域伪监督预算换取更高质量的监督信号，并保持类别层面的覆盖性。

## 4.3 多因素可靠性评分

目标域伪标签是否可用，不能只由单一最大概率决定。为此，RCTA 对每个目标样本构造四个互补的可靠性分量：

$$q_j = \max p_j^{tea}, \tag{4.1}$$

$$e_j = 1 - \frac{-\sum_{k=1}^{K} p_{jk}^{tea} \log p_{jk}^{tea}}{\log K}, \tag{4.2}$$

$$u_j = p_{j,\hat{y}_j^t}^{stu}, \tag{4.3}$$

$$s_j = \frac{1 + \cos(f_j^{tea}, c_{\hat{y}_j^t}^{ref})}{2}. \tag{4.4}$$

其中，$q_j$ 表示教师置信度，$e_j$ 表示逆归一化熵，$u_j$ 表示学生在强增强视图上对伪标签类别的响应强度，$s_j$ 表示教师特征与参考原型之间的相似度。于是综合可靠性得分定义为

$$r_j = \omega_1 q_j + \omega_2 e_j + \omega_3 u_j + \omega_4 s_j, \qquad \sum_{m=1}^{4} \omega_m = 1. \tag{4.5}$$

在当前 fixed-fold benchmark 配置中，四个分量的原始权重依次设置为 1.1、1.0、1.1 和 1.2，并在实现中归一化后参与加权。计算完成后，还会进一步施加幂次变换

$$\tilde{r}_j = r_j^{\gamma}, \tag{4.6}$$

其中当前配置中的 $\gamma = 1.4$，目的是适度放大高可靠样本与中低可靠样本之间的区分度。

这样的设计具有明显互补性。若只依赖最大概率，模型容易把“高置信但错误”的样本误认为可靠；若只依赖熵，难以区分边界犹豫样本与真实混乱样本；若只依赖增强一致性，又会忽略类别结构位置；若只依赖原型相似度，则在原型尚未稳定时容易引入偏差。将四种信息联合起来，可以在“预测尖锐度、视图稳定性、结构匹配度”三个层面同时评估样本质量。

## 4.4 按类门控与样本接纳课程

在获得可靠性得分之后，RCTA 并不让所有目标域样本都参与伪标签监督，而是同时引入分数下界和按类接纳比例两个门控量。分数下界定义为

$$\tau(t) = \tau_{start} + (\tau_{end} - \tau_{start}) \cdot \min\left(\frac{t}{T_\tau}, 1\right), \tag{4.7}$$

按类接纳比例定义为

$$\rho(t) = \rho_{start} + (\rho_{end} - \rho_{start}) \cdot \min\left(\frac{t}{T_\rho}, 1\right). \tag{4.8}$$

在当前 benchmark 配置中，$\tau(t)$ 从 0.34 线性上升到 0.56，$\rho(t)$ 从 0.22 线性上升到 0.72，对应的课程步数均为 2200。其核心意图是：训练早期只保留少量高可靠样本，避免噪声伪监督主导训练；训练中后期再逐步扩大接纳范围，使模型有机会利用更多目标域信息。

与简单的全局阈值不同，RCTA 采用按预测类别分别筛选的策略。对每个预测类别 $k$，先保留满足 $\tilde{r}_j \geq \tau(t)$ 的样本，再在该类别内部选取得分前 $\lceil \rho(t) \cdot n_k \rceil$ 个样本进入门控集合 $\Omega_t$。这种按类门控方式能够缓解类别不均衡带来的“头部类别占满伪标签预算”问题，更适合 29 类流程工业诊断任务。

## 4.5 分层利用：可靠、半可靠与不可靠样本

当前实现并不把目标域样本简单分为“可用”和“不可用”两类，而是进一步划分为可靠、半可靠和不可靠三组。设可靠阈值和半可靠阈值分别为 $\eta_r$ 与 $\eta_s$，则有

$$\Omega_t^r = \{j \mid j \in \Omega_t,\ \tilde{r}_j \geq \eta_r\}, \tag{4.9}$$

$$\Omega_t^s = \{j \mid j \in \Omega_t,\ \eta_s \leq \tilde{r}_j < \eta_r\}, \tag{4.10}$$

$$\Omega_t^u = \{1, \ldots, m_t\} \setminus (\Omega_t^r \cup \Omega_t^s). \tag{4.11}$$

在当前 benchmark 配置中，$\eta_r = 0.66$，$\eta_s = 0.44$。这种分层利用机制的意义在于：同样被 gate 接纳的样本，其可靠程度仍然不同，完全使用同一强度监督并不合理。

具体而言，可靠样本主要承担伪标签监督与较强的一致性约束；半可靠样本主要承担较弱的一致性正则；不可靠样本则不进入伪标签交叉熵，而是通过轻量熵项维持适度结构化。这样做的好处在于，模型不会因为“分数刚刚过线”的样本而获得与高可靠样本同等强度的监督，也不会彻底浪费那些尚未达到高可靠标准、但已经包含一定信息的样本。

## 4.6 可靠性加权伪标签损失与辅助正则

对于通过门控的目标样本，伪标签损失采用带可靠性加权的交叉熵[17]：

$$\mathcal{L}_{pl} = \frac{1}{\sum_{j \in \Omega_t} \tilde{r}_j} \sum_{j \in \Omega_t} \tilde{r}_j\, \ell_{ce}\big(h(\phi(\tilde{x}_{j,s}^t)), \hat{y}_j^t\big)\,. \tag{4.12}$$

这样一来，不同目标样本虽然都被允许进入训练，但高可靠样本会对梯度更新产生更大影响。

除主伪标签损失外，当前实现还额外保留两项与可靠性分层相关的辅助正则。对半可

靠样本，施加较弱的一致性项：

$$\mathcal{L}_{semi-cons} = \frac{1}{|\Omega_t^s|} \sum_{j \in \Omega_t^s} \tilde{r}_j \left\| p_j^{stu} - p_j^{tea} \right\|_2^2 . \tag{4.13}$$

对不可靠样本，则使用轻量熵项维持预测结构化：

$$\mathcal{L}_{u-ent} = \frac{1}{|\Omega_t^u|} \sum_{j \in \Omega_t^u} \left( -\sum_{k=1}^{K} p_{jk}^{stu} \log p_{jk}^{stu} \right) . \tag{4.14}$$

在当前 benchmark 配置中，这两项对应的附加权重分别为 0.04 和 0.01。它们的目标不是单独主导训练，而是对“还不够可靠、但也不是完全无用”的样本提供更温和的处理方式。

## 4.7 与前后模块的耦合关系

可靠性门控位于第三章和第五章之间，既依赖前序模块，也会反向影响后序模块。首先，本章的教师概率、学生强增强响应和参考原型相似度均建立在第三章输出的稳定概率与特征之上；没有第三章的一致性底座，可靠性得分本身会更不稳定。其次，本章筛选出的高可靠样本会进入第五章的目标域伪监督与原型约束，而第五章构造的参考原型又会反过来参与本章的结构相似度评分。

从这个角度看，本章的真正贡献并不仅仅是一个门槛函数，而是把目标域样本利用过程从“单点判断”升级为“基于概率、一致性与结构信息的闭环筛选”。这也是 RCTA 能够避免把所有目标域样本一股脑塞进训练的重要原因。

## 4.8 本章小结

本章围绕可靠性门控的伪标签学习展开，分别说明了伪标签误差传播的来源、多因素可靠性评分、按类门控课程、可靠/半可靠/不可靠三层样本划分，以及可靠性加权伪标签损失与辅助正则。该模块的核心价值在于提高目标域伪监督的质量和利用效率，并为第五章的类条件结构约束提供更干净、更可控的目标域样本来源。

# 第五章 双原型记忆的类条件结构约束

## 5.1 模块定位

全局域对齐能够缩小源域与目标域的整体差异，但并不能自动保证跨域同类样本彼此靠近，也不能保证不同故障类别之间保持足够间隔。在 TEP 这类 29 类工业时序诊断任务中，若只强调域间混合，模型可能把不同类别的样本压缩到相近区域，从而产生类别混叠甚至负迁移。为此，RCTA 在可靠性门控的基础上进一步引入双原型记忆，用显式类别中心约束目标域结构。

本章对应第一章提出的挑战三：全局域对齐容易带来类别混叠，难以保证跨域同类样本聚合、异类样本分离。第三章和第四章分别解决“目标域样本如何进入训练”和“哪些目标域样本可信”，本章则进一步回答“这些样本应被组织到怎样的类别结构中”。

## 5.2 类条件结构缺失的表现

当模型只依赖全局分布对齐时，通常会出现两类现象。第一，源域与目标域整体分布在投影空间中看似重叠，但同类样本并未真正对齐，导致目标域样本仍然围绕错误类别边界分布。第二，不同类别在共享特征空间中过度压缩，尤其是动态响应相近的故障类别之间更容易出现混叠。这一问题在多类别工业时序任务中尤为突出，因为不同故障的局部时序模式可能存在相似片段，仅凭全局域不变性不足以区分类别语义。

因此，本章不再把“域混合得更像”作为唯一目标，而是进一步要求模型满足以下两点：其一，跨域同类样本应围绕共同的类别中心聚合；其二，不同类别中心之间应保持足够间隔。原型记忆正是实现这一目标的一种轻量而直观的手段。

## 5.3 源域原型记忆

为了显式建模类别结构，RCTA 首先为源域维护原型记忆库[19]。设学生网络在源域样本上的特征表示为

$$f_i^s = \phi(x_i^s). \tag{5.1}$$

对第 $k$ 类样本，源域当前批次原型定义为

$$\tilde{c}_k^s = \frac{1}{|\mathcal{B}_s^k|} \sum_{i:y_i^s=k} f_i^s, \tag{5.2}$$

并在实现中做单位化处理。跨批次的源域原型记忆采用动量更新：

$$c_k^s \leftarrow \mathrm{Norm}(\beta c_k^s + (1-\beta)\tilde{c}_k^s)\,, \tag{5.3}$$

其中 $\beta$ 为原型动量系数。当前 benchmark 配置中 $\beta = 0.95$。

源域原型的优势在于标签可靠，能够为各故障类别提供稳定锚点。即使目标域样本尚不可信，源域原型仍可为模型提供“该类别大致位于何处”的结构先验。因此，在训练早期，源域原型实际上承担了“类别几何骨架”的角色。

## 5.4 目标域原型记忆

仅依赖源域原型会忽略目标工况下的类别形态变化，因此 RCTA 同时维护目标域原型记忆。与一些仅使用高可靠样本更新目标原型的设计不同，当前实现采用一种更平滑的方式：在每个优化步结束后，使用教师分支在目标域上的伪类别结果对目标原型进行 EMA 式更新。设目标域教师特征为 $f_j^{t,tea}$，对应伪类别为 $\hat{y}_j^t$，则目标域批次原型可写为

$$\tilde{c}_k^t = \frac{1}{|\mathcal{B}_t^k|} \sum_{j:\hat{y}_j^t=k} f_j^{t,tea}, \tag{5.4}$$

跨批次更新为

$$c_k^t \leftarrow \mathrm{Norm}\big(\beta c_k^t + (1-\beta)\tilde{c}_k^t\big)\,. \tag{5.5}$$

这样的实现有两层考虑。第一，目标域原型记忆若完全依赖门控样本，更新会过于稀疏，在某些类别上很难及时形成中心；第二，EMA 记忆本身具有平滑效果，能够削弱单批次噪声标签的瞬时影响。与此同时，真正直接作用于优化的目标域原型损失仍会受到门控和软权重控制，因此“原型记忆更新较广、原型损失施加较谨慎”构成了当前实现的平衡点。

## 5.5 参考原型构造

在实际训练中，真正参与相似度计算和原型约束的并不是单一来源的类别中心，而是综合当前批次源域原型、源域记忆原型和目标域记忆原型形成的参考原型。记当前源域批次原型为 $\tilde{c}_k^s$，跨批次源域记忆为 $c_k^s$，目标域记忆为 $c_k^t$，则参考原型可抽象表示为

$$c_k^{ref} = \mathrm{Norm}\big(\mathbf{1}[\tilde{c}_k^s]\,\tilde{c}_k^s + \mathbf{1}[c_k^s]\,c_k^s + \mathbf{1}[c_k^t]\,c_k^t\big)\,, \tag{5.6}$$

其中 $\mathbf{1}[\cdot]$ 表示该项是否可用。在当前实现中，若某类别在当前批次缺失，则优先回退到源域记忆；若目标域记忆也可用，则将二者做归一化叠加，从而形成兼顾稳定性与适应性的中心。

这种设计避免了两个极端。只使用源域原型会忽略目标工况差异，只使用目标域原型则在训练早期极易被噪声伪标签带偏。参考原型通过把“当前源域局部信息”“跨批次源

域稳定信息”“目标域渐进适应信息”统一到一个几何中心中，为后续可靠性评分和类条件约束提供了更稳健的支点。

## 5.6 原型吸引损失

在获得参考原型后，RCTA 同时对源域样本和目标域样本施加原型吸引约束。对源域样本，标签为真实标签；对目标域样本，标签为教师给出的伪标签。基础吸引项写为

$$\mathcal{L}_{att} = \frac{1}{N}\sum_{i}\left(1-\cos(f_i, c_{y_i}^{ref})\right). \tag{5.7}$$

当前实现中，原型吸引损失由三部分组成。第一部分是源域吸引项

$$\mathcal{L}_{att}^{s}, \tag{5.8}$$

它保证源域类别边界不会在跨域过程中被破坏。第二部分是门控目标样本吸引项

$$\mathcal{L}_{att}^{t}, \tag{5.9}$$

它把通过第四章筛选的目标样本拉向各自伪类别中心。第三部分是软权重目标吸引项

$$\mathcal{L}_{att}^{soft} = \frac{1}{\sum_j w_j^{soft}}\sum_{j=1}^{m_t} w_j^{soft}\left(1-\cos(f_j^t, c_{\hat{y}_j^t}^{ref})\right), \tag{5.10}$$

其中 $w_j^{soft} \in [0,1]$ 来自第四章的可靠性分层权重。当前实现中，完整原型吸引项为

$$\mathcal{L}_{proto}^{att} = \mathcal{L}_{att}^{s} + \mathcal{L}_{att}^{t} + 0.5\,\mathcal{L}_{att}^{soft}. \tag{5.11}$$

这一设计体现了一个重要思想：并非只有完全“高可靠”的目标样本才能对结构学习有贡献。高可靠样本以硬门控方式提供更强约束，而中间地带样本则以软权重方式提供更温和的几何拉拽，从而在稳定性与信息利用率之间取得折中。

## 5.7 原型分离损失

仅有类内吸引还不够。若不同类别中心本身过于接近，模型仍可能在局部区域发生混叠。为此，进一步定义原型分离损失：

$$\mathcal{L}_{sep} = \frac{1}{|\mathcal{P}|}\sum_{(k,l)\in\mathcal{P}} \max\left(0, \cos(c_k^{ref}, c_l^{ref}) - m\right), \tag{5.12}$$

其中 $\mathcal{P}$ 表示所有有效类别原型对的集合，$m$ 为分离边界。当前 benchmark 配置中，原型分离边界取 $m = 0.20$，分离项权重取 0.08。于是完整的原型约束可写为

$$\mathcal{L}_{proto} = \mathcal{L}_{proto}^{att} + \lambda_{sep}\mathcal{L}_{sep}. \tag{5.13}$$

从几何上看，原型吸引项鼓励同类样本朝中心收缩，原型分离项则防止不同类别中心彼此重叠。二者结合后，特征空间不再只追求“源域与目标域更像”，而是进一步追求“跨域同类更紧、异类更开”。这正是类条件结构学习相对于纯全局对齐的重要补充。

## 5.8 模块作用分析与局限性

本章模块的预期收益主要体现在三个层面。第一，它显式把类别中心引入训练过程，使模型获得全局对齐之外的类条件几何约束。第二，源域与目标域双原型的结合使类别中心既保留了源域标签可靠性，又逐渐吸收了目标域结构信息。第三，参考原型还会反向参与第四章的可靠性评分，使“样本筛选”和“结构建模”形成闭环。

但本章模块也存在边界。若第四章的可靠性控制过弱，目标域伪类别仍可能污染目标原型；若原型分离过强，则可能损伤邻近故障类别之间的自然相似结构；若对训练早期就施加较大原型权重，也会把尚未成熟的类别结构过早固化。因此，本章模块必须与第六章的课程化策略共同使用。

## 5.9 本章小结

本章围绕双原型记忆的类条件结构约束展开，分别说明了类条件结构缺失的表现、源域原型记忆、目标域原型记忆、参考原型构造、原型吸引损失以及原型分离损失。该模块的核心作用是把目标域适应从“只做全局域对齐”推进到“显式塑造跨域类别结构”，为完整 RCTA 提供更清晰的几何组织能力。

# 第六章 课程化优化与完整训练流程

## 6.1 模块定位

第三章、第四章和第五章分别给出了 RCTA 的时序一致性、可靠性门控和双原型结构约束。它们解决的问题不同，所依赖的训练阶段也不同：基础对齐和源域分类可以从训练开始即发挥作用；伪标签和一致性约束需要模型具备初步判别能力；原型约束则更依赖稳定的类别结构。如果多个辅助目标在训练初期同时以较大权重注入，往往会破坏尚未形成的分类边界。

本章对应第一章提出的挑战四：多个辅助目标的作用时机不同，若同时强行注入可能破坏训练稳定性。为此，RCTA 将训练节奏本身纳入方法设计，一方面通过课程化权重调度控制各损失的进入时机，另一方面通过置信保护型模型选择和早停策略控制 checkpoint 选择过程，从而把“训练如何组织”也纳入完整方法的一部分。

## 6.2 两级课程机制

当前实现中的课程化策略并不是单一的“损失预热”，而是包含两个层次。

### 6.2.1 门控课程

第一层课程作用于第四章的样本筛选过程，即门控分数下界 $\tau(t)$ 与按类接纳比例 $\rho(t)$ 的渐进变化。训练早期使用更严格的分数门槛和更小的接纳比例，只允许少量高可靠样本进入伪监督；训练中后期逐步放宽门槛并增加接纳比例，使更多目标域样本参与训练。这个课程的主要作用对象是“**哪些样本可以被使用**”。

### 6.2.2 损失课程

第二层课程作用于各辅助损失的进入时机。若记任一辅助项的基础权重为 $\lambda$，开始步数为 $t_0$，预热长度为 $\Delta t$，则其课程化权重统一写为

$$\lambda(t) = \begin{cases} 0, & t < t_0, \\ \lambda \cdot \min\left(\dfrac{t - t_0}{\Delta t}, 1\right), & t \geq t_0. \end{cases} \tag{6.1}$$

这个课程的主要作用对象是“**哪些目标以多大强度进入优化**”。

在当前 fixed-fold benchmark 配置中，伪标签损失从训练开始即预热，最大发电权重为 0.22，预热步数为 900；一致性损失从第 700 步开始，基础权重为 0.06，预热步数为 1200；原型损失从第 800 步开始，基础权重为 0.07，预热步数为 1200。这样的安排体现了“先建

立可迁移底座，再引入目标域监督，最后强化类别结构”的训练逻辑。

## 6.3 完整目标函数

结合前述各章，RCTA 的完整优化目标可写为

$$\begin{aligned}\mathcal{L}_{\text{RCTA}} = \mathcal{L}_{cls}^{s} + \lambda_{align}(t)\mathcal{L}_{align} + \lambda_{mcc}\mathcal{L}_{mcc} + \lambda_{pl}(t)\mathcal{L}_{pl} \\ + \lambda_{proto}(t)\mathcal{L}_{proto} + \lambda_{cons}(t)\mathcal{L}_{cons} + \lambda_{semi}\mathcal{L}_{semi-cons} + \lambda_{u}\mathcal{L}_{u-ent}.\end{aligned} \tag{6.2}$$

其中，$\mathcal{L}_{cls}^{s}$ 负责源域有标签监督，$\mathcal{L}_{align}$ 负责基础域对齐，$\mathcal{L}_{mcc}$ 用于抑制目标域类别混淆，$\mathcal{L}_{pl}$、$\mathcal{L}_{proto}$ 和 $\mathcal{L}_{cons}$ 分别由第四章、第五章和第三章给出，$\mathcal{L}_{semi-cons}$ 与 $\mathcal{L}_{u-ent}$ 则是第四章分层利用机制中的温和辅助项。

从章节逻辑上看，第三章提供目标域预测的平滑来源，第四章筛选并分层利用目标样本，第五章塑造类条件结构，本章则决定这些目标以怎样的节奏进入优化，并决定训练过程中如何选择更稳健的 checkpoint。换言之，本章并不是单独新增一个损失项，而是负责把前面三个模块真正组织成一个可训练、可收敛的整体。

## 6.4 置信保护型模型选择与早停

在无监督领域自适应中，训练目标本身只是问题的一半，checkpoint 选取同样会显著影响最终结论。若只根据目标域平均置信度选择模型，对抗式方法容易在尚未真正完成对齐时出现“置信度很高但预测结构已塌缩”的情况；若只根据源域评估准确率选择模型，又可能无法反映目标域适应程度。因此，当前 benchmark 为 RCTA 额外设计了置信保护型模型选择指标。

记源域评估准确率为 $\text{Acc}_s^{eval}$，目标域平均置信度为 $\bar{q}_t$，域判别器准确率为 $\text{Acc}_d$，则选择分数可写为

$$S_{\text{guard}} = w_s\text{Acc}_s^{eval} + w_q\bar{q}_t - w_o\max(0, \bar{q}_t - q_{max}) - w_d\max(0, |\text{Acc}_d - d^{\star}| - \delta_d), \tag{6.3}$$

其中 $q_{max}$ 为允许的置信上限，$d^{\star} = 0.5$ 表示理想的域混淆点，$\delta_d$ 表示可接受的域差容忍带。当前 benchmark 配置中，该指标使用 $w_s = 0.80$、$w_q = 0.20$、$w_o = 1.00$、$w_d = 0.25$，并设置信心上限为 0.90、域差容忍带为 0.18。

这个指标的直观含义是：在优先保证源域判别能力的前提下，鼓励目标域预测逐渐形成清晰结构，但惩罚过度自信和域对齐明显失衡的 checkpoint。与“训练完最后一个 epoch 直接取结果”相比，这种选择方式更能体现 RCTA 对稳定性的关注，也更符合 benchmark

比较对可复现性的要求。

## 6.5 训练流程表

算法 1 给出了 RCTA 的训练流程。与第三章到第五章分别介绍局部机制不同，本节的算法表强调的是各模块之间的先后关系和信息流动方向。

**算法 1:** RCTA 训练流程

**Input:** 源域批量 $\mathcal{B}_s$，目标域批量 $\mathcal{B}_t$，学生网络参数 $\theta_{\text{stu}}$，教师网络参数 $\theta_{\text{tea}}$，原型记忆 $C_s, C_t$

**Output:** 更新后的学生网络、教师网络和双原型记忆

```
初始化学生网络、教师网络和源/目标域原型记忆;
for 训练步 t = 1, 2, ..., T do
    从源域和目标域采样 B_s, B_t;
    计算源域分类损失 L_cls^s 和基础对齐损失 L_align;
    对目标域样本构造弱增强 x̃_w^t 与强增强 x̃_s^t;
    教师网络在弱增强视图上生成 p^tea 和伪标签 ŷ^t;
    学生网络在强增强视图上生成 p^stu，计算一致性信息;
    根据置信度、逆熵、增强一致性和原型相似度计算可靠性得分 r;
    按类别执行门控，得到门控集合 Ω_t 及可靠/半可靠/不可靠划分;
    使用 Ω_t 计算伪标签损失，并对半可靠和不可靠样本施加温和正则;
    结合参考原型计算源域吸引、目标域吸引、软权重目标吸引和原型分离损失;
    根据课程函数得到 λ_pl(t)、λ_cons(t)、λ_proto(t);
    汇总 L_RCTA 并更新学生网络参数 θ_stu;
    通过 EMA 更新教师网络参数，并更新源/目标原型记忆;
end
```

## 6.6 递进验证中的 D 模块含义

在论文写作结构中，本章对应的 D 模块不仅仅是“又加了一个损失项”，而是“**把前三章模块组织成完整方法的训练机制**”。具体地，D 模块包含以下三层含义：

1. 将门控课程与损失课程统一起来，决定不同样本和不同损失在训练过程中何时进入优化；
2. 将模型选择与早停显式纳入方法定义，避免因 checkpoint 选择方式不透明而削弱结论可信度；
3. 通过算法流程表将第三章至第五章的机制串联起来，形成从样本生成、样本筛选到结构约束的闭环训练过程。

正因为如此，实验章节中所谓的“A+B+C+D：完整 RCTA”并不是单纯在 A+B+C 上再叠加一个附加权重，而是采用本章给出的完整训练节奏、选择指标和更新流程来运行整

个系统。

## 6.7 本章小结

本章围绕课程化优化与完整训练流程展开，说明了门控课程、损失课程、完整目标函数、置信保护型模型选择指标以及算法流程表。与前三章关注局部模块不同，本章的核心作用是把局部机制组织成一个可训练、可选择、可复现的完整方法，从而为第七章的 benchmark 运行与结果分析提供稳定执行基础。

# 第七章 实验设计与结果组织

## 7.1 实验章节定位

本章作为全文倒数第二章，统一承接前文的 benchmark 构建、方法设计与结果验证任务。与仅对少量场景做“点状展示”的写法不同，本文当前版本明确以 `benchmark_88_2clusters_11scenes_8methods_fixedfold.yaml` 对应的 88-run fixed-fold benchmark 作为主实验口径。也就是说，本章首先围绕当前必须完成的正式 benchmark 给出实验组织、结果表和图件占位；至于更细粒度的模块级消融，则在本章后部作为后续补充实验计划保留结构化位置。

这种组织方式的好处在于：一方面，论文主结果与当前实际要跑的实验配置完全一致，避免正文口径与代码配置脱节；另一方面，第三章至第六章已经把 RCTA 的创新模块分章展开，即使暂时还没有逐模块消融结果，论文的技术逻辑仍然完整，后续只需在既有位置回填补充实验。

## 7.2 数据集与 benchmark 场景

### 7.2.1 TEP 领域自适应数据集

本文采用 Tennessee Eastman Process Domain Adaptation 数据集开展实验。该数据集将 6 个操作模式视为 6 个不同领域，标签空间为 29 类，即正常工况和 28 类故障。与普通单域分类任务相比，该数据集更适合用于分析工业过程在工况切换条件下产生的分布偏移问题，并观察不同领域自适应机制对多类别工业时序诊断的影响[11]。

根据当前工作区中的 `data/benchmark/manifest.json`，6 个域的样本规模与默认 Fold 1 划分情况如表 7.1 所示。可以看到，各域样本总量均接近 2900，默认采用 Fold 1 作为评估折时，训练样本量约为 2300，评估样本量约为 570。这样的规模既能够支撑本文的系统化 benchmark 比较，也保留了工业时序诊断任务的复杂性。

表 7.1 TEP 领域自适应数据集的域规模与默认 Fold 1 划分

| 域 | 样本总数 | 训练样本数 | 评估样本数 | 单样本形状 | 类别数 |
|---|---|---|---|---|---|
| mode1 | 2900 | 2320 | 580 | 600×34 | 29 |
| mode2 | 2845 | 2278 | 567 | 600×34 | 29 |
| mode3 | 2899 | 2320 | 579 | 600×34 | 29 |
| mode4 | 2865 | 2294 | 571 | 600×34 | 29 |
| mode5 | 2883 | 2307 | 576 | 600×34 | 29 |
| mode6 | 2897 | 2318 | 579 | 600×34 | 29 |

### 7.2.2 11 个场景的 fixed-fold benchmark

当前 benchmark 不追求覆盖全部 30 个有向单源场景，而是采用“两簇 + 代表性多源场景”的设计。具体而言，一簇为 mode3 与 mode6 的互迁，另一簇为 mode1、mode2、mode5 之间的互迁，并在后者基础上补充 3 个多源到单目标场景。这样得到总计 11 个迁移场景，其中 8 个为单源场景，3 个为多源场景。

表 7.2 给出了本 benchmark 的场景构成与固定折分配。固定折策略的作用在于：所有方法在同一场景上共享相同的源折与目标折，从而避免方法之间由于折采样差异而产生额外噪声，使比较尽量聚焦于方法本身。

表 7.2 88-run fixed-fold benchmark 的 11 个场景与折分配

| 编号 | 场景类型 | 迁移场景 | 源折设置 | 目标折 |
|---|---|---|---|---|
| S1 | 单源 | mode3→mode6 | Fold 1 | Fold 1 |
| S2 | 单源 | mode6→mode3 | Fold 1 | Fold 5 |
| S3 | 单源 | mode1→mode2 | Fold 2 | Fold 4 |
| S4 | 单源 | mode2→mode1 | Fold 5 | Fold 3 |
| S5 | 单源 | mode1→mode5 | Fold 4 | Fold 3 |
| S6 | 单源 | mode5→mode1 | Fold 4 | Fold 4 |
| S7 | 单源 | mode2→mode5 | Fold 1 | Fold 3 |
| S8 | 单源 | mode5→mode2 | Fold 3 | Fold 4 |
| M1 | 多源 | mode1+mode2→mode5 | mode1: Fold 4, mode2: Fold 1 | Fold 3 |
| M2 | 多源 | mode1+mode5→mode2 | mode1: Fold 2, mode5: Fold 3 | Fold 4 |
| M3 | 多源 | mode2+mode5→mode1 | mode2: Fold 4, mode5: Fold 4 | Fold 4 |

在实验数量上，当前 benchmark 共包含 8 种方法和 11 个场景，因此总运行次数为

$$8 \times 11 = 88. \tag{7.1}$$

这一规模既明显大于只比较个别迁移方向的“小样本结果”，又仍然处于本科论文阶段可以组织与管理的范围内。

## 7.3 统一实验协议

### 7.3.1 输入预处理与归一化

数据集中的每个样本均表示为固定长度的多变量时间窗口，可形式化写为

$$x \in \mathbb{R}^{T \times C}, \tag{7.2}$$

其中 $T = 600$，$C = 34$。在进入神经网络前，数据被转置为 channels-first 形式：

$$x' = \text{Transpose}(x) \in \mathbb{R}^{C \times T}. \tag{7.3}$$

为保证不同方法具有可比性，本文采用域内标准化，即对每个域分别基于该域全量样本统计量执行标准化：

$$\tilde{x}_{n,t,c} = \frac{x_{n,t,c} - \mu_c}{\sigma_c + \varepsilon}. \tag{7.4}$$

其中 $\mu_c$ 和 $\sigma_c$ 为该域第 $c$ 个通道的均值和标准差。该策略对应当前数据配置中的 `normalization_scope=domain`。

### 7.3.2 方法集合与训练设置

当前 benchmark 涉及的 8 种方法为 Source Only、Target Only、CORAL、DAN、DANN、CDAN、DeepJDOT 和 RCTA。其中，Target Only 使用目标域标签进行监督训练，因此在严格意义上不属于无监督领域自适应方法，而是作为监督参考上界参与比较。其余 7 种方法中，Source Only 作为无自适应对照组，CORAL/DAN 代表统计对齐，DANN/CDAN 代表对抗式对齐，DeepJDOT 代表最优传输思想，RCTA 则是本文的改进方法。

为降低无关变量干扰，所有方法共享同一 FCN 骨干和统一结果导出结构，但不同方法在训练轮数、对齐权重和模型选择指标上允许保留合理差异。当前 fixed-fold benchmark 中，基线方法训练轮数主要落在 84–120 之间，RCTA 训练轮数为 112；DeepJDOT 使用更大的 batch size 以支持 OT 代价计算，其余方法大体维持 batch size=32。这样的配置方式更符合 benchmark 的实际目的，即比较方法机制在合理调参后的表现，而非强行让所有方法使用完全一致但未必合适的超参数。

### 7.3.3 运行命令与结果产物

当前 benchmark 的实际运行入口为仓库中的批量脚本 `scripts/run_small_scale_round.sh`。对应的主实验命令为：

```
scripts/run_small_scale_round.sh \
--experiment-config \
configs/experiment/\
benchmark_88_2clusters_11scenes_8methods_fixedfold.yaml
```

运行结束后，脚手架会在 `runs/` 目录下统一生成每次运行的 `result.json`、`review.json`、checkpoint、分析特征文件以及图表；随后自动汇总到 `comparison_summary` 目录，形成整轮 benchmark 的 JSON/Markdown 对照表和汇总图件。也就是说，本章后续所有表格与图件理论上都可以从统一结果产物中回填，而不需要手工拼接零散结果。

## 7.4 总体 benchmark 结果占位

### 7.4.1 8 个单源场景的结果表

表 7.3 预留了 8 个单源场景上的 benchmark 主结果位置。考虑到当前版本的论文重点是先完成结构化写作与实验回填接口，因此表中数值暂以占位形式呈现，待 benchmark 跑完后可直接回填目标域准确率或“准确率 / 平衡准确率”双指标。

表 7.3 8 个单源场景上的主结果（占位）

| 场景 | Source Only | CORAL | DAN | DANN | CDAN | DeepJDOT | RCTA | Target Only |
|---|---|---|---|---|---|---|---|---|
| mode3→mode6 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| mode6→mode3 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| mode1→mode2 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| mode2→mode1 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| mode1→mode5 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| mode5→mode1 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| mode2→mode5 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| mode5→mode2 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |

### 7.4.2 3 个多源场景的结果表

表 7.4 预留了 3 个多源场景上的主结果位置。该表的意义在于观察当前方法在“源域信息更丰富，但域间关系也更复杂”的设置下是否仍然能够保持稳定收益。

表 7.4 3 个多源场景上的主结果（占位）

| 场景 | Source Only | CORAL | DAN | DANN | CDAN | DeepJDOT | RCTA | Target Only |
|---|---|---|---|---|---|---|---|---|
| mode1+mode2→mode5 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| mode1+mode5→mode2 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| mode2+mode5→mode1 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |

### 7.4.3 方法总体汇总表

为避免正文只罗列逐场景结果而缺少总体结论，表 7.5 预留了方法层面的均值汇总位置。建议在回填时至少包含：8 个单源场景平均准确率、3 个多源场景平均准确率、11 个场景总体平均准确率、总体平均平衡准确率以及相对 Source Only 的平均增益。

表 7.5 88-run benchmark 的方法总体汇总（占位）

| 方法 | 单源平均准确率 | 多源平均准确率 | 总体平均准确率 | 总体平均平衡准确率 | 相对 Source Only 平均增益 |
|---|---|---|---|---|---|
| Source Only | 待补充 | 待补充 | 待补充 | 待补充 | 0 |
| CORAL | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| DAN | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| DANN | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| CDAN | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| DeepJDOT | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| RCTA | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |
| Target Only | 待补充 | 待补充 | 待补充 | 待补充 | 待补充 |

在最终版本中，本节将基于上述三张表从以下三个角度展开分析。第一，比较不同方

法在总体平均性能上的高低，观察 RCTA 是否能够稳定优于 Source Only 和强基线。第二，区分单源场景和多源场景，判断方法收益是否具有场景依赖性。第三，利用 Target Only 这一监督参考观察当前无监督领域自适应方法距离“目标域可监督训练”还有多大差距，从而给出更有边界感的结论。

## 7.5 定性分析图件占位

除定量指标外，当前 benchmark 还会自动导出混淆矩阵、t-SNE 投影和汇总热力图。考虑到这些图件的最终版本依赖正式运行结果，本节先给出结构化占位，待 benchmark 跑完后可直接替换。

**实验结果占位图**

11 个场景 × 8 种方法的 benchmark 热力图待补充

图 7-1 88-run benchmark 的场景–方法热力图（占位）

**实验结果占位图**

代表性场景下强基线混淆矩阵待补充

(a) 强基线或 Source Only

**实验结果占位图**

代表性场景下完整 RCTA 混淆矩阵待补充

(b) 完整 RCTA

图 7-2 代表性场景下基线方法与完整 RCTA 的混淆矩阵对比（占位）

在最终回填中，本节建议重点观察以下问题：误分类是否集中于少数易混类别；RCTA 是否能够提升混淆矩阵主对角线连续性；源域与目标域样本在 t-SNE 上是否形成更合理的跨域同类聚类；在多源场景中，多个源域与目标域之间是否出现更平滑的过渡结构。这些定性现象将用于支撑前文关于“稳定目标域利用”和“缓解类别混叠”的论证。

**实验结果占位图**

代表性场景下强基线 t-SNE 图待补充

(a) 强基线或 Source Only

**实验结果占位图**

代表性场景下完整 RCTA t-SNE 图待补充

(b) 完整 RCTA

图 7-3 代表性场景下基线方法与完整 RCTA 的域分布 t-SNE 对比（占位）

## 7.6 模块递进验证的后续占位

需要说明的是，当前论文周期内**必须完成的正式实验**是前述 88-run fixed-fold benchmark，而 A、A+B、A+B+C、A+B+C+D 形式的严格模块递进验证尚未被纳入当前主实验配置。因此，针对第三章至第六章各创新点的模块级消融，本节先保留结构化位置，待后续单独设计 ablation config 后再补入结果。

表 7.6 RCTA 模块递进验证结果（后续专用占位）

| 模型组合 | mode2→mode5 | mode3→mode6 | mode5→mode2 | mode6→mode3 |
|---|---|---|---|---|
| A | 待补充 | 待补充 | 待补充 | 待补充 |
| A+B | 待补充 | 待补充 | 待补充 | 待补充 |
| A+B+C | 待补充 | 待补充 | 待补充 | 待补充 |
| A+B+C+D | 待补充 | 待补充 | 待补充 | 待补充 |

保留这一占位的意义在于：正文的方法章节已经按创新点顺序展开，后续只要补上专门的 ablation 运行配置，就能够在不改论文结构的前提下形成从主 benchmark 到模块级验证的完整闭环。换言之，本文当前并非“没有消融位置”，而是“主 benchmark 先行、消融后补”。

## 7.7 本章小结

本章围绕当前实际需要执行的 88-run fixed-fold benchmark，系统说明了数据集规模、11 个场景的构成与折分配、统一实验协议、运行命令、主结果表和定性图件占位，并将严格模块消融作为后续专用占位单独说明。这样组织后，论文主实验与当前代码配置实现了一一对应，后续只需运行 benchmark 并把结果回填到本章既有结构中，即可形成完整实验论证。

# 第八章 总结与展望

## 8.1 全文工作总结

本文围绕流程工业场景下的领域自适应故障诊断问题，面向 Tennessee Eastman Process Domain Adaptation 数据集，完成了从研究现状梳理、统一 benchmark 组织、典型方法比较框架搭建到 RCTA 方法设计与论文结构重构的一系列工作。全文首先在绪论中明确了研究背景、现有工作缺口和本文的创新定位；随后在基准章节中统一了任务定义、输入表示、共享骨干、模型选择原则与 benchmark 边界；在此基础上，将 RCTA 拆分为教师–学生时序一致性、可靠性门控、双原型记忆和课程化优化四个相互衔接的模块，并分别展开为独立章节；最后在实验章节中将当前必须完成的 88-run fixed-fold benchmark 明确为主实验对象，同时为后续模块消融保留结构化位置。

相较于仅展示个别迁移方向结果或仅给出“完整方法优于基线”的写法，本文更强调从研究问题、方法设计到实验协议的一致性。特别是当前版本已经把论文正文的实验口径与实际运行配置对齐到同一 benchmark 上，使得后续论文完善不再依赖大规模结构调整，而主要是结果回填与分析深化。

## 8.2 主要结论与阶段性认识

在当前版本中，本文可以形成的主要结论与阶段性认识包括以下四点。

1. TEP 多工况故障诊断可以被清晰表述为跨工况无监督领域自适应问题，并能够在统一数据协议、统一骨干和统一结果导出结构下形成可复现的 benchmark 组织方式。
2. 典型领域自适应基线方法为 RCTA 的设计提供了有针对性的参照：统计对齐方法训练稳定但类条件信息不足，对抗式方法适应能力更强但更敏感于训练波动，最优传输方法强调样本级匹配但对计算配置和代价尺度较敏感。
3. RCTA 的四个模块分别回应四类具体痛点：教师–学生时序一致性用于稳定目标域预测来源，可靠性门控用于控制伪标签噪声与类别预算，双原型记忆用于显式塑造类条件结构，课程化优化与置信保护型选择策略用于稳定训练过程与 checkpoint 选择。
4. 本文的创新更适合被理解为面向工业多类别时序迁移任务的机制性集成创新，而不是单一理论模块的基础性突破。其强项在于问题分解清晰、模块衔接明确、实现与 benchmark 协议一致、后续结果回填路径清楚。

## 8.3 当前不足

尽管本文已经在方法设计和实验组织上形成了较完整的链路，但仍存在若干需要继续完善的地方。

1. 当前正文的正式主实验是 88-run fixed-fold benchmark，模块级严格消融尚未完成，因此各子模块的独立增益仍需在后续专门配置上进一步验证。
2. 当前结论更多是基于方法设计逻辑和 benchmark 结构得出的阶段性认识，最终定量结论仍然需要以正式运行结果、统计汇总和代表性图件为支撑。
3. 目前的 RCTA 更偏向离线无监督领域自适应设置，对于开放集故障、在线工况漂移、测试时自适应和轻量部署等更复杂问题尚未展开。
4. 现有方法虽然已经引入类条件结构与训练节奏控制，但仍主要依赖数据驱动特征学习，对流程工业中的控制回路、变量关联和故障传播机理等先验知识利用仍较有限。

## 8.4 面向更强创新性的升级方向

如果后续希望在“写得更扎实”之外进一步提升项目本身的创新强度，本文认为至少有以下四条值得优先推进的升级路线。

1. **面向多源场景的源域关系建模。**当前 benchmark 已经包含 3 个多源到单目标场景，但现有方法仍主要把多个源域视为可直接合并的数据池。后续可以进一步设计“源域可靠性加权”或“源域原型关系建模”机制，使模型在多源场景下根据源域与目标域的接近程度动态分配迁移权重。这一方向与当前 benchmark 直接衔接，工程实现路径清晰，是最容易扩展为更强创新点的路线之一。
2. **引入流程先验的结构化迁移。**当前 RCTA 的原型结构仍然完全建立在特征空间几何上。若进一步结合过程变量之间的物理耦合、控制回路或故障传播路径，构建变量图或分组结构约束，则可以把“纯数据驱动的类条件结构”升级为“数据驱动 + 工业先验”的混合方法，这会显著增强论文的行业针对性。
3. **从离线 UDA 扩展到在线或测试时自适应。**真正的工业部署往往面临持续漂移，而不是一次性的固定迁移。若在当前可靠性门控框架上进一步加入漂移检测、在线原型更新或测试时熵最小化机制，则能够把项目升级到更贴近工程应用的新问题设置。
4. **扩展到未知故障与拒识场景。**当前任务默认源域与目标域共享相同标签空间，但实际工业现场可能出现训练集中未出现的新型异常。若能在可靠性门控和原型结构基

础上进一步引入未知类检测或拒识机制，则会形成比标准 closed-set UDA 更强、更现实的研究问题。

从可操作性看，第一条和第二条最适合作为当前项目的近期升级方向：前者与现有 benchmark 直接匹配，后者则最能增强“工业过程领域特色”，二者都有望把现有 RCTA 从“机制组合改进”推进到“更有辨识度的任务特化创新”。

## 8.5 后续工作安排

围绕上述不足与升级方向，后续工作可以分为三个层次推进。

1. **近期任务：**优先完成 `benchmark_88_2clusters_11scenes_8methods_fixed fold.yaml` 对应的正式运行，回填第七章和附录中的主结果表、热力图、混淆矩阵和 t-SNE 图件，形成可提交版本的实验闭环。
2. **中期任务：**基于现有 RCTA 代码补充专门的模块消融配置，完成 A、A+B、A+B+C、A+B+C+D 形式的递进验证，并从 gate 接纳比例、可靠性得分分布、原型激活类别数等角度增强过程分析。
3. **长期任务：**从多源关系建模、流程先验结构化、在线适应和未知故障拒识等方向中选择一条主线，把项目升级为更具辨识度和后续延展性的研究主题。

## 8.6 本章小结

总体来看，本文已经围绕 TEP 跨工况故障诊断任务形成了一条较为清晰的论文主线：绪论中交代研究现状与挑战，基准章节统一实验前提，方法章节按创新点逐一展开，实验章节围绕当前实际需要执行的 88-run benchmark 组织，最后在本章总结阶段性成果并提出更强创新性的升级方向。当前版本的重点不是制造“结果已定”的假象，而是把论文骨架、方法边界和实验接口全部搭稳，从而为后续结果回填与项目升级创造条件。

# 参考文献

[1] QIN S J. Survey on data-driven industrial process monitoring and diagnosis[J/OL]. Annual Reviews in Control, 2012, 36(2): 220-234. DOI: 10.1016/j.arcontrol.2012.09.004.

[2] GE Z. Review on data-driven modeling and monitoring for plant-wide industrial processes[J/OL]. Chemometrics and Intelligent Laboratory Systems, 2017, 171: 16-25. DOI: 10.1016/j.chemolab.2017.09.021.

[3] TAQVI S A A, ZABIRI H, TUFA L D, et al. A review on data-driven learning approaches for fault detection and diagnosis in chemical processes[J/OL]. ChemBioEng Reviews, 2021, 8(3): 239-259. DOI: 10.1002/cben.202000027.

[4] YU J, ZHANG Y. Challenges and opportunities of deep learning-based process fault detection and diagnosis: A review[J/OL]. Neural Computing and Applications, 2023, 35(1): 211-252. DOI: 10.1007/s00521-022-08017-3.

[5] WU H, ZHAO J. Deep convolutional neural network model based chemical process fault diagnosis[J/OL]. Computers & Chemical Engineering, 2018, 115: 185-197. DOI: 10.1016/j.compchemeng.2018.04.009.

[6] PAN S J, YANG Q. A survey on transfer learning[J/OL]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359. DOI: 10.1109/TKDE.2009.191.

[7] WU H, ZHAO J. Fault detection and diagnosis based on transfer learning for multimode chemical processes [J/OL]. Computers & Chemical Engineering, 2020, 135: 106731. DOI: 10.1016/j.compchemeng.2020.106731.

[8] WANG Y, WU D, YUAN X. LDA-based deep transfer learning for fault diagnosis in industrial chemical processes[J/OL]. Computers & Chemical Engineering, 2020, 140: 106964. DOI: 10.1016/j.compchemeng.2020.106964.

[9] QIN R, ZHAO J. Cross-domain fault diagnosis for chemical processes through dynamic adversarial adaptation network[C/OL]//Computer Aided Chemical Engineering: volume 52 33rd European Symposium on Computer Aided Process Engineering (ESCAPE 33). Elsevier, 2023: 867-873. DOI: 10.1016/B978-0-443-15274-0.50139-6.

[10] DOWNS J J, VOGEL E F. A plant-wide industrial process control problem[J/OL]. Computers & Chemical Engineering, 1993, 17(3): 245-255. DOI: 10.1016/0098-1354(93)80018-I.

[11] MONTESUMA E F, MULAS M, MBOULA F N, et al. Benchmarking domain adaptation for chemical

processes on the Tennessee Eastman Process[A/OL]. 2023. arXiv: 2308.11247. https://arxiv.org/abs/2308.11247.

[12] SUN B, SAENKO K. Deep CORAL: Correlation alignment for deep domain adaptation[C/OL]//Lecture Notes in Computer Science: volume 9915 Computer Vision – ECCV 2016 Workshops. Cham: Springer International Publishing, 2016: 443-450. DOI: 10.1007/978-3-319-49409-8_35.

[13] LONG M, CAO Y, WANG J, et al. Learning transferable features with deep adaptation networks[C/OL]// Proceedings of Machine Learning Research: volume 37 Proceedings of the 32nd International Conference on Machine Learning. Lille, France: PMLR, 2015: 97-105. https://proceedings.mlr.press/v37/long15.html.

[14] GANIN Y, USTINOVA E, AJAKAN H, et al. Domain-adversarial training of neural networks[J/OL]. Journal of Machine Learning Research, 2016, 17(59): 1-35. https://jmlr.org/papers/v17/15-239.html.

[15] LONG M, CAO Z, WANG J, et al. Conditional adversarial domain adaptation[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 31. Curran Associates, Inc., 2018: 1647-1657. https://proceedings.neurips.cc/paper/2018/hash/ab88b15733f543179858600245108dd8-Abstract.html.

[16] DAMODARAN B B, KELLENBERGER B, FLAMARY R, et al. DeepJDOT: Deep joint distribution optimal transport for unsupervised domain adaptation[C/OL]//Lecture Notes in Computer Science: volume 11208 Computer Vision – ECCV 2018. Cham: Springer International Publishing, 2018: 467-483. https://openaccess.thecvf.com/content_ECCV_2018/html/Bharath_Bhushan_Damodaran_DeepJDOT_Deep_Joint_ECCV_2018_paper.html. DOI: 10.1007/978-3-030-01225-0_28.

[17] LEE D H. Pseudo-Label: The simple and efficient semi-supervised learning method for deep neural networks[C/OL]//ICML 2013 Workshop: Challenges in Representation Learning (WREPL). Atlanta, Georgia, USA, 2013. https://storage.googleapis.com/kaggle-forum-message-attachments/8924/pseudo_label_final.pdf.

[18] TARVAINEN A, VALPOLA H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 30. Curran Associates, Inc., 2017: 1195-1204. https://proceedings.neurips.cc/paper/2017/hash/68053af2923e00204c3ca7c6a3150cf7-Abstract.html.

[19] TANWISUTH K, FAN X, ZHENG H, et al. A prototype-oriented framework for unsupervised domain adaptation[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 34. Curran

Associates, Inc., 2021: 17194-17208. https://proceedings.neurips.cc/paper/2021/hash/8edd72158ccd2a879f79cb2538568fdc-Abstract.html.

[20] XIE Q, DAI Z, HOVY E, et al. Unsupervised data augmentation for consistency training[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 33. Curran Associates, Inc., 2020: 6256-6268. https://proceedings.neurips.cc/paper_files/paper/2020/file/44feb0096faa8326192570788b38c1d1-Paper.pdf.

# 附录 A 实验补充材料

## A.1 附录说明

本附录给出正文之外的补充材料，包括当前 88-run fixed-fold benchmark 的关键超参数、RCTA 配置摘要、复现实验命令以及完整结果表占位。所有内容均服务于本文正文聚焦的 benchmark 主实验与后续结果回填工作。

## A.2 基线与参考方法关键超参数

表 1.1 汇总了当前 fixed-fold benchmark 中 7 种基线/参考方法采用的关键超参数。这些配置由 `configs/method/*.yaml` 与 `configs/experiment/benchmark_88_2clusters_11scenes_8methods_fixedfold.yaml` 共同决定。

表 1.1 fixed-fold benchmark 中基线与参考方法关键超参数

| 方法 | epochs | batch size | 学习率 | 关键配置 |
|---|---|---|---|---|
| Source Only | 84 | 32 | $1 \times 10^{-4}$ | 无显式对齐项，作为无自适应对照组 |
| Target Only | 112 | 32 | $1 \times 10^{-4}$ | 使用目标域标签监督训练，仅作为参考上界 |
| CORAL | 96 | 32 | $1 \times 10^{-4}$ | $\lambda_{coral} = 0.55$，协方差均值对齐，warm-start 调度 |
| DAN | 84 | 32 | $1 \times 10^{-4}$ | $\lambda_{mmd} = 0.08$，5 组核尺度，constant 调度 |
| DANN | 84 | 32 | $1 \times 10^{-4}$ | $\lambda_{adv} = 0.40$，GRL warm-start，判别器隐层 256×2 |
| CDAN | 96 | 32 | $1 \times 10^{-4}$ | $\lambda_{cadv} = 0.35$，randomized dim=512，熵条件化，MCC=0.03 |
| DeepJDOT | 120 | 64 | $1 \times 10^{-4}$ | OT 权重 0.55，reg_dist=0.08，reg_cl=1.00，source-aware 选择指标 |

## A.3 RCTA fixed-fold 配置摘要

表 1.2 汇总了当前 benchmark 中 RCTA 采用的关键配置。该配置以 DANN 为基础对齐分支，同时融合 MCC 正则、可靠性门控、双原型记忆、一致性学习和课程化优化。

表 1.2 RCTA fixed-fold 配置摘要

| 模块 | 配置 |
|---|---|
| 训练轮数 | 112 |
| 基础对齐分支 | DANN |
| MCC 正则 | $\lambda_{mcc} = 0.04$，temperature=2.0 |
| 教师网络 | EMA decay=0.992，teacher temperature=1.3 |
| 可靠性权重 | cal_conf=1.1，inv_entropy=1.0，consistency=1.1，proto_sim=1.2 |
| 门控分数课程 | $0.34 \rightarrow 0.56$，持续 2200 steps |
| 按类接纳比例课程 | $0.22 \rightarrow 0.72$，持续 2200 steps |
| 可靠性分层 | reliable floor=0.66，semi-reliable floor=0.44 |
| 伪标签损失 | 最大权重 0.22，warmup 900 steps，可靠性加权，power=1.4 |
| 原型损失 | 最大权重 0.07，start step=800，warmup 1200 steps，separation weight=0.08 |
| 一致性损失 | 最大权重 0.06，start step=700，warmup 1200 steps，gate-only=true，power=1.4 |
| 辅助正则 | semi-reliable consistency=0.04，unreliable entropy=0.01 |
| 原型记忆 | momentum=0.95，separation margin=0.20 |
| 数据增强 | 弱增强：轻微抖动/缩放；强增强：更强抖动、缩放、时间屏蔽、通道 dropout |
| 模型选择 | hybrid_source_eval_confidence_guard，带 overconfidence 和 domain gap 惩罚 |

## A.4 benchmark 复现实验命令

当前论文正文对应的主实验可直接通过如下命令运行：

```
scripts/run_small_scale_round.sh \
--experiment-config \
configs/experiment/\
benchmark_88_2clusters_11scenes_8methods_fixedfold.yaml
```

运行结束后，结果会在 `runs/` 下自动生成，并进一步汇总到 `comparison_summary` 目录。推荐在结果回填时优先使用该汇总目录中的 JSON/Markdown 对照表和自动导出的图件，避免人工抄录时引入误差。

## A.5 完整结果表占位

为了方便后续直接回填，本附录预留了比正文更完整的结果表结构。正文主要保留概览性表格，本附录则适合记录每个场景上的多指标结果。

### A.5.1 单源场景完整结果

表 1.3 8 个单源场景的完整结果（占位）

| 方法 | 场景 | 源域评估准确率 | 目标域准确率 | 目标域平衡准确率 | 选择 epoch | 备注 |
|---|---|---|---|---|---|---|
| 完整实验结果占位，待正式 benchmark 跑完后统一补充。 | | | | | | |

### A.5.2 多源场景完整结果

表 1.4 3 个多源场景的完整结果（占位）

| 方法 | 场景 | 各源域评估准确率 | 目标域准确率 | 目标域平衡准确率 | 选择 epoch | 备注 |
|---|---|---|---|---|---|---|
| 完整实验结果占位，待正式 benchmark 跑完后统一补充。 | | | | | | |

## A.6 补充说明

由于当前版本的重点是将论文结构与 benchmark 配置完全对齐，因此正文中的汇总图与代表性定性图均保留为占位实现。待正式结果产生后，可优先回填正文第七章中的总表与代表性图件，再将更细粒度指标补入本附录，从而形成“正文概览 + 附录明细”的完整呈现方式。

# 致　　谢

值此本科毕业论文完成之际，谨向在大学期间关心、指导和帮助过我的老师、学长、同学及家人致以诚挚的感谢。

首先，衷心感谢指导教师王永健教授，在毕业设计选题、研究思路梳理、实验推进和论文撰写过程中给予了我耐心细致的指导与帮助，使我得以顺利完成本论文的研究工作；同时，在个人发展与后续规划等方面给予我的支持与鼓励，也使我深受感激；严谨认真的治学态度和认真负责的工作作风，使我受益匪浅。

其次，感谢蒋徐颢、蔡闻骁、邹滨阳等学长和同学榜样在学习与成长过程中给予我的帮助与示范。他们在专业学习、科研视野和个人规划方面的经验分享，对我产生了积极而深远的影响。

感谢严震霆、周志铭、曲振宁等同学和朋友在本科阶段给予我的陪伴、支持与鼓励。在课题讨论、日常学习和生活交流中，他们给予了我许多真诚的帮助，使我能够更加从容地面对学习和毕业设计过程中的困难与挑战。

最后，衷心感谢我的父母和家人。感谢他们一直以来给予我的理解、包容和支持，使我能够安心完成本科阶段的学习任务与毕业论文工作。