本科毕业设计（论文）报告

题 目：基于领域自适应的工业过程故障诊断方法研究

学　　号：08022311

姓　　名：陈鲲龙

学　　院：自动化

专　　业：自动化

指导教师：王永健、童国道

起止日期：2026 年 3 月 ~2026 年 6 月

东南大学毕业（设计）论文独创性声明

本人声明所呈交的毕业（设计）论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签名：_____　　日期：__2026__年__6__月_____日

东南大学毕业（设计）论文使用授权声明

东南大学有权保留本人所送交毕业（设计）论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括刊登）论文的全部或部分内容。论文的公布（包括刊登）授权东南大学教务处办理。

论文作者签名：_____　　导师签名：_____

日期：__2026__年__6__月_____日　　日期：__2026__年__6__月_____日

摘　　要

工业过程故障诊断对于保障生产安全、降低非计划停机损失和提升过程运行可靠性具有重要意义。随着流程工业工况日益复杂，基于数据驱动的故障诊断方法得到了广泛应用。然而，在不同操作条件、不同负载水平或不同时间阶段下采集到的过程数据往往存在明显的分布偏移，导致仅依赖源域标注数据训练得到的模型在目标域上的诊断性能显著下降。围绕这一问题，本文以 Tennessee Eastman Process Domain Adaptation 数据集为研究对象，面向单源到单目标的无监督领域自适应故障诊断场景，构建了一个面向 benchmark 复现与方法比较的实验工作流。

本文结合当前项目实现，完成了数据勘察、基准元数据构建、训练评估、结果汇总与图表导出等基础模块，并在统一的一维卷积特征提取骨干网络下实现了 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 等代表性方法。针对流程工业时序信号的特点，本文对域内标准化、固定折划分、目标域无标签训练、目标域测试评估等关键环节进行了统一约定，同时设计了准确率、平衡准确率、混淆矩阵与特征可视化等评价方式，以支撑不同领域自适应方法迁移效果的系统分析。基于六组代表性单源场景以及部分多源场景的 benchmark 对比结果可以看到，相较于 Source Only，分布对齐和对抗式方法在目标域上普遍能够获得明显提升，其中 DAN 与 DANN 的平均表现较为突出，但不同场景间仍存在稳定性差异和类别混叠现象。

在上述 benchmark 分析基础上，本文进一步提出一种原型引导的类条件对齐改进思路，通过结合源域类别原型、高置信目标域伪标签与全局域对齐损失，在保持训练可行性的同时增强跨域同类聚合能力。尽管全量场景统计和改进方法实验结果仍有待进一步补充，本文已经完成了论文整体结构、实验基线与改进方法设计，并形成了一个较为规范、可复现、便于扩展的流程工业领域自适应故障诊断实验框架。

关键词：流程工业故障诊断，领域自适应，迁移学习，Tennessee Eastman Process，基准复现

ABSTRACT

Industrial fault diagnosis is essential for production safety, reduction of unplanned downtime, and reliable process operation. With increasingly complex operating conditions in process industries, data-driven diagnosis methods have become widely adopted. However, process data collected under different operating modes, load levels, or time periods usually exhibit evident distribution shifts, which makes a model trained only with labeled source-domain data generalize poorly to a target domain. To address this issue, this thesis focuses on the Tennessee Eastman Process Domain Adaptation dataset and builds a benchmark-oriented workflow for single-source to single-target unsupervised domain adaptation in industrial fault diagnosis.

Based on the current project implementation, the thesis organizes the full pipeline including data inspection, benchmark metadata construction, model training, evaluation, result aggregation, and figure export. Under a unified one-dimensional convolutional backbone, several representative methods have been implemented for comparison, including Source Only, CORAL, DAN, DANN, CDAN, and DeepJDOT. To make the benchmark comparable and reproducible, this work defines a consistent protocol covering domain-wise normalization, fixed fold splitting, unlabeled target-domain adaptation, and target-domain evaluation. It also prepares multiple analysis views such as accuracy, balanced accuracy, confusion matrices, and feature visualization.

Based on six representative single-source scenarios together with part of the multi-source settings, the benchmark results show that, compared with the Source Only baseline, distribution-alignment and adversarial methods generally provide clear gains on the target domain, while DAN and DANN demonstrate stronger average performance among the completed scenes. At the same time, the benchmark also reveals remaining issues such as scenario sensitivity, class confusion, and unstable conditional alignment.

Based on these observations, the thesis further formulates a prototype-guided class-conditional adaptation strategy, which combines source prototypes, high-confidence target pseudo labels, and global domain alignment to improve cross-domain intra-class compactness. Although the full-scenario statistics and final validation of the improved method still need to be supplemented, the current draft already establishes a complete manuscript structure, a reproducible benchmark baseline, and a concrete method design for subsequent implementation and evaluation.

KEY WORDS: Industrial Fault Diagnosis, Domain Adaptation, Transfer Learning, Tennessee Eastman Process, Benchmark Reproduction

目　　录

摘　　要 I
ABSTRACT II
目　　录 IV
第一章　绪论 1
1.1 研究背景与意义 1
1.2 研究问题与研究目标 1
1.3 研究内容与技术路线 2
1.3.1 研究内容 2
1.3.2 技术路线 2
1.4 论文结构安排 2
第二章　相关基础与文献综述 4
2.1 流程工业故障诊断方法概述 4
2.1.1 基于机理模型的方法 4
2.1.2 基于多元统计的方法 4
2.1.3 基于深度学习的方法 4
2.2 领域自适应理论基础 5
2.2.1 迁移学习与领域自适应定义 5
2.2.2 单源无监督领域自适应设定 5
2.2.3 全局对齐与类条件对齐 5
2.3 TEP 多工况故障诊断研究现状 6
2.3.1 TEP 过程与故障类别 6
2.3.2 多工况分布偏移特点 6
2.3.3 现有迁移诊断方法评述 6
2.4 本章小结 6
第三章　问题定义与 Benchmark 实验平台 7
3.1 任务定义与符号说明 7
3.1.1 输入输出定义 7

3.1.2 源域与目标域定义 7
3.1.3 优化目标 7
3.2 数据集与预处理流程 7
3.2.1 数据组织与工况划分 7
3.2.2 时序样本构造与标签设置 8
3.2.3 归一化与折划分策略 8
3.3 Benchmark 实验平台设计 8
3.3.1 统一训练流程 8
3.3.2 统一评估流程 8
3.3.3 结果管理与可视化模块 8
3.4 评价指标与对比设置 8
3.5 本章小结 9
第四章 基线方法复现与 Benchmark 结果分析 10
4.1 实验目的与设置 10
4.2 FCN 骨干网络与 Source Only 基线 10
4.3 基线方法复现说明 10
4.3.1 分布对齐基线 10
4.3.2 对抗式基线 11
4.3.3 最优传输基线 11
4.4 Benchmark 结果 11
4.4.1 代表性单源场景的平均结果 11
4.4.2 分场景观察 11
4.5 结果分析与改进动机 12
4.5.1 当前 benchmark 揭示的主要问题 12
4.5.2 对创新方法设计的启示 12
4.6 本章小结 13
第五章 原型引导的类条件对齐方法设计 14
5.1 方法设计动机 14
5.2 改进方法总体框架 14

5.3 源域类别原型构建 15
5.4 目标域高置信伪标签筛选 15
5.5 原型引导的类条件约束 16
5.5.1 原型一致性损失 16
5.5.2 类中心对齐损失 16
5.5.3 目标域伪标签监督项 16
5.6 整体优化目标与训练流程 16
5.7 实验验证方案 17
5.7.1 与基线方法的总体比较 17
5.7.2 消融实验设计 17
5.7.3 重点分析指标 17
5.8 本章小结 18
第六章 总结与展望 19
6.1 全文工作总结 19
6.2 主要结论 19
6.3 不足与未来展望 19
参考文献 20
附录 A 实验配置与补充材料 21
A.1 附录说明 21
A.2 附录扩展说明 21
致 谢 22

第一章 绪论

1.1 研究背景与意义

流程工业广泛存在于化工、能源、冶金、制药等关键行业，其生产过程通常具有连续运行、耦合强、非线性明显和安全要求高等特点。一旦关键设备或工艺环节发生异常，不仅会造成产品质量下降，还可能引发连锁波动甚至安全事故。因此，如何及时、准确地发现并识别工业过程中的故障，一直是过程监测与控制领域的重要研究方向。随着传感器和控制系统的普及，工业现场可以持续采集大量过程变量，这为基于数据驱动的故障诊断方法提供了良好的应用基础[1]。

传统的数据驱动故障诊断方法通常默认训练数据与测试数据满足相同分布，但这一假设在真实工业场景中往往难以成立。设备老化、原料波动、控制策略变化以及操作负载切换等因素，都会导致不同时间或不同工况下采集到的数据分布发生偏移。当模型仅利用某一工况下的标注数据进行训练时，其在新工况或新域上的诊断性能往往显著下降。对于流程工业而言，重新采集并标注大量目标域故障样本通常成本高昂，甚至在某些工况下几乎不可行。因此，研究能够利用源域知识提升目标域诊断性能的迁移学习与领域自适应方法，具有明确的工程价值和现实意义[2]。

Tennessee Eastman Process（TEP）是过程系统工程领域广泛采用的工业过程仿真基准，由 Downs 和 Vogel 提出[3]。围绕该过程构造的领域自适应数据集能够较好地模拟不同操作模式下的分布差异，为验证故障诊断模型的跨域泛化能力提供了统一平台。基于 TEP 数据集构建规范的 benchmark，系统比较不同领域自适应方法在流程工业故障诊断中的适用性，不仅有助于梳理现有方法的优缺点，也能为后续方法改进和工程部署提供实验基础。

1.2 研究问题与研究目标

本文关注的核心问题是：在目标域缺少故障标签的条件下，如何利用源域标注样本和目标域无标注样本，构建能够适应工况变化的故障诊断模型。围绕这一问题，本文将研究场景限定为单源域到单目标域的无监督领域自适应诊断任务。源域与目标域分别对应不同的 TEP 操作模式，模型输入为多变量过程时序片段，输出为对应的故障类别预测。

为使研究工作聚焦且可复现，本文设置了以下几个具体目标。首先，基于当前工作区中的数据处理与训练脚本，构建一套清晰、统一的 benchmark 复现实验流程，使数据读取、归一化、折划分、训练、评估和可视化等环节具有稳定接口。其次，在统一骨干网络与尽

量一致的训练协议下，实现并比较多种代表性领域自适应方法，包括分布对齐类、对抗式方法和最优传输类方法，从而为分析不同方法在流程工业场景中的行为差异提供基础。最后，通过准确率、平衡准确率、混淆矩阵和特征可视化等多维指标，对模型的源域拟合能力、目标域迁移能力和类别混淆现象进行系统分析。

考虑到迁移场景数量较多，本文在统一实验协议的前提下，优先完成 benchmark 平台搭建、基线方法复现与代表性场景分析，并在此基础上凝练改进方法设计。这样的组织方式既有利于保证正文结构与当前代码实现保持一致，也便于在既有框架上继续补充更完整的实验结果与误差分析。

1.3 研究内容与技术路线

1.3.1 研究内容

结合当前工作区中的实现基础，本文的研究内容主要包括两个方面。其一，围绕 TEP 多工况单源到单目标无监督领域自适应任务，统一数据接口、训练协议、结果汇总与可视化流程，并在相同 backbone 下复现 Source Only、CORAL、DAN、DANN、CDAN 和 DeepJDOT 等典型方法。其二，在 benchmark 分析基础上，围绕类条件对齐、原型分类器和置信度感知训练策略设计具有针对性的改进方法，并给出相应的验证思路。

1.3.2 技术路线

本文的总体技术路线可以概括为：首先，构建面向 TEP 多工况迁移场景的 benchmark 实验平台；其次，以一维全卷积网络作为统一时序特征提取 backbone，完成各类典型领域自适应基线的复现与对比；再次，结合 benchmark 分析中暴露出的类别混淆、跨域同类未充分对齐等问题，设计类条件或 prototype-aware 的改进策略；最后，通过总体指标、分场景结果、消融实验和可视化分析，系统评估改进方法在目标域上的诊断性能与稳定性。

1.4 论文结构安排

全文共分为六章，各章内容安排如下。

第一章为绪论，主要介绍研究背景、研究问题、研究目标以及本文的技术路线。第二章为相关基础与文献综述，围绕流程工业故障诊断、领域自适应理论以及 TEP 多工况诊断研究现状展开梳理。第三章为问题定义与 Benchmark 实验平台，介绍任务设定、数据处理流程、统一训练评估协议与评价指标。第四章为基线方法复现与 Benchmark 结果分析，重点组织 FCN backbone 下各类典型领域自适应方法的统一比较。第五章为改进方法设计与

实验验证，用于给出本文的改进方法框架、损失设计与验证方案。第六章为总结与展望，对全文工作进行归纳，并讨论后续可继续深入的研究方向。

第二章 相关基础与文献综述

2.1 流程工业故障诊断方法概述

2.1.1 基于机理模型的方法

早期工业过程故障诊断较多依赖过程机理模型、专家知识和人工规则。这类方法在对象机理清晰、工况变化范围有限的场景下具有较好的可解释性，但对于大型耦合流程、复杂控制回路和频繁变化的工业现场而言，往往面临建模困难、维护成本高和泛化能力有限等问题。

2.1.2 基于多元统计的方法

工业过程故障诊断研究经历了从机理模型方法到数据驱动方法不断发展的过程。早期方法较多依赖精确的过程机理建模、专家经验或人工设计特征，这类方法在机理明确、工况单一的场景下具有较好的可解释性，但面对大型复杂工业过程时，往往存在建模困难、推广性有限和维护成本较高等问题。随着工业信息化水平提高，基于历史运行数据进行状态监测与故障识别逐渐成为主流思路[1]。

主成分分析、偏最小二乘及其动态扩展形式长期是流程工业监测中的重要工具。这类方法能够从高度相关的工业变量中提取潜变量，兼顾降维、监测和一定程度的可解释性，因此在工业过程故障检测与诊断中始终具有重要参考价值。

2.1.3 基于深度学习的方法

数据驱动方法通常通过统计建模、机器学习或深度学习技术，从大量过程变量中自动提取与故障相关的表征。典型方法包括主成分分析、偏最小二乘、支持向量机以及近年来广泛应用的卷积神经网络和循环神经网络等。相比传统方法，深度模型能够直接从原始或弱处理后的多变量时序信号中学习高层特征，在复杂模式识别任务中展现出更强的拟合能力。然而，深度模型往往需要较多标注数据，并且对训练集与测试集分布一致性的依赖更强。当工况发生变化时，模型容易出现性能衰减，这使得跨域泛化成为工业故障诊断研究中的关键问题。

对于流程工业场景，仅依赖单一工况下采集到的故障样本训练模型，难以覆盖真实生产中可能出现的工况变化。与通用视觉任务不同，工业过程数据具有时序性、强相关性和工况依赖性，诊断模型不仅需要识别类别间差异，还要对不同域之间的统计偏移保持鲁棒。因此，将迁移学习与领域自适应思想引入工业过程故障诊断，已经成为近年来值得关注的

发展方向。

2.2 领域自适应理论基础

2.2.1 迁移学习与领域自适应定义

迁移学习旨在利用已有任务或已有域中的知识，提升目标任务或目标域上的学习效果。Pan 和 Yang 将迁移学习系统地定义为在源域和目标域分布或任务不同的情况下，通过知识迁移改善目标任务学习性能的过程[2]。其中，领域自适应是迁移学习的重要分支，主要研究源域和目标域任务相同但数据分布不同的情形。按照目标域是否具有标签，领域自适应可分为监督式、半监督式和无监督式等多种设置，本文重点关注目标域无标签的无监督领域自适应。

2.2.2 单源无监督领域自适应设定

本文采用的任务设定属于单源域到单目标域的无监督领域自适应。源域具有类别标签，目标域在训练阶段不使用标签，二者共享相同的故障类别集合，但数据分布并不一致。对于 TEP 多工况场景而言，不同 mode 可以自然视作不同 domain，因此该设定能够较好贴合跨工况迁移诊断问题。

2.2.3 全局对齐与类条件对齐

现有无监督领域自适应方法大体可以分为三类。第一类是分布对齐方法，其核心思想是在保持源域分类能力的同时，缩小源域与目标域特征分布之间的差异。例如，CORAL 通过对齐特征协方差矩阵减小二阶统计量差异[4]；DAN 则利用多核最大均值差异在再生核希尔伯特空间中约束源域与目标域特征分布接近[5]。这类方法结构相对清晰，训练较为稳定，适合作为流程工业场景中的基础对比方案。

第二类是对抗式领域自适应方法。DANN 在特征提取网络后引入域判别器，并利用梯度反转层实现特征学习与域判别之间的对抗博弈，从而促使提取到的特征具有域不变性[6]。CDAN 在此基础上进一步利用分类预测结果对特征进行条件化，使域判别过程能够感知类别结构信息，从而缓解简单对抗对齐可能造成的类别混叠问题[7]。对抗式方法通常具有较强的表示学习能力，但训练稳定性和超参数敏感性也更值得关注。

第三类是基于最优传输的领域自适应方法。相关方法通过构造源域和目标域样本之间的运输代价，直接在概率分布层面寻找匹配关系。DeepJDOT 将特征空间距离与类别预测差异结合起来，在深度特征学习过程中联合优化跨域样本匹配与分类目标[8]。这类方法能

够在全局层面描述跨域样本关系，但通常对批大小、代价构造和计算效率较为敏感。

总体来看，不同领域自适应方法在假设前提、优化目标与训练稳定性方面各有特点。将这些方法置于统一的流程工业故障诊断 benchmark 中进行比较，有助于观察它们在工业时序数据上的适用范围与局限性。

2.3 TEP 多工况故障诊断研究现状

2.3.1 TEP 过程与故障类别

Tennessee Eastman Process 是经典的化工过程仿真平台，包含多个相互耦合的单元操作和控制回路，能够模拟多种正常工况与故障情形[3]。由于该过程结构较为完整、变量丰富且具有较强代表性，TEP 长期被用于过程监测、故障检测和故障诊断算法的评估。与一般静态分类数据集相比，TEP 数据具有明显的动态特性和工业背景，更能体现方法在复杂过程系统中的实际适应能力。

2.3.2 多工况分布偏移特点

在本文对应的数据集设置中，不同操作模式可被视为不同领域，同一故障类别在不同模式下的统计分布存在偏移，这为构造领域自适应诊断任务提供了天然条件。结合当前工作区中的数据接口和实验配置，本文主要关注单源域到单目标域的迁移情形，并以固定折划分、统一归一化方式和共享骨干网络实现跨方法对比。这样的设计有助于减少与任务无关的干扰因素，把分析重点放在不同适配机制本身。

2.3.3 现有迁移诊断方法评述

从已有 TEP 迁移诊断研究可以看出，统一数据划分、预处理方式与 backbone 结构，对于公平比较不同领域自适应方法至关重要。TEP 基准不仅能够用于验证模型在跨工况诊断中的迁移能力，也能够为误差分析、可视化解释与方法改进提供一致的实验基础。

2.4 本章小结

本章从工业过程故障诊断、迁移学习与领域自适应方法以及 TEP 基准三个方面梳理了与本文课题密切相关的研究背景。可以看到，工业过程中的域偏移问题使得传统仅依赖同分布假设的诊断模型面临明显挑战，而分布对齐、对抗学习和最优传输等方法为跨域故障诊断提供了可行思路。基于此，下一章将结合当前项目实现，对本文采用的任务定义、模型结构与具体方法进行说明。

第三章 问题定义与 Benchmark 实验平台

3.1 任务定义与符号说明

3.1.1 输入输出定义

本文研究的任务为单源域到单目标域的无监督领域自适应故障诊断。设源域为 $\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$，其中 x_i^s 表示源域样本，y_i^s 表示其故障类别标签；目标域为 $\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}$，目标域训练阶段不使用标签。本文的目标是在利用源域有标签样本和目标域无标签样本的条件下，训练一个能够在目标域测试集上保持较好诊断性能的分类模型。

结合当前代码实现，输入样本采用多变量过程时序片段表示，按照 channels-first 的方式组织为 (N, C, T) 形状，其中 $C = 34$ 表示过程变量通道数，T 表示时间长度，输出为 29 类故障类别的分类结果。源域与目标域分别对应不同操作模式下采集的数据，本文通过统一配置文件指定源域、目标域、折划分和归一化策略，从而保证不同实验设置之间具有一致的数据处理方式。

3.1.2 源域与目标域定义

在本文的实验设定中，不同 TEP 操作模式被视为不同 domain。源域提供有标签样本，目标域仅在测试阶段使用标签进行评估。这样的设定能够将多工况故障诊断问题转化为标准的无监督领域自适应问题，便于与已有文献进行对比。

3.1.3 优化目标

从模型结构上看，本文采用编码器 ϕ 从输入时序样本中提取特征表示，再由分类器 h 输出故障类别预测，即 $\hat{y} = h(\phi(x))$。训练目标包括源域分类损失，以及根据不同领域自适应方法引入的分布对齐损失、对抗损失或最优传输损失。

3.2 数据集与预处理流程

3.2.1 数据组织与工况划分

为了实现多方法的统一比较，本文构建了面向 benchmark 的实验流程。整体流程包括原始数据勘察、元数据构建、训练集与测试集划分、归一化处理、模型训练、结果汇总以及图表导出等模块。当前工作区中已实现相应脚本和配置接口，能够根据实验配置自动完成场景组织与结果保存。

3.2.2 时序样本构造与标签设置

原始数据经过统一读取后，被组织为可直接供 PyTorch 数据集调用的多变量时序样本。每个样本对应一个故障类别标签，类别总数为 29。这样的输入组织形式能够兼容当前 benchmark 主线中的 FCN backbone，并为方法扩展提供统一接口。

3.2.3 归一化与折划分策略

在数据处理阶段，本文采用固定折划分来区分训练样本与评估样本，并在域内执行标准化处理，以减小量纲差异对模型训练的影响。在实验管理阶段，各方法共用统一的运行目录结构与 JSON 结果摘要，便于对目标域准确率、源域训练表现以及可视化结果进行集中整理。这种先规范流程、再开展方法比较的思路，有助于提升实验复现性和结果可比性。

3.3 Benchmark 实验平台设计

3.3.1 统一训练流程

本文采用配置文件驱动的训练方式，统一管理数据配置、方法配置和实验配置。训练脚本能够根据配置自动完成数据加载、模型构建、损失计算、结果保存与评审摘要导出，从而保证不同方法之间的训练协议尽量一致。

3.3.2 统一评估流程

评估阶段围绕源域训练表现、源域评估表现和目标域测试表现展开，并统一导出准确率、平衡准确率、混淆矩阵等指标。对于领域自适应任务而言，目标域测试结果是判断方法有效性的核心依据，而源域表现则能够帮助分析过拟合和迁移失效等问题。

3.3.3 结果管理与可视化模块

当前工作区支持自动生成结果 JSON、review 摘要和多种图表产物，包括混淆矩阵、域融合 t-SNE 和类别分布 t-SNE 等。这些模块不仅服务于实验对比，也可直接作为论文图表和误差分析的基础材料。

3.4 评价指标与对比设置

本文的 benchmark 对比以统一 backbone、统一数据划分和统一训练协议为前提，重点比较 Source Only、CORAL、DAN、DANN、CDAN 和 DeepJDOT 等代表性方法的目标域诊断性能。评价指标主要包括目标域准确率、平衡准确率、混淆矩阵，以及反映域对齐程度和类别聚合情况的可视化结果。

3.5 本章小结

本章围绕问题定义、数据处理流程、benchmark 平台和评价指标，对本文实验工作的统一设定进行了说明。基于这一平台，下一章将对各类基线方法的复现与 benchmark 结果组织方式进行介绍。

第四章 基线方法复现与 Benchmark 结果分析

4.1 实验目的与设置

本章的目标是基于统一的 FCN backbone 和统一训练协议，对当前已经实现的典型领域自适应方法进行 benchmark 对比，明确不同方法在 TEP 多工况迁移场景中的表现差异，并为改进方法设计提供问题依据。考虑到全量 72 组迁移场景的实验量较大，正文先选取六组代表性单源到单目标场景进行集中展示，并结合已完成的部分多源场景做补充讨论。六组代表性单源场景分别为：mode1→mode4、mode4→mode1、mode2→mode5、mode5→mode2、mode3→mode6 和 mode6→mode3。

在实验协议上，各方法均采用相同的一维 FCN 特征提取网络、相同的数据划分方式与相同的训练轮数设置。目标域训练阶段不使用真实标签，仅在测试阶段统计目标域准确率与平衡准确率。与此同时，实验流程还会记录源域训练准确率、源域评估准确率以及结果汇总文件，用于分析方法是否存在“源域性能下降但目标域收益有限”的对齐失衡现象。

4.2 FCN 骨干网络与 Source Only 基线

本文采用一维全卷积网络作为统一特征提取 backbone。该网络由三层一维卷积、归一化和非线性映射构成，并通过时间维平均池化得到紧凑特征表示。相比直接引入复杂时序结构，FCN 在当前 TEP benchmark 中具有实现简单、训练稳定和便于跨方法公平比较等优点，因此被用作本研究的统一主干网络。

Source Only 方法仅依赖源域监督分类损失进行训练，不显式处理源域与目标域之间的分布偏移，因此可视为所有领域自适应方法的基础对照组。若某一领域自适应方法在目标域上不能显著优于 Source Only，则说明其对齐策略尚未真正缓解跨工况迁移带来的分布差异问题。

4.3 基线方法复现说明

4.3.1 分布对齐基线

CORAL 通过约束源域与目标域特征协方差矩阵的一致性来减小二阶统计差异[4]；DAN 则使用多核最大均值差异来约束特征分布，在核空间中实现更细致的边缘分布对齐[5]。这两类方法的共同特点是训练目标较为直接，通常能在不引入额外判别器的情况下稳定收敛，因此适合作为 benchmark 中的基础分布对齐参照。

4.3.2 对抗式基线

DANN 在共享特征提取网络之后加入域判别器，并利用梯度反转层实现特征表示与域分类之间的对抗学习，从而逼近域不变特征[6]。CDAN 则进一步将类别预测结果纳入条件化对齐过程，使对抗过程能够感知类别结构信息，以缓解简单全局对齐造成的类别混叠问题[7]。在本工作中，两类方法均已基于当前 benchmark 主线完成统一实现与调度策略补充。

4.3.3 最优传输基线

DeepJDOT 通过联合建模特征空间距离与类别预测差异，构建源域和目标域样本之间的运输代价，在深度特征学习过程中同时优化分类与跨域匹配[8]。该方法能够提供样本级的跨域关系约束，但也更容易受到批大小、代价尺度和训练稳定性的影响。

4.4 Benchmark 结果

4.4.1 代表性单源场景的平均结果

在当前已完成的六组代表性单源场景上，表 4.1 给出了各方法的平均目标域准确率，以及相对于 Source Only 的平均提升。可以看到，所有领域自适应方法在平均意义上均优于 Source Only，其中 DAN 与 DANN 的平均表现最为突出。

表 4.1 六组代表性单源场景上的平均目标域准确率

方法	平均目标域准确率	相对 Source Only 平均提升
Source Only	0.5510	0.0000
CORAL	0.6956	0.1446
DAN	0.7688	0.2177
DANN	0.7533	0.2023
CDAN	0.6824	0.1314
DeepJDOT	0.6196	0.0685

进一步比较每个具体场景中的相对变化可以发现，CORAL、DAN、DANN 和 DeepJDOT 在已完成的六组代表性单源场景中均优于 Source Only，说明引入域对齐机制对于 TEP 跨工况故障诊断是必要且有效的。CDAN 在四组场景中优于 Source Only，但在 `mode4→mode1` 和 `mode6→mode3` 两组场景中的优势并不稳定，表明条件对齐策略在当前实现下仍对场景分布和训练配置较为敏感。

4.4.2 分场景观察

从已完成场景的最好结果来看，`mode3→mode6`、`mode2→mode5` 与 `mode5→mode2` 三组场景中，DAN 与 DANN 表现相对更强，目标域准确率已达到约 0.80 以上；在 `mode1→mode4`

这一较难场景中，CDAN 的目标域准确率达到了 0.8126，显著高于 Source Only 的 0.3608，体现出条件化对齐在复杂类别结构迁移中仍具有潜力。另一方面，DeepJDOT 的平均收益相对有限，说明最优传输类方法在当前时序故障诊断任务上还需要进一步优化代价构造与训练稳定性。

已完成的多源到单目标场景结果也反映出一个重要现象：当源域信息更加充分时，Source Only 本身已经能够达到较高的目标域准确率，例如当前已完成的 `mode2-mode3-mode4-mode` 场景中，Source Only 已达到 0.7586，而 CORAL 进一步提升到了 0.8241。这说明多源信息融合本身是一个值得继续深入的方向，但同时也提示单纯依靠更多源域数据并不能完全替代更细粒度的类条件对齐机制。

4.5 结果分析与改进动机

4.5.1 当前 benchmark 揭示的主要问题

结合已完成实验结果，可以总结出当前 benchmark 暴露出的三个主要问题。第一，Source Only 在源域上通常能够获得较高准确率，但在目标域上的性能明显下降，说明跨工况分布偏移对故障诊断模型的影响依然显著。第二，分布对齐方法虽能整体提升目标域性能，但不同方法在不同场景上的稳定性存在明显差异。例如 CDAN 在部分场景中表现突出，但并非在所有场景中都优于 DAN 或 DANN。第三，部分方法在目标域上取得收益的同时，会出现源域分类能力下降或训练过程更敏感的情况，这说明“全局域对齐”与“类别判别能力”之间仍存在权衡。

4.5.2 对创新方法设计的启示

上述现象表明，当前问题的关键并不只是“是否进行对齐”，而是“如何在保持类别判别能力的前提下进行更稳定的对齐”。现有全局边缘分布对齐方法能够减小整体域差异，但无法显式保证跨域同类样本靠近、异类样本保持分离；而条件对齐方法虽然引入了类别信息，却仍容易受到伪标签噪声和训练不稳定性的影响。因此，改进方法需要同时兼顾以下三点：其一，保留当前 benchmark 中已经验证有效的全局域对齐机制；其二，引入更直接的类别结构约束以减少跨域类别混叠；其三，通过置信度筛选和渐进式权重调度控制目标域伪标签噪声对训练的负面影响。

4.6 本章小结

本章在统一 FCN backbone 和统一实验协议下，对 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 等基线方法进行了 benchmark 比较。已完成的六组代表性单源场景结果表明，领域自适应方法整体上显著优于 Source Only，其中 DAN 与 DANN 的平均目标域表现较强，而 CDAN 在个别困难场景中展现出更高上限但稳定性仍需提升。基于这些结果，本文把创新重点进一步收敛到“如何利用类别结构信息提升跨域同类聚合能力”这一问题上，下一章将据此给出一种更具体的原型引导类条件对齐方案。

第五章 原型引导的类条件对齐方法设计

5.1 方法设计动机

第四章的 benchmark 结果表明，现有领域自适应基线虽然已经能够在目标域上取得明显收益，但仍存在三个尚未解决的问题。首先，单纯的全局分布对齐难以显式保证跨域同类样本聚合、异类样本分离，因此当不同故障类别在目标域中边界接近时，模型仍可能出现较严重的类别混叠。其次，条件对齐方法虽然能够利用类别预测信息，但目标域伪标签本身存在噪声，若直接以其驱动对齐，容易把错误类别关系进一步强化。最后，从当前结果看，不同方法在场景之间的波动仍然较大，这意味着改进方法除了追求更高上限，还需要兼顾训练稳定性和实现可行性。

基于上述问题，本文在当前已实现的 FCN+CDAN/DANN benchmark 主线上，提出一种原型引导的类条件对齐方法。该方法的核心思想是：利用源域有标签样本构建稳定的类别原型，以高置信目标域伪标签为桥梁，把全局域对齐与类别级特征聚合结合起来，从而在不明显增加工程复杂度的前提下提高跨工况故障诊断中的类条件迁移能力。

5.2 改进方法总体框架

本文提出的改进方法记为原型引导的类条件对齐方法（Prototype-Guided Conditional Alignment, PGCA）。整体框架仍由特征提取器、分类器和域对齐模块三部分组成，其中 FCN 作为共享时序特征提取 backbone，以保持与第四章 benchmark 基线的一致性。与现有基线相比，PGCA 的主要新增内容包括以下三项：

1. 源域类别原型构建模块：利用源域标签对每一类故障维护稳定的特征中心；
2. 目标域高置信伪标签筛选模块：只让可信度较高的目标域样本参与类条件对齐；
3. 原型引导的类条件约束：同时约束目标域样本靠近对应类别原型，并减小源域与目标域类中心之间的偏差。

在训练过程中，方法保留现有全局域对齐损失作为基础约束，例如 CDAN 的条件对抗损失或 DANN 的域对抗损失；与此同时，通过原型级和类别级约束进一步增强跨域同类聚合，从而缓解“全局对齐有效但类别边界不清晰”的问题。

5.3 源域类别原型构建

设特征提取器为 $\phi(\cdot)$，分类器为 $h(\cdot)$。对于一个源域小批量 $\mathcal{B}_s = \{(x_i^s, y_i^s)\}_{i=1}^{m_s}$，记其特征表示为

$$f_i^s = \phi(x_i^s). \tag{5.1}$$

对于第 k 类故障，本文以该类别样本在特征空间中的均值作为小批量原型：

$$\tilde{c}_k = \frac{1}{|\mathcal{B}_s^k|} \sum_{i:y_i^s=k} f_i^s, \tag{5.2}$$

其中 $\mathcal{B}_s^k$ 表示当前批中属于第 k 类的样本集合。为了减小单个小批量波动对类别中心的影响，本文采用指数滑动平均方式更新全局原型：

$$c_k \leftarrow \mu c_k + (1-\mu)\tilde{c}_k, \tag{5.3}$$

其中 $\mu \in [0, 1)$ 为动量系数。这样得到的源域类别原型一方面能够反映各故障类别的稳定中心，另一方面又能随训练过程逐步更新，作为目标域特征对齐的参照。

5.4 目标域高置信伪标签筛选

对于目标域小批量 $\mathcal{B}_t = \{x_j^t\}_{j=1}^{m_t}$，记其预测概率为

$$p_j^t = \mathrm{softmax}(h(\phi(x_j^t))). \tag{5.4}$$

伪标签定义为最大概率对应的类别：

$$\hat{y}_j^t = \arg\max p_j^t. \tag{5.5}$$

同时记预测置信度为

$$q_j^t = \max p_j^t. \tag{5.6}$$

为了降低错误伪标签带来的负迁移风险，本文不直接让所有目标域样本参与类条件训练，而是通过置信度阈值 τ 选择高置信子集

$$\Omega_t = \{j \mid q_j^t > \tau\}. \tag{5.7}$$

随着训练进行，阈值和对应损失权重采用渐进式策略，使模型先依赖源域监督和全局对齐获得相对稳定的表示，再逐步利用目标域高置信样本开展更细粒度的类条件迁移。

5.5 原型引导的类条件约束

5.5.1 原型一致性损失

对于被选中的高置信目标域样本，本文希望其特征尽量接近对应类别的源域原型，因此定义原型一致性损失为

$$\mathcal{L}_{proto} = \frac{1}{|\Omega_t|} \sum_{j \in \Omega_t} \left\| \phi(x_j^t) - c_{\hat{y}_j^t} \right\|_2^2. \tag{5.8}$$

该项约束的作用是直接缩小目标域特征与源域同类中心的距离，从而增强跨域同类样本的聚合性。

5.5.2 类中心对齐损失

除了让单个目标域样本靠近源域原型，本文还进一步考虑类别整体统计的一致性。对于第 k 类，定义当前批次的源域类中心和目标域伪标签类中心分别为

$$\bar{f}_k^s = \frac{1}{|\mathcal{B}_s^k|} \sum_{i: y_i^s = k} f_i^s, \tag{5.9}$$

$$\bar{f}_k^t = \frac{1}{|\Omega_t^k|} \sum_{j \in \Omega_t, \hat{y}_j^t = k} \phi(x_j^t), \tag{5.10}$$

其中 Ω_t^k 表示被预测为第 k 类且满足置信度阈值的目标域样本集合。进一步定义类中心对齐损失为

$$\mathcal{L}_{cc} = \frac{1}{K} \sum_{k=1}^{K} \left\| \bar{f}_k^s - \bar{f}_k^t \right\|_2^2, \tag{5.11}$$

其中 K 为故障类别总数。与单纯的全局边缘分布对齐相比，该项约束更直接地刻画了“同类跨域应接近”的目标。

5.5.3 目标域伪标签监督项

在高置信样本基础上，本文进一步引入弱监督形式的目标域分类损失：

$$\mathcal{L}_{pl} = -\frac{1}{|\Omega_t|} \sum_{j \in \Omega_t} \log p(\hat{y}_j^t \mid x_j^t). \tag{5.12}$$

该项的作用是进一步巩固目标域中已经相对可靠的类别判别边界，但其权重需要在训练早期保持较小，避免伪标签噪声对模型造成过强扰动。

5.6 整体优化目标与训练流程

在保留现有全局域对齐损失 $\mathcal{L}_{global}$ 的基础上，PGCA 的总损失函数可写为

$$\mathcal{L} = \mathcal{L}_{cls}^s + \lambda_g \mathcal{L}_{global} + \lambda_p \mathcal{L}_{proto} + \lambda_c \mathcal{L}_{cc} + \lambda_t \mathcal{L}_{pl}, \tag{5.13}$$

其中 $\mathcal{L}_{cls}^{s}$ 表示源域监督分类损失，λ_g、λ_p、λ_c 和 λ_t 分别为各损失项的权重。训练流程上，本文按照以下策略组织训练：

1. 训练初期主要依赖源域分类损失和全局域对齐损失，先获得较稳定的跨域共享表示；
2. 当分类器输出逐步稳定后，开启高置信目标域样本筛选，并逐步增大 λ_p、λ_c 和 λ_t；
3. 在每轮迭代中更新源域类别原型，利用原型一致性和类中心对齐共同约束目标域表示；
4. 最终通过统一 benchmark 场景评估该方法相对基线的目标域性能收益与稳定性变化。

该设计与当前工作区已经实现的训练框架保持兼容，可优先在现有的 CDAN 或 DANN 实现上增加额外损失项完成原型验证。

5.7 实验验证方案

5.7.1 与基线方法的总体比较

实验验证首先在第四章已经完成的六组代表性单源场景上考察 PGCA 相对于 Source Only、DAN、DANN 和 CDAN 的增益情况；在此基础上，再扩展到 72 场景 benchmark 的全量对比中进行补充说明。

5.7.2 消融实验设计

为了明确各模块贡献，本文设计以下消融版本：

1. 仅保留全局域对齐损失的基线版本；
2. 全局域对齐 + 原型一致性损失；
3. 全局域对齐 + 类中心对齐损失；
4. 全局域对齐 + 原型一致性 + 类中心对齐；
5. 完整版本，即进一步加入高置信伪标签监督项。

通过上述逐步叠加方式，可以分析每个模块对目标域性能、训练稳定性和类别区分能力的具体影响。

5.7.3 重点分析指标

在验证过程中，除了目标域准确率和平衡准确率外，还将重点关注以下现象：其一，源域准确率是否因为额外对齐约束而出现明显下降；其二，混淆矩阵中易混类别是否得到改善；其三，t-SNE 可视化中跨域同类样本是否比现有基线更加聚合；其四，所提方法在不同迁移方向上的收益是否更加稳定。

5.8 本章小结

本章在第四章 benchmark 结果分析的基础上，进一步给出了一个更具体、可执行的创新方向，即原型引导的类条件对齐方法。该方法尝试把源域类别原型、高置信目标域伪标签和全局域对齐机制结合起来，以提升跨工况故障诊断中的类条件迁移能力。相较于停留在原则层面的改进设想，这一方案已经明确了核心模块、损失函数、训练流程与验证路径，也为后续实验补充提供了清晰主线。

第六章 总结与展望

6.1 全文工作总结

本文围绕流程工业场景下的领域自适应故障诊断问题，面向 Tennessee Eastman Process Domain Adaptation 数据集，完成了论文整体结构梳理、任务定义明确和 benchmark 实验平台搭建。通过统一数据接口、训练协议、结果汇总和图表导出流程，本文已经建立起一个可复现、可扩展的实验主线，并在统一 FCN backbone 下实现了 Source Only、CORAL、DAN、DANN、CDAN 与 DeepJDOT 等典型基线方法，为基线比较和改进方法设计提供了共同参照。

6.2 主要结论

本文的主要结论可概括为三个方面。其一，TEP 多工况故障诊断可以被清晰表述为单源域到单目标域的无监督领域自适应问题，并能够通过统一的 benchmark 协议开展系统比较。其二，在已完成的代表性单源场景上，相较于 Source Only，现有领域自适应方法整体能够获得明显的目标域性能提升，其中 DAN 与 DANN 的平均表现相对更优，说明域对齐机制在该任务中确有必要。其三，现有方法虽然能够提高目标域准确率，但仍存在场景敏感、类别混叠和训练稳定性不足等问题，因此有必要进一步引入原型引导的类条件对齐机制。

6.3 不足与未来展望

当前工作仍存在若干不足。首先，由于实验规模较大，全量 72 组场景 benchmark 尚未全部纳入正文统计，现有结论仍以代表性单源场景和部分多源场景为主。其次，虽然 benchmark 主线已经稳定，但第五章提出的改进方法仍需补充完整的实验结果、消融分析与参数敏感性讨论。最后，当前框架主要面向离线无监督领域自适应设置，对更复杂的多源迁移、在线诊断和工程部署问题尚未深入展开。

后续研究可以从以下几个方向继续展开。其一，完成 72 场景 benchmark 结果的整理与汇总，形成更完整的横向比较、误差分析与图表展示。其二，在现有 CDAN/DANN 主线基础上实现本文提出的原型引导类条件对齐方法，并优先在代表性场景上验证其有效性。其三，通过消融实验、参数敏感性分析和可视化分析，明确各个新增模块对跨域同类聚合和最终诊断性能的贡献。通过这些工作，可使本文从“完成 benchmark 搭建与方法复现”进一步推进到“形成具有明确创新点和实验支撑的流程工业领域自适应故障诊断研究结果”。

参考文献

[1] QIN S J. Survey on data-driven industrial process monitoring and diagnosis[J]. Annual Reviews in Control, 2012, 36(2): 220-234.

[2] PAN S J, YANG Q. A survey on transfer learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2009, 22(10): 1345-1359.

[3] DOWNS J J, VOGEL E F. A plant-wide industrial process control problem[J]. Computers & Chemical Engineering, 1993, 17(3): 245-255.

[4] SUN B, SAENKO K. Deep CORAL: Correlation alignment for deep domain adaptation[C]//Computer Vision – ECCV 2016 Workshops. 2016: 443-450.

[5] LONG M, CAO Y, WANG J, et al. Learning transferable features with deep adaptation networks[C]// Proceedings of the 32nd International Conference on Machine Learning. 2015: 97-105.

[6] GANIN Y, USTINOVA E, AJAKAN H, et al. Domain-adversarial training of neural networks[J]. Journal of Machine Learning Research, 2016, 17(59): 1-35.

[7] LONG M, CAO Z, WANG J, et al. Conditional adversarial domain adaptation[C]//Advances in Neural Information Processing Systems: volume 31. 2018.

[8] DAMODARAN B B, KELLENBERGER B, FLAMARY R, et al. Deepjdot: Deep joint distribution optimal transport for unsupervised domain adaptation[C]//Proceedings of the European Conference on Computer Vision. 2018: 447-463.

附录 A 实验配置与补充材料

A.1 附录说明

本附录用于放置不便完全写入正文、但对复现实验和理解实现细节仍有参考价值的补充材料，例如训练配置文件摘要、更多实验表格、运行目录结构说明、结果文件字段说明以及关键脚本入口说明等。

A.2 附录扩展说明

当前附录主要用于说明正文未完全展开但与实验复现相关的补充材料组织方式。随着实验结果持续整理，可进一步补充各方法关键超参数表、典型实验命令、结果 JSON 字段解释、图表导出脚本说明，以及正文未展开的补充可视化结果。若附录内容较多，也可继续扩展为多个附录文件。

致　　谢

值此本科毕业论文完成之际，谨向在大学期间关心、指导和帮助过我的老师、学长、同学及家人致以诚挚的感谢。

首先，衷心感谢指导教师王永健教授，在毕业设计选题、研究思路梳理、实验推进和论文撰写过程中给予了我耐心细致的指导与帮助，使我得以顺利完成本论文的研究工作；同时，在个人发展与后续规划等方面给予我的支持与鼓励，也使我深受感激；严谨认真的治学态度和认真负责的工作作风，使我受益匪浅。

其次，感谢蒋徐颢、蔡闻骁、邹滨阳等学长和同学榜样在学习与成长过程中给予我的帮助与示范。他们在专业学习、科研视野和个人规划方面的经验分享，对我产生了积极而深远的影响。

感谢严震霆、周志铭、曲振宁等同学和朋友在本科阶段给予我的陪伴、支持与鼓励。在课题讨论、日常学习和生活交流中，他们给予了我许多真诚的帮助，使我能够更加从容地面对学习和毕业设计过程中的困难与挑战。

最后，衷心感谢我的父母和家人。感谢他们一直以来给予我的理解、包容和支持，使我能够安心完成本科阶段的学习任务与毕业论文工作。