



東南大學

本科毕业设计（论文）报告

基于领域自适应的

工业过程故障诊断方法研究

学号:	08022311
姓名:	陈鲲龙
学院:	自动化
专业:	自动化
指导教师:	王永健、童国道
起止日期:	2026. 3. 11-2026. 6. 1

2026 年 6 月 1 日

东南大学毕业（设计）论文独创性声明

本人声明所呈交的毕业（设计）论文是我个人在导师指导下进行的研究工作及取得的科研成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得东南大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

论文作者签名：_____ 日期： 2026 年 6 月 ____ 日

东南大学毕业（设计）论文使用授权声明

东南大学有权保留本人所送交毕业（设计）论文的复印件和电子文档，可以采用影印、缩印或其他复制手段保存论文。本人电子文档的内容和纸质论文的内容相一致。除在保密期内的保密论文外，允许论文被查阅和借阅，可以公布（包括刊登）论文的全部或部分内容。论文的公布（包括刊登）授权东南大学教务处办理。

论文作者签名：_____ 导师签名：_____
日期： 2026 年 6 月 ____ 日 日期： 2026 年 6 月 ____ 日

摘 要

ABSTRACT

目 录

摘 要	I
ABSTRACT.....	II
目 录	III
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 工业过程故障诊断研究现状	2
1.2.2 迁移学习研究现状	3
1.2.3 领域自适应研究现状	3
1.3 国内外研究现状总结	5
1.4 核心挑战与创新点	5
1.5 研究技术路线	7
1.6 论文结构安排	8
第二章 跨工况领域自适应故障诊断基本方法	9
2.1 引言	9
2.2 基于联合分布最优传输的领域自适应方法	10
2.2.1 深度联合分布最优传输方法	10
2.2.2 多源加权联合分布最优传输方法	12
2.3 基于卷积式时间序列领域自适应的迁移诊断方法	13
2.3.1 卷积式时间序列特征提取方法	13
2.3.2 基于领域对抗学习的特征对齐方法	14
2.4 本章小结	15
第三章 基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法	17
3.1 引言	17
3.2 时序原型非平衡联合分布对齐基本原理	17
3.2.1 非平衡最优传输对齐原理	18
3.2.2 源域类别原型约束原理	18

3.2.3 时间序列统计代价构建原理	19
3.3 基于时序原型非平衡联合分布对齐的诊断模型构建	20
3.3.1 单源跨工况诊断问题建模	20
3.3.2 非平衡联合传输代价构建	20
3.3.3 源域原型与时序统计约束融合	21
3.3.4 源域监督对比特征学习	22
3.3.5 总体目标函数与算法流程	22
3.4 本章小结	23
第四章 基于多证据置信均衡伪标签的单源领域自适应故障诊断方法	24
4.1 引言	24
4.2 多证据置信均衡伪标签学习基本原理	24
4.2.1 目标域伪标签学习原理	24
4.2.2 教师模型一致性学习原理	25
4.2.3 类别均衡约束原理	25
4.3 基于多证据置信均衡伪标签的目标域样本利用策略	26
4.3.1 传输语义分布估计	26
4.3.2 教师预测语义分布估计	26
4.3.3 源域原型语义分布估计	26
4.3.4 多证据一致性筛选机制	27
4.3.5 动态置信阈值与类别均衡机制	27
4.3.6 强弱增强一致性约束	28
4.3.7 总体目标函数与算法流程	28
4.4 本章小结	29
第五章 基于类条件源域可靠性加权的多源领域自适应故障诊断方法	30
5.1 引言	30
5.2 类条件源域可靠性加权基本原理	30
5.2.1 多源迁移与负迁移问题	30
5.2.2 源域可靠性度量原理	31
5.2.3 类条件源域权重分配原理	31

5.3 基于类条件源域可靠性加权的多源对齐策略	32
5.3.1 多源跨工况诊断问题建模	32
5.3.2 逐源联合分布最优传输对齐	32
5.3.3 类条件源域可靠性矩阵构建	32
5.3.4 领域对抗特征约束与教师先验约束	34
5.3.5 教师先验保护的诊断结果融合	34
5.3.6 总体目标函数与算法流程	35
5.4 本章小结	36
第六章 实验设计与结果分析	37
6.1 引言	37
6.2 数据集与实验场景	37
6.3 实验结果	37
6.3.1 单源时序原型非平衡对齐实验结果	37
6.3.2 单源置信均衡伪标签实验结果	37
6.3.3 多源类条件源域可靠性实验结果	37
6.4 实验结果分析	37
6.4.1 诊断准确率对比分析	37
6.4.2 故障类别混淆矩阵分析	37
6.4.3 跨域特征分布可视化分析	37
6.4.4 综合诊断性能分析	37
6.5 本章小结	37
第七章 总结与展望	38
7.1 工作总结	38
7.1.1 本文主要研究内容	39
7.1.2 本文主要创新点	39
7.1.3 存在不足	40
7.2 未来展望	41
参考文献	44
致 谢	47

第一章 绪论

1.1 研究背景与意义

随着现代工业系统向大型化、连续化、自动化和智能化方向发展，工业过程的运行状态日益复杂，过程变量之间的耦合关系也更加紧密。石油化工、能源生产、流程制造等系统通常包含大量传感器、执行器和控制回路，一旦关键设备或生产环节发生异常，可能导致产品质量下降、设备损坏、生产停机，甚至引发安全事故。因此，及时、准确地识别工业过程故障类型，对保障生产安全、提高系统可靠性和降低维护成本具有重要意义。

工业过程故障诊断通常包括故障检测和故障识别两个环节。故障检测关注系统是否偏离正常运行状态，故障识别则进一步判断故障类型或故障来源。随着数据采集和工业物联网技术的发展，基于数据驱动的智能故障诊断方法逐渐成为研究热点。相比依赖精确机理模型的传统方法，数据驱动方法能够从历史运行数据中学习故障特征，适用于复杂非线性系统和高维多变量过程。近年来，深度学习方法凭借端到端特征提取能力，在旋转机械、化工过程、能源系统和智能制造等场景中取得了较好效果^[1,2]。

然而，工业故障诊断模型在实际部署中仍面临显著挑战。多数深度学习模型默认训练数据与测试数据服从相同分布，但工业过程往往存在工况变化、生产模式切换、环境扰动、传感器漂移和控制策略调整等因素，使得不同运行条件下的数据分布出现偏移。当模型仅在某一工况下训练，而被应用到另一工况时，诊断性能往往会明显下降。与此同时，真实工业系统中故障样本采集困难，目标工况下的标注数据更加稀缺。一方面，故障状态通常伴随安全风险和经济损失，无法大量重复采集；另一方面，故障标签需要依赖专家经验或维护记录，人工标注成本高且容易受到主观因素影响。因此，如何利用已有源工况的有标签数据，在目标工况缺少标签甚至完全无标签的条件下实现可靠诊断，是工业智能故障诊断中的关键问题。

领域自适应是迁移学习中的重要研究方向，旨在利用源域有标签数据和目标域无标签数据，通过缩小源域与目标域之间的分布差异，提高模型在目标域上的泛化能力^[2,3]。对于工业过程故障诊断而言，不同生产模式、不同负载或不同环境条件可以被视为不同领域，而故障类别空间通常保持一致。因此，无监督领域自适应为跨工况故障诊断提供了自然的问题建模方式。通过领域自适应，模型能够在不依赖目标域标签的情况下利用目标域数据分布信息，从而缓解工况变化带来的性能退化。

本文选取田纳西伊斯曼过程领域自适应数据集作为研究对象。田纳西伊斯曼过程是化工过程控制与故障诊断领域广泛使用的仿真基准，其不同生产模式对应不同的数据分布。相关基准研究表明，不同模式下变量相关结构和 Wasserstein 距离存在明显差异，特别是 mode 2 与其他模式差异较大，因此该数据集适合用于验证跨工况领域自适应故障诊断方法^[4]。本文围绕单源域到单目标域和多源域到单目标域两类场景，研究基于最优传输、时序原型、置信伪标签和类条件源域可靠性的领域自适应故障诊断方法，以期提高模型在目标工况下的诊断准确性和稳定性。

1.2 国内外研究现状

1.2.1 工业过程故障诊断研究现状

工业过程故障诊断方法大体可分为基于机理模型的方法、基于信号处理的方法和基于数据驱动的方法。基于机理模型的方法依赖系统数学模型或专家知识，通过残差分析、状态估计和控制理论判断系统是否异常。这类方法可解释性较强，但在复杂工业过程中，精确建立机理模型往往十分困难，尤其是当系统具有强非线性、多变量耦合和复杂控制结构时，模型构建与参数辨识成本较高。

基于信号处理的方法通常通过时域、频域或时频域分析提取故障特征，再结合分类器进行故障识别。该类方法在旋转机械和传感器信号分析中应用广泛，但其性能依赖人工特征设计，对不同设备和不同工况的适应能力有限。随着工业数据规模增大和计算能力提升，基于机器学习和深度学习的数据驱动方法逐渐成为故障诊断研究的主流方向。支持向量机、随机森林、人工神经网络、卷积神经网络和循环神经网络等方法能够从历史数据中学习故障模式，在多个工业场景中取得较好效果^[1]。

在工业过程故障诊断中，过程数据通常表现为多变量时间序列。不同变量之间存在复杂相关关系，同一故障在不同时间阶段可能呈现不同动态响应。因此，如何从多变量时序数据中提取稳定、可判别的故障特征，是智能诊断方法的关键。全卷积网络、长短期记忆网络、注意力机制和 Transformer 等结构已被用于时间序列故障诊断，以增强模型对局部趋势、长期依赖和变量间关系的建模能力。

尽管深度学习方法在工业故障诊断中取得了显著进展，但多数方法仍依赖训练集与测试集独立同分布的假设。在实际生产中，设备状态、生产负荷、环境条件和控制设定的变化会导致数据分布偏移，使得模型在新工况下性能下降。此外，故障样本稀缺、类别不均

衡和目标工况标注不足也限制了监督学习方法的应用。因此，如何在跨工况、少标签或无标签条件下提升诊断模型的泛化能力，成为当前工业过程故障诊断研究的重要方向。

1.2.2 迁移学习研究现状

迁移学习旨在利用已有任务或已有领域中的知识，提升目标任务或目标领域上的学习性能。当目标任务数据有限时，迁移学习能够缓解模型对大量标注数据的依赖。根据迁移对象不同，迁移学习可分为样本迁移、特征迁移、模型迁移和关系迁移等类型；根据源任务和目标任务是否一致，也可进一步区分为同构迁移、异构迁移、领域自适应和领域泛化等问题设置^[3,5]。

在故障诊断领域，迁移学习主要用于解决不同设备、不同负载、不同工况和不同数据采集条件之间的知识迁移问题。例如，在一个工况下采集的故障样本较为充分，而另一个工况下故障样本较少时，可以利用源工况模型或源工况特征辅助目标工况诊断。深度迁移学习进一步结合深度神经网络的表征学习能力和迁移学习的知识复用能力，使模型能够在跨工况诊断、跨设备诊断和小样本诊断中获得更强泛化性能^[5]。

迁移学习在工业故障诊断中的应用主要有两类思路。第一类是预训练与微调，即先利用源域有标签数据训练特征提取器，再使用少量目标域有标签样本进行微调。这类方法简单有效，但需要目标域标签，在目标域完全无标签的场景下难以使用。第二类是特征对齐，即通过统计距离、对抗学习或最优传输等方法缩小源域与目标域特征分布差异，使源域训练得到的分类器能够迁移到目标域。相比监督微调，特征对齐更适合目标域标签缺失的场景。

然而，迁移学习并不总是带来正向效果。当源域与目标域差异较大，或者源域知识与目标域任务不匹配时，迁移可能导致目标域性能下降，即负迁移问题。在工业过程故障诊断中，不同工况之间的故障动态响应可能存在差异，同一故障类别在不同生产模式下的特征中心和变量相关结构也可能发生变化。因此，迁移学习方法不仅需要利用源域知识，还需要判断哪些知识适合迁移、何时进行迁移以及如何避免不可靠源域或不可靠样本对目标域造成干扰。

1.2.3 领域自适应研究现状

领域自适应是迁移学习中研究较为充分的一类问题。其典型设定为：源域拥有有标签样本，目标域只有无标签样本或少量标签样本，二者类别空间相同但数据分布不同。根据目标域标签使用情况，可分为有监督领域自适应、半监督领域自适应和无监督领域自适应。

本文关注无监督领域自适应，即训练过程中不使用目标域标签，只利用源域标签和目标域无标签样本进行模型适配。

现有领域自适应方法可大致分为基于度量学习的方法、基于对抗学习的方法以及基于重构或生成的方法。基于度量学习的方法通过最小化源域与目标域之间的统计差异实现对齐，常用度量包括最大均值差异、相关对齐、条件分布差异和 Wasserstein 距离等。其中，最优传输方法能够在样本层面建立源域与目标域之间的匹配关系，并显式刻画从一个分布变换到另一个分布的最小代价，具有较强的几何解释性。DeepJDOT 将最优传输扩展到深度特征空间，通过联合考虑特征距离和标签预测代价，在对齐源目标分布的同时保留分类判别信息^[6]。

基于对抗学习的方法通常借助领域判别器，使特征提取器学习到难以区分源域和目标域的领域不变表示。领域对抗神经网络通过梯度反转层实现源目标特征混淆，条件对抗方法进一步将类别预测信息引入领域判别过程，以缓解纯边缘分布对齐可能造成的类别混淆。对于时间序列数据，CoDATS 提出卷积式时间序列领域自适应框架，利用时间序列卷积特征提取器和领域对抗学习实现跨域特征对齐，并支持多源数据利用^[7]。

在多源领域自适应场景中，模型可以利用多个源域的有标签数据适配同一个目标域。相比单源设置，多源数据提供了更丰富的运行模式和故障信息，但也带来了源域间分布差异和负迁移风险。若简单合并多个源域，模型可能忽略不同源域与目标域之间的差异，导致不可靠源域信息干扰目标域诊断。WJDOT 针对多源领域自适应问题，在最优传输框架下同时学习源目标分布对齐和源域权重，使模型能够利用源域多样性并降低不相关源域的影响^[8]。

针对田纳西伊斯曼过程领域自适应数据集的基准研究表明，不同生产模式会引起明显的分布偏移，且基于最优传输的方法在该基准上整体优于部分基于最大均值差异和 H-distance 的方法^[4]。该结论说明，最优传输方法适合刻画工业过程跨工况数据之间的几何分布差异。但与此同时，深度领域自适应方法可能因过度追求领域不变特征而削弱故障类别判别性，多源方法也可能因源域整体加权粒度过粗而难以处理类别级负迁移。因此，有必要在现有 DeepJDOT、WJDOT 和 CoDATS 等方法基础上，进一步引入故障时序结构、目标样本可靠性和类条件源域可靠性建模机制。

1.3 国内外研究现状总结

综合上述研究现状可以看出，工业过程故障诊断已从传统机理建模和人工特征设计逐渐发展到深度学习和领域自适应阶段。深度学习方法能够自动提取多变量时序特征，提升复杂工业过程中的故障识别能力；迁移学习和领域自适应方法则进一步缓解了不同工况之间的数据分布偏移问题，为目标工况标签缺失情况下的故障诊断提供了有效思路。

然而，现有方法在跨工况工业过程故障诊断中仍存在以下不足。第一，单源领域自适应方法通常关注源域与目标域的整体分布对齐，但对工业时间序列中的故障动态响应和类别结构利用不足。在最优传输框架中，若小批量样本内类别组成不匹配，平衡传输约束可能迫使目标样本与不可靠源样本进行匹配，从而造成错误对齐。第二，目标域无标签条件下，伪标签质量难以保证。若仅依据分类器置信度进行目标样本筛选，可能受到过置信错误预测和类别偏置影响，进而放大错误伪标签。第三，多源领域自适应中不同源域对目标域的贡献并不一致，同一源域对不同故障类别的可迁移性也可能不同。仅使用源域整体权重难以刻画源域与故障类别之间的细粒度可靠性关系。第四，工业故障诊断模型不仅需要追求目标域诊断性能，也需要具备一定可解释性，以便分析哪些源域、哪些故障类别以及哪些迁移机制对目标域诊断产生贡献。

基于以上问题，本文围绕田纳西伊斯曼过程跨工况故障诊断任务，构建单源和多源两条领域自适应研究路线。单源路线以 DeepJDOT 为基础，依次引入时序原型非平衡联合分布对齐和多证据置信均衡伪标签学习；多源路线结合 CoDATS 的时间序列表征能力、WJDOT 的逐源联合分布传输思想以及类条件源域可靠性加权机制，提升多源场景下的选择性迁移能力。

1.4 核心挑战与创新点

本文研究的核心任务是在目标工况缺少标签的条件下，利用源工况有标签数据和目标工况无标签数据，实现工业过程故障类型的准确识别。结合田纳西伊斯曼过程数据特点和现有领域自适应方法局限，本文面临的主要挑战包括以下三个方面。

第一，单源跨工况诊断中的类别结构保持问题。DeepJDOT 等联合分布最优传输方法能够在特征和标签预测联合空间中进行源目标对齐，但普通平衡传输可能在小批量训练中产生错误强制匹配，同时缺少对工业时序故障动态结构和类别原型的显式建模。为此，本文提出基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法。该方法在

DeepJDOT 基础上引入非平衡最优传输，降低不可靠样本被强制匹配的风险；同时构建源域类别原型和时间序列统计代价，并通过源域监督对比学习增强类内紧凑性和类间分离性，从而提高跨工况对齐过程中的故障类别结构保持能力。

第二，目标域无标签条件下的伪标签可靠性问题。在目标域标签不可用时，模型通常需要借助伪标签利用目标域样本，但伪标签可能受到错误传输、过置信预测和类别偏置影响。为此，本文提出基于多证据置信均衡伪标签的单源领域自适应故障诊断方法。该方法从传输计划、教师模型预测和源域原型距离三个角度估计目标样本的语义分布，仅当多类证据一致且置信度满足要求时，才将目标样本纳入伪标签学习。同时，本文引入动态置信阈值、类别均衡机制和强弱增强一致性约束，以降低错误伪标签传播和类别坍塌风险。

第三，多源跨工况诊断中的源域负迁移问题。多源场景下，源域数量增加虽然带来更多有标签样本，但不同源域与目标域之间存在差异，简单合并源域或使用全局源域权重可能无法有效判断某一源域对具体故障类别的可靠性。为此，本文提出基于类条件源域可靠性加权的多源领域自适应故障诊断方法。该方法结合 CoDATS 的卷积式时间序列表征能力、WJDOT 的逐源联合分布最优传输机制和类条件源域可靠性矩阵，进一步判断不同源域对不同故障类别的迁移贡献，并通过领域对抗特征约束与教师先验保护实现稳定的多源融合。

综上，本文的主要创新点如下：

（1）提出基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法。该方法通过非平衡最优传输缓解源目标样本错误强制匹配，通过源域类别原型和时间序列统计代价增强故障结构表达，并结合源域监督对比学习提高特征空间的类别可分性。

（2）提出基于多证据置信均衡伪标签的单源领域自适应故障诊断方法。该方法融合传输语义、教师预测语义和源域原型语义三类证据，对目标域样本进行一致性筛选，并结合动态置信阈值、类别均衡和强弱增强一致性约束，提高目标域无标签样本利用的可靠性。

（3）提出基于类条件源域可靠性加权的多源领域自适应故障诊断方法。该方法在多源场景下引入逐源联合分布最优传输和源域-故障类别可靠性矩阵，使模型能够根据不同源域对不同故障类别的贡献进行选择性的迁移，从而缓解多源负迁移并提升多源诊断结果的可解释性。

1.5 研究技术路线

本文研究技术路线围绕“数据预处理—基础模型构建—单源方法改良—多源方法改良—实验验证与分析”展开。

首先，对田纳西伊斯曼过程领域自适应数据集进行整理和预处理。该数据集包含多个生产模式，每个生产模式对应一个领域；每个样本为多变量时间序列，标签包括正常状态和多类故障状态。针对不同变量尺度差异较大的特点，本文对各生产模式下的连续变量进行标准化处理，并按照固定 fold 构造训练和测试场景。在实验设置上，目标域测试标签仅用于最终评价，不参与训练、调参或模型选择。

其次，构建跨工况领域自适应故障诊断的基础模型。对于单源域到单目标域场景，本文以 DeepJDOT 为基础，利用深度特征与标签预测的联合最优传输实现源目标对齐；对于多源域到单目标域场景，本文以 WJDOT 为基础，利用逐源最优传输和源域权重学习建模多源迁移关系。同时，考虑到工业过程数据为多变量时间序列，本文引入卷积式时间序列特征提取结构和领域对抗约束，为多源场景提供较强的时序表征能力。

再次，针对单源场景提出两级递进改良。第一阶段，针对 DeepJDOT 中平衡传输可能导致错误强制匹配以及故障类别结构保持不足的问题，提出时序原型非平衡联合分布对齐方法。第二阶段，针对目标域伪标签不可靠问题，提出多证据置信均衡伪标签学习方法，从传输计划、教师模型和原型距离三个方面筛选可信目标样本，并引入类别均衡和一致性约束进一步增强目标域学习稳定性。

然后，针对多源场景提出类条件源域可靠性加权方法。该方法首先利用卷积式时间序列表征和领域对抗学习获得具有迁移能力的特征空间，再对每个源域分别计算与目标域之间的联合分布最优传输代价，进而构建源域-故障类别可靠性矩阵。通过该矩阵，模型能够区分不同源域对不同故障类别的贡献，并结合教师先验保护机制完成多源诊断结果融合。

最后，通过单源和多源跨工况实验验证本文方法的有效性。单源实验主要比较源域直接迁移、典型领域自适应方法、DeepJDOT 及本文单源改良方法；多源实验主要比较源域直接迁移、CoDATS、WJDOT 及本文多源改良方法。评价指标包括诊断准确率、宏平均 F1 值、平衡准确率、混淆矩阵和跨域特征可视化结果。通过性能对比、消融实验和可解释性分析，验证本文方法在跨工况故障诊断中的有效性和适用性。

1.6 论文结构安排

本文共分为七章，各章内容安排如下。

第一章为绪论。首先介绍工业过程故障诊断的研究背景与意义，分析跨工况故障诊断中分布偏移、目标域标签不足和多源负迁移等问题；然后综述工业过程故障诊断、迁移学习和领域自适应的研究现状；最后给出本文面临的核心挑战、主要创新点、研究技术路线和论文整体结构。

第二章为跨工况领域自适应故障诊断基本方法。该章介绍本文后续方法所依赖的基础理论和基底模型，包括基于联合分布最优传输的领域自适应方法、深度联合分布最优传输方法、多源加权联合分布最优传输方法，以及基于卷积式时间序列领域自适应的迁移诊断方法，为后续章节的方法设计提供理论基础。

第三章为基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法。该章针对单源跨工况诊断中平衡最优传输可能导致错误匹配、故障类别结构表达不足等问题，提出结合非平衡最优传输、源域类别原型、时间序列统计代价和监督对比学习的单源领域自适应诊断模型。

第四章为基于多证据置信均衡伪标签的单源领域自适应故障诊断方法。该章在第三章方法基础上，进一步解决目标域伪标签不可靠问题。通过传输语义分布、教师预测语义分布和源域原型语义分布构造多证据伪标签，并结合动态置信阈值、类别均衡机制和强弱增强一致性约束，提高目标域样本利用的可靠性。

第五章为基于类条件源域可靠性加权的多源领域自适应故障诊断方法。该章面向多源跨工况诊断任务，提出结合卷积式时间序列表征、逐源联合分布最优传输和类条件源域可靠性矩阵的多源适配方法，以实现可靠源域和可靠故障类别的选择性迁移。

第六章为实验设计与结果分析。该章介绍田纳西伊斯曼过程领域自适应数据集、单源和多源实验场景、数据预处理方式、评价指标和对比方法，并通过准确率对比、混淆矩阵、特征可视化和消融实验分析本文方法的有效性。

第七章为总结与展望。该章总结全文主要研究内容和创新点，分析当前工作存在的不足，并对未来在弱监督目标域校准、在线测试时自适应、多源可解释迁移和工业现场轻量化部署等方向的研究进行展望。

第二章 跨工况领域自适应故障诊断基本方法

2.1 引言

工业过程故障诊断的核心目标是根据过程变量、控制变量和传感器信号判断系统当前是否发生故障，并进一步识别故障类别。在传统监督学习设置下，通常假设训练数据和测试数据服从相同或相近的概率分布。然而，在实际工业过程中，生产模式切换、负荷变化、控制策略调整和环境扰动等因素会导致数据分布发生偏移，使得在源工况下训练得到的诊断模型难以直接泛化到目标工况。对于田纳西伊斯曼过程这类多模式化工过程，不同生产模式对应不同数据分布，而目标模式下的故障标签往往难以大量获取。因此，跨工况故障诊断可自然建模为领域自适应问题。

无监督领域自适应的典型设置为：源域拥有有标签样本，目标域仅拥有无标签样本，源域与目标域共享相同的标签空间，但样本分布不同。设源域为

$$\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}, \quad (2.1)$$

目标域为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}, \quad (2.2)$$

其中 x_i^s 和 x_j^t 表示多变量时间序列样本， y_i^s 表示源域故障类别标签。领域自适应的目标是在不使用目标域标签的条件下，学习一个诊断函数 h ，使其在目标域样本上具有较高的分类准确率。由于源域和目标域之间存在分布差异，即

$$P_s(X) \neq P_t(X), \quad (2.3)$$

直接使用源域训练得到的模型往往会产生性能退化。

在现有领域自适应方法中，最优传输方法能够从分布几何角度度量源域和目标域之间的差异，并通过传输计划刻画样本之间的匹配关系^[9]。与仅对齐均值或核空间统计量的方法相比，最优传输能够保留样本级匹配信息，因此适合处理跨工况工业过程数据中的复杂分布偏移。另一方面，对于多变量时间序列故障诊断任务，卷积式时间序列特征提取方法能够从原始序列中自动提取局部动态模式和全局故障表征^[10,11]。基于领域对抗学习的特征对齐方法则通过领域判别器促使特征提取器学习源域和目标域难以区分的共享特征^[12]。

本章围绕本文后续方法所依赖的三类基础方法展开。首先介绍基于联合分布最优传输的领域自适应方法，包括适用于单源场景的深度联合分布最优传输方法和适用于多源场景

的多源加权联合分布最优传输方法；然后介绍基于卷积式时间序列领域自适应的迁移诊断方法，包括卷积式时间序列特征提取方法和基于领域对抗学习的特征对齐方法。通过本章介绍，为第三章、第四章和第五章的方法改良奠定基础。

2.2 基于联合分布最优传输的领域自适应方法

最优传输是一类用于度量两个概率分布之间差异的数学工具。其基本思想是：给定源分布和目标分布，寻找一个传输计划，使得将源分布中的质量搬运到目标分布所需的总代价最小。设源域样本集合为 $\{x_i^s\}_{i=1}^{n_s}$ ，目标域样本集合为 $\{x_j^t\}_{j=1}^{n_t}$ ，二者之间的代价矩阵为 $C \in \mathbb{R}^{n_s \times n_t}$ ，其中 C_{ij} 表示源样本 x_i^s 与目标样本 x_j^t 之间的匹配代价。最优传输问题可写为

$$\gamma^* = \arg \min_{\gamma \in \Pi(a,b)} \sum_{i=1}^{n_s} \sum_{j=1}^{n_t} \gamma_{ij} C_{ij}, \quad (2.4)$$

其中 γ 为传输计划， $\Pi(a,b)$ 表示满足源域边际分布 a 和目标域边际分布 b 的传输计划集合，即

$$\Pi(a,b) = \{\gamma \in \mathbb{R}_+^{n_s \times n_t} \mid \gamma \mathbf{1}_{n_t} = a, \gamma^T \mathbf{1}_{n_s} = b\}. \quad (2.5)$$

对于领域自适应任务而言，传输计划 γ 不仅反映样本之间的距离关系，也可用于描述源域样本如何与目标域样本建立对应关系。

在故障诊断场景中，仅对齐特征分布并不一定能够保证类别判别性。如果源域某一类故障样本与目标域另一类故障样本在特征空间中被错误匹配，模型可能获得领域不变但类别混淆的特征表示。为缓解该问题，联合分布最优传输方法同时考虑特征空间距离和标签预测代价，使传输计划不仅关注源域和目标域样本在特征空间中的接近程度，也关注源域标签与目标域预测结果之间的一致性^[13]。

2.2.1 深度联合分布最优传输方法

深度联合分布最优传输方法（Deep Joint Distribution Optimal Transport, DeepJDOT）是面向单源无监督领域自适应的一类深度最优传输方法^[6]。该方法将深度神经网络分为特征提取器和分类器两部分。设特征提取器为 $f_\theta(\cdot)$ ，分类器为 $g_\phi(\cdot)$ ，则输入样本 x 的深度特征表示为

$$z = f_\theta(x), \quad (2.6)$$

对应的类别预测概率为

$$\hat{y} = g_\phi(z). \quad (2.7)$$

DeepJDOT 的核心思想是在深度特征和标签预测的联合空间中构造最优传输代价。对于源域样本 (x_i^s, y_i^s) 和目标域样本 x_j^t ，其联合传输代价通常由两部分组成：

$$C_{ij} = \lambda_f d(f_\theta(x_i^s), f_\theta(x_j^t)) + \lambda_y \ell(y_i^s, g_\phi(f_\theta(x_j^t))), \quad (2.8)$$

其中 $d(\cdot, \cdot)$ 表示特征空间距离， $\ell(\cdot, \cdot)$ 表示标签预测损失， λ_f 和 λ_y 分别为特征代价和标签代价的权重。第一项用于缩小源域与目标域在深度表征空间中的距离，第二项用于约束目标域样本的预测结果与其匹配的源域标签保持一致。

基于上述代价矩阵，DeepJDOT 的领域自适应损失可表示为

$$\mathcal{L}_{OT} = \sum_{i=1}^{n_s} \sum_{j=1}^{n_t} \gamma_{ij} C_{ij}, \quad (2.9)$$

其中 γ_{ij} 表示源域样本 i 与目标域样本 j 之间的传输质量。模型训练时通常还需要保留源域监督分类损失：

$$\mathcal{L}_{src} = \frac{1}{n_s} \sum_{i=1}^{n_s} \ell(y_i^s, g_\phi(f_\theta(x_i^s))). \quad (2.10)$$

因此，DeepJDOT 的总体优化目标可写为

$$\min_{\theta, \phi} \mathcal{L}_{src} + \lambda_{OT} \mathcal{L}_{OT}, \quad (2.11)$$

其中 λ_{OT} 为最优传输对齐损失的权重。

DeepJDOT 的优势在于，它并非仅对齐源域和目标域的边缘特征分布，而是在特征和标签预测组成的联合空间中进行对齐。这样做能够在缩小领域差异的同时保留一定的类别判别信息，适合用于源域有标签、目标域无标签的跨工况故障诊断任务。然而，DeepJDOT 仍存在一些局限。首先，普通最优传输通常采用平衡边际约束，即要求源域和目标域样本质量均被完整匹配。在小批量训练中，若源域和目标域批次内类别组成不一致，可能导致目标样本被迫与不可靠的源样本匹配。其次，DeepJDOT 的传输代价主要由深度特征距离和标签预测损失构成，并未显式利用工业过程时间序列中的故障动态结构和类别原型信息。第三，在目标域预测尚不可靠的训练早期，标签预测代价可能受到错误预测影响，从而引入错误对齐。

因此，本文第三章在 DeepJDOT 的基础上进一步引入非平衡最优传输、源域类别原型、时间序列统计代价和源域监督对比学习，以增强单源跨工况故障诊断中的类别结构保持能力。

2.2.2 多源加权联合分布最优传输方法

在多源领域自适应场景中，模型可利用多个源域的有标签数据适配一个无标签目标域。设共有 K 个源域，第 k 个源域表示为

$$\mathcal{D}_{s_k} = \{(x_i^{s_k}, y_i^{s_k})\}_{i=1}^{n_k}, \quad k = 1, 2, \dots, K, \quad (2.12)$$

目标域为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}. \quad (2.13)$$

多源领域自适应不仅需要处理源域与目标域之间的分布偏移，还需要处理不同源域之间的分布差异，即

$$P_{s_k}(X) \neq P_t(X), \quad P_{s_k}(X) \neq P_{s_l}(X), \quad k \neq l. \quad (2.14)$$

一种简单策略是将所有源域样本合并为一个大源域，再执行单源领域自适应。然而，该策略容易忽略不同源域之间的差异。当某些源域与目标域差异较大时，这些源域中的信息可能对目标域诊断造成干扰，引发负迁移。多源加权联合分布最优传输方法（Weighted Joint Distribution Optimal Transport, WJDOT）通过为不同源域分配权重，在利用多源数据的同时降低不可靠源域的影响^[8]。

对于第 k 个源域，可构造其与目标域之间的联合传输代价：

$$C_{ij}^{(k)} = \lambda_f d(f_\theta(x_i^{s_k}), f_\theta(x_j^t)) + \lambda_y \ell(y_i^{s_k}, g_\phi(f_\theta(x_j^t))). \quad (2.15)$$

对应的最优传输损失为

$$\mathcal{L}_{\text{OT}}^{(k)} = \sum_{i=1}^{n_k} \sum_{j=1}^{n_t} \gamma_{ij}^{(k)} C_{ij}^{(k)}. \quad (2.16)$$

WJDOT 进一步引入源域权重 α_k ，使不同源域对最终目标函数的贡献不同：

$$\mathcal{L}_{\text{WJDOT}} = \sum_{k=1}^K \alpha_k \mathcal{L}_{\text{OT}}^{(k)}, \quad \sum_{k=1}^K \alpha_k = 1, \quad \alpha_k \geq 0. \quad (2.17)$$

其中， α_k 越大，表示第 k 个源域对目标域适配越重要； α_k 越小，表示该源域可能与目标域差异较大或对目标域贡献较弱。

WJDOT 的核心优势在于保留了多源域的差异性，并通过源域重加权机制利用有益源域、抑制不可靠源域。对于田纳西伊斯曼过程这类多生产模式数据，不同模式之间可能存在不同程度的相似性，部分源模式对某一目标模式具有较好迁移效果，而另一些源模式可能引入负迁移。因此，多源加权思想适合用于跨工况故障诊断。

然而，WJDOT 的源域权重通常是源域整体层面的权重，无法直接刻画“某个源域对

某个故障类别是否可靠”。在工业过程故障诊断中，一个源域整体上接近目标域，并不代表它对所有故障类别都具有同等可迁移性。例如，某一生产模式可能对正常类和部分故障类具有较好迁移能力，但对其他故障类存在明显偏移。因此，本文第五章将在 WJDOT 的基础上进一步引入类条件源域可靠性矩阵，将源域整体加权扩展为源域-故障类别级别的可靠性加权。

2.3 基于卷积式时间序列领域自适应的迁移诊断方法

工业过程数据通常表现为多变量时间序列。相比图像数据或普通表格数据，时间序列数据具有时间相关性、动态变化性和变量耦合性等特点。对于田纳西伊斯曼过程，每个样本由多个连续变量在一段时间内的采样值组成，不同故障会在时间维度上表现出不同动态响应模式。因此，在跨工况故障诊断中，特征提取器不仅需要提取每个变量的局部变化，还需要捕捉不同时间段和不同变量之间的综合故障信息。

CoDATS 是一种面向时间序列传感器数据的卷积式深度领域自适应方法，其核心思想是利用卷积式时间序列特征提取器学习可迁移表征，并结合领域对抗学习减小源域与目标域之间的特征分布差异^[7]。与直接使用通用图像领域自适应网络不同，CoDATS 面向时间序列数据设计特征提取结构，因此适合作为本文多源跨工况实验中的强基线和表征基础。

2.3.1 卷积式时间序列特征提取方法

卷积神经网络能够通过局部卷积核提取时间序列中的局部动态模式。在多变量时间序列故障诊断中，输入样本可表示为

$$x \in \mathbb{R}^{C \times T}, \quad (2.18)$$

其中 C 表示变量或通道数， T 表示时间步长度。对于田纳西伊斯曼过程数据， C 对应连续过程变量数量， T 对应一个样本窗口内的采样时间长度。

一维卷积层通过在时间维度上滑动卷积核提取局部时间特征。设第 l 层输入为 $H^{(l-1)}$ ，卷积核参数为 $W^{(l)}$ ，偏置为 $b^{(l)}$ ，则卷积输出可表示为

$$H^{(l)} = \sigma(W^{(l)} * H^{(l-1)} + b^{(l)}), \quad (2.19)$$

其中 $*$ 表示卷积运算， $\sigma(\cdot)$ 表示非线性激活函数。通过堆叠多层卷积网络，模型能够从短期局部波动逐渐学习到更高层次的故障模式。

在时间序列分类任务中，全卷积网络常由多个一维卷积块和全局平均池化层组成^[10,11]。卷积块用于提取局部动态特征，归一化层用于稳定训练过程，非线性激活函数用于增强模

型表达能力，全局平均池化层用于将时间维度特征压缩为固定长度向量。设最后一层卷积输出为 $H \in \mathbb{R}^{d \times T'}$ ，全局平均池化可表示为

$$z_r = \frac{1}{T'} \sum_{t=1}^{T'} H_{r,t}, \quad r = 1, 2, \dots, d, \quad (2.20)$$

其中 z 为最终时间序列特征表示。

卷积式时间序列特征提取方法具有以下优点。第一，卷积核能够捕捉故障发生后过程变量在局部时间范围内的变化趋势。第二，多层卷积结构能够逐步扩大感受野，从而学习较长时间范围内的动态响应。第三，全局平均池化能够减少模型参数数量，降低过拟合风险。第四，相比循环神经网络，卷积结构训练效率较高，适合大规模多变量时间序列实验。

在本文中，卷积式时间序列特征提取器不仅用于对比方法 CoDATS，也为第五章的多源改良方法提供基础表征。由于最优传输代价依赖样本在特征空间中的距离，特征提取器的质量会直接影响传输计划的可靠性。若特征表示无法区分故障类别，即使后续采用最优传输或源域加权机制，也难以获得理想适配效果。因此，利用卷积式时间序列网络构建稳定的故障表征，是多源跨工况故障诊断的重要基础。

2.3.2 基于领域对抗学习的特征对齐方法

领域对抗学习是一类典型的深度领域自适应方法。其基本思想是通过一个领域判别器判断特征来自源域还是目标域，同时训练特征提取器生成使领域判别器难以区分的特征表示。这样，特征提取器在保持源域分类能力的同时，能够学习源域和目标域共享的领域不变特征^[12]。

设特征提取器为 $F(\cdot)$ ，故障分类器为 $C(\cdot)$ ，领域判别器为 $D(\cdot)$ 。对于源域样本，分类器根据特征输出故障类别预测；对于源域和目标域样本，领域判别器输出其所属领域。源域分类损失为

$$\mathcal{L}_{\text{cls}} = -\frac{1}{n_s} \sum_{i=1}^{n_s} \sum_{c=1}^{N_c} \mathbb{I}(y_i^s = c) \log C_c(F(x_i^s)), \quad (2.21)$$

其中 N_c 为故障类别数， $C_c(\cdot)$ 表示分类器输出属于第 c 类的概率。

领域判别损失可表示为

$$\mathcal{L}_{\text{dom}} = -\frac{1}{n_s} \sum_{i=1}^{n_s} \log D(F(x_i^s)) - \frac{1}{n_t} \sum_{j=1}^{n_t} \log (1 - D(F(x_j^t))). \quad (2.22)$$

领域判别器希望最小化 $\mathcal{L}_{\text{dom}}$ ，从而正确区分源域和目标域；特征提取器则希望最大化该损

失，使源域和目标域特征变得难以区分。该对抗过程可写为

$$\min_{F,C} \max_D \mathcal{L}_{\text{cls}} - \lambda_d \mathcal{L}_{\text{dom}}, \quad (2.23)$$

其中 λ_d 为领域对抗损失权重。在实际实现中，通常使用梯度反转层将领域判别器的梯度反向传递给特征提取器，从而在一次反向传播中实现对抗优化。

CoDATS 将卷积式时间序列特征提取结构与领域对抗学习相结合，用于时间序列传感器数据的领域自适应。对于多源场景，CoDATS 可利用多个源域的有标签数据训练分类器，并通过领域对抗约束缩小源域和目标域之间的特征差异。其优势在于能够直接面向时间序列数据学习较强的深度表征，并通过对抗训练增强跨域泛化能力。

然而，基于领域对抗学习的方法也存在一定局限。首先，领域对抗学习主要强调源域和目标域整体特征分布难以区分，但并不必然保证同一故障类别在不同领域之间正确对齐。若过度追求领域不变性，可能削弱类别判别信息，导致故障类别边界模糊。其次，在多源场景中，不同源域对目标域的贡献并不一致，领域对抗学习若简单合并所有源域，可能难以区分有益源域和不可靠源域。再次，领域判别器提供的是整体领域混淆信号，缺少对具体源域、具体故障类别迁移贡献的解释。

因此，在本文第五章中，CoDATS 的卷积式时间序列表征和领域对抗约束将作为多源方法的重要基础，而 WJDOT 的逐源联合分布最优传输和类条件源域可靠性加权机制将用于进一步刻画源域与故障类别之间的细粒度迁移关系。通过结合卷积式时间序列表征、最优传输对齐和类条件源域可靠性建模，本文期望在多源跨工况故障诊断中同时兼顾表征能力、迁移性能和可解释性。

2.4 本章小结

本章介绍了本文研究所依赖的跨工况领域自适应故障诊断基本方法。首先，针对源域有标签、目标域无标签的跨工况诊断问题，介绍了基于联合分布最优传输的领域自适应思想。深度联合分布最优传输方法通过在深度特征和标签预测联合空间中构造最优传输代价，实现单源源域与目标域之间的对齐；多源加权联合分布最优传输方法进一步引入源域权重，使模型能够在多源场景下利用可靠源域并抑制不可靠源域。

其次，本章介绍了基于卷积式时间序列领域自适应的迁移诊断方法。卷积式时间序列特征提取方法能够从多变量过程数据中学习局部动态模式和全局故障表示；基于领域对抗学习的特征对齐方法通过领域判别器和特征提取器之间的对抗优化，促使模型学习源域和

目标域共享的领域不变特征。CoDATS 将时间序列卷积特征提取与领域对抗学习结合，适合处理多源时间序列传感器数据的跨域迁移诊断任务。

总体而言，DeepJDOT 为本文第三章和第四章的单源领域自适应方法提供联合分布最优传输基础，WJDOT 为本文第五章的多源加权迁移提供源域重加权基础，CoDATS 为多源跨工况故障诊断提供强时间序列表征和领域对抗对齐基础。然而，现有方法仍存在平衡传输可能错误匹配、故障类别结构建模不足、目标伪标签可靠性不足以及多源源域权重粒度较粗等问题。后续章节将在本章方法基础上，分别提出时序原型非平衡联合分布对齐方法、多证据置信均衡伪标签方法和类条件源域可靠性加权方法，以进一步提升跨工况工业过程故障诊断性能。

第三章 基于时序原型非平衡联合分布对齐的 单源领域自适应故障诊断方法

3.1 引言

第二章介绍了 DeepJDOT 的基本思想：在深度特征与标签预测的联合空间中构造最优传输代价，使源域有标签样本能够与目标域无标签样本建立样本级匹配关系。该思想继承了联合分布最优传输的类别保持优势^[6,13]，但在工业过程跨工况故障诊断中仍存在两个实际问题。

第一，田纳西伊斯曼过程样本为多变量时间序列，不同生产模式下同一故障类别的均值漂移、波动幅度和动态变化趋势可能同时发生改变。若仅使用深度特征距离和分类预测代价构造传输矩阵，模型容易忽略原始时序统计结构。第二，小批量训练时源域和目标域批次的类别组成并不总是匹配。普通平衡最优传输要求源域和目标域边际质量被完整匹配，当批次内某些类别缺失或目标样本暂时不可可靠匹配时，平衡约束可能迫使样本与错误类别发生传输，从而造成负对齐。

针对上述问题，本章提出基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法。该方法在 DeepJDOT 基础上进行三方面改进：一是引入非平衡小批量最优传输，使部分不可靠传输质量可以被削减；二是维护源域类别原型，并利用目标样本到源域类别原型的相对距离修正传输代价；三是从原始过程窗口中提取均值、标准差和一阶差分统计量，构造时间序列统计代价。与此同时，方法在训练前期使用源域监督对比学习增强特征空间的类内紧凑性和类间分离性。需要强调的是，本章方法训练过程中不使用目标域标签，目标域标签只在最终实验评价阶段使用。

3.2 时序原型非平衡联合分布对齐基本原理

设源域样本为 $\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$ ，目标域无标签样本为 $\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}$ 。其中， $x \in \mathbb{R}^{C \times T}$ 表示包含 C 个过程变量和 T 个时间步的多变量时间序列窗口， $y_i^s \in \{1, 2, \dots, N_c\}$ 为源域故障类别标签。模型由时间序列特征提取器 F_θ 和分类器 G_ϕ 组成：

$$z = F_\theta(x), \quad p = G_\phi(z). \quad (3.1)$$

其中 z 为深度特征表示， p 为类别预测概率。

本文采用的特征提取器为一维全卷积网络。其结构包括核大小为 9、5、3 的三层一维

卷积块，每个卷积块后接归一化和 ReLU 激活，最后在时间维度上进行全局平均池化，得到固定维度的样本表示。全卷积网络已被证明是时间序列分类中的强基线结构^[10,11]，适合在 TEP 多变量时间序列上提取局部动态响应和全局故障表征。

3.2.1 非平衡最优传输对齐原理

最优传输从分布几何角度度量两个经验分布之间的差异，是领域自适应中刻画源目标分布偏移的重要工具^[9,14]。给定源域小批量特征 $\{z_i^s\}_{i=1}^{m_s}$ 和目标域小批量特征 $\{z_j^t\}_{j=1}^{m_t}$ ，传统平衡最优传输要求传输计划 γ 同时满足固定源边际和目标边际：

$$\gamma \mathbf{1}_{m_t} = a, \quad \gamma^T \mathbf{1}_{m_s} = b. \quad (3.2)$$

在小批量领域自适应中，该约束可能过强。若当前小批量中源域某些类别样本过多，而目标域对应类别样本不足，平衡约束会要求所有源域质量被完整分配，进而可能产生错误匹配。

非平衡最优传输通过放松边际约束缓解该问题。受非平衡小批量最优传输领域自适应思想启发^[15]，本文在传输目标中加入边际偏离惩罚：

$$\mathcal{L}_{\text{UOT}} = \min_{\gamma \geq 0} \langle \gamma, C \rangle + \varepsilon \text{KL}(\gamma \| ab^T) + \tau_s \text{KL}(\gamma \mathbf{1}_{m_t} \| a) + \tau_t \text{KL}(\gamma^T \mathbf{1}_{m_s} \| b), \quad (3.3)$$

其中 C 为联合传输代价矩阵， ε 为熵正则系数， τ_s 和 τ_t 分别控制源边际与目标边际的放松程度。 τ_s 、 τ_t 越大，传输计划越接近平衡传输；二者较小时，部分不可靠质量可以被削减。代码实现中使用 POT 工具中的 `sinkhorn_unbalanced` 求解小批量传输计划，并记录总传输质量、行列边际偏差和传输熵等诊断量。

在本文方法中，非平衡传输并不改变无监督领域自适应的基本设定。目标域标签不参与传输计划求解，传输计划只由源域标签、源目标特征、目标预测分布、源域原型和时序统计代价共同决定。

3.2.2 源域类别原型约束原理

类别原型通过类内样本特征均值表示类别中心，是度量学习和小样本学习中的常用思想^[16]。在领域自适应中，原型结构也常用于缓解伪标签噪声和维护目标域语义结构^[17]。本文并不直接使用目标标签构造目标原型，而是在训练过程中维护源域类别原型，并利用源域类别结构约束目标样本的传输匹配。

设第 c 类源域原型为 μ_c 。对于一个源域小批量，先对源域特征进行归一化，再按源标

签求类均值：

$$\bar{\mu}_c = \frac{1}{|\mathcal{B}_s^c|} \sum_{i:y_i^s=c} \frac{z_i^s}{\|z_i^s\|_2}. \quad (3.4)$$

为降低小批量波动，本文采用指数滑动平均更新源域原型：

$$\mu_c \leftarrow \frac{\rho\mu_c + (1-\rho)\bar{\mu}_c}{\|\rho\mu_c + (1-\rho)\bar{\mu}_c\|_2}, \quad (3.5)$$

其中 ρ 为原型动量系数。若某一类别首次在小批量中出现，则直接用当前批次均值初始化该类别原型；若类别在当前批次中缺失，则保持其历史原型不变。

在构造传输代价时，本文不是简单地将目标样本到其匹配源类原型的距离作为绝对惩罚，而是使用相对原型代价。设目标样本 x_j^t 到第 c 类源域原型的距离为

$$d_{cj}^{\text{proto}} = \left\| \frac{z_j^t}{\|z_j^t\|_2} - \mu_c \right\|_2^2. \quad (3.6)$$

若源样本 x_i^s 属于类别 y_i^s ，则相对原型代价定义为

$$r_{ij}^{\text{proto}} = \text{clip} \left(\frac{d_{y_i^s j}^{\text{proto}} - \bar{d}_{-y_i^s, j}^{\text{proto}}}{\sigma_j^{\text{proto}} + \epsilon}, r_{\min}, r_{\max} \right), \quad (3.7)$$

其中 $\bar{d}_{-y_i^s, j}^{\text{proto}}$ 表示目标样本到其他有效源类原型距离的均值， σ_j^{proto} 表示有效类别原型距离的标准差。该设计关注“目标样本是否相对更接近当前源类原型”，从而比绝对距离更适合跨工况特征尺度变化场景。

3.2.3 时间序列统计代价构建原理

TEP 跨工况诊断数据具有明显的多变量时序特征。相关基准研究指出，不同生产模式之间存在显著分布差异，尤其是不同模式下变量相关结构和 Wasserstein 距离会发生变化^[4]。因此，本文在深度特征和标签预测代价之外，额外构造时间序列统计代价，用于补充原始过程窗口层面的动态信息。

需要说明的是，本文的时间序列统计代价是针对本地 TEP 代码实现设计的，不是直接复现某篇已有方法。其设计受到时间序列深度表征与全卷积分类结构的启发^[10,11]，但具体统计描述符和与非平衡联合传输的结合方式均由本文实现确定。

对于样本 $x \in \mathbb{R}^{C \times T}$ ，先沿时间维度计算每个变量的均值和标准差：

$$m(x) = \frac{1}{T} \sum_{t=1}^T x_{:,t}, \quad s(x) = \sqrt{\frac{1}{T} \sum_{t=1}^T (x_{:,t} - m(x))^2}. \quad (3.8)$$

同时计算一阶差分 $\Delta x_{:,t} = x_{:,t} - x_{:,t-1}$ 的均值和标准差：

$$m_{\Delta}(x) = \frac{1}{T-1} \sum_{t=2}^T \Delta x_{:,t}, \quad s_{\Delta}(x) = \sqrt{\frac{1}{T-1} \sum_{t=2}^T (\Delta x_{:,t} - m_{\Delta}(x))^2}. \quad (3.9)$$

然后将四类统计量拼接并归一化，得到时序描述符：

$$\psi(x) = \frac{[m(x), s(x), m_{\Delta}(x), s_{\Delta}(x)]}{\|[m(x), s(x), m_{\Delta}(x), s_{\Delta}(x)]\|_2 + \epsilon}. \quad (3.10)$$

源样本与目标样本之间的时序统计代价为

$$c_{ij}^{\text{temp}} = \frac{1}{d_{\psi}} \|\psi(x_i^s) - \psi(x_j^t)\|_2^2, \quad (3.11)$$

其中 d_{ψ} 为描述符维度。该代价能够在不引入目标标签的前提下，使传输计划同时参考故障窗口的水平、波动和变化趋势。

3.3 基于时序原型非平衡联合分布对齐的诊断模型构建

3.3.1 单源跨工况诊断问题建模

本章方法对应代码中的 TPU-DeepJDOT 方法。其输入为一个有标签源工况和一个无标签目标工况。训练时每一步从源域采样小批量 $\mathcal{B}_s$ ，从目标域采样小批量 $\mathcal{B}_t$ 。源域小批量用于计算监督分类损失和更新源域类别原型，目标域小批量只以无标签形式参与特征对齐。

源域监督分类损失定义为

$$\mathcal{L}_{\text{src}} = -\frac{1}{|\mathcal{B}_s|} \sum_{(x_i^s, y_i^s) \in \mathcal{B}_s} \log p_{\theta}(y_i^s | x_i^s). \quad (3.12)$$

其中 $p_{\theta}(\cdot|x)$ 为分类器输出的 softmax 概率。该损失保证模型首先在源工况上具备故障类别识别能力。

在训练日程上，本文设置源域预热阶段和对齐阶段。预热阶段主要优化源域分类损失和监督对比损失，使特征空间形成较稳定的类别结构；随后逐步打开最优传输对齐项、原型代价项和时间序列统计代价项，避免训练初期目标预测不稳定时过早施加强对齐约束。

3.3.2 非平衡联合传输代价构建

对于源样本 x_i^s 和目标样本 x_j^t ，本章方法构造由深度特征代价、标签预测代价、原型相对代价和时序统计代价组成的联合代价：

$$C_{ij} = \lambda_f c_{ij}^f + \lambda_y c_{ij}^y + \lambda_p(t) r_{ij}^{\text{proto}} + \lambda_{\tau}(t) c_{ij}^{\text{temp}}. \quad (3.13)$$

其中，深度特征代价为

$$c_{ij}^f = \frac{1}{d_z} \|z_i^s - z_j^t\|_2^2, \quad (3.14)$$

d_z 为特征维度。标签预测代价使用源域真实标签与目标域预测概率之间的交叉熵：

$$c_{ij}^y = -\log p_\theta(y_i^s | x_j^t). \quad (3.15)$$

代码中对应参数 `reg_dist` 和 `reg_cl` 分别控制特征代价与标签代价权重。

参数 `prototype_cost_weight` 和 `temporal_cost_weight` 通过 `warmup` 日程逐步增大。

基于联合代价矩阵 C ，本文求解非平衡传输计划 γ^* ，并将其代入训练损失：

$$\mathcal{L}_{\text{align}} = \langle \gamma^*, C^{\text{loss}} \rangle + \varepsilon \text{KL}(\gamma^* \| ab^T) + \tau_s \text{KL}(\gamma^* \mathbf{1} \| a) + \tau_t \text{KL}((\gamma^*)^T \mathbf{1} \| b). \quad (3.16)$$

其中 C^{loss} 与求解计划的代价保持一致，但标签项在训练目标中使用交叉熵形式，以便对目标预测产生有效梯度。由于 γ^* 在代码中以 `detach` 形式进入目标函数，梯度主要通过代价矩阵传递给特征提取器和分类器。

3.3.3 源域原型与时序统计约束融合

源域原型和时序统计代价并非独立训练分支，而是直接进入非平衡联合传输代价。其作用主要体现在传输计划求解阶段：当目标样本与某个源类原型相对接近，且原始时序统计特征与某个源样本更相似时，对应传输代价会降低；反之则提高匹配代价。

为了保证训练稳定，本文采用延迟启动和线性预热策略。设原型代价基础权重为 λ_p^0 ，启动步数为 t_p ，预热步数为 T_p ，则当前原型权重为

$$\lambda_p(t) = \lambda_p^0 \min \left(\frac{\max(t - t_p, 0)}{T_p}, 1 \right). \quad (3.17)$$

时序统计代价权重 $\lambda_r(t)$ 采用相同形式。

代码中，原型代价日程的启动步数对应 `prototype_start_step`。

原型代价日程的预热步数对应 `prototype_warmup_steps`。

时序统计代价日程的启动步数对应 `temporal_start_step`。

时序统计代价日程的预热步数对应 `temporal_warmup_steps`。

这种融合方式具有两个优点。首先，原型代价在类别结构层面约束目标样本与源类别的相对关系，有助于缓解联合传输中的类别混淆。其次，时序统计代价从原始信号层面补充均值、波动和变化趋势信息，能够在深度特征尚未完全稳定时提供额外的过程动态约束。

二者均不依赖目标标签，因此符合无监督领域自适应设定。

3.3.4 源域监督对比特征学习

为进一步增强源域特征空间的类别判别性，本文在训练前期加入源域监督对比学习。监督对比学习通过拉近同类别样本特征、推远不同类别样本特征，提高表示空间的类内紧凑性和类间分离性^[18]。

设一个源域小批量中第 i 个样本的归一化特征为 $\tilde{z}_i$ ，其同类正样本集合为

$$\mathcal{P}(i) = \{k \neq i \mid y_k^s = y_i^s\}. \quad (3.18)$$

源域监督对比损失为

$$\mathcal{L}_{\text{supcon}} = -\frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \frac{1}{|\mathcal{P}(i)|} \sum_{p \in \mathcal{P}(i)} \log \frac{\exp(\tilde{z}_i^T \tilde{z}_p / T_c)}{\sum_{a \neq i} \exp(\tilde{z}_i^T \tilde{z}_a / T_c)}, \quad (3.19)$$

其中 $\mathcal{I}$ 表示存在至少一个同类正样本的源域样本集合， T_c 为对比学习温度系数。代码实现中该损失只使用源域标签，不使用目标域标签；在默认配置中其主要作用于源域预热阶段，随后关闭或保持较小权重，避免对后续跨域对齐产生过强约束。

3.3.5 总体目标函数与算法流程

综上，本章方法的总体目标函数为

$$\mathcal{L}_{\text{TPU}} = \mathcal{L}_{\text{src}} + \lambda_c(t) \mathcal{L}_{\text{supcon}} + \lambda_{\text{ot}}(t) \mathcal{L}_{\text{align}}, \quad (3.20)$$

其中 $\lambda_c(t)$ 为监督对比损失权重， $\lambda_{\text{ot}}(t)$ 为非平衡联合传输对齐权重。 $\lambda_{\text{ot}}(t)$ 采用 warm-start 日程，并在源域预热阶段保持为零； $\mathcal{L}_{\text{align}}$ 内部还包含逐步启动的原型代价和时序统计代价。

本章方法的训练流程如下。

1. 初始化特征提取器、分类器和源域类别原型，原型初始状态标记为未激活。
2. 在每次迭代中采样源域有标签小批量和目标域无标签小批量，计算源域和目标域深度特征及分类输出。
3. 根据当前源域小批量更新源域类别原型，并计算源域分类损失和源域监督对比损失。
4. 构造源目标样本间的深度特征代价、标签预测代价、原型相对代价和时间序列统计代价。
5. 使用非平衡 Sinkhorn 求解小批量传输计划，计算非平衡联合传输损失。
6. 按当前训练步的权重日程组合源域分类、监督对比和传输对齐损失，并更新网络参

数。

该流程对应本地实现中的 `tpu_deepjdot` 配置。相较于普通 DeepJDOT, 本文方法在不使用目标标签的前提下, 为传输计划增加了“可放弃不可靠质量”的非平衡机制、“类别中心相对接近性”的源域原型机制, 以及“原始时间窗口动态统计”的时序代价机制, 从而更适合 TEP 跨工况故障诊断场景。

3.4 本章小结

本章提出了基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法。针对平衡最优传输在小批量训练中可能产生错误强制匹配的问题, 本文引入非平衡 Sinkhorn 传输, 使不可靠传输质量可以通过边际松弛被削减。针对工业过程故障类别结构保持不足的问题, 本文维护源域类别原型, 并根据目标样本到源域各类别原型的相对距离构造原型代价。针对多变量时间序列动态信息利用不足的问题, 本文从原始过程窗口中提取均值、标准差和一阶差分统计量, 构造时间序列统计代价。最后, 本文在源域预热阶段加入监督对比学习, 以增强源域特征表示的类别可分性。

本章方法构成后续第四章的基础。第四章将在该模型之上进一步利用目标域无标签样本的高可靠伪标签信息, 研究如何通过传输计划、教师模型和源域原型三类证据筛选目标样本, 并通过类别均衡和一致性约束提高目标域学习的稳定性。

第四章 基于多证据置信均衡伪标签的 单源领域自适应故障诊断方法

4.1 引言

第三章方法通过非平衡联合传输、源域原型和时序统计代价增强了单源跨工况对齐能力，但目标域样本仍主要通过传输代价间接参与训练。随着模型训练推进，部分目标域样本的语义预测会逐渐变得稳定，若能够可靠地利用这些样本，可以进一步提升目标工况下的类别边界质量。然而，在无监督领域自适应中，目标域真实标签不可用于训练，直接使用模型预测作为伪标签可能放大错误预测，尤其是在 TEP 跨模式数据分布差异较大、故障类别较多的情况下，错误伪标签会导致目标域类别坍塌或过度偏向少数高置信类别。

为解决目标域伪标签不可靠问题，本章提出基于多证据置信均衡伪标签的单源领域自适应故障诊断方法。该方法对应本地实现中的 CBTPU-DeepJDOT，在第三章 TPU-DeepJDOT 的基础上加入教师模型、强弱增强一致性、多证据语义融合和类别均衡伪标签学习。方法不依赖目标域标签，而是融合三类证据：由非平衡传输计划得到的传输语义分布、由 EMA 教师模型得到的预测语义分布、由源域类别原型得到的原型语义分布。只有当多类证据一致、置信度足够高且传输语义熵较低时，目标样本才参与伪标签学习。

4.2 多证据置信均衡伪标签学习基本原理

4.2.1 目标域伪标签学习原理

伪标签学习的基本思想是将模型对无标签样本的高置信预测作为临时监督信号，从而扩大可训练样本集合^[19]。在领域自适应中，伪标签还能帮助目标域样本形成更清晰的类别结构，但其可靠性受到源目标分布偏移和模型过置信错误预测影响。原型式目标结构学习和伪标签去噪研究表明，引入类别结构信息有助于缓解伪标签噪声^[17]。

在本文场景中，若仅使用分类器输出的最大概率作为伪标签依据，容易出现两类问题。第一，目标域样本可能因为跨工况偏移而被错误地高置信分类；第二，高置信样本的类别分布可能天然不均衡，使模型持续强化少数类别。因此，本章不直接采用单一分类器置信度，而是构建由传输、教师和原型三类证据组成的软伪标签分布。

设目标样本 x_j^t 的融合语义分布为 q_j^{mix} ，其伪标签为

$$\hat{y}_j^t = \arg \max_c q_{jc}^{\text{mix}}, \quad (4.1)$$

置信度为

$$\kappa_j = \max_c q_{jc}^{\text{mix}}. \quad (4.2)$$

只有当 κ_j 超过动态阈值且三类证据之间差异较小时，样本才被纳入伪标签集合。

4.2.2 教师模型一致性学习原理

教师模型一致性学习通过维护学生模型参数的指数滑动平均，获得更稳定的目标预测。**Mean Teacher** 方法表明，权重平均教师模型可为无标签样本提供更平滑、更可靠的一致性目标^[20]。本文采用相同思想，在训练过程中维护 EMA 教师网络：

$$\bar{\theta} \leftarrow \xi \bar{\theta} + (1 - \xi) \theta, \quad (4.3)$$

其中 θ 为学生模型参数， $\bar{\theta}$ 为教师模型参数， ξ 为 EMA 衰减系数。教师模型不通过梯度更新，而是在每次学生模型参数更新后进行滑动平均。

对于目标样本的弱增强视图 $a_w(x_j^t)$ ，教师模型输出预测分布：

$$q_j^{\text{cls}} = \text{softmax} \left(\frac{G_{\bar{\theta}}(F_{\bar{\theta}}(a_w(x_j^t)))}{T_{\text{tea}}} \right), \quad (4.4)$$

其中 T_{tea} 为教师温度系数。该分布作为目标域预测语义证据，同时也用于强弱增强一致性约束。

4.2.3 类别均衡约束原理

工业故障诊断数据常存在类别不均衡，伪标签集合的不均衡程度可能比源域标签更严重。若高置信伪标签集中在少数类别，模型会进一步偏向这些类别，形成自强化偏差。类别均衡学习通过调整类别权重或类别先验，缓解长尾类别被忽略的问题^[21]。自然不均衡伪标签研究也指出，伪标签偏置会显著影响无标签学习效果，需要额外去偏置机制^[22]。

本文实现中，类别均衡主要作用于被接受的伪标签集合。设当前被接受样本的伪标签类别频率为 $\hat{\pi}_c$ ，则对强增强目标样本的 logits 进行对数先验调整：

$$\tilde{u}_{jc} = u_{jc} - \eta \log(\hat{\pi}_c + \epsilon), \quad (4.5)$$

其中 u_{jc} 为强增强视图的原始 logit， η 为调整强度。该调整会降低频繁伪标签类别的相对优势，提高稀有伪标签类别被学习的机会。类似的分布对齐思想也在半监督学习和领域自适应统一框架中得到关注^[23,24]，但本文实现并未使用目标真实类别先验，而是仅根据当前接受的伪标签统计进行训练时校正。

4.3 基于多证据置信均衡伪标签的目标域样本利用策略

4.3.1 传输语义分布估计

第三章的非平衡传输计划不仅给出源目标样本之间的匹配关系，还可以提供目标样本的类别语义分布。设传输计划为 γ ，源样本标签为 y_i^s 。对于目标样本 x_j^t ，来自第 c 类源样本的传输质量为

$$m_{cj}^{\text{ot}} = \sum_{i: y_i^s = c} \gamma_{ij}. \quad (4.6)$$

归一化后得到传输语义分布：

$$q_{jc}^{\text{ot}} = \frac{m_{cj}^{\text{ot}}}{\sum_{c'=1}^{N_c} m_{c'j}^{\text{ot}} + \epsilon}. \quad (4.7)$$

若某个目标样本主要从少数源类接收传输质量，则 q_j^{ot} 熵较低，说明传输计划对该样本的类别语义较明确；若多个源类同时向其传输，则熵较高，说明该样本不适合作为可靠伪标签。本文用归一化熵

$$H(q_j^{\text{ot}}) = -\frac{1}{\log N_c} \sum_{c=1}^{N_c} q_{jc}^{\text{ot}} \log(q_{jc}^{\text{ot}} + \epsilon) \quad (4.8)$$

作为传输语义可靠性指标之一。

4.3.2 教师预测语义分布估计

教师预测语义分布 q_j^{cls} 来自 EMA 教师模型对目标弱增强样本的预测。相比当前学生模型，EMA 教师模型在参数空间上进行了时间平均，通常具有更平滑的决策边界。因此， q_j^{cls} 既提供类别预测证据，也作为强增强一致性学习的目标分布。

本文只使用教师模型对目标无标签样本的输入输出关系，不引入目标标签。教师模型参数由学生模型滑动平均得到，其更新发生在优化器更新之后。代码中教师网络始终处于 eval 状态，避免 BatchNorm 或 Dropout 等训练状态造成额外扰动。

4.3.3 源域原型语义分布估计

源域原型语义分布由目标样本特征到各源类原型的距离计算得到。设源域类别原型为 $\{\mu_c\}_{c=1}^{N_c}$ ，目标弱增强样本特征为 z_j^t 。目标样本到第 c 类源域原型的距离为

$$d_{jc}^{\text{proto}} = \left\| \frac{z_j^t}{\|z_j^t\|_2} - \mu_c \right\|_2^2. \quad (4.9)$$

原型语义分布定义为

$$q_{jc}^{\text{proto}} = \frac{\exp(-d_{jc}^{\text{proto}}/T_{\text{proto}})}{\sum_{c'=1}^{N_c} \exp(-d_{jc'}^{\text{proto}}/T_{\text{proto}})}, \quad (4.10)$$

其中 T_{proto} 为原型温度系数。若某些源类原型尚未被激活，则在计算中对其进行屏蔽，避免未初始化原型影响伪标签判断。

4.3.4 多证据一致性筛选机制

本章的核心设计是融合传输计划、教师预测和原型距离三类证据，而不是依赖单一置信度来源。具体地，对三个语义分布进行幂加权几何平均：

$$q_{jc}^{\text{mix}} = \frac{(q_{jc}^{\text{ot}})^{\alpha_{\text{ot}}}(q_{jc}^{\text{cls}})^{\alpha_{\text{cls}}}(q_{jc}^{\text{proto}})^{\alpha_{\text{proto}}}}{\sum_{c'=1}^{N_c} (q_{jc'}^{\text{ot}})^{\alpha_{\text{ot}}}(q_{jc'}^{\text{cls}})^{\alpha_{\text{cls}}}(q_{jc'}^{\text{proto}})^{\alpha_{\text{proto}}}}, \quad (4.11)$$

其中 α_{ot} 、 α_{cls} 和 α_{proto} 分别控制三类证据的贡献。代码实现中使用 $\log$ 概率求和后 softmax 的方式计算该分布，以提高数值稳定性。

设三类证据的最大概率类别分别为

$$\hat{y}_j^{\text{ot}}, \quad \hat{y}_j^{\text{cls}}, \quad \hat{y}_j^{\text{proto}}. \quad (4.12)$$

若三者完全一致，则该样本具备较强语义一致性。对于三者不完全一致但分布差异很小的样本，本文使用 Jensen–Shannon 差异作为补充筛选标准：

$$D_{\text{JS}} = \frac{1}{3} \sum_{q \in \{q^{\text{ot}}, q^{\text{cls}}, q^{\text{proto}}\}} \text{KL}(q \parallel \bar{q}), \quad \bar{q} = \frac{q^{\text{ot}} + q^{\text{cls}} + q^{\text{proto}}}{3}. \quad (4.13)$$

最终接受条件为

$$\mathcal{A}_j = [\hat{y}_j^{\text{ot}} = \hat{y}_j^{\text{cls}} = \hat{y}_j^{\text{proto}} \text{ or } D_{\text{JS}} \leq \delta_{\text{JS}}] \wedge \left[\max_c q_{jc}^{\text{mix}} \geq \tau(t) \right] \wedge [H(q_j^{\text{ot}}) \leq h_{\text{ot}}]. \quad (4.14)$$

其中 δ_{JS} 为分布差异阈值， h_{ot} 为传输语义熵阈值。该机制是本文针对本地实现设计的多证据筛选策略，不能简单视为已有文献方法的直接复现。

4.3.5 动态置信阈值与类别均衡机制

伪标签阈值采用动态下降策略。设伪标签启动步数为 t_0 ，阈值从 τ_{start} 逐步下降到 τ_{end} ：

$$\tau(t) = \tau_{\text{start}} + \min \left(\frac{\max(t - t_0, 0)}{T_\tau}, 1 \right) (\tau_{\text{end}} - \tau_{\text{start}}). \quad (4.15)$$

训练早期阈值较高，只接受最可靠目标样本；随着模型稳定，阈值逐渐降低，使更多目标样本参与训练。

为避免一次迭代中接受过多低质量伪标签，代码还支持最大接受比例限制。若满足条件的样本数超过 `pseudo_max_acceptance` 指定比例，则根据融合置信度、JS 差异和传输熵构造排序分数，只保留得分最高的一部分样本。

对于被接受样本集合 $\mathcal{A}$ ，伪标签学习使用软目标交叉熵：

$$\mathcal{L}_{\text{pl}} = -\frac{1}{|\mathcal{A}|} \sum_{j \in \mathcal{A}} \sum_{c=1}^{N_c} q_{jc}^{\text{mix}} \log \text{softmax}_c(\tilde{u}_j), \quad (4.16)$$

其中 $\tilde{u}_j$ 为经过类别频率对数调整后的强增强 logits。该损失只对通过多证据筛选的目标样本生效，因此比直接对全部目标样本施加伪标签约束更保守。

4.3.6 强弱增强一致性约束

强弱增强一致性是半监督学习中的重要机制。FixMatch 通过弱增强产生高置信伪标签，并要求强增强视图保持一致预测^[25]。本文借鉴这一思想，但结合工业过程时间序列特点设计增强方式：弱增强包括小幅随机扰动和幅值缩放；强增强在此基础上进一步加入时间片段遮蔽和通道 dropout。

设目标样本的弱增强和强增强分别为 $a_w(x_j^t)$ 和 $a_s(x_j^t)$ 。教师模型在弱增强上产生 q_j^{cls} ，学生模型在强增强上产生预测 $p_\theta(a_s(x_j^t))$ 。一致性损失定义为

$$\mathcal{L}_{\text{cons}} = \frac{1}{|\mathcal{B}|} \sum_{j \in \mathcal{B}} \text{KL}(q_j^{\text{cls}} \| p_\theta(a_s(x_j^t))), \quad (4.17)$$

其中 $\mathcal{B}$ 包括被接受的高置信伪标签样本，以及部分融合置信度达到中等阈值且传输熵较低的目标样本。这样做可以让未达到伪标签训练标准但仍具备一定稳定性的样本参与一致性约束。

4.3.7 总体目标函数与算法流程

本章方法的总损失为

$$\mathcal{L}_{\text{CBTPU}} = \mathcal{L}_{\text{src}} + \lambda_c(t) \mathcal{L}_{\text{supcon}} + \lambda_{\text{ot}}(t) \mathcal{L}_{\text{align}} + \lambda_{\text{pl}}(t) \mathcal{L}_{\text{pl}} + \lambda_{\text{cons}}(t) \mathcal{L}_{\text{cons}} + \lambda_{\text{im}}(t) \mathcal{L}_{\text{im}}. \quad (4.18)$$

其中前三项与第三章一致， $\mathcal{L}_{\text{pl}}$ 为多证据伪标签损失， $\mathcal{L}_{\text{cons}}$ 为强弱增强一致性损失。 $\mathcal{L}_{\text{im}}$ 为可选的信息最大化正则项，用于鼓励目标预测个体低熵且批次类别分布不过度坍塌；在实验配置中其权重较小，仅作为辅助稳定项。

本章方法训练流程如下。

1. 初始化学生网络、EMA 教师网络和源域类别原型。
2. 每次迭代采样源域有标签小批量和目标域无标签小批量，对目标样本生成弱增强和强增强视图。
3. 使用学生网络计算源域分类输出、目标弱增强输出和目标强增强输出；使用教师网络计算目标弱增强语义分布。

4. 更新源域类别原型，并计算源域分类损失、监督对比损失和非平衡联合传输损失。
5. 由传输计划得到 q^{ot} ，由教师预测得到 q^{cls} ，由源域原型距离得到 q^{proto} 。
6. 对三类语义分布进行幂加权融合，依据一致性、JS 差异、融合置信度和传输熵筛选目标样本。
7. 对接受样本计算类别均衡软伪标签损失，对接受样本和中等置信样本计算强弱增强一致性损失。
8. 组合各项损失更新学生网络，并在优化器更新后用学生参数滑动更新教师网络。

该流程保证目标域样本的利用始终建立在多证据一致性之上。与单一高置信伪标签方法相比，它能同时利用传输计划的跨域匹配信息、教师模型的时间平均预测和源域原型的类别结构信息，从而降低错误伪标签传播风险。

4.4 本章小结

本章在第三章时序原型非平衡联合分布对齐方法基础上，提出了基于多证据置信均衡伪标签的目标域样本利用策略。该策略从非平衡传输计划、EMA 教师模型和源域类别原型三类来源构建目标域语义分布，通过一致性判断、JS 差异、动态置信阈值和传输熵筛选可靠目标样本。针对伪标签类别偏置问题，本文在被接受伪标签集合上进行对数先验调整，缓解少数高置信类别对训练的主导。针对目标时序样本扰动稳定性问题，本文引入弱增强教师预测和强增强学生预测之间的一致性约束。

本章方法仍然保持严格无监督领域自适应设定，训练过程中不使用目标域标签。目标域标签仅在后续实验章节中用于最终性能评价。通过上述多证据筛选和类别均衡机制，模型能够更加可靠地利用目标域无标签样本，为单源跨工况故障诊断提供更稳定的目标域决策边界。

第五章 基于类条件源域可靠性加权的 多源领域自适应故障诊断方法

5.1 引言

第三章和第四章面向单源到单目标场景，研究如何在一个有标签源工况和一个无标签目标工况之间进行可靠对齐。在实际工业过程中，历史数据往往来自多个生产模式或多个相邻工况。多源领域自适应能够利用更丰富的源域故障样本，但也引入了新的问题：不同源域与目标域的相似程度不同，同一源域对不同故障类别的可迁移性也可能不同。若简单合并多个源域，模型可能被不可靠源域或不可靠故障类别干扰，出现负迁移。

为此，本章提出基于类条件源域可靠性加权的多源领域自适应故障诊断方法。该方法对应本地实现中的 CA-CCSR-WJDOT 主线，结合 CoDATS 的时间序列领域对抗表征、WJDOT 的逐源联合分布传输思想，以及本文设计的类条件源域可靠性矩阵。方法在每个源域与目标域之间分别计算联合传输代价，并从原型距离、类条件传输代价、目标预测熵和源域类别召回误差四个角度估计“源域-故障类别”的可靠性，再据此分配类条件源域权重。训练和模型选择过程中不使用目标域标签；目标域标签只在最终评价和报告生成阶段读取。

5.2 类条件源域可靠性加权基本原理

5.2.1 多源迁移与负迁移问题

设共有 K 个源域，源域集合为

$$\mathcal{D}_{s_k} = \{(x_i^{s_k}, y_i^{s_k})\}_{i=1}^{n_k}, \quad k = 1, 2, \dots, K, \quad (5.1)$$

目标域无标签样本为

$$\mathcal{D}_t = \{x_j^t\}_{j=1}^{n_t}. \quad (5.2)$$

多源领域自适应的目标是在目标标签不可用的条件下，利用多个源域的有标签数据学习目标域诊断模型。

多源数据并不总是越多越好。负迁移研究指出，当源域知识与目标域分布或任务结构不匹配时，迁移学习可能降低目标域性能^[26]。在 TEP 多生产模式故障诊断中，某个源模式可能整体接近目标模式，但对部分故障类别仍存在明显偏移；也可能某个源模式整体较远，却对特定故障类别具有较高参考价值。因此，仅使用源域整体权重难以刻画这种细粒

度迁移关系。

本文将多源负迁移问题细化为类条件可靠性问题：对于每个源域 s_k 和每个故障类别 c ，估计该源域在该类别上是否适合向目标域迁移。该估计结果形成可靠性矩阵 $R \in \mathbb{R}^{K \times N_c}$ ，并进一步转化为类条件源域权重矩阵 $\alpha \in \mathbb{R}^{K \times N_c}$ 。

5.2.2 源域可靠性度量原理

WJDOT 通过源域加权联合分布最优传输为多源领域自适应提供了重要基础，其思想是在多个源域之间分配权重，使更可靠源域对目标域适配贡献更大^[8]。多源专家融合方法也表明，不同源域或不同专家可以根据目标样本特征进行差异化组合^[27]。本文受这些思想启发，但本地实现并未简单训练多个独立专家，而是在共享时间序列表征和共享 CoDATS 分类头下，对每个源域分别计算传输统计，并进一步构造类条件可靠性矩阵。

源域可靠性可从多个角度估计。若某源域某类别原型与目标域对应类别原型距离较近，则说明该源类别特征结构可能适合迁移；若该源域某类别到目标域的传输代价较低，则说明联合特征-标签空间匹配较好；若该源域对目标样本的预测熵较低，则说明其目标预测更确定；若源域自身在该类别上的召回误差较小，则说明该源域对该类别的监督学习质量较高。本文将这些信息组合为源域-类别可靠性分数。

5.2.3 类条件源域权重分配原理

多源领域自适应中的矩匹配方法强调不同源域与目标域之间的分布统计关系^[28]，WJDOT 则强调通过联合分布传输学习源域权重^[8]。本文进一步将源域权重从全局源域级别扩展到故障类别级别。对于每个类别 c ，所有源域在该类别上的权重满足

$$\sum_{k=1}^K \alpha_{kc} = 1, \quad \alpha_{kc} \geq 0. \quad (5.3)$$

其中 α_{kc} 越大，表示第 k 个源域对第 c 类故障更可靠。

本文的类条件源域可靠性矩阵是本地实现中的自设计机制，应理解为受源域重加权、多源专家融合和负迁移抑制思想启发，而不是某一文献中已有机制的直接照搬。该矩阵不仅参与训练中的类条件传输损失聚合，也会作为解释性诊断结果导出，用于分析不同源模式对不同故障类别的贡献。

5.3 基于类条件源域可靠性加权的多源对齐策略

5.3.1 多源跨工况诊断问题建模

本章方法采用共享特征提取器 F_θ 和共享分类器 G_ϕ 。特征提取器仍为一维全卷积网络，分类器采用 CoDATS 风格的两层隐藏层分类头，以增强时间序列诊断表征能力。对于第 k 个源域样本，模型输出

$$z_i^{s_k} = F_\theta(x_i^{s_k}), \quad p_i^{s_k} = G_\phi(z_i^{s_k}). \quad (5.4)$$

对于目标样本，模型输出

$$z_j^t = F_\theta(x_j^t), \quad p_j^t = G_\phi(z_j^t). \quad (5.5)$$

源域监督分类损失对所有源域求平均或按配置聚合：

$$\mathcal{L}_{\text{src}} = \frac{1}{K} \sum_{k=1}^K \frac{1}{|\mathcal{B}_{s_k}|} \sum_{(x_i^{s_k}, y_i^{s_k}) \in \mathcal{B}_{s_k}} \ell(y_i^{s_k}, G_\phi(F_\theta(x_i^{s_k}))). \quad (5.6)$$

代码中还支持源域类别均衡权重，用于缓解源域小批量内部类别数量不均衡。

5.3.2 逐源联合分布最优传输对齐

对于每个源域 s_k ，本文分别构造其与目标域之间的联合传输代价：

$$C_{ij}^{(k)} = \lambda_f \|z_i^{s_k} - z_j^t\|_2^2 + \lambda_y \ell(y_i^{s_k}, p_j^t). \quad (5.7)$$

其中标签预测代价使用源域标签与目标预测之间的交叉熵。与直接合并所有源域不同，逐源传输为每个源域保留独立的传输计划：

$$\gamma_k^* = \arg \min_{\gamma_k \in \Pi(a_k, b)} \langle \gamma_k, C^{(k)} \rangle. \quad (5.8)$$

本地 CA-CCSR-WJDOT 主配置中使用 Sinkhorn 求解平衡传输计划，并分别记录每个源域的传输损失、各类别传输质量和各类别平均传输代价。

第 k 个源域第 c 类的传输质量为

$$M_{kc}^{\text{ot}} = \sum_{i: y_i^{s_k} = c} \sum_j \gamma_{k,ij}, \quad (5.9)$$

对应的类条件传输代价为

$$D_{kc}^{\text{ot}} = \frac{\sum_{i: y_i^{s_k} = c} \sum_j \gamma_{k,ij} C_{ij}^{(k)}}{M_{kc}^{\text{ot}} + \epsilon}. \quad (5.10)$$

该矩阵是后续类条件可靠性评估的重要组成部分。

5.3.3 类条件源域可靠性矩阵构建

本文从四类证据构建源域-类别可靠性矩阵。

第一，源目标原型距离。对每个源域按源标签计算源域类别原型 μ_{kc}^s 。目标域类别原型 μ_c^t 由目标无标签样本的预测分布估计：若某一类别存在足够数量的高置信目标样本，则使用这些样本特征均值作为目标原型；否则使用目标预测概率或传输质量形成的软重心作为补充。源目标原型距离为

$$D_{kc}^{\text{proto}} = \|\mu_{kc}^s - \mu_c^t\|_2^2. \quad (5.11)$$

第二，类条件传输代价 D_{kc}^{ot} 。该项来自逐源联合分布最优传输，反映第 k 个源域第 c 类在特征-标签联合空间中与目标域匹配的难度。

第三，目标预测熵。设第 k 个源域对应的目标预测分布为 p_{kj}^t 。对于当前暂定属于第 c 类的目标样本集合 $\mathcal{T}_c$ ，计算归一化预测熵均值：

$$H_{kc}^{\text{pred}} = \frac{1}{|\mathcal{T}_c|} \sum_{j \in \mathcal{T}_c} \left(-\frac{1}{\log N_c} \sum_{r=1}^{N_c} p_{kjr}^t \log(p_{kjr}^t + \epsilon) \right). \quad (5.12)$$

熵越低，说明该源域对目标样本的预测越确定。

第四，源域类别召回误差。对第 k 个源域当前小批量或评估批次，计算第 c 类源域样本召回率 Recall_{kc}^s ，并定义

$$E_{kc}^s = 1 - \text{Recall}_{kc}^s. \quad (5.13)$$

该项用于避免源域自身尚未学好的类别被赋予过高迁移权重。

四类证据在每个类别维度上分别进行 min-max 归一化后线性组合：

$$R_{kc} = w_p \tilde{D}_{kc}^{\text{proto}} + w_o \tilde{D}_{kc}^{\text{ot}} + w_h \tilde{H}_{kc}^{\text{pred}} + w_e \tilde{E}_{kc}^s. \quad (5.14)$$

可靠性分数越小，表示源域 k 对类别 c 越可靠。随后按类别维度进行 softmax 转换：

$$\alpha_{kc} = \frac{\exp(-R_{kc}/T_c)}{\sum_{k'=1}^K \exp(-R_{k'c}/T_c)}. \quad (5.15)$$

代码实现中还包含最低权重 floor、可选 top- m 源域保留以及可靠性 ramp。可靠性 ramp 用于在训练早期保持接近均匀权重，待源域传输和目标预测更稳定后再逐渐启用类条件权重：

$$\alpha_{kc}(t) = (1 - r(t)) \frac{1}{K} + r(t) \alpha_{kc}, \quad (5.16)$$

其中 $r(t) \in [0, 1]$ 为可靠性启用进度。

基于类条件源域权重，类条件传输损失为

$$\mathcal{L}_{\text{CCSR}} = \frac{1}{|\mathcal{C}_{\text{act}}|} \sum_{c \in \mathcal{C}_{\text{act}}} \sum_{k=1}^K \mathbb{I}_{kc} \alpha_{kc} D_{kc}^{\text{ot}}, \quad (5.17)$$

其中 $\mathbb{I}_{kc}$ 表示源域 k 是否存在第 c 类样本， $\mathcal{C}_{\text{act}}$ 为当前至少有源域支持的类别集合。

5.3.4 领域对抗特征约束与教师先验约束

为了获得更稳定的时间序列跨域表征，本章方法在逐源传输和类条件可靠性之外，引入 CoDATS 风格的领域对抗特征约束。领域对抗学习通过梯度反转层训练特征提取器，使源域和目标域特征在领域判别器看来难以区分^[12]。CoDATS 将该思想应用于时间序列传感器数据，并使用适合时间序列任务的分类头结构^[7]。

设领域判别器为 D_ω ，源域特征集合为 Z_s ，目标域特征集合为 Z_t 。领域对抗损失为

$$\mathcal{L}_{\text{adv}} = -\frac{1}{|Z_s|} \sum_{z \in Z_s} \log D_\omega(z) - \frac{1}{|Z_t|} \sum_{z \in Z_t} \log(1 - D_\omega(z)). \quad (5.18)$$

通过梯度反转层，判别器最小化该损失，而特征提取器接收反向梯度，从而学习更难区分源目标领域的表示。代码中领域对抗权重采用 `warm-start` 日程，避免训练初期对抗信号过强。

此外，本章方法引入教师先验约束，用于防止多源传输和类条件加权造成目标预测漂移。教师模型通常由前一阶段较稳定的 CoDATS 检查点加载，并在训练过程中冻结。知识蒸馏表明，教师模型的软概率可以携带比硬标签更丰富的类别相似性信息^[29]；Mean Teacher 思想也说明稳定教师有助于无标签训练^[20]。本文将教师输出作为目标域先验保护项，而不是目标标签监督。

设教师模型在目标样本上的 logits 为 u_j^{tea} ，学生模型 logits 为 u_j^{stu} 。教师先验约束可写为

$$\mathcal{L}_{\text{tea}} = T^2 \text{KL} \left(\text{softmax} \left(\frac{u_j^{\text{tea}}}{T} \right) \parallel \text{softmax} \left(\frac{u_j^{\text{stu}}}{T} \right) \right), \quad (5.19)$$

其中 T 为蒸馏温度。代码还支持以归一化特征均方误差作为辅助教师锚定形式。

5.3.5 教师先验保护的诊断结果融合

训练结束后，本地实现还导出教师安全融合诊断结果。该阶段先固定学生模型和教师模型输出，再根据无标签目标样本上的置信度、熵和教师-学生一致性确定融合系数。随后才读取目标域评估标签计算准确率、宏平均 F1 和混淆矩阵，因此不会造成训练或预测阶段的目标标签泄漏。

设学生预测概率为 p_j^{stu} ，教师预测概率为 p_j^{tea} 。基础融合形式为

$$p_j^{\text{final}} = (1 - \eta_j) p_j^{\text{stu}} + \eta_j p_j^{\text{tea}}, \quad (5.20)$$

其中 $\eta_j \in [0, 1]$ 由教师和学生的 `top-1` 预测是否一致、两者置信度差异以及预测熵差异确定。当教师与学生预测一致时，融合系数较小，主要用于平滑预测；当二者不一致且教师

更高置信、低熵时，允许教师以较大权重参与最终概率。对于 `prior_balanced` 变体，代码先混合教师和学生概率，再根据预测批次的类别先验进行无标签概率校正：

$$p_j^{\text{pb}} = \frac{p_j^{\text{base}} / (\bar{p}^{\text{base}})^\beta}{\sum_c p_{jc}^{\text{base}} / (\bar{p}_c^{\text{base}})^\beta}, \quad (5.21)$$

其中 $\bar{p}^{\text{base}}$ 为当前目标批次平均预测分布， β 为先验均衡强度。该机制用于缓解目标预测类别数量坍塌，同样不使用目标真实标签。

教师安全融合的作用是保护已有稳定教师先验，同时允许学生在更高置信、更低熵时覆盖教师预测。与训练中的类条件源域可靠性矩阵互补，它为最终诊断结果提供了另一层保守校正。

5.3.6 总体目标函数与算法流程

本章训练阶段的总体目标函数为

$$\mathcal{L}_{\text{CA-CCSR}} = \lambda_s \mathcal{L}_{\text{src}} + \lambda_{\text{adv}}(t) \mathcal{L}_{\text{adv}} + \lambda_{\text{ot}} r_{\text{ot}}(t) \mathcal{L}_{\text{WJDOT}} + \lambda_{\text{ccsr}} r_{\text{ccsr}}(t) \mathcal{L}_{\text{CCSR}} + \lambda_{\text{tea}}(t) \mathcal{L}_{\text{tea}}. \quad (5.22)$$

其中 $\mathcal{L}_{\text{WJDOT}}$ 为逐源传输损失的源域级聚合， $\mathcal{L}_{\text{CCSR}}$ 为类条件可靠性加权传输损失， $\mathcal{L}_{\text{adv}}$ 为领域对抗损失， $\mathcal{L}_{\text{tea}}$ 为教师先验约束。各权重均采用配置中的 `warmup` 或 `ramp` 日程控制。

本章方法训练流程如下。

1. 初始化共享 FCN 特征提取器、CoDATS 分类头、领域判别器和冻结教师模型。
2. 每次迭代从多个源域分别采样有标签小批量，并从目标域采样无标签小批量。
3. 对每个源域分别计算源域分类损失、源域类别原型、源域类别召回误差以及该源域到目标域的联合传输计划。
4. 根据逐源传输结果得到源域级传输损失、类条件传输质量和类条件传输代价。
5. 根据目标预测构建目标类别原型，并融合原型距离、传输代价、预测熵和源域召回误差，得到类条件源域可靠性矩阵。
6. 将可靠性矩阵转化为类条件源域权重，计算类条件传输损失。
7. 计算 CoDATS 风格领域对抗损失和教师先验约束，组合总损失并更新学生模型参数。
8. 训练完成后，固定学生和教师输出，根据教师安全融合规则生成最终目标域预测；目标域标签只在预测固定后用于评价指标计算。

通过上述流程，模型能够在多源跨工况诊断中同时利用多个源域的互补信息，并对不同源域在不同故障类别上的可靠性进行细粒度建模。

5.4 本章小结

本章提出了基于类条件源域可靠性加权的多源领域自适应故障诊断方法。针对多源场景中的负迁移问题，本文不再仅使用源域整体权重，而是构建源域-故障类别级别的可靠性矩阵。该矩阵综合源目标原型距离、类条件传输代价、目标预测熵和源域类别召回误差，并通过类别维度 softmax 转化为类条件源域权重。基于该权重，模型能够对不同故障类别选择更可靠的源域信息。

本章方法还结合 CoDATS 风格时间序列领域对抗表征和冻结教师先验约束，提升多源训练稳定性；在最终诊断阶段，通过教师安全融合在学生预测和教师预测之间进行无标签置信校正。整个训练和融合过程均不使用目标域真实标签，目标标签仅用于最终实验评价。该方法为后续实验章节中的多源跨工况故障诊断提供了核心模型基础和可解释性分析依据。

第六章 实验设计与结果分析

6.1 引言

6.2 数据集与实验场景

6.3 实验结果

6.3.1 单源时序原型非平衡对齐实验结果

6.3.2 单源置信均衡伪标签实验结果

6.3.3 多源类条件源域可靠性实验结果

6.4 实验结果分析

6.4.1 诊断准确率对比分析

6.4.2 故障类别混淆矩阵分析

6.4.3 跨域特征分布可视化分析

6.4.4 综合诊断性能分析

6.5 本章小结

第七章 总结与展望

7.1 工作总结

本文围绕工业过程跨工况故障诊断中的领域分布偏移、目标域标签不足以及多源负迁移等问题，开展了基于领域自适应的故障诊断方法研究。以田纳西伊斯曼过程领域自适应数据集为实验对象，本文分别从单源域到单目标域和多源域到单目标域两类典型场景出发，研究了联合分布最优传输、时序原型约束、置信均衡伪标签学习以及类条件源域可靠性加权等方法在工业过程故障诊断中的应用。

在单源场景中，本文以深度联合分布最优传输方法为基础，首先针对普通平衡最优传输可能导致错误强制匹配、且原始联合传输过程缺少工业时间序列故障结构约束的问题，提出了基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法。该方法通过非平衡最优传输降低不可靠源目标样本被强制匹配的风险，并结合源域类别原型、时间序列统计代价和源域监督对比学习增强故障类别结构表达能力。进一步地，针对目标域无标签条件下伪标签可靠性不足的问题，本文提出了基于多证据置信均衡伪标签的单源领域自适应故障诊断方法。该方法综合传输计划、教师模型预测和源域原型距离三类语义证据，对目标域样本进行一致性筛选，并通过动态置信阈值、类别均衡机制和强弱增强一致性约束，提高目标域无标签样本利用的可靠性。

在多源场景中，本文以多源加权联合分布最优传输为基础，考虑到不同源域与目标域之间存在差异，且同一源域对不同故障类别的贡献并不一致，提出了基于类条件源域可靠性加权的多源领域自适应故障诊断方法。该方法结合卷积式时间序列领域自适应表征、逐源联合分布最优传输和源域-故障类别可靠性矩阵，对不同源域在不同故障类别上的迁移贡献进行建模，从而实现更加细粒度的多源选择性迁移。同时，本文在多源方法中引入领域对抗特征约束与教师先验保护机制，以增强时序表征能力并降低新增迁移损失对已有强表征的破坏风险。

实验部分围绕单源跨工况和多源跨工况两类任务展开。本文采用诊断准确率、宏平均 F1 值、平衡准确率、混淆矩阵和跨域特征可视化等指标，对所提方法与源域直接迁移、典型领域自适应方法、DeepJDOT、WJDOT、CoDATS 以及目标域监督参考方法进行了对比分析。同时，通过消融实验和可解释性分析，对时序原型约束、非平衡传输、多证据伪标签筛选、类别均衡机制以及类条件源域可靠性矩阵等关键模块的作用进行了验证。考虑到

不同跨工况任务的分布偏移程度和源域可靠性差异并不一致，本文在结果分析中重点关注整体趋势、典型成功场景和局部失效场景，而不将单一场景结果解释为绝对优势。整体而言，本文方法在跨工况故障诊断任务中体现出一定的适应能力和解释价值，为工业过程故障诊断中的无监督领域自适应研究提供了一种可行思路。

7.1.1 本文主要研究内容

本文的主要研究内容可以概括为以下三个方面。

第一，研究了单源跨工况故障诊断中的时序原型非平衡联合分布对齐方法。针对深度联合分布最优传输方法在小批量训练中可能存在的错误强制匹配问题，本文引入非平衡传输思想，对源域与目标域样本之间的传输约束进行松弛，使不可靠匹配能够被弱化。同时，考虑到工业过程样本为多变量时间序列，本文构造了源域故障类别原型和时间序列统计代价，用于增强跨工况对齐过程中的故障类别结构保持能力。为提高源域类别原型的稳定性，本文进一步加入源域监督对比学习，使特征空间中的同类故障样本更加紧凑、异类故障样本更加分离。

第二，研究了单源跨工况故障诊断中的多证据置信均衡伪标签学习方法。针对目标域无标签样本难以直接利用、伪标签易受噪声影响的问题，本文没有直接采用分类器置信度作为唯一依据，而是从传输计划、教师模型预测和源域原型距离三个角度构建目标样本的多证据语义分布。只有当多类证据在类别判断上具有较高一致性且满足动态置信阈值要求时，目标样本才被纳入伪标签学习过程。与此同时，本文在可信伪标签集合上估计类别频率，并结合类别均衡和强弱增强一致性约束，缓解目标伪标签类别偏置和过拟合风险。

第三，研究了多源跨工况故障诊断中的类条件源域可靠性加权方法。针对多源数据简单合并可能掩盖源域差异、全局源域权重难以表达类别级迁移可靠性的问题，本文构建了源域-故障类别可靠性矩阵。该矩阵综合考虑源域类别原型距离、类内传输代价、目标预测不确定性和源域类别性能等因素，用于度量不同源域在不同故障类别上的迁移可靠性。在此基础上，本文将 CoDATS 的卷积式时间序列表征能力、WJDOT 的逐源联合传输思想和 CCSR 的类条件源域加权机制结合起来，以提升多源跨工况故障诊断的选择性迁移能力和可解释性。

7.1.2 本文主要创新点

本文的主要创新点如下。

（1）提出了一种基于时序原型非平衡联合分布对齐的单源领域自适应故障诊断方法。

该方法在深度联合分布最优传输基础上，引入非平衡最优传输机制，以缓解小批量训练中目标样本被错误源样本强制匹配的问题；同时利用源域类别原型和时间序列统计代价刻画工业故障的类别结构与动态响应特征，并通过源域监督对比学习增强特征空间的类别可分性。该创新点使单源领域自适应故障诊断从单纯的样本级联合分布对齐进一步扩展到具有时序类别结构约束的选择性对齐。

（2）提出了一种基于多证据置信均衡伪标签的单源领域自适应故障诊断方法。该方法针对目标域伪标签不可靠问题，综合利用传输语义分布、教师预测语义分布和源域原型语义分布三类证据，对目标域样本进行一致性筛选。与仅依赖分类器最大置信度的伪标签方法不同，本文方法通过多证据一致性机制降低单一预测源过置信带来的错误传播风险，并进一步结合动态置信阈值、类别均衡和强弱增强一致性约束，提高目标域无标签样本利用过程的稳定性。

（3）提出了一种基于类条件源域可靠性加权的多源领域自适应故障诊断方法。该方法针对多源跨工况场景中的源域负迁移问题，将源域整体权重细化为源域-故障类别层面的可靠性权重，用于刻画不同源域对不同故障类别的迁移贡献。在模型设计上，本文结合卷积式时间序列表征、领域对抗特征约束、逐源联合分布最优传输和教师先验保护机制，使多源迁移过程既能够利用强时序表征，又能够通过类条件源域可靠性矩阵进行可解释的源类选择。

7.1.3 存在不足

尽管本文围绕跨工况领域自适应故障诊断提出了多种改良方法，并在田纳西伊斯曼过程数据集上进行了实验验证，但仍存在以下不足。

第一，部分跨工况任务中源域与目标域差异较大，模型性能提升幅度仍然有限。特别是在目标模式与源模式之间分布差异显著时，源域类别原型、传输计划和教师预测都可能受到较大偏移影响，导致目标域伪语义估计不够稳定。虽然本文通过非平衡传输、多证据筛选和教师先验保护等机制降低了错误迁移风险，但在更强分布偏移场景下仍可能出现适配不足或负迁移现象。

第二，本文方法包含多个相互作用的模块，模型复杂度和训练成本相对较高。与源域直接迁移或简单领域对抗方法相比，本文方法需要计算最优传输代价、更新源域类别原型、估计多证据伪标签以及构建源域-类别可靠性矩阵。这些步骤提升了方法的表达能力和可解释性，但也增加了训练时间和实现复杂度。对于工业现场部署场景，如何在保证诊断性

能的同时降低计算开销，仍需进一步研究。

第三，目标域无标签条件下的模型选择仍然是一个困难问题。本文在训练过程中避免使用目标域评估标签，并采用源域验证性能、目标预测熵、类别分布稳定性和教师先验等无标签指标辅助模型选择。然而，这些指标只能间接反映目标域性能，不能完全替代真实目标域标签监督。当目标域分布偏移较大或预测分布发生坍塌时，无标签模型选择策略仍可能存在偏差。

第四，本文的多源可靠性建模主要依赖特征距离、传输代价、预测不确定性和源域类别性能等统计量。虽然这些指标能够反映一定的源域-类别可靠性差异，但它们仍然是经验性度量，对不同数据集、不同故障类型和不同模型结构的泛化能力有待进一步验证。此外，类条件源域可靠性矩阵能够提供一定解释性，但其解释仍主要停留在源域和故障类别层面，尚未深入到具体传感器变量、物理过程环节和故障传播机理层面。

第五，本文实验主要基于田纳西伊斯曼过程领域自适应数据集展开。该数据集具有代表性的多模式化工过程特点，适合验证跨工况领域自适应方法，但其仍属于仿真基准数据。实际工业系统中可能存在更复杂的噪声、缺失值、传感器漂移、未知故障、渐变工况和实时数据流等情况。因此，本文方法在真实工业现场中的鲁棒性和可部署性仍需要进一步检验。

7.2 未来展望

针对本文工作仍存在的不足，未来可从以下几个方向继续开展研究。

第一，研究弱监督目标域校准方法。本文主要关注无监督领域自适应场景，即训练过程中不使用目标域标签。然而，在实际工业现场中，完全无标签和完全有标签之间还存在许多弱监督情形，例如仅有少量目标域标签、部分故障标签不完整、标签存在噪声或专家只能提供粗粒度标注。未来可以考虑将少量可靠目标标签用于校准类别原型、源域可靠性矩阵或伪标签阈值，而不是直接进行目标域监督训练。这样既可以保持领域自适应方法对标签稀缺场景的适用性，又能利用少量专家知识提高目标伪标签和源类可靠性估计的准确性。

第二，研究在线测试时领域自适应方法。本文采用离线领域自适应设置，即训练阶段可以访问一批无标签目标域数据。但在实际工业系统中，目标工况数据往往以流式方式到达，且生产条件可能随时间持续变化。未来可以研究在线测试时自适应方法，使模型能够

在推理过程中根据新到达的无标签样本持续更新自身状态^[30]。同时，需要避免在线自适应过程中因错误伪标签导致的误差累积和灾难性遗忘问题。对于工业故障诊断而言，在线适配还需要考虑实时性、安全性和稳定性，不能因模型更新影响关键故障报警的可靠性。

第三，研究更强的可解释领域自适应故障诊断方法。本文通过源域-故障类别可靠性矩阵展示了不同源域对不同故障类别的贡献差异，但解释粒度仍然有限。未来可以进一步结合注意力机制、特征归因、因果分析和过程机理知识，分析哪些传感器变量、哪些时间片段以及哪些物理过程环节对跨工况迁移起关键作用。对于化工过程故障诊断而言，将领域自适应结果与反应器、冷凝器、分离器、压缩机等实际过程单元联系起来，有助于提升模型在工业应用中的可信度和可用性。

第四，研究面向真实工业部署的轻量化领域自适应模型。本文方法包含最优传输、原型更新、教师模型和多源可靠性估计等步骤，计算成本相对较高。未来可以通过模型剪枝、知识蒸馏、低秩近似、量化推理和轻量化时序网络设计降低模型复杂度。同时，可以进一步研究小批量最优传输的高效近似算法，使其适用于边缘设备或嵌入式工业监控系统。对于实时故障诊断任务，模型不仅需要准确，还需要满足低延迟、低资源占用和稳定运行的要求。

第五，研究更加鲁棒的多源选择与负迁移抑制机制。本文从源域-类别层面对多源可靠性进行建模，但当源域数量进一步增加、源域质量差异更大或目标工况显著偏离所有已有源工况时，现有可靠性矩阵可能仍不足以完全避免负迁移。未来可以引入不确定性估计、贝叶斯源域选择、元学习校准或因果不变特征学习，对源域可迁移性进行更稳健的判断。同时，也可以研究源域自动筛选机制，使模型在发现某些源域与目标域关系较弱时，能够主动降低其参与训练和推理的权重。

第六，研究面向开放故障和未知工况的领域自适应诊断方法。本文默认源域和目标域具有相同故障类别空间，属于闭集领域自适应设置。但实际工业系统可能出现训练集中未包含的新故障类型，也可能遇到新的生产模式和未知扰动。未来可以扩展到开放集领域自适应、部分领域自适应和通用领域自适应等更复杂设置，使模型不仅能够识别已知故障，还能够发现未知故障或拒识不确定样本。这对于提升工业故障诊断系统的安全性和实际应用价值具有重要意义。

综上，本文研究为跨工况工业过程故障诊断提供了基于最优传输、时序原型、置信伪标签和类条件源域可靠性的领域自适应方法框架。未来若能进一步结合弱监督目标校准、

在线自适应、可解释建模和轻量化部署等方向，有望提升模型在真实工业场景中的泛化能力、稳定性和实用价值。

参考文献

- [1] LEI Y, YANG B, JIANG X, et al. Applications of machine learning to machine fault diagnosis: A review and roadmap[J/OL]. Mechanical Systems and Signal Processing, 2020, 138: 106587. DOI: 10.1016/j.ymssp.2019.106587.
- [2] WANG C, WANG Z, LIU Q, et al. A comprehensive survey on domain adaptation for intelligent fault diagnosis[J/OL]. Knowledge-Based Systems, 2025, 327: 114109. DOI: 10.1016/j.knosys.2025.114109.
- [3] PAN S J, YANG Q. A survey on transfer learning[J/OL]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359. DOI: 10.1109/TKDE.2009.191.
- [4] MONTESUMA E F, MULAS M, MBOULA F N, et al. Benchmarking domain adaptation for chemical processes on the Tennessee Eastman Process[A/OL]. 2024. arXiv: 2308.11247. <https://arxiv.org/abs/2308.11247>.
- [5] LI W, HUANG R, LI J, et al. A perspective survey on deep transfer learning for fault diagnosis in industrial scenarios: Theories, applications and challenges[J/OL]. Mechanical Systems and Signal Processing, 2022, 167: 108487. DOI: 10.1016/j.ymssp.2021.108487.
- [6] DAMODARAN B B, KELLENBERGER B, FLAMARY R, et al. DeepJDOT: Deep joint distribution optimal transport for unsupervised domain adaptation[C/OL]//Lecture Notes in Computer Science: volume 11208 Computer Vision – ECCV 2018. Cham: Springer International Publishing, 2018: 467-483. https://openaccess.thecvf.com/content_ECCV_2018/html/Bharath_Bhushan_Damodaran_DeepJDOT_Deep_Joint_ECCV_2018_paper.html. DOI: 10.1007/978-3-030-01225-0_28.
- [7] WILSON G, DOPPA J R, COOK D J. Multi-source deep domain adaptation with weak supervision for time-series sensor data[C/OL]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. ACM, 2020: 1768-1778. DOI: 10.1145/3394486.3403228.
- [8] TURRISI R, FLAMARY R, RAKOTOMAMONJY A, et al. Multi-source domain adaptation via weighted joint distributions optimal transport[C/OL]//Proceedings of Machine Learning Research: volume 180 Proceedings of the Thirty-Eighth Conference on Uncertainty in Artificial Intelligence. PMLR, 2022: 1970-1980. <https://proceedings.mlr.press/v180/turrisi22a.html>.
- [9] COURTY N, FLAMARY R, TUIA D, et al. Optimal transport for domain adaptation[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(9): 1853-1865. DOI: 10.1109/TPAMI.20

16.2615921.

- [10] WANG Z, YAN W, OATES T. Time series classification from scratch with deep neural networks: A strong baseline[C/OL]//2017 International Joint Conference on Neural Networks. IEEE, 2017: 1578-1585. DOI: 10.1109/IJCNN.2017.7966039.
- [11] ISMAIL FAWAZ H, FORESTIER G, WEBER J, et al. Deep learning for time series classification: A review[J/OL]. Data Mining and Knowledge Discovery, 2019, 33(4): 917-963. DOI: 10.1007/s10618-019-00619-1.
- [12] GANIN Y, USTINOVA E, AJAKAN H, et al. Domain-adversarial training of neural networks[J/OL]. Journal of Machine Learning Research, 2016, 17(59): 1-35. <https://jmlr.org/papers/v17/15-239.html>.
- [13] COURTY N, FLAMARY R, HABRARD A, et al. Joint distribution optimal transportation for domain adaptation[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 30. Curran Associates, Inc., 2017. <https://proceedings.neurips.cc/paper/2017/hash/0070d23b06b1486a538c0eaa45dd167a-Abstract.html>.
- [14] PEYRÉ G, CUTURI M. Foundations and trends in machine learning: volume 11 computational optimal transport: With applications to data science[M/OL]. Now Publishers, 2019: 355-607. DOI: 10.1561/2200000073.
- [15] FATRAS K, SÉJOURNÉ T, COURTY N, et al. Unbalanced minibatch optimal transport; applications to domain adaptation[C]//Proceedings of Machine Learning Research: volume 139 Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021: 3186-3197.
- [16] SNELL J, SWERSKY K, ZEMEL R S. Prototypical networks for few-shot learning[C]//Advances in Neural Information Processing Systems: volume 30. 2017: 4077-4087.
- [17] ZHANG P, ZHANG B, ZHANG T, et al. Prototypical pseudo label denoising and target structure learning for domain adaptive semantic segmentation[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 12414-12424. DOI: 10.1109/CVPR46437.2021.01223.
- [18] KHOSLA P, TETERWAK P, WANG C, et al. Supervised contrastive learning[C]//Advances in Neural Information Processing Systems: volume 33. 2020: 18661-18673.
- [19] LEE D H. Pseudo-Label: The simple and efficient semi-supervised learning method for deep neural networks[C/OL]//ICML 2013 Workshop: Challenges in Representation Learning (WREPL). Atlanta, Georgia, USA, 2013. https://storage.googleapis.com/kaggle-forum-message-attachments/8924/pseudo_label_fina

l.pdf.

- [20] TARVAINEN A, VALPOLA H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): volume 30. Curran Associates, Inc., 2017: 1195-1204. <https://proceedings.neurips.cc/paper/2017/hash/68053af2923e00204c3ca7c6a3150cf7-Abstract.html>.
- [21] CUI Y, JIA M, LIN T Y, et al. Class-balanced loss based on effective number of samples[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 9268-9277.
- [22] WANG X, WU Z, LIAN L, et al. Debaised learning from naturally imbalanced pseudo-labels[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022.
- [23] BERTHELOT D, CARLINI N, CUBUK E D, et al. Remixmatch: Semi-supervised learning with distribution alignment and augmentation anchoring[C]//International Conference on Learning Representations. 2020.
- [24] BERTHELOT D, ROELOFS R, SOHN K, et al. Adamatch: A unified approach to semi-supervised learning and domain adaptation[C]//International Conference on Learning Representations. 2022.
- [25] SOHN K, BERTHELOT D, LI C L, et al. Fixmatch: Simplifying semi-supervised learning with consistency and confidence[C]//Advances in Neural Information Processing Systems: volume 33. 2020: 596-608.
- [26] ZHANG W, DENG L, ZHANG L, et al. A survey on negative transfer[J/OL]. IEEE/CAA Journal of Automatica Sinica, 2023, 10(2): 305-329. DOI: 10.1109/JAS.2022.106004.
- [27] GUO J, SHAH D, BARZILAY R. Multi-source domain adaptation with mixture of experts[C/OL]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 4694-4703. DOI: 10.18653/v1/D18-1498.
- [28] PENG X, BAI Q, XIA X, et al. Moment matching for multi-source domain adaptation[C/OL]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 1406-1415. https://openaccess.thecvf.com/content_ICCV_2019/html/Peng_Moment_Matching_for_Multi-Source_Domain_Adaptation_ICCV_2019_paper.html. DOI: 10.1109/ICCV.2019.00149.
- [29] HINTON G, VINYALS O, DEAN J. Distilling the knowledge in a neural network[A]. 2015. arXiv: 1503.02531.
- [30] WANG Q, FINK O, VAN GOOL L, et al. Continual test-time domain adaptation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 7201-7211.

致 谢

值此本科毕业论文完成之际，谨向在大学期间关心、指导和帮助过我的老师、学长、同学及家人致以诚挚的感谢。

首先，衷心感谢指导教师王永健教授，在毕业设计选题、研究思路梳理、实验推进和论文撰写过程中给予了我耐心细致的指导与帮助，使我得以顺利完成本论文的研究工作；同时，在个人发展与后续规划等方面给予我的支持与鼓励，也使我深受感激；严谨认真的治学态度和认真负责的工作作风，使我受益匪浅。

其次，感谢蒋徐颢、蔡闻骁、邹滨阳等学长和同学榜样在学习与成长过程中给予我的帮助与示范。他们在专业学习、科研视野和个人规划方面的经验分享，对我产生了积极而深远的影响。

感谢严震霆、周志铭、曲振宁等同学和朋友在本科阶段给予我的陪伴、支持与鼓励。在课题讨论、日常学习和生活交流中，他们给予了我许多真诚的帮助，使我能够更加从容地面对学习和毕业设计过程中的困难与挑战。

最后，衷心感谢我的父母和家人。感谢他们一直以来给予我的理解、包容和支持，使我能够安心完成本科阶段的学习任务与毕业论文工作。

止於至善



SOUTHEAST UNIVERSITY